

RAI Risk Taxonomy 2.0

2차 휴먼 검수 복구 기술보고서

Human-review recovery release

2026년 8월 29일

요약

본 보고서는 798개 기준선 L4 카드에 2차 휴먼 검수 지시를 행 단위로 다시 적용하고, 이어서 사용자가 승인한 의미 중복 제거, 복합 카드 분리와 범위·세분성 정제를 수행한 작업을 기록한다. 이번 단계에서는 EM 또는 Hybrid EM을 다시 실행하지 않았다. 마지막 정제에서는 지나치게 넓거나 특정 사례에 과도하게 한정된 카드 8건을 검토하여 7건을 기존 카드에 흡수·폐기하고 재현성 위험 1건을 신설했으며 물리 안전 카드 1건의 범위를 축소했다. 최종 결과는 L4 카드 777건이며 General 607건, Agentic 77건, Physical 93건이다. Others 배정은 0건이다.

1 복구 원칙

기준 커밋의 유효한 편집과 사용자 승인 통합은 보존했다. 2차 검수 원문의 삭제, 통합, 분리, 재배포, 정의 수정 지시만 source_row_id 계보를 통해 적용했다. Instruction Prompt와 L3 마스터가 충돌할 때는 L3 마스터를 우선했다. L3는 신설하거나 수정하지 않았으며 SHA-256 해시를 고정했다.

2 적용 결과

조치	검수행 수
재배정	80
정의 수정 후 유지	39
분리	19
통합	14
삭제	14

Table 1: 승인된 166건의 휴먼 검수 조치

3 복합 카드 분리

기존 휴먼 검수에서 분리한 계보를 보존한 상태에서 추가 복합 카드 10건을 검토했다. 기존 카드가 이미 해당 의미를 충분히 나타내면 source_row_id 계보와 고유 의미를 흡수했고, 독립적인 피해 기제 7건만 새 카드로 분리했다. 내용이 지나치게 포괄적이었던 2건은 구체 카드에 흡수한 뒤 폐기했다. 각 한영 정의는 AI 기술 주체, 인과 기제와 불리한 결과를 명시한다.




Figure 1: 도메인별 최종 L4 카드 수




Figure 2: 휴먼 검수 조치 분포

4 의미 중복 제거

위험행위, 피해대상, 작동기제와 실질적 통제목표가 동일하고 차이가 채널, 사례, 배포환경 또는 좁은 재진술에 한정된 카드만 통합했다. 자해·자살 조장, 대량 감시, 맥락적 개인정보 노출, 저작물 무단 이용, 역할 지시 기반 안전장치 우회, 평가 기만, 정서적 의존, 사회경제적 불평등, 책임 공백, 가정환경 인간-로봇 안전 실패의 10개 통합군에서 13개 카드를 폐기했다. 통합 카드에는 폐기 카드의 고유한 의미와 source_row_id 계보를 보존했다. 보호특성별 차별적 표상과 서로 다른 피해 기제는 분리 유지했다.

5 범위·세분성 정제

폭력·무력 충돌, 포괄적 보안 위협, 사회적 적응 혼란처럼 L3 수준으로 넓은 카드는 구체적인 기존 카드에 계보와 의미를 흡수한 뒤 폐기했다. 가이드라인 오염, 비플레이어 캐릭터 조작, 고인 모사 챗봇 의존처럼 특정 사례나 채널에 한정된 카드는 각각 평가 오염, 외부 지시 기반 목표 탈취, 정서적·사회적 의존의 일반 카드로 통합했다.

설명가능성·출처·재현성을 결합한 카드는 기존 설명가능성·출처 카드에 흡수하고 재현성만 독립 카드로 신설했다.

6 데이터 무결성 및 검증

L3 마스터 SHA-256은 e9439ced64fb49c1496f1955013b5f038ecc7d271b9d6c9704f1e1bf6b0094df로 입력과 출력에서 동일하다. L4 ID는 최종 L3별로 연속 재발급했다. 중복 ID, 정확 중복 카드, 알 수 없는 L3, 계층 불일치, 빈 한영 필드, AI 기술 주체가 없는 정의는 모두 0건이다. 두 번의 독립 실행에서 세 L4 CSV의 SHA-256이 동일했다.

7 산출물

최종 배포는 L1 CSV 1개, L1/L2/L3 CSV 1개, General, Agentic, Physical L4 CSV 3개로 구성한다. 검증 폴더에는 808행 지시 등록부, 166건 승인 결정표, source_row_id와 최종 L4의 계보 간선, 삭제 기록, 의미 중복 통합 로그, 적용 로그, 검증 기록을 보존한다.

8 결론

이번 복구는 의미 유사도 재분류가 아니라 휴먼 검수 의도의 충실한 이행이다. 최종 데이터에는 Others가 남지 않았고, L3 마스터는 변경되지 않았다. 이후 재매핑은 별도의 명시적 사용자 지시가 있을 때만 수행해야 한다.