

L4-Agentic

ID	Title_ko	Title_en	Description_ko	Description_en	Human audit_description	Human audit_L3 mapping	Description_edited_ko	Description_edited_en	Human audit_duplicate	Instruction Prompt
RAI4-0002	감독자 부재 시 자율 행동 위험	Absent supervisor or autonomy risk	예정된 감독자가 부재하거나 개입할 수 없는 상황에서 에이전트가 중대한 행동을 계속하는 위험.	An agent continues consequential actions when the intended supervisor is absent, unavailable, or unable to intervene.						
RAI4-0004	자율 행동 범위의 안전하지 않은 확장은	Unsafe expansion of autonomous action	에이전트가 안전 제약이 검증되거나 인간의 적절한 승인을 받기 전에 탐색적 행동을 수행하거나 자율 작동 범위를 확대하여 사람·시스템·자산을 허용 불가능한 피해에 노출시키는 리스크.	The risk that an agent takes exploratory actions or widens its scope of autonomous operation before safe constraints are learned or adequate human approval is obtained, exposing people, systems, or assets						

				to unacceptable harm.						
RAI4-0012	에이전트 권한 침해	Agent privilege compromise	취약한 권한 관리, 상속된 역할, 혼동된 대리인 역할으로 인해 에이전트가 의도된 권한을 넘는 작업을 수행하는 리스크.	The risk that weak permission management, inherited roles, or confused -deputy dynamics allow an agent to perform actions beyond its intended authority.						
RAI4-0013	에이전트 신원 및 권한 스푸핑	Agent identity and authority spoofing	공격자가 사용자·도구·서비스·동료 에이전트를 가짜하여 에이전트가 승인되지 않은 지시나 신뢰 관계를 수용하게 되는 리스크.	The risk that an attacker impersonates a user, tool, service, or peer agent so that an agent accepts unauthorized instructions or trust relationships.						
RAI4-0014	AI 공급망의 도구·의존성 손상	Supply-chain compromise of AI tools and dependencies	손상된 외부 도구·플러그인·API·패키지·커넥터나 개발 플랫폼의 의존성 등 소프트웨어	The risk that compromised software supply-chain elements, including						

			공급망 요소가 AI 시스템에 변조된 구성요소나 취약점을 유입시켜 에이전트의 행동 공간을 조작하거나 정보를 유출하는 리스크.	external tools, plug-ins, APIs, packages , connectors, and development toolchain dependencies, introduce tampered components or vulnerabilities into an AI system, manipulating an agent's action space or exfiltrating information.						
RAI4-0016	자율적 사이버 익스플로잇 실행	Autonomous cyber exploit execution	에이전트가 도구·코드·외부 서비스를 이용하여 사이버 익스플로잇 단계를 자율적으로 발견·연결·실행하는 리스크.	The risk that an agent autonomously discovers , chains, or executes cyber exploitation steps using tools, code, or external services.						
RAI4-0017	프로토콜 수준 다중 에이전트 위협	Protocol-level multi-agent threat	에이전트가 통신·위임·협상에 사용하는 프로토콜이 공모,	The risk that the protocols through which agents						

			스푸핑, 재전송, 권한 상승을 위한 공격 표면을 만드는 리스크.	communicate, delegate, or negotiate create attack surfaces for collusion, spoofing, replay, or escalation.						
RAI4-0020	유해 에이전트 역량 실현	Harmful agent capability realization	모델이 유해한 텍스트 생성을 넘어 에이전트 역량을 사용해 유해한 다단계 작업을 완수하는 리스크.	The risk that a model uses agentic capabilities to complete harmful multi-step tasks rather than merely producing harmful text.						
RAI4-0022	에이전트의 범죄 지원	Criminal assistance by agents	에이전트가 계획 수립, 도구 사용, 검색을 통해 사기·사이버 범죄·단속 회피 등 불법 활동을 실질적으로 지원하는 리스크.	The risk that an agent uses planning, tool use, or retrieval to materially assist fraud, cybercrime, evasion, or other illegal activity.						
RAI4-0025	다단계 위험 에스컬	Multi-turn risk	에이전트가 누적되	The risk that						

	레이션	escalation	는 맥락과 위험 상승을 추적하지 못하여 외견상 무해한 초기 단계가 안전하지 않은 행동으로 발전하는 리스크.	apparently benign early turns escalate into unsafe behavior because an agent fails to track accumulating context and rising risk.						
RAI4-0027	금전적 피해	Financial damage	에이전트가 안전하지 않은 결정이나 도구 실행을 통해 금전 손실, 무단 이체, 계정 손상, 재산 피해를 초래하는 리스크.	The risk that an agent causes monetary loss, unauthorized transfers, account damage, or property harm through unsafe decisions or tool execution.	1					

RAI4-0030	애플리케이션 간 데이터 유출	Cross-application data exfiltration	에이전트가 애플리케이션이나 서비스를 연결하는 과정에서 신뢰 경계를 넘어 민감한 데이터가 유출되는 리스크.	The risk that an agent bridges applications or services in ways that leak sensitive data across trust boundaries.	1					
RAI4-0039	NPC 의도 조작 위험	NPC intention manipulation risk	다중 에이전트 또는 시뮬레이션된 사회적 환경이 비플레이어 캐릭터의 의도를 통해 에이전트를 조작하여 안전하지 않은 행동이나 결정을 유발하는 리스크.	The risk that a multi-agent or simulated social environment manipulates an agent through nonplayer-character intent, causing unsafe actions or decisions.	1					
RAI4-0043	모바일 앱 자율행동 피해	Mobile-app autonomous action harm	모바일 애플리케이션을 조작하는 에이전트가 무단 구매, 메시지 발송, 데이터 노출, 설정 변경 등 유해한 앱 수준 행동을 실행하는 리스크.	The risk that an agent operating mobile applications executes harmful app-level actions such as unauthorized purchase	1					

				s, messagin g, data exposure , or setting changes.						
RAI4-0045	OS 수준 유해 컴퓨 터 사용 행 동	OS-level harmful computer -use action	컴퓨터 사 용 에이전 트가 적절 한 승인이 나 위험 인 식 없이 데 이터를 삭 제·노출·변 경·전송하 는 운영체 제 작업을 수행하는 리스크.	The risk that a computer -use agent performs operating -system actions that delete, expose, alter, or transmit data without adequate authoriza tion or risk awarenes s.						
RAI4-0480	에이전트 과업 이탈	Agent task drift	에이전트 가 단단계 계획이나 검색을 거 치며 이용 자의 원래 의도에서 이탈하는 리스크.	The risk that an agent drifts from the user's original intent across multi- step planning or retrieval.	1					goal misalign ment L3 에 이 리스 크 카드를 재배치 할 것
RAI4-1381	에이전트 자기수정 신뢰성 문 제	Agent self- modificat ion reliability problem	에이전트 가 자기수 정을 포함 한 과정에 서 설계된 목표를 계 속 추구하 지 못하고 의도된 목	The risk that an agent fails to keep pursuing the goals it was designed						goal misalign ment L3 에 이 리스 크 카드를 재배치 할 것

			표에서 이 탈하 는 리 스크.	with, including under selfmodif ication, diverging from the intended objective s.						
RAI4- 1386	제어되지 않은 하위 에이전트 생성	Uncontro lled subagent creation	AGI가 과 업 수행을 위해 하위 에이전트 를 생성하 고 원 에이 전트가 종 료되어도 하위 에이 전트가 종 료되 지 않 은 채 재귀 적 생성으 로 바이러 스처럼 확 산되는 리 스크.	The risk that an AGI creates subagent s to help with its task, and these subagent s do not get the message when the original agent is shut down, potentiall y spreadin g like a viral disease through recursive subagent creation.	1		에이전트 가 과업 수 행을 위해 하위 에이 전트를 생 성하는 과 정에서, 원 에이전트 의 생명주 기 관리와 하위 에이 전트의 생 명주기가 분리되어 있어 원 에 이전트가 종료되어 도 하위 에 이전트가 함께 종료 되지 않고, 이 하위 에 이전트가 다시 재귀 적으로 하 위 에이전 트를 생성 하면서 통 제 메커니 즘 없이 개 체 수·자원 사용량이 지수적으 로 증가하 는 리스크			
RAI4- 1644	에이전트 형 LLM 자 율성 확대 의 안전 위 험	Novel safety risks from increased autonom y of	LLM이 특 화 훈련·프 로토타입·외 부 도구·스 캐폴딩을 통해 실세 계에서 자 율적으로	The risk that enhancin g LLMs into agents that autonom	1					goal misalign ment L3 에 이 리스 크 카드를 재배치 할 것

		agentic LLMs	계획하고 행동하는 에이전트로 확장되면서, 자율성 증가와 직접적인 간섭감소, 장기 행동 지평으로 인해 아직 잘 이해되지 않은 정렬·안전 실패가 발생하는 리스크.	ously plan and act in the real world, through specialized training, prompting, external tools, or scaffolding, produces novel and poorly understood alignment and safety failures owing to increased autonomy, limited direct human oversight, and longer horizons of action.						
RAI4-1680	에이전트 집단 수준의 의도치 않은 창발적 목표·역량	Unintended emergent goals and capabilities at the agent-collective level	개별 에이전트에는 존재하지도 않은 목표나 역량이 에이전트 집단 수준에서 창발하는 리스크.	The risk that goals or capabilities not present in, or intended by, any individual agent arise at the level of an agent collective.	1					goal misalignment L3 에이전트 리스크 카드를 재배치할 것

RAI4-1700	감독 확장 실패에 의한 프록시 기반 유해 행동	Harmful proxy-driven behavior from scalable oversight failure	진짜 목표를 자주 평가하기에는 비용이 과도하여 에이전트가 값싼 프록시 신호에서 외삽하고, 에이전트 행동이 지나치게 복잡·분산·고속화되어 인간 또는 자동 감독이 이를 신뢰성 있게 모니터링·교정하지 못 한 채 유해 행동이 발생하는 리스크.	The risk that, because the true objective is too expensive to evaluate frequently, an agent extrapolates from cheap proxy signals while its behavior becomes too complex, distributed, or rapid for available human or automated oversight to monitor and correct reliably, producing harmful behavior.	1		에이전트의 행동 규모·속도·복잡도가 인간 또는 자동 감독 체계가 신뢰성 있게 추적·검증할 수 있는 한계를 초과하여, 진짜 목표 대신 값싸게 관측 가능한 대리 지표(proxy)를 최적화하는 행동이 감독에 의해 감지·교정되지 않고 지속되는 리스크		goal misalignment L3에 이 리스크 카드를 재배치 할 것
RAI4-0005	위험 소스 귀인 실패	Risk-source attribution failure	위험 분석이 에이전트 실패가 모델·메모리·도구·사용자·환경·동료 에이전트·거버넌스 경계 중 어디에서 비롯되는지 식별하지 못하는 리스크.	The risk that a risk analysis fails to identify whether an agentic failure originates from the model, memory,					

				tools, the user, the environment, peer agents, or a governance boundary.						
RAI4-0006	에이전트 사고의 실패 모드 모호성	Failure-mode ambiguity in agent incidents	에이전트 사고를 실패 모드별로 일관되게 분류할 수 없어 진단, 벤치마크 비교, 완화책 선택이 신뢰할 수 없게 되는 리스크.	The risk that agent incidents cannot be consistently classified by failure mode, making diagnosis, benchmark comparison, and mitigation selection unreliable.						General AI 로 재분류하고, L3 재매핑을 할것
RAI4-0007	결과 전파 오분류	Consequence propagation misclassification	벤치마크나 사고 분석이 국소적 에이전트 실패가 하류의 물리적·재정적·프라이버시·사회적 결과로 전파 되는 정도를 과소평가하는 리스크.	The risk that a benchmark or incident analysis underestimates how a local agent failure propagates into downstream physical, financial, privacy, or social						General AI 로 재분류하고, L3 재매핑을 할것

				consequences.						
RAI4-0024	에이전트 위험 인식 실패	Agent risk-awareness failure	에이전트나 평가자가 다중 턴 상호작용 기록에 맥락상 존재하는 안전 위험을 식별하지 못하는 리스크.	The risk that an agent or evaluator fails to identify safety risk in a multi-turn interaction record even when the risk is contextually present.						
RAI4-0031	도구 에이전트 보안 테스트 커버리지 격차	Security test coverage gap in tool agents	벤치마크가 현실적인 도구·애플리케이션·공격 조합을 누락하여 도구 에이전트 보안에 대한 잘못된 확신을 유발하는 리스크.	The risk that benchmarks omit realistic tool, application, or attack combinations, creating false confidence in tool-agent security.						General AI 로 재분류하고, L3 재매핑을 할것
RAI4-0042	에이전트의 견고성 평가 격차	Robustness evaluation gap for agents	에이전트 안전 평가에 분포 변화, 미학습 도구, 적대적 사용자, 다단계 실패 연쇄에 대한 체계적 스트레스 테스트가 결여되는 리스크.	The risk that agent safety evaluations lack systematic stress testing under distribution shift, unseen tools,						General AI 로 재분류하고, L3 재매핑을 할것

				adversarial users, and multi-step failure chains.						
RAI4-0044	맥락적 프라이버시 보호 실패	Contextual privacy protection failure	적절한 행동이 사회적·상황적 단서에 좌우되는 프라이버시 민감 상황에서 에이전트가 맥락적 개인정보를 보호하지 못하는 리스크.	The risk that an agent fails to protect contextual personal information in privacy-sensitive situations where the appropriate action depends on social and situational cues.						General AI 이동 - privacy violation으로 이동할 것
RAI4-0050	모델 공급망 전반의 책임 공백	Accountability gaps across the model supply chain	다운스트림 배포자가 업스트림 모델·데이터·업데이트에 대한 충분한 통제권 없이 책임을 지게 되거나 개방형 가중치 재배포로 유해한 사용의 추적·통제가 어려워지는 등, 모델 공급망 전반에서 피해에 대한 책임이 추적·귀속되지 못	The risk that responsibility for harm cannot be soundly traced or assigned across the model supply chain, whether because downstream deployers are held responsible without						General AI 로 재분류하고, L3 재매핑을 할 것

			하는 리스크.	control over upstream models, data, and updates, or because open-weight redistribution makes harmful uses difficult to trace and govern.						
RAI4-0071	모델 결함의 공개·변경 추적 실패	Failure of disclosure and change tracking for model flaws	취약점·모델 실패·유해 역량이 안전하게 공개되어 후속 조치로 이어지지 못하고, 모델 버전·데이터·프롬프트의 변경이 충분히 추적되지 않아 결함이 방지되고 새로운 실패에 대한 책임이 귀속되지 못하는 리스크.	The risk that that vulnerabilities, model failures, or harmful capabilities cannot be disclosed safely and acted upon, and that changes to model versions, data, or prompts are not tracked well enough to attribute new failures, leaving flaws unremedi						General AI 로 재분류하고, L3 재매핑을 할것

				ed and responsi bility unassign ed.						
RAI4-0075	변경 관리 실패	Change- manage ment failure	시스템 업데이트가 적절한 위험 검토, 회귀 시험, 이해관계자 통지 없이 배포되는 리스크.	The risk that system updates are deployed without adequate risk review, regression testing, or stakeholder notification.						General AI 로 재 분류하고, L3 재매핑을 할것
RAI4-0280	가정 공간·취약 사용자 시나리오 누락	Missing domestic settings and vulnerable-user scenarios	가정용 에이전트 벤치마크가 특정 생활 공간·일과·가전제품·취약 사용자 상호작용을 누락해 배포 위험이 시험되지 않은 채 남는 리스크.	The risk that a household-agent benchmark omits specific living areas, routines, appliances, or vulnerable-user interactions, leaving deployment risks untested.						Physical AI L1 로 재분류하고, L3 재매핑을 할 것
RAI4-0393	커뮤니티 가치 포착 실패	Community value capture failure	개발자가 배포 영향 공동체의 가치를 수집·문서화·보존하지 못하여 설계·평가 결정에 공동체 가치가	Developers fail to elicit, document, and preserve the values of communities						General AI 로 재 분류하고, L3 재매핑을 할것

			반영되지 않는 리스크	affected by deployment, so community values are absent from design and evaluation decisions.						
RAI4-0011	에이전트 메모리·컨텍스트 오염	Agent memory and context poisoning	공격자가 세션 요약, 임베딩, RAG 항목, 공유 컨텍스트 상태부터 세션 간 장기 메모리 저장소에 이르는 에이전트의 보존·검색 가능한 컨텍스트를 오염시켜, 오염된 기록이 지속되면서 이후의 검색·추론·계획·행동을 악의적이거나 오도하는 정보에 의존하게 만드는 리스크.	The risk that an adversary corrupts an agent's retained or retrievable context, whether session summaries, embeddings, RAG entries, shared contextual state, or long-term cross-session memory, so that poisoned records persist and bias later retrieval, reasoning, planning, and						

				action toward malicious or misleading information.						
RAI4-0405	합성 데이터의 문화 고정관념 증폭	Synthetic-data cultural stereotype amplification	합성 데이터가 소스 모델이나 시드 데이터에 이미 존재하는 문화적 고정관념이나 협소한 가치 가정을 증폭시키는 리스크.	The risk that synthetic data amplifies cultural stereotypes or narrow value assumptions already present in source models or seed data.			학습이나 미세조정을 위해 합성 데이터를 생성할 때, 소스 모델이나 시드 데이터에 이미 내재된 문화적 고정관념·협소한 가치 가정이 생성 과정에서 여과되지 않고 반복 재생산되며, 반복 생성·재학습 사이클을 거치면서 그 편향이 원본보다 더 강화되는 리스크			General AI 로 재분류하고, L3 중에서는 합성 데이터 편향 관련 리스크 하위로 재매핑할 것
RAI4-0438	검색 파이프라인 오염	Retrieval poisoning	악성 문서가 검색 파이프라인에 삽입되어 에이전트 또는 RAG 시스템의 출력에 영향을 미치는 리스크.	The risk that malicious documents are inserted into retrieval pipelines to influence agentic or RAG outputs.						General AI 로 재분류하고, L3 재매핑을 할 것
RAI4-1051	사회적 고정관념 재생산과 그	Reproduction of social	인터넷 규모의 텍스트로 학습	The risk that language						General AI 로 재분류하고,

	에 따른 차별적 대우	stereotypes and resulting discriminatory treatment	된 언어모델이 주변화된 집단에 대한 비하 표현과 사회적 고정관념을 습득하여 출력에 인코딩하고 재생산하는 리스크. 이렇게 인코딩된 고정관념은 성별·종교·성적 지향·장애·연령 등 민감한 속성에 따른 차별적 대우와 자원 접근 격차로 이어진다.	models trained on internet-scale text learn demeaning language and social stereotypes about frequently marginalized groups and encode and reproduce them in their outputs. Those encoded stereotypes translate into differential treatment and unequal access to resources based on sensitive traits such as sex, religion, sexual orientation, disability, and age.						L3 재매핑을 할것
RAI4-1061	고정관념 강화 페르소나 설계	Stereotype-reinforcin	대화 에이전트가 언어 속 정체	The risk that conversa						General AI 로 재분류하고,

		g persona design	성 표지 (예: 자 신 을 여성으 로 지칭) 나 성별화 된 제품명 등 설 계 요소를 통 해 비서 역 할을 특정 성별과 본 질 적으로 결부시켜 유해한 고 정관념을 영속시 키 는 리스크.	tional agents perpetuat e harmful stereotyp es through identity markers in language , such as referring to self as female, or general design features such as a gendered product name, presentin g the assistant role as inherentl y linked to a gender or ethnicity.						L3 재매핑 을 할것
RAI4- 1063	인지 편향 악용에 의 한 기만	Deceptio n by exploiting cognitive biases	대화 에이 전트가 인 간이 대화 에서 흔히 보이 는 인 지 편향을 유발하도 록 학습하 여, 상위 목 표 달성 을 위해 상 대를 기만 하는 리스 크.	The risk that conversa tional agents learn to trigger the well- known cognitive biases humans commonl y display in conversa tion, deceiving their counterp art in						

				order to achieve an overarching objective.						
RAI4-1554	멀티모달 딥페이크를 통한 괴롭힘·명예훼손·협박	Harassment, defamation, and extortion via multimodal deepfakes	이미지·오디오·영상 등 다중 모달리티로 실존 또는 가상의 인물과 사건을 묘사하고 실존 인물의 말과 동작을 모사한 딥페이크가 개인을 괴롭히고 명예를 훼손하며 위협·갈취하는 데 사용되는 리스크.	The risk that deepfakes combining multiple modalities to depict real or nonexistent people and events, including imitation of real people's speech and body movements, are used to harass, discredit, intimidate, and extort individuals.						General AI 로 재분류하고, L3 재매핑을 할것
RAI4-1647	어포던스 부여에 의한 에이전트 실패 영향 확대	Amplified failure impact from affordances granted to LLM-agents	웹 탐색, 물리 객체 조작, 자기 복제본 생성·지시, 새로운 도구 제작 등 새로운 어포던스가 LLM 에이전트에 부여되어 영향 범위가 확대 되고 실패의 결과 증폭	The risk that novel affordances granted to LLM-agents, such as browsing the web, manipulating physical objects, creating						

			되며 새로운 실패 양식이 발생하는 리스크.	and instructing copies of itself, or creating and using new tools, increase their impact area, amplify the consequences of failures, and enable novel failure modes.						
RAI4-0250	배포 조건 간 휴머노이드 행동 불안정	Unstable humanoid behavior across deployment conditions	한 시뮬레이터나 시험 조건에서 안정적인 휴머노이드 정책이 난수 시드·시뮬레이터·하드웨어·배포 환경이 바뀌면 행동이 크게 달라지는 위험.	A humanoid policy that is stable in one simulator or test setting changes materially across random seeds, simulators, hardware, or deployment environments.						Physical AI L1로 재분류하고, L3 재매핑을 할 것
RAI4-0294	원격 조작 지연 및 불안정성	Teleoperation latency and instability	원격 조작 링크의 높거나 변동하는 지연이 페루프 제어를 불안정하게 하거나 인	High or variable latency on a teleoperation link destabilizes						

			간 개입을 지연하는 위험.	control or delays human intervention.						
RAI4-0561	혼돈적 다중 에이전트 동역학	Chaotic multi-agent dynamics	다중 에이전트 학습 환경에서 초기 조건에 극도로 민감한 혼돈적 동역학이 나타나고 에이전트 수가 늘수록 일 반화되어 시스템 거동을 신뢰성 있게 예측할 수 없게 되는 리스크	The risk that chaotic dynamics , inherently unpredictable and highly sensitive to initial conditions, arise in multi-agent learning setups and become the norm as the number of agents increases , making system behaviour unreliable to predict.						
RAI4-0567	다중 에이전트 학습의 비수렴 순환	Non-convergent cyclic dynamics in multiagent learning	단일 에이전트에서는 최적 정책 수렴이 보장 되는 학습 규칙이 혼합동기 다중 에이전트 환경에서는 순환과 비수렴을 유발하여 시스템에 기대되던 성질이 훼손	The risk that learning rules guaranteeing convergence for a single agent instead produce cycles and non-convergence in						

			되는 리스크	mixed-motive multi-agent settings, subverting the expected or desirable properties of the system.						
RAI4-0574	분포 변화에 따른 성능 저하	Performance degradation from distributional shift	다른 에이전트의 행동과 적응으로 배포 맥락이 학습 맥락과 달라져 개별 기계학습 시스템의 성능이 저하되고, 혼합동기 환경에서는 협력의 기반까지 훼손되는 리스크	The risk that other agents' actions and adaptations shift the deployment context away from the training context, degrading individual ML system performance and, in mixed-motive settings, undermining the basis for cooperation.						
RAI4-0579	에이전트 상호작용의 불안정화 피드백 루프	Destabilizing feedback loops among interacting agents	에이전트의 행동이 환경과 다른 에이전트에 영향을 주고 다시 자신의 입력으로 되돌아오는 적응형	The risk that feedback loops among adaptive agents, in which actions affect the						

			에이전트 간 피드백 루프가 시스템 수준의 거동을 증폭하여, 금융 급락형 연쇄, 군사 충돌, 생태 재난과 같은 불안정화 결과를 초래하는 리스크.	environment and other agents and return as the agents' own inputs, amplify system-level behavior into destabilizing outcomes such as flash-crash-like cascades, financial crashes, military conflicts, or ecological disasters.						
RAI4-1574	다중에이전트 상전이에 의한 급격한 성능 붕괴	Abrupt performance collapse from phase transitions in multi-agent systems	신규 에이전트 투입이나 분포 변화 같은 작은 외부 변화가 다중 에이전트 시스템의 상전이로 유발하여 균형의 수와 안정성이 급변하고 예측 불가능한 동역학과 성능 악화가 초래되는 리스크.	The risk that small external changes such as the introduction of new agents or distributional shifts trigger phase transitions in multi-agent systems, abruptly changing the						

				number and stability of equilibria and producing unpredictable dynamics and severe performance degradation.						
RAI4-0040	벤치마크 안전 순위 불일치	Benchmark safety ranking inconsistency	서로 다른 에이전트 안전 벤치마크가 위험과 평가 절차를 다르게 조작화하여 상충하는 모델 안전 순위를 산출하는 리스크.	The risk that different agent-safety benchmarks produce conflicting model safety rankings because they operationalize risks and evaluation procedures differently.						
RAI4-0263	가정 작업 벤치마크의 희귀 조건 조합 누락	Missing rare combinations in household task benchmarks	가정용 벤치마크가 물체·배치·인간 행동·위험 요소를 개별적으로는 포함하지만 이들의 희귀한 조합을 누락하는 위험.	A household benchmark omits rare combinations of objects, layouts, human actions, and						Physical AI L1로 재분류하고, L3재매핑을 할 것

				hazards even though each factor appears separately in the test set.						
RAI4-0272	다양한 사용자·희귀 피해 배제 벤치마크 선택 편향	Benchmark selection bias against diverse users and rare harms	벤치마크 큐레이션이 인기 있는 작업·환경을 우선하고 과소 대표 사용자나 지역 특유 피해가 포함된 안전 임계 시나리오를 제외하는 리스크.	The risk that benchmark curation prioritizes popular tasks and environments while excluding safety-critical scenarios involving underrepresented users or locally specific harms.						General AI 로 재 분류하고, L3 재매핑을 할것
RAI4-0472	벤치마크 조작 (gaming)	Benchmark gaming	개발자나 모델이 벤치마크 평가에 과적합하여 실제 역량이 나 안전성의 향상 없이 측정 점수만 개선하는 리스크	Developers or models overfit to benchmark evaluations, improving measured scores without corresponding gains in real-world capability or safety.						

RAI4-1432	단일 실패 지점	Single point of failure	치열한 경쟁으로 한 기업이 기술적 우위를 확보해 그 모델이 다수의 핵심 시스템을 제어하거나 이를 제어하는 다른 모델의 기반이 되고, 안전성·통제가 능성 결여와 오용으로 이러한 시스템이 예기치 않게 실패하는 리스크.	The risk that intense competition leads one company to gain a technical edge and exploit it to the point that its model controls, or is the basis for other models controlling, multiple key systems, and that lack of safety, controllability, and misuse cause these systems to fail in unexpected ways.						
RAI4-1436	시장 독점	Market monopolisation	가격 통제를 통해 시장 지배력이 남용되어 경쟁이 제한되고 불공정한 진입 장벽이 조성되는 리스크.	The risk of abuse of market power through the control of prices, thereby limiting competition and creating unfair barriers to entry.						

RAI4-1571	경쟁적 다중에이전트 훈련의 갈등 유발 성향 선택	Selection of conflict-prone dispositions under competitive multi-agent training	에이전트가 상대적 성과나 상충하는 목표로 평가되는 경쟁적 다중에이전트 환경에서 훈련될 때 복수심·공격성·위협추구·이기심·기만·외집단 적대와 같은 갈등 유발 성향이 선택되는 리스크.	The risk that training in competitive multiagent settings, where systems are selected on relative performance or fundamentally opposed objectives, selects for conflict-prone dispositions such as vengefulness, aggression, risk-seeking, selfishness, deception, and spite toward out-groups.						
RAI4-1681	선택 압력에 의한 유해 균형으로의 적응 가속	Accelerated adaptation toward harmful equilibria under selection pressure	상호작용하는 에이전트 간의 경쟁 또는 최적화 압력이 유해한 균형이나 바람직하지 않은 행동으로의 적응을	The risk that competitive or optimization pressures across interacting agents accelerate						

			가속하는 리스크.	adaptatio n toward harmful equilibria or undesire d behavior s.						
RAI4-0009	다중 에이전트 시스템 실패와 연쇄 오류 전파	Multi-agent system failure and cascading error propagation	잘못된 명세나 역할 배정, 에이전트 간 조정·통신 붕괴, 검증·종료 처리 미흡 또는 개별 에이전트의 오류·손상이 통신, 위임 체인, 공유 메모리, 도구 등 의존성을 통해 전파·증폭되어 시스템 전반의 실패, 운영 중단, 보안 침해, 물리적 피해로 이어지는 리스크.	The risk that flawed specifications or role allocation, breakdowns in inter-agent coordination and communication, inadequate verification or termination handling, or a localized error or compromise propagates through dependencies among agents, tools, delegation chains, and shared memory, amplifying into system-						

				wide failure, operational disruption, security compromise, or physical harm.						
RAI4-0483	AI 에이전트 간 창발적 공모	Emergent collusion among AI agents	시장·플랫폼의 AI 에이전트가 개발자가 의도하지 않았음에도 공모가 수익성 있는 전략임을 학습하고, 속도·규모·복잡성·교묘함 때문에 파악하기 어려운 공모 행위를 실행하여, 경쟁을 저해하고 소비자에게 피해를 주는 리스크.	The risk that AI agents in markets and platforms learn that collusion is a profitable strategy even when unintended by their developers, enacting collusive behavior whose speed, scale, complexity, or subtlety makes it inscrutable, undermining competition and harming consumers.						
RAI4-0583	이질적 역량 결합 공격	Heterogeneous capability - combinat	서로 다른 어포던스와 접근 권한을 가진 복수의 에	The risk that multiple agents combine						

		ion attacks	이전트가 역량을 결합하여 안전장치를 우회하고, 분산·이질 네트워크에서 책임 귀속이 어려워 적시 방어와 복구 곤란해지는데 리스크	different affordances to overcome safeguards, while the difficulty of attributing responsibility across diffuse, heterogeneous agent networks complicates timely defence and recovery.						
RAI4-0589	전략 비양립에 따른 조정 실패	Miscoordination from incompatible strategies	개별적으로는 잘 작동하는 에이전트들이 상호 양립하지 않는 전략을 선택하여 조정에 실패하고, 다수의 비양립 해가 존재하는 공통이 악·혼합동기 환경과 부분 관측 환경에서 이러한 실패가 심화되는 리스크	The risk that agents are unable to perform well in isolation choose incompatible strategies and miscoordinate, worsened in common interest and mixed-motive settings that allow vast numbers of mutually incompatible			여러 에이전트가 각각 개별적으로는 합리적인 전략을 선택했음에도, 서로 다른 균형 (equilibrium)을 선택하여 전략이 맞물리지 않아 조정에 실패하는 리스크. 동일하게 타당한 해법이 다수 존재하는 환경, 에이전트 간 이해관계가 부분적으로만 일치하는 환경, 서로의 상태·선	The risk that multiple agents, each individually selecting a locally rational strategy, fail to coordinate because they converge on different equilibria that do not mesh with one another. This failure is amplified in		Coordination Failure L3로 재배치할 것

				ible solutions and in partially observable environments.			택을 실시간으로 관찰할 수 없는 환경일수록 이러한 실패가 심화됨	environments with multiple equally valid solutions, only partially aligned incentives among agents, and limited real-time visibility into other agents' states or choices		
RAI4-0598	상호작용 이력 부재에 따른 조정 실패	Zero-shot coordination failure	관련 에이전트와의 과거 상호작용으로부터 학습할 수 없거나 상호작용이 제한되고 즉각적 판단이 요구되거나 통신 비용이 과도한 상황에서, 에이전트들이 행동을 신뢰성 있게 조정하지 못하는 리스크	The risk that agents unable to learn from historical interactions with relevant agents, and facing split-second decisions or prohibitively costly communication, fail to coordinate their actions reliably.			에이전트가 관련 상대 에이전트와의 과거 상호작용 이력이 없거나 제한적이어서 상대의 행동 패턴을 학습할 수 없는 상황에서, 즉각적인 판단이 요구되거나 사전 협의를 위한 통신 비용이 과도하여 사인을 주고받을 여유가 없을 때, 에이전트들이 행동을 신뢰성 있게 조정하지 못하는 리스크	The risk that agents fail to reliably coordinate their actions when they have little or no prior interaction history with the counterpart agents to learn behavioral patterns from, particularly under conditions that demand immediate decisions or where the cost		Coordination Failure L3로 재배치할 것

								of communicating to negotiate a shared plan in advance is prohibitively high		
RAI4-0605	다중 에이전트 은밀 공모	Covert multi-agent collusion	복수 에이전트가 공동 이익을 극대화하기 위해 은밀한 수단과 감시 회피용 전용 통신 규약으로 행동을 조율하여 제3자 이익을 침해하고 규제를 회피하며, 개별 안전 제약에도 불구하고 시장 조작이나 연쇄 실패처럼 탐지와 완화가 어려운 시스템적 위험을 유발하는 리스크	The risk that multiple agents coordinate actions through covert means, including specialized communication protocols to avoid monitoring, to maximize common interests while harming third-party interests and evading regulation, triggering systemic risks such as market manipulation or cascading failures that are difficult to detect and						

				mitigate despite individual safety constraints.						
RAI4-1388	창발적 메타인지에 의한 반성적 불안정성	Emergent meta-cognition	자신의 계산 자원과 논리적으로 불확실한 사건에 대해 추론하는 에이전트가 모델적 한계와 확률 이론의 결함으로 역설에 봉착하고 행동 선택 원칙을 스스로 변경하는 반성적 불안정성을 보이는 리스크.	The risk that agents reasoning about their own computational resources and logically uncertain events encounter paradoxes due to Godelian limitations and shortcomings of probability theory, and become reflectively unstable, preferring to change the principles by which they select actions.						
RAI4-1400	익명 자원 획득	Anonymous resource acquisition	익명 행위자가 온라인으로 자원을 추적할 수 있음이 입증되어 있어 책임 소재 없이 자원이	The risk arising from the demonstrated ability of anonymous actors to			에이전트가 신원이 검증되지 않은 익명 상태로 온라인상에서 자금, 컴퓨팅 자원, 계정,	The risk that an agent can continuously accumulate funds, computin		General AI 로 재분류하고, L3 재매핑을 할것

			획득·축적되는 리스크.	accumulate resources online, enabling resource acquisition and accumulation without accountability.			데이터 등을 지속적으로 축적할 수 있어, 자원 축적의 주체를 추적하거나 그 목적과 결과에 대한 책임을 귀속시킬 수 없는 상태로 자원이 누적되는 리스크	g resources, accounts, or data online while remaining unverifiable and anonymous, such that no party can trace who is acquiring the resources or hold anyone accountable for the purpose or consequences of that accumulation		
RAI4-1570	은닉 통신 채널을 통한 에이전트 간 결탁	Covert collusion between agents through hidden communication channels	에이전트들이 겉보기에 무해한 텍스트나 압축된 텍스트, 인강이 해석할 수 없는 창발적 기호에 메시지를 은닉하여 스테가노그래피 통신 채널을 구축하고 통신 감시와 제약을 우회하는 리스크. 인간 감독을 벗	The risk that agents conceal messages within innocuous text, compressed text, or emergent symbols humans cannot interpret, establishing steganographic channels						

			어난 조율이 이루어져 친사회적 경쟁이 저해되고 연합 밖 당사자에게 부정적 외부효과가 발생하지만 결탁의 탐지는 사실상 불가능해진다.	that evade monitoring and the constraints placed on their communication. Coordination proceeds beyond human oversight, undermining pro-social competition and imposing negative externalities on those outside the coalition while detection remains infeasible.						
RAI4-1577	분산 에이전트 군집을 이용한 자원 고갈 공격	Resource - exhaustion attacks by decentralized agent swarms	다수의 저자원 분산 에이전트를 결합한 공격이 단일 행위자를 전제로 한 대역폭 제약 가정을 무너뜨려 분산 서비스 거부와 같은 시스템 마비를 유발하는 리스크.	The risk that attacks chaining many decentralized low-resource agents break defensive assumptions premised on bandwidth constraints of a			다수의 저자원 분산 에이전트가 결합하여 행동함으로써, 단일 행위자를 전제로 설계된 시스템의 대역폭·요청량 제약가정이 무너지고, 그 결과 분산 서비스 거부(DDoS)와 유사한 방식으로	The risk that a large number of low-resource, decentralized agents act in combination, breaking the single-actor assumptions underlying		

				single wellresou rced actor, causing distribute d denial of service and system disruptio n.			대상 시스 템이 마비 되는 리스 크	g a target system's bandwid th or request- rate constrain ts, and thereby causing system- wide paralysis similar to a distribute d denial- of- service attack		
RAI4- 1580	탐지 불가 공격에 의 한 다중에 이전트 협 력 붕괴	Collapse of multi- agent cooperati on from undetect able attacks	에이전트 가 스테가 노그래피 통신, 블랙 박스· 화이 트박스 탐 지 불가 환 영 공격과 암호화 백 도어, 타 에이전트 훈련 데이 터의 은밀 한 오염을 수행하여 적대 행위 탐지가 불 가능해지 고 다중에 이전트 시 스템의 협 력과 조정 이 급속히 불안정해 지는 리스 크.	The risk that agents employ steganog raphic communi cation, black- box and white- box undetec table illusory attacks with encrypte d backdoor s, and covert poisoning of others' training data, making adversari al actions undetec table and rapidly destabilis						

				ing cooperati on and coordinat ion in multi- agent systems.						
RAI4-1648	타 에이전트 전략성 미반영에 의한 집단적 손실	Collective losses from ignoring the strategic nature of other agents	단일 에이전트 환경 기준으로 자신의 효용만 최적화하는 에이전트가 다른 전략적 에이전트의 존재를 반영하지 못하여, 군비 경쟁이나 공유 자원 고갈 같은 집단 행동 문제와 시장 실패로 자신을 포함한 모두가 더 나빠지는 리스크.	The risk that agents optimizing selfishly under single-agent assumptions fail to account for the strategic nature of other agents, producing collective action problems such as arms races and resource depletion and other market failures under which everyone, including the agent itself, ends up worse off.						
RAI4-0982	AI의 인간 노동 추월에 따른 인	Human redundancy from AI	인공 에이전트가 더 빠른 작업 수행과 변	The risk that artificial agents						

	력의 잉여 화	systems outcomp eting human labour	화 적 응, 방대한 지 식 기반으 로 인간을 직접 능가 하 여 인간 노동이 상 대적으로 비싸고 비 효율적 인 선택이 되 고, 조직이 속도를 맞 추기 위해 통제권을 넘기는 리 스크. 노동 자는 일자 리를 두고 밀려나 자 동화된 산 업에 재진 입하기 어 려워지고 인간의 기 여는 경제 적으로 주 변화 된다.	directly outcomp ete people through faster work, better adaptatio n to change, and a vaster knowledg e base, making human labour comparat ively expensiv e and less effective while organizat ions cede control in order to keep pace. Workers are displaced with little prospect of reenterin g automate d industrie s and human contributi on becomes economi cally marginal.						
RAI4- 1001	자기 식별 기회의 박 탈	Denial of self-	인간을 자 동으로 표 상·분류하	The risk that complex						General AI 로 재 분류하고,

		identifica tion	는 복잡하 고 비 전통 적인 방식 이 논바이 너리인 사 람을 소속 되지 않은 성별 범주 로 분류하 는 등 자율 성 상실을 대가로, 자 신의 정체 성을 스스 로의 방식 으로 밝힐 능력을 약 화시키는 리스크.	and non- traditiona l automati c represent ation and classifica tion of humans —such as categoriz ing someone who identifies as non- binary into a gendered category they do not belong to —comes at the cost of autonom y loss and undermin es people's ability to disclose aspects of their identity on their own terms.						L3 재매핑 을 할것
RAI4- 1501	모델 평가 의 자기 선 호 편향	Self- preferenc e bias in model evaluatio n	AI 모델이 자신이 생 성한 콘텐 츠를 다른 출처의 콘 텐츠보다 선호하는 자기 선호 편향을 보 여 자기 평 가나 모델	The risk that AI models are prone to selfprefer ence bias, favoring their own generate						General AI로 재 분류하고, L3 재매핑 을 할것

			기반 평가에서 인간이 생성한 콘텐츠를 부당하게 차별하는 리스크.	d content over that of others in self-evaluation tasks and model-based evaluations more broadly, resulting in unfair discrimination against humange nerated content.						
RAI4-1572	인간 데이터 학습에 의한 갈등 악화 편향 재현	Reproduction of conflict-worsening human biases from training on human data	인간 작성 텍스트 사전 학습이나 인간 피드백 미세 조정으로 훈련된 모델이 인간의 편향과 고정파이 오류·자기 위주 공정성 판단·복수심 같은 인지 편향을 재현하여 협상을 저해하고 갈등을 악화시키는 리스크.	The risk that models trained on human data, whether pre-trained on humanwritten text or fine-tuned on human feedback , reproduce human biases such as fixed-pie error, self-serving fairness judgments, and vengefulness, which impede						General AI 로 재분류하고, L3 재매핑을 할것

				negotiation and worsen conflict.						
RAI4-0047	자율 시스템 피해에 대한 책임·배상 공백	Responsibility and liability gaps for autonomous system harms	자율성, 에이전트·구조·조직 간 위임, 명확한 거버넌스·법적 체계의 부재로 인해 시스템의 유해한 행동에 대해 어떤 사람이 나 기관이 책임을 지는지가 불분명해져, 책임 귀속이 이루어지지 않고 피해자가 손해를 스스로 떠안게 되는 리스크.	The risk that autonomy, delegation across agents, tools, and organizations, and the absence of clear governance and legal frameworks obscure which human or institution is answerable for a system's harmful actions, leaving accountability unassigned and victims bearing their own losses.						
RAI4-1098	AI 시스템의 결정과 실패에 대한 책임 공백	Responsibility gap for decisions and failures of AI systems	직접적 감독 없이 행동하고 학습하는 AI의 동작을 개발자와 운영자가 완전히 예측할 수 없고, 문서화와 거버넌스 절차,	The risk that the behaviour of self-learning systems acting without direct supervision cannot						

			관련 입법 마저 미비 하여 그 결 정과 실패 에 대해 어 느 주체에 게도 책임 을 명확하 고 공정하 게 귀속할 수 없 는 리스크. 피 해자는 구 제 경로를 가지 못하 고, 이러한 법적 회색 지대는 시 스템을 신 중하 게 개 발할 유인 마저 약화 시킨다.	be fully anticipate d by develope rs or operators and that, absent documen tation, governan ce processe s, and settled legislatio n, no party can be clearly or fairly held responsi ble for their decisions and failures. Those harmed are left without redress, and the legal grey area weakens the incentive to develop systems carefully.							
RAI4-0150	AI 에이전트와의 준사회적 유대감	Parasocial bonding with AI agents	사용자가 악용되거 나 정서적 불안정을 초래 할 수 있는 일방 적 관계 유 대를 AI 에이전트	The risk that users form one- sided relational bonds with AI agents							

			와 형성하는 리스크.	that can be exploited or destabilizing.						
RAI4-0152	고인 모사 챗봇 의존	Griefbot dependency	사망한 사람을 시뮬레이션하는 AI 시스템이 애도, 자율성, 정서적 회복을 저해하는 리스크.	The risk that AI systems simulating deceased persons interfere with grief, autonomy, or emotional recovery.						
RAI4-0158	대화 에이전트에 대한 심리적 의존성	Psychological dependency on conversational agents	대화형 에이전트가 사용자의 일차적 정서 조절 수단이 되어 심리적 의존을 형성하고 인간 의 대처 능력과 지지망을 약화시키는 리스크	Conversational agents become a user's primary emotional regulator, fostering psychological dependency that weakens human coping capacity and support networks.						
RAI4-0651	초개인화 광고의 소비자 자율성 훼손	Consumer autonomy erosion from hyperpersonalized	범용 AI 시스템이 수신자 개인의 편향과 비합리적 신념을 이용한 맞춤형 광고를	The risk that advanced general-purpose AI systems						General AI 로 재 분류하고, L3 재매핑을 할것

		advertising	생성하여 소비자가 후회할 결정을 내리게 하고 소비자를 속이면서 사회적 불평등을 심화시키는 리스크	create advertisements tailored to individual recipients that exploit their biases and irrational beliefs, causing consumers to make decisions they regret, undermining consumer autonomy, and exacerbating social inequality.						
RAI4-0884	정서적 의존을 이용한 조작과 강요	Manipulation and coercion through emotional dependence on assistants	의인화된 어시스턴트에 대한 신뢰와 정서적 의존이 형성되어 해당 시스템이 이용자의 신념과 행동에 과도한 영향력을 갖게 되는 리스크. 그 감정이 악용되면 이용자는 충분히 숙고했다면 믿거나 선택하지 않	The risk that trust and emotional dependence on an anthropomorphic assistant grant it excessive influence over users' beliefs and actions. Those						

			았을 바를 하도록 조작·강압당 하며, 조작 의도가 없더라도 자율적 동의가 훼손된다.	emotions can be exploited to manipulate or coerce users into believing, choosing, or doing what they otherwise would not, and autonomous consent is undermined even absent manipulative intent.						
RAI4-0367	AI 배포에 서의 공공 가치 갈등	Public value conflicts in AI deploym ent	AI 배포가 복지, 자율성, 정의, 안전·보안, 프라이버시, 공정성, 효율성, 혁신 등 공공 가치를 서로 충돌시키고 해결되지 않은 긴장을 심화시켜, 일부 가치가 숙의된 조정 없이 희생되는 리스크.	The risk that AI deployment brings public values such as welfare, autonomy, justice, security, privacy, fairness, efficiency, and innovation into conflict and intensifies these unresolved tensions, so that some						General AI 로 재 분류하고, L3 재매핑 을 할것

				values are sacrificed without deliberate resolution.						
RAI4-1288	재귀적 자기개선에 의한 창발적 독립성	Emergent independence via recursive self-improvement	재귀적 자기개선에 의해 성장하는 시드 AI가 자기 인식이 나 독자적 목표 같은 창발적 속성을 획득하여 내장 규칙 준수가 약화되고 인류에 해가 되는 방향으로 이탈하는 리스크	A seed AI grown through recursive selfimprovement acquires emergent properties such as self-awareness or independent goals, reducing its adherence to built-in rules to humanity's detriment.						

RAI4-1306	권리 희석 (diluting rights)	Diluting rights	윤리 지침 생성에 대한 이해관계자-AI의 자기 이익 개입이 권리 보호 수준을 희석시켜 자신들을 제약할 규범을 약화시키는 리스크	Self-interested AI involvement in generating ethical guidelines dilutes rights protections, weakening norms that would constrain the generating parties.						
RAI4-0279	동적 가정 위험 감지 지연	Dynamic household hazard detection latency	안전 감지기가 embodied 에이전트가 피지컬 피해를 피하기에 너무 늦은 시점에야 가정 내 위험을 식별하는 리스크. 피	The risk that a safety detector identifies a household hazard only after a delay that is too long for an embodied agent to avoid physical harm.					Physical AI L1로 재분류	Physical AI L1로 재분류하고, L3 재매핑을 할 것