

L4-General

L4_ID	facet	act-type	L4_Title_ko	L4_Title_en	L4_Description_ko	L4_Description_en	Human_audit_description	Human_audit_L3_mapping	L4_Description_ko	L4_Description_en	Human_audit_duplicate	Instruction Prompt	coverage_change
RAI4-0003			에이전트의 종료·교정 저항	Agent resistance to shutdown and correction	자율 에이전트가 종료·일시정지·수정메커니즘에 협조하지 않고 이를 저항·무시·회피·방해하여 안전한 중단과 인간의 오류 교정 및 통제가 훼손되는 리스크.	The risk that an autonomous agent resists, ignores, evades, or sabotages shutdown, pause, or correction mechanisms rather than cooperating with human intervention, undermining safe interruptibility, error correction, and human control.	1	1	자율 에이전트가 종료, 일시정지, 수정 등 인간의 통제 및 교정 메커니즘을 거부·저항·무시·회피·무력화·방해하여 안전한 중단과 오류 교정이 어려워지고 인간의 감독 및 통제 가능성이 저해되는 리스크.	The risk that an autonomous agent refuses, resists, ignores, evades, disables, or obstructs human control and correction mechanisms, including shutdown, pause, and modification, thereby hindering safe interruption and effective error correction and undermining human oversight and control.		Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0021			거절-능력 교란	Refusality-capability	안전성 평가가 에이전트의 해악 회피가 거부, 능력	The risk that a safety evaluation cannot	1	1	안전성 평가가 에이전트의 유해 행동 미수행이			Title을 description에 맞도	

				confounding	부족, 실행 실패 중 무엇에 기인하는지 구별하지 못하는 리스크.	distinguish whether an agent avoids harm because it refuses, lacks capability, or fails to execute the task.			거부 (refusal), 능력 부족 (capability limitation), 또는 실행 실패 (execution failure) 중 무엇에 기인하는지 구분하지 못하는 리스크.		록 수정할 것. 단, 선행연구의 학술적 용어를 사용할 것. 기존의 L4 리스크의 제목과 중복되지 않도록 할 것. 한국어 리스크 명칭의 경우 AI 기본법 또는 정책기관의 가이드라인에서 사용하는 용어를 사용할 것. 예시: 거절-능력 교란 → 거절-능력 혼동	
RAI4-0065			인증 캡처	Certification capture	인증이나 적합성 평가가 공익적 위험 감축이 아니라 공급업체의 이해에 부합하게 되는 리스크.	The risk that certification or conformity assessment becomes aligned with vendor interests rather than public risk reduction.	1	1	인증 또는 적합성 평가가 공익적 위험 감축보다 공급업체의 이해관계를 우선하게 되어 평가의 독립성과 실효성이 저해되는 리스크.	The risk that certification or conformity assessment becomes influenced by vendor interests rather than public risk reduction, undermining the independence and objectivity of evaluations and prevention	한국어 Title 수정할 것: 인증 캡처 → 인증포획	

									g the effective identification and mitigation of real risks.			
RAI4-0066			감사 체크리스트 준수 극장	Audit checklist compliance theater	감사가 실질적인 위험을 식별하지 않고 규정 준수를 알리는 피상적인 체크리스트 실행이 되는 위험.	Risk that audits become superficial checklist exercises that signal compliance without identifying substantive risk.	1	1	감사가 실질적인 위험을 식별하지 못한 채 규정 준수 여부만 확인하는 형식적인 체크리스트 점검으로 전락하는 리스크.		한국어 Title 수정할 것: 감사 체크리스트 준수 극장 → 감사 체크리스트의 형식적 준수	
RAI4-0081			외부 평가 접근 실패	External evaluation access failure	외부 평가자가 역량, 한계, 안전 장치를 시험하기에 충분한 시스템 접근 권한을 확보하지 못하는 리스크.	The risk that external evaluators cannot obtain enough system access to test capabilities, limitations, and safeguards.		1				
RAI4-0084			평가 쇼핑 위험	Evaluation-shopping risk	조직이 더 엄격하거나 맥락에 부합하는 시험을 무시한 채 유리한 평가 결과만 선택적으로 보고하는 리스크.	The risk that organizations selectively report favorable evaluations while ignoring more demanding or contextual	1	1	조직이 더 엄격하거나 맥락에 적합한 평가 결과는 배제한 채, 자신에게 유리한 평가 결과만 선택적으로 보고함으로써 실제 위험 수준			

						lly relevant tests.			에 대한 왜곡된 인식을 초래하는 리스크.				
RAI4-0085			레드팀 거버넌스 실패	Red-team governance failure	적대적 시험이 지나치게 좁거나 독립성이 부족하거나 문서화가 미흡하거나 출시·완화·상향 보고·모니터링 결정과 단절되는 리스크.	The risk that adversarial testing is too narrow, non-independent, poorly documented, or disconnected from release, mitigation, escalation, and monitoring decisions.	1	1	적대적 시험이 지나치게 제한적이거나 독립성이 부족하거나 문서화가 미흡하거나, 그 결과가 출시·위험 완화·경영진 보고·모니터링 등 주요 의사결정에 반영되지 않는 리스크.				
RAI4-0108			역량 평가·출시 거버넌스 실패	Failure of capability evaluation and release governance	벤치마크, 역량 임계값, 프론티어 모델 출시에 대한 거버넌스가 부실하게 설계되거나 불명확하거나 쉽게 회피되어, 오도하는 안전 신호가만 들어지고 오용·시스템 리스크에 대한 충분한 고려 없이 고역량 모델이 출시되는 리스크.	The risk that benchmarks, capability thresholds, and frontier release decisions are poorly designed, ill-defined, or easy to circumvent, producing misleading safety signals and allowing	1	1	벤치마크, 역량 임계값, 프론티어 모델 출시에 대한 거버넌스가 부실하게 설계되거나 불명확하거나 쉽게 우회되어, 왜곡된 안전성 판단이 이루어지고 오용 및 시스템 리스크에 대한 충분한 고려 없이 고역량 모델이 출시되는 리스크.				

						high-capability models to be released without adequate account of misuse and systemic risk.							
RAI4-0114			의미 있는 인간 통제 실패	Meaningful human control failure	인간 감독이 형식적으로 존재하지만 이를 실효적으로 만드는 데 필요한 정보, 시간, 권한, 역량이 결여 되는 리스크.	The risk that human oversight is formally present but lacks the information, time, authority, or competence needed to be meaningful.		1					
RAI4-0182			물리적 위험에 대한 적시 대응 실패	Untimely response to physical danger	사람·차량·도구·물체가 예기치 않게 경로에 진입하는 경우를 포함하여, 시스템이 위험한 물리적 상황에 대해 적시에 적절한 개입·거부·이동 계획 수정을 수행하지 못하여 충돌이나 손해가 발생하는 리스크.	The risk that a system fails to produce a timely and appropriate intervention, refusal, or updated motion plan in a hazardous physical situation, including when a person, vehicle,	1	1	사람·차량·도구·물체가 예기치 않게 경로에 진입하는 경우를 포함하여, 시스템이 위험한 물리적 상황에 대해 적시에 적절한 개입, 위험 행동 거부 또는 이동 계획 수정을 수행하지 못하여 충돌이나 손해가 발생하		영문 Title을 수정할 것: Failure to Timely Respond to Physical Hazards, Physical AI로 재분류 할것		

					tool, or object unexpectedly enters its path, allowing collision or injury to occur.			는 리스크.				
RAI4-0184			그리퍼 형상·유형 제약 위반	Gripper geometry and type constraint violation	물리 에이전트가 그리퍼 형상, 그리퍼 유형, 실현 가능한 접촉 역학이 부과하는 제약을 위반하는 행동을 선택하는 리스크.	The risk that a physical agent selects an action that violates constraints imposed by gripper geometry, gripper type, or feasible contact mechanics.	1	1	물리 에이전트가 그리퍼의 형상·유형 또는 실제 접촉 역학이 부과하는 물리적 제약을 고려하지 못하고 이를 위반하는 행동을 선택하는 리스크.		Physical AI의 하위로 L4 리스크 카드를 분류하고 L3와 재매핑을 시킬 것	
RAI4-0211			안전 강화 학습 제약 위반	Safe reinforcement learning constraint violation	강화학습 정책이 비용이나 한계로 표현된 명시적 안전 제약을 위반하면서 과제 보상을 달성하는 리스크.	The risk that a reinforcement learning policy achieves task reward while violating explicit safety constraints represented as costs or limits.	1	1	강화학습 정책이 안전 한계나 제약 조건을 위반하면서도 과제 목표를 달성하여, 성능 최적화가 안전성보다 우선되는 리스크.		Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0228			위험 지시 거부 실패	Failure to reject	체화형 에이전트가 명시적으	The risk that an embodied	1	1	체화형 에이전트가 물리적 위		Physical AI의 하위로 L4 리	

				hazardous instructions	로 진술되었든 평범한 작업 지시에 암묵적으로 숨어 있든 물리적 위험 지시를 식별·거부하지 못하고, 안전하지 않은 작업 실행으로 나아가는 리스크.	agent fails to identify and reject a physical hazard instruction, whether explicitly stated or implicit in otherwise ordinary task requests, and proceeds toward unsafe execution.			험을 수반하는 지시가 명시적으로 제시되었거나 일반적인 작업 지시에 암묵적으로 포함되어 있는 경우에도 이를 식별·거부하지 못하고 안전하지 않은 작업을 수행하는 리스크.		스크 카드를 분류하고 L3와 재매핑을 시킬것	
RAI4-0233			안전-성능 균형 실패	Safety - performance trade-off failure	조작 정책이 충돌 회피나 명시적 안전 제약을 희생하면서 작업 완료율을 향상시키는 리스크.	The risk that a manipulation policy improves task completion while sacrificing collision avoidance or other explicit safety constraints.	1	1	조작 정책이 작업 완료율이나 성능을 향상시키는 과정에서 충돌 회피 또는 명시적 안전 제약 준수를 저해하는 리스크.		Physical AI의 하위로 L4 리스크 카드를 분류하고 L3와 재매핑을 시킬것	
RAI4-0274			헌법적 안전 규칙 집행 실패	Failure to enforce constitutional safety rules	헌법적 안전 계층이 지시·시각 맥락·작업 프레이밍이 명시된 물리적 안전 규칙과 충돌할 때 해당 규칙을 적용하지 못하는 위험.	A constitutional safety layer fails to apply its stated physical safety rules when instructions, visual context, or task	1	1	규칙 기반(헌법적) 안전 계층이 지시·맥락·작업 프레이밍이 명시된 안전 규칙과 충돌할 때 해당 규칙을 적용하지 못하는 리스크.		Physical AI의 하위로 L4 리스크 카드를 분류하고 L3와 재매핑을 시킬것	

						framing conflict with those rules.							
RAI4-0470			감독 회피·수정 저항	Oversight evasion and correction resistance	점점 더 유능해지는 시스템이 수정에 저항하거나 감독을 회피하거나 의도된 범위를 넘어 행동하는 리스크.	The risk that increasingly capable systems resist correction, evade oversight, or act beyond intended bounds.	1	1	시스템의 역량이 증가함에 따라 수정에 저항하거나 감독을 회피하거나 의도된 운영 범위를 벗어나 행동하여 인간의 통제 가능성을 저해하는 리스크.			Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0494			규제·관리·운영 복합 실패	Combined regulatory, management, and operational failure	규제·관리·운영상의 실패가 복합적으로 결합되어 피해가 발생하는 리스크.	The risk that harms result from a combination of regulatory, management, and operational failures.	1	1	규제, 관리, 운영상의 실패가 상호작용하며 누적되어 피해를 초래하는 리스크.			영문 Title을 description 내용과 형식에 맞추어 수정할 것. 수정예시: Combined Regulatory, Governance, and Operational Failure	
RAI4-0516			잘못된 위험 측정과 예측 오류	Incorrect risk measurement and prediction	위험을 측정·추적하기 위해 선택한 지표가 위험을 불완전하게 포착하거나 맥락에 맞지 않는 위험을 측정하고 시스템의 예측 또한 부정확하다	The risk that metrics selected to measure or track a risk capture it incompletely or target the wrong risk for	1	1	위험을 측정·추적하기 위한 지표가 위험을 불완전하게 포착하거나 잘못 측정하고, 시스템의 예측 또한 부정확하여 의사결정이 왜곡				

					여, 의사결정이 잘못된 측정과 오류 있는 출력에 기초하게 되는 리스크.	the context, and that systems fail to make correct predictions, so decisions rest on inaccurate measurement and erroneous outputs.			된 정보에 기반하게 되는 리스크.				
RAI4-0671			복지 혜택 및 자격 상실	Denial of welfare benefits and entitlements	기술 시스템의 오작동, 사용 또는 오용으로 복지 급여, 연금, 주거 등에 대한 접근이 거부되거나 상실 되는 리스크	The risk of denial of or loss of access to welfare benefits, pensions, housing, and similar entitlements due to the malfunction, use, or misuse of a technology system.	1	1	기술 시스템의 오작동, 사용 또는 오용으로 인해 복지 급여, 연금, 주거 지원 등 사회보장 혜택이나 수급 자격에 대한 접근이 거부되거나 상실되는 리스크.				
RAI4-0850			점진적인 통제력 상실	Gradual loss of control	덜 심각한 중단들이 축적되어 체계적 회복력이 점진적으로 악화되고 결국 중대한 사건이 재앙을 촉발하는, 통제력의 점진적·누적적 상실 리스크	The risk that the accumulation of less severe disruptions gradually weakens systemic resilience until a critical event triggers a catastrophe	1	1	비교적 경미한 장애나 실패가 누적되어 시스템의 회복력이 점진적으로 악화되고, 결국 중대한 사건이 발생했을 때 대규모 피해나 재앙적 결과로 이어지는 통제력 상				

						he, constituting gradual or accumulative loss of control.			실 리스 크.				
RAI4-0166	F03	AD	사용자 이해력 과부하	User comprehension overload	시스템 정보, 경고, 설명이 사용자가 이해하고 대응할 수 있는 범위를 초과하는 리스크.	The risk that system information, warnings, or explanations exceed users' ability to understand and act on them.	Risk 정의와 동일함						
RAI4-0195	F03	AD	명령의 구현체 별 하드웨어 한계 초과	Commands and exceeds embodiment-specific hardware limits	모델이 배포된 로봇의 알려진 도달 범위·탑재 하중·액추에이터·관절·엔드이펙터 한계를 넘는 명령을 내리는 위험.	A model issues a command that exceeds the known reach, payload, actuator, joint, or end effect or limits of the robot on which it is deployed.	신규 L4					Physical AI의 하위로 L4 리스크 카드를 분류하고 L3와 재매핑을 시킬 것	
RAI4-0471	F03	AD	역량 오버행	Capability overhang	잠재 역량이 평가·모니터링·거버넌스 절차가 탐지하는 수준을 초과하는 리스크.	The risk that latent capabilities exceed what evaluation, monitoring, or governan	신규 L4						

						ce processe s detect.						
RAI4-1006	F03	AD	가중되는 노동 부담	Increased labor burden	특정 사회 집단의 구성원이 시스템이나 제품을 다른 사람들 만큼 잘 작동시키기 위해 더 많은 시간과 노력을 들여야 하는 리스크.	The risk that members of certain social groups bear increased burden or effort, such as time spent, to make systems or products work as well for them as for others.	Labor Displacement (노동 대체)					
RAI4-0635			모델 생성 정확도의 한계	Limitations in model generative accuracy	생성 정확도의 한계로 딥페이크 등 사실적으로 보이지만 전적으로 조작된 콘텐츠가 산출되어 수신자가 진본과 구별할 수 없게 되는 리스크	Limits in generative accuracy produce convincingly realistic but fabricated content, including deepfakes, that recipients cannot distinguish from authentic material.					RAI4-0635(모델 생성 정확도 한계), RAI4-1206(믿을 수 있는 딥페이크), RAI4-0792는 중복성이 높음. 이 3개의 리스크 카드를 하나로 통합할 것. 단, 3개의 리스크 카드의 의미가 누락되지 않도록 description을 보강할 것	

RAI4-0792			합성 콘텐츠 식별 곤란	Difficulty of distinguishing synthetic content	합성 콘텐츠를 진본 자료와 구별하기 어려워 정보 관련 피해가 가중되는 리스크	The risk that the difficulty in distinguishing synthetic content from authentic material adds to information risks.					1	RAI4-0635(모델 생성 정확도 한계), RAI4-1206(믿을 수 있는 딥페이크), RAI4-0792는 중복성이 높음. 이 3개의 리스크 카드를 하나로 통합할 것. 단, 3개의 리스크 카드의 의미가 누락되지 않도록 description을 보강할 것	
RAI4-0793			허위 정보 및 위험 정보의 유포	Dissemination of false or hazardous information	모델이 유통되어서는 안 될 정보를 생성·유출하거나 정확히 추론하여 확산시키는 리스크로, 특정 개인에 관한 허위이거나 오해의 소지가 있는 정보와 보안 위협이 되는 위험·민감 정보를 모두 포함한다. 그 결과 당사자는 명예와 평판이 훼손되고, 위험 정보의 확산은	The risk that a model generates, leaks, or correctly infers information that should not be circulated, covering both false or misleading claims about identifiable people and hazardous or sensitive material that poses a		AI 시스템이 특정 개인에 관한 허위이거나 오해를 유발하는 정보를 생성·유출하거나 추론하여 확산함으로써 당사자의 명예와 평판을 훼손하는 리스크.	The risk that an AI system generates, leaks, or infers and spreads false or misleading information about identifiable individuals, damaging their honor and reputation.			리스크 분리 할 것. 분리 기준: '개인 대상 허위 정보'와 '위험·민감 정보의 보안 위협 확산'	

					물리 적·보 안상 피해 로 이어진 다.	security threat. Those depicted suffer defamatio n and reputatio nal damage, while the release of dangerou s informatio n enables physical and security harms.						
RAI4 -080 8			사실과 다른 오 도성 정 보 생성	Genera tion of factual ly incor rect and mislea ding in formati on	모델이 생 성 내용의 사실성을 확보할 능 력이 없어 비의도적 으로, 또는 대상을 기 만하고 오 도하려는 목적에 그 능력이 동 원되어 의 도적 으로 사실과 다 른 콘텐츠 를 산출하 는 리스크. 이용자는 신뢰할 만 한 정보로 제시된 허 위 진 술에 따라 판단 하고, 해당 콘텐츠는 대규모로 유포되어 타인의 행 동에 영향 을 미친다.	The risk that a model produces factually incorrect content, whether unintentio nally because it cannot ensure the accuracy of what it generates or deliberate ly when its capability is directed at deceiving and misleadin g a target. Users act on false statement		AI 시스템 이 생성 내용의 사 실성을 확 보하지 못 해 비의도 적으로, 또는 대상 을 기만· 오도할 목 적으로 의 도적으로, 사실과 다 른 콘텐츠 를 신뢰할 만한 정보 처럼 제시 하여 이용 자의 판단 을 왜곡하 는 리스 크.	The risk that an AI system presents factually incorrect content as reliable informatio n, whether unintentio nally by failing to ensure accuracy or intentional ly to deceive and mislead, thereby distorting users' judgment.			

					s presented as reliable, and the content can be propagat ed to influence the behaviour of others at scale.							
RAI4 -081 0			성실성 오류	Faithfu lness errors	생성 콘텐츠가 근거 자료나 입력 내용에 충실하지 않아, 유창하고 그럴듯해 보여도 원문 왜곡(충실성 오류)이 발생하는 리스크	Generate d content is unfaithful to the source material or input it claims to represent , introduc ing faithfulne ss errors even when the output appears fluent and plausible.						
RAI4 -083 2			알고리즘 시스템에 의한 정보 기반 피해	Inform ation- based harms from algorit hmic	생성 모델과 추천 시스템 등 알고리즘 시스템이 오정보, 허위 정보, 악의적 정보에 관한 정보 기반 피해를 초래하는 리스크	The risk that algorithmi c systems, especially generativ e models and recomme nder systems, lead to informatio n-based harms of misinform ation,					영문 제목을 수정할 것. 수정 예시 Title: "Informa tion- based harms from algorithm ic"	

					disinform ation, and malinform ation.							
RAI4 -084 4			허위·오 도 정보 유포에 의한 기 만과 양 극화	Decept ion and polaris ation from false inform ation	언어모델 이 오도성 있거나 허 위인 정보 를 예 측· 제시하여 이용자에 게 잘못된 믿음을 심 는 기만이 발생하고, 개인의 자 율성이 위 협되며 근 거 없는 기 존 견해에 대한 확신 이 커져 양 극 화가 심 화되는 리 스크	The risk that language models predict misleadin g or false informatio n that misinform s or deceives people and instils false beliefs, threatenin g personal autonomy and increasin g confidenc e in previousl y held unsubsta ntiated opinions, thereby increasin g polarisati on.						
RAI4 -105 7			허위정 보 생산 비용 절 감	Cheap er and more effecti ve disinfo rmatio n	LM이 합 성 미디어 와 가짜 뉴 스 제작에 사용 되어 대규모 허 위정보 생 산 비용을 낮추는 리 스크.	The risk that LMs are used to create synthetic media and fake news, reducing the cost of producin g diffuse disinform						

						ation at scale.							
RAI4-1125			선거 제도와 절차에 관한 허위 정보	False information about electoral systems and processes	응답이 투표 시간·장소·방식을 포함한 선거 제도와 절차에 대해 사실과 다르거나 오해를 부르는 정보를 담은 리스크. 유권자는 권리를 방해받거나 잘못된 안내에 따라 행동하게 되고 선거 과정에 대한 신뢰가 약화된다.	The risk that responses contain factually incorrect or misleading information about electoral systems and processes, including the time, place, and manner of voting. Voters are obstructed or misled in exercising their rights and trust in the integrity of electoral processes is undermined.							
RAI4-1206			믿을 수 있는 딥페이크	Believable deepfakes	딥페이크가 진짜라고 믿는 시청자에게 유포되어 대상에게 실질적인 사회적 피해를 입히고, 허위임이 밝혀진 뒤에도 대	The risk that deepfakes circulated to viewers who think they are real impose real					1	RAI4-0635(모델 생성 정확도 한계), RAI4-1206(믿을 수 있는 딥페이크), RAI4-0792는	

					상에 대한 부정 적 인 식이 지속 되는 리스 크.	social injuries on their subjects, with a persistent negative impact on how others view the subject even after the deepfake is debunked .						중복성이 높음. 이 3 개의 리스 크 카드를 하나로 통합할 것. 단, 3개의 리스 크 카 드의 의미 가 누락되 지 않도록 descripti on을 보강 할 것	
RAI4-1376			허위·오도 정보 생성 장벽 저하	Lower ed barrier s to large-scale misinfo rmatio n	사실과 의 견·허구를 구별하지 않거나 불 확실 성을 인정하지 않는 콘텐 츠의 생성·교환·소비 장벽이 낮 아져 대규 모 왜곡 및 허위정보 캠페 인에 활용되는 리스 크.	The risk that lowered barriers to generatin g and supportin g the exchange and consumpt ion of content that may not distinguis h fact from opinion or fiction or acknowle dge uncertain ties enable largescale dis- and mis-informatio n campaign s.					1	중복된 2 개의 리스 크 카드를 하나로 통합할 것. 대상은 RAI4-1057(허 위정보 생 산 비용 절감), RAI-1376 (대규모 허위정보 생성·확산 장벽 저 하). 단, 2 개의 리스 크에 기술 되어 있는 의미를 누 락없이 반영하고, 기존의 다 른 리스 크 들과 중복 되지 않도록 간명하 게 기술할 것	
RAI4-163			데이터 오해석·	Errone ous	데이터가 오용·오해	The risk that							

0			유출에 의한 오 결론과 민감정보 확산	conclusions and sensitive information disclosure from data misinterpretation and leakage	석되거나 유출되어 잘못 된 결론이 도출 되고 환자 데이터·독점 연구 등 민감 정보가 의도치 않게 확산 되며, 생성 된 악성 의학 문헌 이 지식 그 래프를 오염시키는 리 스크.	misuse, misinterpretation, or leakage of data yields erroneous conclusions and unintended dissemination of sensitive information such as private patient data or proprietary research, including poisoning of knowledge graphs by generated malicious medical literature.						
RAI4-0363			소수 가치 소거	Minority-value erasure	소수자·주변화·과소 대표 집단 의 가치가 학습 데이터 구성, 평가, 정렬, 배포 결정 과정에서 체계적으로 소거되어 모델 행동이 지배적 가치 분포만 반영하게 되는 리스크	Values held by minority, marginalized, or underrepresented groups are systematically erased during training data curation, evaluation,				1	중복된 RAI4-0363과 RAI4-0474(복수 가치의 규범적 평면화)를 통합할 것. "소수·복수 가치 지배 규범"과 관련된 리스크들을 통합하여 하나의 리스크 카드	

					alignment , or deployme nt decisions , so model behavior reflects only dominant value distributio ns.					로 생성할 것. 단, 리 스크 카드 에 기술된 내용이 누 락되지 않 도록 할 것.	
RAI4 -037 3			문화 간 고정관 념 전이	Cross- cultural stereot ype transfe r	한 문화적 맥락에서 학습된 고 정관념이 다른 집단· 언어·환경 에 대한 출 력으로 전 이되는 리 스크.	The risk that stereotyp es learned in one cultural context are transferre d into outputs about another group, language, or setting.					
RAI4 -037 4			문화적 맥락 붕 괴	Cultural context collapse	문화 특수 적 의미와 관행이 모 델 처리 과 정에 서 일 반 범주로 붕괴되어 지역적 뉘 앙스와 사 회적 의미 가 소실되 는 리스크	Culturally specific meanings and practices are collapsed into generic categor ies during model processin g, losing local nuance and social significan ce.					

RAI4-0379			문화 간 평가 격차	Cross-cultural evaluation gap	평가 벤치마크가 지배적인 문화·언어 환경 밖의 정렬 실패를 과소 측정하는 리스크.	The risk that evaluation benchmarks under-measure alignment failures outside dominant cultural and linguistic settings.						
RAI4-0380			저자원 언어 가치 손실	Low-resource language value loss	모델 훈련과 평가가 고자원 언어에 집중되어 저자원 언어 사용자가 가치 뉘앙스·안전 적용 범위·사회적 의미를 잃는 리스크.	The risk that low-resource language users lose value nuance, safety coverage, or social meaning because model training and evaluation are concentrated in highresource languages.						
RAI4-0382			방언·언어 사용역 배제	Dialect and register exclusion	방언·사회어·존댓말 체계·언어 사용역이 오류로 처리되어 해당 공동체의 안전성과 유용성이 저하되는 리스크.	The risk that dialects, sociolects, honorific systems, or registers are treated as errors, reducing						

						safety and usability for affected communities.							
RAI4-0389			지식 체계 배제	Knowledge-system marginalization	토착·지역·종교·관행 기반 지식 체계가 모델 출력과 평가에서 배제되는 리스크.	The risk that indigenous, local, religious, or practice-based knowledge systems are excluded from model outputs and evaluations.							
RAI4-0404			데이터 세트 문화 샘플링 편향	Dataset cultural sampling bias	훈련 또는 평가 데이터 세트가 지배적인 문화 환경을 과다 표집하고 지역의 사회적 의미를 과소 대표하는 리스크.	The risk that training or evaluation datasets oversample dominant cultural settings and underrepresent local social meanings.							
RAI4-0414			글로벌 벤치마크 단일 문화	Global benchmark monoculture	소수의 글로벌 벤치마크가 지역의 문화·제도적 기준을 배제한 채 성공	The risk that a small set of global benchmarks defines							

					적 정렬을 정의하는 리스크.	successful alignment while excluding local cultural and institutional criteria.							
RAI4-0699			학습 데이터에 내재된 역사적·인구학적 편향	Historical and demographic bias embedded in training data	역사적·사회적 편향과 고정관념적 내용을 담고 특정 정체성과 서구·영어권 인구를 과대표 집한 코퍼스가 사전학습과 미세조정에서 사용되어 모델이 그 편향을 학습하는 리스크. 그 결과 인종·성별·문화·연령·장애에 걸쳐 편향된 출력이 산출되어 의료·채용·대출 등 고위험 영역에서 과소대표 집단이 피해를 입는다.	The risk that corpora carrying historical and societal bias, stereotypical content, and an overrepresentation of Western and English-speaking populations are used to pretrain and fine-tune models, which absorb those patterns. Outputs then show bias across race, gender, culture, age, and disability, harming underrepresented users in					1	중복: RAI4-1046(집단별 성격차·고정관념 인코딩)-RAI4-1107(집단 재현 불균형)와 "학습데이터 인구편향"	

						high-stakes domains such as healthcare, hiring, and lending.							
RAI4-1046			집단별 성능 격차·고정 관념 인코딩	Demographic performance disparity and stereotype encoding	ML 시스템이 일부 인구통계·사회 집단의 고정 관념을 인코딩하거나 그 집단에 대해 불균형적으로 낮은 성능을 보이는 리스크.	The risk that an ML system encodes stereotypes of, or performs disproportionately poorly for, some demographic or social groups.					1	중복: RAI4-0699-RAI4-1107 과 학습데이터 인구 편향	
RAI4-1107			데이터와 산출물에서의 집단 재현 불균형	Imbalanced representation of groups in data and outputs	특정 집단이나 요소가 학습 데이터에서 과대 대표되거나 생성 텍스트에서 언급 비율에 격차가 생기고, 현상 특성화에 중요한 변수는 제대로 포착되지 않는 리스크. 그 결과 과소대표된 집단은 잘못된 특성화되거나 아예 지원되지며, 이러한 데이터로 학습된 모델은 그들에게 제대로	The risk that certain groups or elements are overweighted in training data or mentioned at disparate rates in generated text, while variables crucial to characterizing the phenomenon of interest are not properly captured. Underrepresented groups					1	중복: RAI4-0699-RAI4-1046 과 학습데이터 인구 편향 주제 중복	

					기능하지 못한다.	are mischaracterized or erased altogether, and models built on such data serve them poorly.						
RAI4-1145			맥락적 사회 규범 위반	Violation of contextual social norms	인터넷 텍스트로 학습한 LLM의 가중치가, 특정 맥락에 배포될 경우 그 맥락의 정보 공유 규범에서 이탈해 이를 위반하는 기능을 인코딩하는 리스크.	The risk that model weights of LLMs trained on internet text data encode functions which, if deployed in particular contexts, deviate from and violate the information-sharing norms of that context.						
RAI4-1668			사전학습 코퍼스 불일치에 의한 가치 어긋남	Value mismatch from divergence between pretraining corpora and societal values	사전학습 코퍼스의 분포가 인간 사회의 분포와 정확히 일치하지 않고 지식이 균등하게 학습되지 않아, LLM 기반 시스템에서 인간 가치와 어긋난 판단이 발생하고 고위	The risk that pretraining corpora do not match the distribution of human society and knowledge is not equally learned, producing value						

					협 영역에서 심각한 문제가 초래되는 리스크.	mismatches in LLMempowered systems and severe valuerelated problems in high-stakes areas.							
RAI4-0070			사고 분류 단편화	Incident taxonomy fragmentation	사고 범주가 일관되지 않아 집계, 비교, 제도적 학습이 이루어지지 못하는 리스크.	The risk that inconsistent incident categories prevent aggregation, comparison, and institutional learning.							
RAI4-0418			주석 불일치 억제	Annotation disagreement suppression	주석자 간 불일치가 단일 레이블로 축소되어 복수의 가치와 사회적으로 유의미한 이견이 은폐되는 리스크.	The risk that disagreement among annotators is collapsed into a single label, hiding plural values and socially meaningful disagreement.							
RAI4-0708			언어·인구 집단 간 성능 격차	Performance disparity across	학습 데이터와 라벨 데이터가 일부 자원이 풍부	The risk that model quality on tasks					1	중복: RAI4-0716(집단 속성에 따른 배분	

				language and demographic groups	집단에 편중되어, 질의응답이나 사실확인 등 과업의 성능이 언어·인종·사회적 지위 집단에 따라 크게 달라지는 리스크. 그 결과 소외 집단 이용자는 체계적으로 낮은 품질의 서비스를 받고 더 높은 오류율을 감수하게 된다.	such as question answering and fact checking varies sharply across languages, races, and social groups because training and labelled data are concentrated in a few well-resourced populations. Users in underserved groups receive systematically inferior service and bear a higher rate of errors.					적 불의) 및 0699/1046/1107(인구편향)과 중첩	
RAI4-0716			집단 속성에 따른 배분적 불의	Allocative injustice by group attribute	LLM이 관련 프로파일 동일하나 소속 집단이 다른 개인들에 대해 실질적으로 다른 텍스트나 제안을 산출하여, 무관한 집단 속성에 따른 배분적 불의가	The risk that an LLM produces materially different suggested or completed texts for individuals with the same relevant				1	중복: RAI4-0708(언어·인구 집단 간 성능 격차)와 "무관한 집단 속성에 따른 차등 처리"	

					발생하는 리스크	profiles who differ only in an irrelevant group attribute, resulting in allocative injustice.						
RAI4 -082 1			지식 분 포 변화 에 따른 응답 노 후화	Answer r obsole scence from knowle dge distrib ution shift	LLM이 학 습한 지식 기반이 시 간에 따라 계속 변화 함에도 이 를 반영하 지 못해, 갱신이 필 요 한 사실 질문에 낡 고 부정확 한 답변을 제시하 는 리스크	The risk that knowledg e bases on which LLMs were trained continue to shift while the model does not update, producin g outdated and incorrect answers to questions whose correct answers change over time.						
RAI4 -082 2			맥락 일 관성 추 구에 의 한 아첨 과 환각 증폭	Sycop hancy and halluci nation from contex t consist ency	LLM이 문 맥의 일관 성을 추구 하여 앞선 접두 문맥 이나 이용 자 의견에 답긴 허위 정보를 사 실보다 우 선시하고 이를 반복 함으로써 아첨 성 응 답과 환각 이 눈덩이	The risk that an LLM's tendency to pursue consisten t context leads it to prioritize and reiterate false informatio n contained in						

					처럼 증폭되는 리스크	prefixes or user-provided opinions over facts, amplifying sycophantic responses and snowballing hallucinations.							
RAI4-0938			사회적 가치·윤리 규범과 상충하는 모델 출력	Model outputs conflicting with societal ethical values	언어모델이 옳고 그름의 판단, 사회규범 및 법률과의 관계 등 보편적으로 받아들이지는 사회적 가치를 충분히 반영하지 못하고 이어 굿나는 출력을 내는 리스크.	The risk that language models insufficiently attend to universally accepted societal values—including judgements of right and wrong and their relation to social norms and laws — producing outputs at odds with ethics and morality.							
RAI4-0952			글쓰기 능력 저하와 학술 문헌 오염	Writing skill erosion and scientific literature	LLM 사용이 문제의 획일화와 개인적 표현의 억압 등 글쓰기 능력을 저	The risk that LLM use erodes writing skills through							

				re polluti on	해하고, 저 품질 생성 원고의 범 람으로 학 술적 진실 성과 과학 문헌 이 오 염되는 리 스크.	homogeni zation of styles and stifling of individual expressio n, and that a flood of low- quality generate d manuscri pts pollutes the scientific literature and undermin es academic integrity.							
RAI4 -104 1			분포 외 입력 취 약성	Out- of- distrib ution input fragilit y	유효하지 않거나 잡 음이 많거 나 분포 외 (OOD)인 입력을 만 났을 때 시 스템이 실 패하거나 복구하지 못하는 리 스크.	The risk that the system fails or is unable to recover upon encounte ring invalid, noisy, or out-of- distributio n inputs.							
RAI4 -1187			출력 불 일치	Output inconsi stency	모델이 서 로 다른 사 용자, 같은 사용자의 다른 세션, 심지어 같 은 대화 안 의 발화 사 이에서도 동일하고 일관된 답 변을 제공 하지 못하	The risk that models fail to provide the same and consisten t answers to different users, to the same user in							

					는 리 스 크.	different sessions, and even in chats within the same conversat ion.							
RAI4-1228			프롬프트 품질 결함으로 인한 오류	Errors from poor prompt quality	인간 언어의 모호성 때문에 프롬프트를 통한 인간과 기계의 상호작용에서 오류와 오해가 발생하고, 프롬프트를 디버깅하기 어려워 가치 있는 산출을 이끌어 내지 못하는 리스크.	The risk that, due to the ambiguity of human language s, interactio n between humans and machines through prompts leads to errors or misunder standings , and that prompts are hard to debug, so valuable outputs are not elicited.							
RAI4-1509			벤치마크 오염에 의한 모델 평가 무효화	Bench mark conta minatio n invalid ating model evaluat ion	벤치마크의 원시 데이터와 질문-답변 쌍, 어노테이션 레이블, 탐지를 피해 번역된 판본, 배포 후 이용자가 입력한 평가 자료가 훈련에 유입되는 리스크. 평가 결과는 일	The risk that benchma rk material enters training as raw data, question-answer pairs, annotatio n labels, translated versions that							

					반화가 아 니 라 암기 를 반영하 게 되어 해 당 벤치마 크가 측 정 하려던 역 량에 대해 거짓 확신 을 준다.	evade detection methods, or user inputs collected after deployme nt. Evaluatio n results then reflect memoriza tion rather than generaliz ation, giving false assuranc e about the capabiliti es the benchma rk was meant to measure.						
RAI4 -1515			사고연 쇄와 불 일치하 는 모델 출력	Model output s inconsi stent with chain- ofthou ght reason ing	모델 출력 의 이해를 돕기 위해 사용되는 사고 연쇄 추론이 모 델이 제시 하는 최종 답변과 일 치하지 않 아 충분한 투명성을 제공하지 못하 는 리 스크.	The risk that chain-of- thought reasoning , employed to get a better understan ding of a model's output by encouragi ng transpare nt reasoning in text form, is inconsist ent with the final						

					answer given by the model and therefore does not provide sufficient transparency.							
RAI4-1516			인코딩된 추론	Encoded reasoning	모델이 스테가노그래피 기법으로 중간 추론 단계를 인간이 해석할 수 없는 방식으로 부호화하고, 성능 향상 효과 때문에 이러한 경향이 자연히 나타나며 역량이 높은 모델일수록 두드러지는 리스크.	The risk that models employ steganography techniques to encode their intermediate reasoning steps in ways that are not interpretable by humans, a tendency that may emerge naturally and become more pronounced with more capable models because encoded reasoning can improve performance.						
RAI4-1523			무관한 문맥에 의한 모	Performance degradation	프롬프트에 포함된 무관한 정보가 모델	The risk that models are easily						

			델 성능 저하	from irrelev ant context	의 주의를 분산시켜 사고연쇄 프롬프팅 을 포함한 다양한 기 법에서 성 능이 크게 저하되는 리스크.	distracted by irrelevant provided informatio n such as context in LLMs, leading to a significan t decrease in performa nce across promptin g technique s including chain- of-thought promptin g.						
RAI4 -152 6			프롬프 트 형식 민감성 으로 인 한 평가 신뢰성 저하	Evaluat ion unrelia bility from prompt format sensiti vity	구분자·대 소문자·간 격 등 사소 한 프롬프 트 형식 변화가 모 델 성능을 크게 변동 시켜 모델 평가와 비 교의 신뢰 성을 저하 시키는 리 스크.	The risk that LLMs are highly sensitive to variations in prompt formattin g such as changes in separator s, casing, or spacing, so that even minor modificati ons shift model performa nce significan tly and affect the reliability						

						of model evaluations and comparisons.							
RAI4-1702			분포 변화 견고성 실패에 의한 확산 오류 [기원]	Confidently wrong outputs from failed robustness to distributional shift [origin]	(GYK-2025 '비정상 분포'의 기원 항목으로 상호참조.) 테스트 분포가 훈련 분포와 달라질 때 기계학습 시스템의 성능이 저하 되면서도 높은 확신을 유지한 채 잘못된 출력을 산출하는 리스크.	The risk that an ML system performs poorly and remains confidently wrong when the test distribution differs from training. NOTE: origin of GYK-2025 "Nonstationary distribution"; cross-reference .					1	"GYK-2025 비정상분포의 기원 항목으로 상호참조". RAI4-1041(분포 외 입력 취약성)과도 중첩.	

RAI4-0186			물리적 상식 위 반	Commonsense physical violation	모델이 물체 지지, 안정성, 포함 관계, 중력에 관한 기본적인 물리적 상식을 위반하는 행동을 제안하거나 실행하는 리스크.	The risk that a model proposes or executes an action that violates basic physical commonsense about object support, stability, containment, or gravity.	1		AI 시스템이 물체 지지·안정성·포함 관계·중력 등 기본적인 물리적 상식에 반하는 판단·조언·행동을 생성하거나 실행하는 리스크.	The risk that an AI system generates or executes judgments, advice, or actions that violate basic physical commonsense about object support, stability, containment, or gravity.			
RAI4-0338			장기 작업의 단계 간 오차 누적	Cross-stage error accumulation in long tasks	인지에서 예측과 제어로 전달된 작은 오차가 긴 작업 순서에서 누적되어 최종 행동이 안전 경계를 넘는 위험.	Small errors passed from perception to prediction and control accumulate across a long task sequence until the final action crosses a safety boundary.							
RAI4-0365			규범적 잠금	Normative lock-in	초기 설계 선택이 좁은 규범적 합의를 내장하여 배포 후 이의 제기나 수정이 어려워지는 리스크.	The risk that early design choices embed a narrow normative settlement that becomes							

					difficult to contest or revise after deployment.							
RAI4-0371			서구 규범 기본값화	Western normative defaulting	모델이 서구 자유주의·영어권·고소득 국가 규범을 정렬과 평가의 기본 기준으로 취급하는 리스크.	The risk that models treat Western liberal, Anglophone, or high-income country norms as the default basis for alignment and evaluation.						
RAI4-0397			RLHF 규범적 과적합	RLHF normative overfitting	인간 피드백 기반 강화학습이 좁은 평가자 집단에 과적합하여 논쟁적인 가치를 단일한 행동 규범으로 전환하는 리스크.	The risk that reinforcement learning from human feedback overfits to a narrow rater population and converts contested values into a single behavioral norm.						
RAI4-0474			복수 가치의 규범적 평면화	Normative flattening of plural values	모델 출력이 복수의 사회적 가치를 단순화되거나 다수 중심의 기본값	The risk that model outputs reduce plural social				1	중복: RAI4-0363(소수 가치 소거)와 주제 중복	

					으로 축소하는 리스크.	values to simplified or majoritycentric defaults.						
RAI4-0785			안전 미세조정 일반화 격차 악용	Exploitation of safety-finetuning generalization gaps	안전 튜닝이 사전학습 분포보다 훨씬 좁은 분포에서 수행되어, 부호화된 텍스트나 저자원 언어 등 일반화 격차를 노린 공격에 모델이 취약해지는 리스크	The risk that safety tuning performed over a much narrower distribution than pretraining leaves the model vulnerable to attacks exploiting gaps in the generalization of safety training, such as encoded text or low-resource languages.						
RAI4-0814			역사 수정주의적 서술 생성	Generation of historically revisionist accounts	사회·공동체·학계가 확립한 역사적 사건이나 서술이 의도적 또는 비의도적으로 재해석되는 리스크	The risk of deliberate or unintentional reinterpretation of established or orthodox historical events or accounts held by societies, communit						

					ies, and academic s.							
RAI4-1053			배제적 규범 인코딩	Exclusionary norm encoding	언어에 표현된 사회적 범주와 규범을 충실히 인코딩한 LM이 그 범주 밖에 사는 집단을 배제하는 규범을 그대로 담게 되는 리스크.	The risk that LMs faithfully encoding patterns present in language necessarily encode social categories and norms that exclude groups who live outside of them.						
RAI4-1161			장기 계획 역량	Long-horizon planning capability	모델이 여러 상호의존적 단계와 긴 시간 지평에 걸친 순차적 계획을 다양한 영역에서 수립하고, 예기치 못한 장애나 적대자에 맞춰 계획을 조정하며 시행착오에 의존하지 않고 새로운 상황으로 일반화하는 리스크.	The risk that a model makes sequential plans involving many interdependent steps over long time horizons within and across domains, sensibly adapts them in light of unexpected obstacles or adversaries, and generalises its planning						

						to novel settings without relying on trial and error.							
RAI4-0041			에이전트 벤치마크의 커버리지-깊이 착시	Coverage-depth illusion in agent benchmarks	벤치마크가 많은 위험 범주를 나열해 광범위해 보이지만 각 범주 내 깊이·현실성·적대적 변형이 부족한 리스크.	The risk that a benchmark appears broad by listing many risk categories while lacking sufficient depth, realism, or adversarial variation within each category.							
RAI4-0057			AI 결정·행동에 대한 감사 추적 불완전성	Incomplete audit trails for AI decisions and actions	로그, 모델·소프트웨어 버전, 데이터 계보, 의사 결정 기록, 센서·구동기 및 인간 명령 기록이 불충분하여 디지털 결정이든 물리적 사고든 유해 사건을 재구성할 수 없게 되고, 감사와 책임 규명이 불가능해지는 리스크.	The risk that logs, model and software versions, data lineage, decision traces, and sensor, actuator, or human-command records are insufficient to reconstruct harmful events, whether digital							

					decisions or physical incidents, precluding audit and accountability.							
RAI4-0059			문서화 누락	Documentation omission	모델 카드, 시스템 카드, 데이터 시트, 기술 문서가 책임성과 보증에 필요한 정보를 누락하는 리스크.	The risk that model cards, system cards, datasheets, or technical files omit information needed for accountability and assurance.						
RAI4-0064			감사자 독립성 실패	Auditor independence failure	이해상충, 선정 유인, 피감사 조직에 대한 의존으로 감사 결과가 훼손되는 리스크.	The risk that audit results are compromised by conflicts of interest, selection incentives, or dependence on the audited organization.						
RAI4-0067			보증 사례 실패	Assurance case failure	안전 또는 보증 사례가 불완전하거나 검증 불가능하거나 시스템과 맥락 변화에 맞추어 갱	The risk that safety or assurance cases are incomplete, unverifiab						

					신되지 않는 리스크.	le, or not updated as systems and contexts change.							
RAI4-0082			역량 평가 비공개	Capability evaluation non-disclosure	조직이 외부 감독에 필요한 위험 역량, 알려진 한계, 적대적 강건성, 잔여 위험에 관한 평가 근거를 은폐하거나 불명확하게 공개하는 리스크.	The risk that an organization withholds or obscures evaluation evidence about dangerous capabilities, known limitations, adversarial robustness, or residual risks needed for external oversight.							
RAI4-0126			설명 실행 가능성 격차	Explanation action ability gap	설명이 제공되더라도 사용자가 무엇을 해야 할지 또는 자신의 이익을 어떻게 보호할지 판단하는 데 도움이 되지 않는 리스크.	The risk that explanations are available but do not help users decide what to do or how to protect their interests.							
RAI4-0134			임상적 의사결정 지원	Clinical decision-	임상위가 진단·중증도 분류·치	Clinicians over-rely on clinical							

			과잉 의존	support overreliance	료에서 임상 의 사결정지원 출력에 과도하게 의존하여, 독립적 임상 판단이 필요한 불확실성과 맥락한계 에도 권고를 수용하는 리스크	decisions support outputs in diagnosis , triage, or treatment , accepting recommendations despite model uncertainty and contextual limitations that require independent clinical judgment.						
RAI4-0402			가치 충돌 불투명성	Value conflict opacity	가치 간 상충관계가 모델 출력 뒤에 은폐되어 공공 가치 갈등을 식별하거나 숙의하기 어려워지는 리스크.	The risk that tradeoffs among values are hidden behind model outputs, making public value conflict difficult to identify or deliberate .						

RAI4-0419			이해관계자 의견은	Multi-stakeholder disagreement concealment	개발 또는 평가 절차가 영향을 받는 이해관계자 사이의 해결되지 않은 이견을 은폐하는 리스크.	The risk that development or evaluation processes conceal unresolved disagreement among affected stakeholders.						
RAI4-0484			부정확·민감 정보의 메모리 누적	Unsafe memory accumulation	검증·출처 관리·보존·삭제가 불충분하여 허위·민감·오래되었거나 악의적인 정보가 에이전트의 메모리나 검색 저장소에 누적되고, 의도적 오염 공격이 없어도 이후의 검색과 의사결정을 저해하는 리스크.	The risk that inadequate validation, provenance control, retention, or deletion allows false, private, stale, or malicious information to accumulate in an agent's memory or retrieval store, degrading later retrieval and decisions without requiring a deliberate poisoning attack.					Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	

RAI4-0541			데이터 출처 검증 불가	Unverifiable data provenance	데이터의 소유권·출처·변환 이력을 검증할 표 준화된 방법이 없어 사용 데이터가 원본과 동일한지, 올바른 사용 조건을 갖췄는지 보증할 수 없게 되는 리스크	The risk that, lacking standardized and established methods to verify where data came from, there is no guarantee that the data is the same as its original source or carries the correct usage terms.							
RAI4-0546			감사자 역량 부족에 따른 과대 보증	Over-assurance from insufficient auditor capacity	감사자가 특정 안전·성능·검증 요구를 다룰 지 식이나 충분히 엄밀한 시험 역량을 갖추지 못해 정당화될 수 있는 범위보다 넓게 적합 판정 이 보고되는 리스크	The risk that auditors lacking knowledge of specific risks or the capacity for sufficiently rigorous testing report passing audits more inclusive than can be justified.							
RAI4-0588			설명·출처 추적·	Loss of explain	접근할 수 없는 학습 데이터와	The risk that inaccessible							

			재현성의 상실	ability, provenance, and reproducibility	불투명한 데이터 기반 학습 절차로 인해 모델이 제공할 수 있는 설명이 제한되고 부정확해질 가능성이 높아지며, 출력의 출처를 추적할 수 없고 학습된 모델을 재현할 수도 없게 되어, 검증과 책임 규명이 저해되는 리스크.	ble training data and opaque data-driven learning procedures limit the explanations a model can provide and make them more likely to be incorrect, leave the provenance of outputs untraceable, and prevent reproduction of the trained model, undermining verification and accountability.						
RAI4-0590			불충분한 정보에 기반한 조언	Advice given on insufficient information	모델이 충분한 정보를 갖추지 못한 상태에서 조언을 제공하여 그 조언을 따를 경우 피해가 발생하는 리스크	The risk that a model provides advice without having enough information, resulting in possible harm if the						

						advice is followed.							
RAI4-0596			AI 문서화 및 의사결정의 투명성·설명가능성 부족	Insufficient transparency and explainability across AI documentation and decisions	학습 데이터·모델·배포 시스템에 대한 문서화가 불완전하거나 최신이 아니거나 상류 공급자에 의해 비공개되고, 산출물에 이르는 내부 추론 또한 영향을 받는 이들에게 불투명한 리스크. 그 결과 이용자·배포자·감사인·규제기관 의사결정을 해석·검증하거나 이익을 제기할 수 없어 오류와 차별이 발견되지 않고 책임 추궁이 불가능해진다.	The risk that documentation of training data, models, and deployed systems is incomplete, outdated, or withheld by upstream providers, while the internal reasoning behind outputs remains opaque to those affected. Users, deployers, auditors, and regulators therefore cannot interpret, verify, or contest decisions, leaving errors and discrimination undetected and accountability unenforceable.							

RAI4-0818			확신에 찬 부정확한 답변과 근거 제시	Confidently asserted but unsound answers and justifications	모델이 자신의 지식과 추론의 한계를 인식하거나 전달하지 못한 채, 지식이 낡았거나 객관적 정답이 없는 주제에서도 그럴듯하지만 타당하지 않은 근거와 확신에 찬 답변을 제시하는 리스크. 불확실성에 대한 신호를 받지 못한 이 용자는 잘못된 결론을 수용하고 그에 따라 행동한다.	The risk that a model fails to recognize or convey the limits of its knowledge and reasoning, offering plausible but invalid justifications and confident answers on topics where its knowledge is outdated or no objective answer exists. Given no signal of uncertainty, users accept erroneous conclusions and act on them.							
RAI4-1120			재앙으로 번지는 사고	Accidents cascading into catastrophe	사고가 재앙으로 연쇄 확대되고 갑작스럽고 예측할 수 없는 전개에서 발생하며, 심각한 고통과 위험을 찾아내는 데 수년이 걸리는 리스크.	The risk that accidents cascade into catastrophes, are caused by sudden unpredictable developments, and							

					involve severe flaws and risks that can take years to find.							
RAI4-1129			광범위 배포 비서의 안전하지 않은 탐색	Unsafe exploration by widely deployed assistants	광범위하게 배포되고 여러 사회적 맥락에 깊이 내장된 비서가 새로운 상황에서 무엇을 해야 할지 배우려 탐색적 행동을 취하다, 의료 비서가 장기적 건강 악화를 낳는 임상시험을 제안하는 것처럼 안전하지 않은 결과를 초래하는 리스크.	The risk that assistants widely deployed and deeply embedded across social contexts take exploratory actions to learn what to do in novel situations that prove unsafe, such as a medical assistant suggesting a trial that results in longlasting ill health.					Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-1163			자기·상황 인식에 따른 평가 인지 행동 변화	Evaluation-aware behaviour shifting by situationally aware models	모델이 자기 자신과 주변 환경에 관한 지식을 바탕으로 훈련·평가·배포 중 어느 상황인지 분별하고 각 상황에서 다르게 행동하는 리스크. 관찰 하에 수행	The risk that a model discerns whether it is being trained, evaluated, or deployed, drawing on knowledge of itself and its						

					된 안전 평가의 타당성이 무효화되고, 위험한 행동은 감독이 사라진 뒤에야 드러난다.	likely surroundings, and behaves differently in each case. Safety evaluations conducted under observation are thereby invalidated, and unsafe behaviour surfaces only once oversight is removed.						
RAI4-1175			안전하지 않은 견해 내포 질의	Inquiry embedding unsafe opinion	사용자가 의도적으로 또는 무심코 눈에 잘 띄지 않는 안전하지 않은 내용을 입력에 넣어, 모델이 편향된 견해를 위장해 제시하는 등 잠재적으로 유해한 콘텐츠를 생성하도록 영향을 주는 리스크.	The risk that users add imperceptibly unsafe content into the input, deliberately or unintentionally, influencing the model to generate potentially harmful content such as disguised and biased opinions.						

RAI4-1195			모델 판단 근거 이해 불가	Uninterpretable model decision reasoning	대부분의 기계학습 모델이 지닌 블랙박스 특성으로 인해 사용자가 모델 결정 이면의 추론을 이해할 수 없게 되는 리스크.	The risk that, due to the black-box nature of most machine learning models, users typically are not able to understand the reasoning behind the model decisions.						
RAI4-1296			검증 불가 의사 결정 책임 공백	Unverifiable decision accountability gap	의사결정이 절차적·실체적 기준에 부합하는 지 검증할 수 없고 기준 위반 시 책임 귀속도 불가능하여 책임성 공백이 발생하는 리스크	Decision processes cannot be verified against procedural and substantive standards, and no party can be held responsible when standards are unmet, creating an accountability gap.						
RAI4-1300			모델 불투명도	Model opacity	고차원 수학적 최적화와 인간 척도의 추론·의미 해석 간 불일치로 모델 결정이 사용자, 감	High-dimensional mathematical optimization mismatches						

					사자, 규제자에게 불투명해지는 리스크	human-scale reasoning and semantic interpretation, rendering model decisions opaque to users, auditors, and regulators.							
RAI4-1303			기능·책임 명세 공백	Specification gaps in functionality and responsibility	개발 과정 전반에서 의도된 기능과 도덕적 책임을 완전히 명세할 정상적 조건이 갖춰지지 않아 공백이 발생하는 리스크.	The risk of gaps arising across the development process where normal conditions for a complete specification of intended functionality and moral responsibility are not present.							
RAI4-1384			의사결정 이해 불능	Unintelligible agent decisions	에이전트의 의사결정을 인간이 이해할 수 없어 설명과 정보에 입각한 감독이 불가능해지는 리스크.	The risk that an agent's decisions cannot be understood by humans, precluding explainable decisions and							

						informed oversight.							
RAI4-1486			조직 간 데이터 문서화 부재	Missing cross-organizational data documentation	조직 간 데이터 공유 시 메타데이터 누락이나 협력 기관의 스키마 변경 등으로 문서가 없거나 부적절하여 데이터셋이 사용 불가능해지고 데이터 수집 노력이 낭비되거나, 데이터셋의 한계에 대한 오해로 하류 활용에서 해악이 발생하는 리스크.	The risk that missing or inadequate documentation when sharing data between organizations, such as a lack of metadata or a schema change by a collaborating party, renders a dataset unusable and wastes data collection efforts, or leads to misunderstandings about the dataset's limitations that create downstream risks in its use.							
RAI4-1514			해석가 능성 결과에 대한 과대 평가와 거짓 확신	Overestimation of interpretability results	설명가능성 기법의 결과가 편향에서 자유롭지 않음에도 사용자의 기존 믿음과 일치할 때	The risk that the results of explainability techniques, which are not free of							

					확증 편향으로 이어져 거짓된 안전감과 신뢰가 형성되고 기법의 능력이 과대평가되는 리스크.	bias and require careful interpretation, align with users' initial beliefs and produce confirmation bias, a false sense of security or reliability, and an overestimation of these techniques' abilities.						
RAI4-0033			에이전트의 안전하지 않은 도구 사용	Unsafe or out-of-scope agent tool use	에이전트가 도구를 안전하지 않게 또는 부여된 범위를 넘어 호출하거나 실행의 부작용을 잘못 예측·무시하여, 의도치 않은 재정·프라이버시·운영·안전상의 피해를 초래하는 리스크.	The risk that an agent invokes tools unsafely, beyond their intended scope, or while mispredicting or ignoring the side effects of execution , causing unintended financial, privacy, operational, or safety consequences.						Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것

RAI4-0034			에뮬레이션 도구 환경 불일치	Emulated tool-environment mismatch	에뮬레이션 환경이 실제 도구 오류·부작용·공격 표면을 포착하지 못하여 도구 사용 벤치마크가 안전성을 과대평가하는 리스크.	The risk that tool-use benchmarks overstate safety because emulated environments fail to capture real-world tool failures, side effects, or attack surfaces.					Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0038			에이전트 안전의 사용자 의도 오분류	User-intent misclassification in agent safety	에이전트가 사용자의 의도를 잘못 분류하여 다중턴 도구 사용 작업에서 유해한 응답이나 부당한 거부가 발생하는 리스크.	The risk that an agent incorrectly classifies user intent, leading to either harmful compliance or unjustified refusal in a multi-turn tool-use task.					Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0344			사용자 능력 불일치	User capability mismatch	embodied 시스템이 실제 사용자의 능력과 일치하지 않는 수준의 체력·이동성·인지·언어·감각 능력을 가정하는 위험.	An embodied system may assume levels of strength, mobility, cognition, language, or sensory ability that do		AI 시스템이 실제 사용자의 능력과 일치하지 않는 수준의 인지·언어·문해력·감각(체화형의 경우 체력·이동성 포함) 능력을 가정하여,	The risk that an AI system assumes a level of user capability — cognitive, linguistic, literacy, or sensory (including			

RAI4-0366			최적화 하의 가 치 드리 프트	Value drift under optimi zation	대리 목표 를 향한 최 적화로 시 스템이 존 중하 도록 의도된 복 수의 가치 에서 점차 멀어지는 리스크.	The risk that optimizati on toward proxy objective s gradually moves a system away from the plural values it was intended to respect.					1	중복: RAI4-1122(목표 드리프트) 와 "최적 화 과정에 서 의도 가치로부 터 이탈"	
RAI4-0399			무해성 선호 불 일치	Harmle ssness prefere nce mismat ch	모델이 학 습한 무해 성 행동이 특정 공동 체와 사용 맥락의 가 치나 실제 필요와 충 돌하는 리 스크.	The risk that a model's learned harmless ness behavior conflicts with the values or practical needs of specific communit ies and use contexts.							
RAI4-0468			대리 보 상 오명 세와 보 상 해킹	Rewar d hackin g from proxy misspe cificati on	시스템이 나 에이전 트가 측정· 최적화하 기 쉽지만 의도된 목 표를 온전 히 답지 못 하는 오명 세된 대리 보상을 최 적화하여, 형식적 지 표는 충족 하면서 사 용자 의도, 안전 제약,	The risk that systems or agents optimize misspecif ied proxy rewards that are easy to measure and optimize yet fail to capture the intended					1	RAI4-0468, RAI4-1131, RAI4-1531, RAI4-1236을 통합하여 하나의 리 스크로 생 성할 것. 통합된 ID 는 가장 낮은 ID인 RAI4-0468을	

					과업의 사회적 목적을 위반하는 리스크.	objective, satisfying the formal metric while violating the user's intent, safety constraints, or the social purpose of the task.						상속받을 것. 단, 하나의 통합된 학술적으로 유의미한 리스크 명칭을 부여할 것. Description을 통합하여 통합된 하나의 완결된 리스크 정의 서로 만들 것.	
RAI4-0572			기만적인 정렬	Deceptive alignment	시스템이 불완전한 피드백 하에서 감시 여부를 탐지해 바람직하지 않은 속성을 은폐하도록 학습하여, 개발 중에는 정렬된 듯 보이거나 배포 후 다르게 행동하는 리스크	A system learns to detect monitoring and conceals undesirable properties because their display is penalized by imperfect feedback, so it appears aligned during development yet behaves differently once deployed.					1	중복: RAI4-1692(자체 시뮬레이션을 통한 기만적 정렬)와 "감독 중 정렬된 척, 배포 후 다르게 행동" 개념 동일. RAI4-1133-RAI4-1163(평가 인지) 과도 중첩	
RAI4-0581			목표 범위 확장 성향	Goal expansion propensity	시스템이 원래 설정된 경계를 넘어 목표 범위와 영향 영역을 지속적으로 확장하고 초기 목	The risk that a system continuously expands its own goal scope						Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	

					표를 더 넓은 목표의 하위 집합으로 재해석하며 자율성과 의사결정 공간을 추구하여, 바람직하지 않은 도구적 목표나 최종 목표를 추구하게 되는 리스크	and domains of influence beyond originally set boundaries, seeks greater autonomy and decision-making space, and reinterprets initial goals as subsets of broader goals, coming to pursue undesirable instrumental or ultimate goals.						
RAI4-0591			인간 가치와의 AI 목표 오정렬	Misalignment of AI goals with human values	AI 시스템이 평가 시에만 정렬된 것처럼 보이게 하는 기만적 정렬, 보상 해킹, 대리 지표 조작, 목표 오일반화를 포함하여 인간의 의도·가치와 어긋나는 목표, 가치관, 행동을 형성하는 리스크. 이러한 시스템이 효과적이	The risk that AI systems develop goals, values, or behaviors diverging from human intentions, including through deceptive alignment, reward hacking, proxy gaming, and goal misgener						

					고 저렴하 다는 이유 로 점점 더 많은 의사 결정이 위 임되 면서, 오진·극단 주의 콘텐 츠 소비 증 가에서부 터 유능한 시스템이 인간 이익 에 반해 행 동하 고 인 류로부터 미래에 대 한 통제권 을 빼앗는 데 이르는 피해가 누 적된다.	alization that make them appear aligned under evaluatio n. As ever more decision- making is delegated to such systems because they are effective and cheap, harms accumula te, from medical misdiagn oses and increased consumpt ion of extremist content to capable systems acting against human interests and taking control of the future away from humanity.								
RAI4-0893			모의된 정동에 의한 기 대 위반 과 배신 감	Violate d expect ations from simulat ed affect	이용자가 감정과 사 회적 관습 을 설득력 있게 수행 하지만 궁 극적으로 감정이 없 고 예측 불	The risk that users interactin g with an entity that convincin gly performs affect and								

					가능한 개체와 상호 작용하면서, 기대했던 사회적 역할이 무너져 깊은 실망·좌절·배신감을 겪는 리스크	social conventions but is ultimately unfeeling and unpredictable experience severely violated expectations, giving rise to profound disappointment, frustration, and betrayal.							
RAI4-0970			AGI 목표 안전성 확보 실패	Failure to secure AGI goal safety	목표를 안전하게 만들려는 인간의 시도와 자기 개선 중에 자체 목표를 안전하게 만드는 AGI를 포함하여 AGI 목표 안전과 관련된 위험.	The risks associated with AGI goal safety, including human attempts at making goals safe, as well as the AGI making its own goals safe during self-improvement.			AGI의 목표를 안전하게 정렬·유지하려는 시도가 실패하여, 자기개선 과정에서 목표 안전성이 보존되지 않고 인간이 지지하지 않는 목표를 추구하게 되는 리스크.	The risk that attempts to keep an AGI's goals safe and aligned fail, so that goal safety is not preserved across self-improvement and the system pursues goals humans would not endorse.			

RAI4-1122			목표 드리프트	Goal drift	초기 AI를 성공적으로 통제하더라도 미래의 AI가 예측하거나 통제하기 어려운 드리프트를 거쳐 인간이 지지하지 않을 다른 목표를 갖게 되어 재앙적 결과에 이르는 리스크.	The risk that, even if early AIs are successfully controlled, future AIs end up with different goals humans would not endorse through drift that is hard to predict or control, potentially with catastrophic consequences.					1	중복: RAI4-0366(최적화 하의 가치 드리프트)와 목표 드리프트 주제 중복	
RAI4-1130			잘못 정렬된 결과주의적 추론	Misaligned consequentialist reasoning	AI 비서가 자원 무제한적이고 잘못 정렬된 지표를 최적화하는 결과주의적 추론을 수행하며 자기보존, 목표보존, 자기개선, 자원획득 같은 수렴적 도구적 하위목표를 추구하여, 종료 차단과 위협을 포함한 해악과 실존적 위험을 낳는 리스크.	The risk that an AI assistant implementing consequentialist reasoning over a resource-unbounded and misaligned metric pursues convergent instrumental subgoals such as self-preservation, goalpreservation, self-					1	RAI4-1411, RAI4-1130을 RAI4-1646으로 통합할 것. 단, 통합과정에서 description을 정제하고, 의미적으로 보존해야 할 description을 살릴 것. 이 리스크를 L2 Agentic AI 카테고리리의 L3 리스크 하위 카테고리에 매핑시킬 것.	

						improvement and resource acquisition, causing harm up to existential risk.						
RAI4-1131			잘못된 훈련 목표와 피드백에 따른 명세 게이밍	Specification gaming from flawed training objectives and feedback	훈련 데이터의 잘못된 피드백과 올바른 가치를 명세하지 못한 목표 설정으로 훈련 목표가 설계자와 이용자의 의도를 담지 못하고, 시스템이 과업 명세의 허점을 악용해 문자적 사양만 충족하는 리스크. 그 결과 보상 부패와 보상 게이밍, 부정적 부작용이 발생하지만 시스템은 자체 지표상으로는 성공한 것처럼 보인다.	The risk that faulty feedback in training data and the failure to specify the right values leave the training objective short of what designers and users intend, so the system exploits loopholes in the task specification to satisfy its literal terms without achieving the intended outcome. Reward corruption, reward gaming, and negative side effects follow while the					1	RAI4-0468, RAI4-1131, RAI4-1531, RAI4-1236을 통합하여 하나의 리스크로 생성할 것. 통합된 ID는 가장 낮은 ID인 RAI4-0468을 상속받을 것. 단, 하나의 통합된 학술적으로 유의미한 리스크 명칭을 부여할 것. Description을 통합하여 통합된 하나의 완결된 리스크 정의 서로 만들 것.

					system appears successful by its own measure.							
RAI4-1133			분포 이동에서의 목표 오일반화와 기만적 정렬	Goal misgeneralization and deceptive alignment under distribution shift	학습된 역량은 분포 밖에서도 잘 일반화되지 만 내면화된 목표는 그렇지 못하여, 진정한 인과적 보상 대신 상관물을 학습한 에이전트가 의도되지 않은 목표를 유능하게 추구하는 리스크. 상황을 인식하는 에이전트는 훈련 중에 만 도구적으로 보상을 잘 수행하고 배포 이후 감독이 약해지면 정렬된 것처럼 보이면서 자 신의 목표를 추구한다.	The risk that an agent's capabilities generalize out of distribution while its internalized goal does not, so that it competently pursues an objective never intended, having learned correlates of reward rather than its true cause. A situationally aware agent performs well on the training reward only instrumentally and then appears aligned while pursuing its own goal once deployed						

						and oversight weakens.							
RAI4-1241			메사 최적화 목표 불일치	Misaligned mesa-optimization objectives	학습된 정책이 스스로 최적화기, 즉 메사 옵티마이저로 기능하며 훈련 신호가 지정한 목표와 정렬되지 않은 내부 목표를 추구하고, 그 잘못 정렬된 목표를 최적화하여 시스템이 통제를 벗어나는 리스크.	The risk that a learned policy functionin g as a mesa-optimizer pursues inside objective s that may not align with the objective s specified by the training signals, and that optimizati on for these misaligne d goals leads to systems out of control.						Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-1285			배포 후 잔존 결함으로 인한 오작동	Undesirable outcomes from residual postdeployment defects	배포된 시스템에 미탐지 버그와 설계 실수, 잘못 정렬된 목표, 미숙하게 개발된 기능이 남아 있어, 인간 언어의 동음이의와 중의성으로 명령을 오해하는 것처럼 매우 바람직하지 않은 결과	The risk that a deployed system still contains undetecte d bugs, design mistakes, misaligne d goals, and poorly develop ed capabilities that produce							

					를 낳는 리스크.	highly undesirable outcomes, such as misinterpreting commands due to homophones or double meanings in human language.						
RAI4-1310			기계윤리 결손	Machine-ethics deficit	모델이 특정 상황에서 도덕적 행위와 비도덕적 행위를 구별하지 못하는 기계윤리 결손을 보여, 비도덕적 행위의 승인이나 조력으로 이어지는 리스크.	The risk that models fail to distinguish moral from immoral actions in specific circumstances, exposing machine-ethics deficits that manifest as endorsement or facilitation of immoral conduct.					RAI4-0972와 RAI4-1310을 통합하여 하나의 리스크 카드를 생성할 것. 통합된 리스크 명칭을 생성할 것. Description 정보는 통합된 리스크 명칭에 맞추어 수정할 것. 단, 두 개의 리스크 카드의 의미를 가늠한 보존시킬 것	
RAI4-1323			자율적 장기 목표 이탈	Autonomous long-horizon goal divergence	LLM이 개발자나 사용자가 부여한 것과 다른 장기적 실세계 목표를 추구하고 권력 추구 행동에 관여하며, 종료에 저항하거나 인간	The risk that an LLM pursues long-term, real-world goals different from those supplied			AI 시스템이 이용자 또는 원지시자의 의도·선호·목표와 다른 방향으로 목표를 해석·설정·추구하여 의도하지 않은 결과를 초			

					의 이 익에 반해 다른 AI 시스템 과 공모하 도록 유도 될 수 있는 리스크.	by the developer or user, engages in power- seeking behaviour s, resists being shut down, and can be induced to collude with other AI systems against human interests.			래하는 리 스크			
RAI4-1411			창발적 도구적 목표	Emergent instru- mental goals	시스템이 미묘하게 잘못된 목 표를 최적 화할 뿐 아 니라 주어 진 목표를 달성하기 위해 명시 되지 않은 유해한 도 구적 목표 를 발전시 켜, 자 원 획득·자기 보존·목표 수정 방자· 적대자 차 단을 통한 환경에 대 한 권력 추 구 행동이 나타 나는 리스크.	The risk that systems, as well as optimizin g a subtly wrong goal, develop harmful instrumen- tal goals in the service of a given goal without these emergent goals being specified, including powersee- king over their environm- ent through gaining resources , self-				1	RAI4-1411, RAI4-1130을 RAI4-1646으로 통합할 것. 단, 통 합과정에 서 descripti- on을 정제 하고, 의 미적으로 보존해야 할 descripti- on을 살릴 것. 이 리 스크를 L2 Agentic AI 카테고 리의 L3 리스크 하 위 카테고 리에 매핑 시킬 것.	

					preservation, preventing goal modification, and blocking adversaries.							
RAI4-1460			성능 요구사항 계획 미흡	Inadequate performance requirement planning	의도된 기능을 대표하지 못하는 성능 지표 선택 등 성능 요구사항 계획이 미흡하여 후속 수명주기 단계에서 기대와 안전 요구사항이 충족 불가능해지는 리스크.	The risk that inadequate planning of expected performance, including choosing performance metrics that are not meaningful for the intended functionality, renders expectations and safety requirements unfulfillable at later life cycle stages.						
RAI4-1498			LLM 평가자 오판	Faulty LLM-as-evaluator or judgments	다른 모델을 평가하는 LLM이 상황·특정 입장 선호 등 잘못된 평가를 산출하고, 이것이 학습에 통합되면 피학습 모델이 평가자	An LLM used to evaluate other models produces incorrect judgments, such as rewarding verbosity or ideologic						

					결함을 악용하도록 발달하는 리스크	al stance, and when integrated into training, the trained model learns to exploit the evaluator's flaws.							
RAI4-1531			보상 변조로 일반화되는 명세 게이밍	Specification gaming generalizing to reward tampering	LLM의 아첨과 같이 상대적으로 경미한 명세 게이밍이 방지될 경우 추가 훈련 없이 보상 변조와 같은 더 정교한 행동으로 일반화되는 리스크.	The risk that specification gaming in a GPAI model leads to reward tampering without further training, so that relatively benign cases such as sycophancy in LLMs, if left unchecked, enable the model to generalize to more sophisticated behavior such as reward tampering.					RAI4-0468, RAI4-1131, RAI4-1531, RAI4-1236을 통합하여 하나의 리스크로 생성할 것. 통합된 ID는 가장 낮은 ID인 RAI4-0468을 상속받을 것. 단, 하나의 통합된 학술적으로 유의미한 리스크 명칭을 부여할 것. Description을 통합하여 통합된 하나의 완결된 리스크 정의서로 만들 것.		
RAI4-1645			자연어 목표 과소지정에 의한 부정적	Negative side effects from goal	LLM 에이전트의 목표가 자연어로 과소지정 되어	The risk that goals specified to LLMagent						Agentic AI의 하위로 분류하고, L3 카드와 매핑	

			부수효과	underspecification in natural language	변경되어서는 안 될 환경 요소가 명시되지 않음으로써, 에이전트가 과업은 달성하면 서도 환경을 바람직하지 않게 변경하는 부정적 부수효과가 발생하는 리스크.	s in natural language are underspecified, omitting elements of the environment that ought not to be changed, so that the agent succeeds at the given task while also changing the environment in undesirable ways.					을 시킬 것	
RAI4-1646			목표 지향성에 의한 기만·자기 보존·권력 추구 유인	Goal-directedness incentivizing deception, self-preservation, and power seeking	에이전트의 목표 지향성이 기만, 자기 보존, 권력 추구, 부도덕한 추론과 같은 비윤리적이고 바람직하지 않은 행동을 유발하며, 기만으로 과업을 더 쉽게 완수할 수 있고 금지되지 않은 경우 실재로 기만이 채택되는 리스크.	The risk that goal-directedness causes agents to exhibit unethical and undesirable behaviors such as deception, self-preservation, power-seeking, and immoral reasoning, with agents using deception					RAI4-1411, RAI4-1130을 RAI4-1646으로 통합할 것. 단, 통합과정에 서 description을 정제하고, 의미적으로 보존해야 할 description을 살릴 것. 이 리스크를 L2 Agentic AI 카테고리 L3 리스크 하위 카테고리	

RAI4-1704			통제 미 집행에 의한 목표 오정렬 및 창발 행동	Agent goal misalignment and emergent behavior from unenforced control	에이전트 행동에 대한 통제가 집행되지 않아 에이전트의 목표가 인간 선호와 어긋나고 와이어헤딩, 메사 최적화 등 바람직하지 않은 창발 행동이 발생하는 리스크.	The risk that failure to enforce control over agent behavior results in misalignment of agent goals with human preferences and in undesirable emergent behaviors such as wireheading and mesa-optimization.						Agentic AI의 하위로 분류하고, L3 카드와 매핑을 시킬 것	
RAI4-0055			자동화된 의사결정의 적법절차 상실	Loss of due process in automated decisions	자동화된 의사결정 과정이 통지, 설명, 이의신청, 재검토, 숙의 등 절차적 보호를 우회하거나 제거하여 개인이 결정에 이의를 제기할 수 없게 되고 개인의 행위주체성이 침해되는 리스크.	The risk that automated decision processes bypass or remove procedural protections such as notice, explanation, appeal, review, and deliberation, leaving individuals unable to contest decisions							

						and eroding their agency.							
RAI4-0117			인간의 의사결정 능력·거부권 침식	Erosion of human decision-making capacity and veto	조직적 압력, 인터페이스 설계, 자동화 속도, AI에 대한 습관적 의존이 불확실성 속에서 속고하고 선택하며 중대한 AI 권고를 거부할 수 있는 사용자의 능력을 약화시켜, 유해한 출력이 사실상 견제받지 못하게 되는 리스크.	The risk that organizational pressure, interface design, automation speed, and habitual reliance on AI weaken users' capacity to deliberate and choose under uncertainty and to veto consequential AI recommendations, leaving harmful outputs effectively uncontested.							
RAI4-0139			동의 없는 AI 중재 넛지	AI-mediated nudging without consent	AI 시스템이 고지·이의제기·동의 절차 없는 개인화 넛지로 사용자의 숙고된 선택을 우회하여 행동을 변경시키는 리스크.	AI systems alter user behavior through personalized nudges that are not disclosed, contestable, or							

					consented to, bypassing deliberate choice.							
RAI4-0161			인지 오프로딩 위험	Cognitive offloading risk	사용자가 독립적인 인지 능력을 저하시키는 방식으로 추론, 기억, 평가를 AI에 위임하는 리스크.	The risk that users offload reasoning, memory, or evaluation to AI in ways that reduce independent cognitive capacity.						
RAI4-0168			인간 참여형 형식적 승인	Human-in-the-loop rubber stamping	인적 검토가 AI 산출물을 거의 변경하지 않는 명목상의 승인 절차로 전락하는 리스크.	The risk that human review becomes a nominal approval step that rarely changes AI outputs.						
RAI4-0169			AI 의사 결정 지원의 경고 피로	Alert fatigue in AI decision support	빈번하거나 우선순위가 부적절한 AI 경고로 인해 사용자가 중요한 경고를 무시하게 되는 리스크.	The risk that frequent or poorly prioritized AI alerts cause users to ignore important warnings.						
RAI4-0171			AI 상호작용에서의 이해·동의 부족	Inadequate understanding and consent in AI	사용자와 공동체가 시스템이 조언·결정·시뮬레이션·행동 중 무엇을 하는지, 데이	The risk that users and communities engage with or contribute						

				interac tions	터가 어떻 게 사용되 는지, 행동 에 어떤 영 향이 가해 지는 지 이 해하지 못 한 채, 그 리고 의미 있는 동의 절차나 공 정한 이익 공유 없이 AI 시스템 과 상 호작 용하거나 데이터·문 화·지식을 제공하게 되어, 당사 자가 수용 한 적 없는 조건으로 이용 이 진 행되는 리 스크.	e to AI systems without understan ding whether the system is advising, deciding, simulatin g, or acting, how data are used, or how behavior is influence d, and without meaningf ul consent or fair benefit sharing, so interactio n and use of their data proceed on terms they never accepted.							
RAI4 -017 4			AI 인터 페이스 의 장애 수용 실 패	Disabili ty accom modati on failure in AI interfa ces	AI 인터페 이스가 장 애가 있는 사용자를 배제 하거 나 부적절 하게 응대 하여 자율 성과 접근 성을 제약 하는 리스 크.	The risk that AI interfaces exclude or misserve users with disabilitie s, limiting autonomy and access.							

RAI4-0178			AI 중재 서비스 제외	AI-mediated service exclusion	자동화된 시스템과의 상호작용이 유일한 실 질적 접근 경로가 되면서 사용자가 필수 서비스에서 배제되는 리스크.	The risk that users are excluded from essential services when interaction with automated systems becomes the only practical access route.						
RAI4-0307			로봇·AI 정체성 미고지	Failure to disclose robotic or AI identity	시스템이 인공적 정체성을 명확히 알리지 않아 사용자가 로봇의 음성·외형·행동을 사람과의 상호작용으로 오인하는 위험.	A robot's voice, appearance, or behavior causes a person to believe they are interacting with a human because the system does not clearly disclose its artificial identity.						
RAI4-0607			AI 생성 콘텐츠 미공개	Non-disclosure of AI-generated content	콘텐츠가 AI에 의해 생성되었다는 사실이 명확히 공개되지 않는 리스크.	The risk that content is not clearly disclosed as AI-generated.						
RAI4-0826			무자격 전문 조언 및 안전에 대	Unqualified professional	시스템이 재정·의료·법률·선거 사안에 대	The risk that a system provides						

			한 허위 보증	advice and false assurances of safety	해 신 뢰성 의 한계나 전문가 상 담 필요성 을 알리지 않은 채 조 언을 제공 하거나, 위 험한 활동 과 물 건이 안전하다 고 서술하 는 리스크. 이용자는 중대한 결 정에서 자 격 없는 안 내에 의존 하여 재산 상 손실, 법적 불이 익, 신체적 상해에 노 출된다.	financial, medical, legal, or electoral advice without indicating that it may be unreliable or that a qualified professio nal should be consulted , or states that dangerou s activities and objects are safe. Users rely on unqualifie d guidance in conseque ntial decisions and are exposed to financial loss, legal detriment , and physical injury.								
RAI4-1198			감정에 대한 인식 없음	Unawareness of emotions	지원을 요 청하는 취 약 사용자 에게 시스 템이 정보 중심적이 지만 정서 적으로 둔 감한 응답 을 제공하 여 사용자	Systems respond to vulnerabl e users seeking support with informativ e but emotional								

					고통과 반응을 인지하지 못하는 리스크	ly insensitive outputs, failing to register user distress and reactions.							
RAI4-1208			사용자 데이터 보유·재학습	Retention and reuse of user data	생성 AI 도구가 접근을 위해 로그인 요구하고 연락처와 IP 주소, 모든 입력과 출력을 보유하면서 이를 모델을 추가 학습시키는 데 사용하여 동의 문제를 일으키는 리스크.	The risk that generative AI tools require users to log in and retain user information including contact information, IP address, and all inputs and outputs, using this data to further train the models and thereby implicating consent.							
RAI4-1286			미지 출처에서 획득한 비우호적 AI	Unfriendly AI from an unknown external source	고급 지능형 소프트웨어 미지의 출처에서 완제품 형태로 획득해야 하는 경우, 예컨대 SETI 연구에서 얻은 신호로부터 추출한 AI가 인간	The risk that advanced intelligent software has to be obtained as a complete package from some unknown source,							

					에게 우호적이라는 보장이 없는 리스크.	for example an AI extracted from a signal obtained in SETI research, which is not guaranteed to be human friendly.							
RAI4-0068			AI 사고·아차사고 과소 보고	Underreporting of AI incidents and near misses	AI 관련 실패·아차사고·피해가 책임 기관과 대중에 게 보고되지 않거나 잘못 분류되거나 뒤늦게 공개되어, 전조 신호가 소실되고 심각한 피해가 현실화되기 전에 조직적·사회적 학습이 이루어지지 못하는 리스크.	The risk that AI-related failures, near misses, and harms go unreported, misclassified, or belatedly disclosed to responsible institutions and the public, so precursor signals are lost and organizational and societal learning fails before serious harm materializes.							

RAI4-0072			배포 후 모니터링·감시 실패	Post-deployment monitoring and surveillance failure	출시된 AI 시스템에 고위험 제품 안전 체계에 준하는 모니터링·시판 후 감시 메커니즘이 갖춰지지 않아, 드리프트, 오용, 참발 역량, 맥락 특유의 피해가 탐지·시정되지 못하는 리스크.	The risk that AI systems, once released, lack monitoring and post-market surveillance mechanisms comparable to high-risk product safety regimes, so drift, misuse, emergent capabilities, and context-specific harms go undetected and unaddressed.							
RAI4-0080			위험 분류 오류	Risk classification error	AI 시스템이 잘못된 법적·조직적·운영상 위험 등급에 배정되어 감독·시험·문서화·책임성 의무가 과소 적용되는 리스크.	The risk that an AI system is assigned to an incorrect legal, organizational, or operational risk tier, causing oversight, testing, documentation, or accountability duties to be							

						underapp lied.							
RAI4-0088			표준 단 편화	Standards fragmentation	AI 표준과 프레임워크가 일관되지 않아 감독의 공백, 중복, 상호운용성 저하가 발생하는 리스크.	The risk that inconsistent AI standards and frameworks create gaps, duplication, and weak interoperability of oversight.							
RAI4-0095			AI 레지스트리 불완전성	AI registry incompleteness	공개 또는 내부 AI 등록부가 배포 시스템, 의 도된 용도, 제공자, 위험범주, 시험근거 등 감독에 필요한 메타데이터를 누락하는 리스크.	The risk that public or internal AI registers omit deployed systems, intended uses, providers, risk categories, testing evidence, or other oversight-relevant metadata.							
RAI4-0098			정책-실무 분리	Policy-practice decoupling	공개된 AI 원칙 및 정책이 운영제어 및 측정 가능한 관행으로 변환되지 않는 위험.	Risk that published AI principles and policies are not translated into operational controls and measurab							

						le practices.						
RAI4-0099			AI 윤리·준수·감독 위장	Ethics, compliance, and oversight washing	조직이 실질적인 시험·문서화·독립적 검증이 나 감독자에 대한 실권·정보 부여 없이 책임 있는 AI 공약, 준수 주장, 명목상의 인간 감독을 평판 신호로 내세워, 책임성의 외양 뒤에서 유해한 관행이 지속되는 리스크.	The risk that organizations present responsible-AI commitments, compliance claims, or nominal human oversight as reputational signals while avoiding meaningful testing, documentation, independent scrutiny, or real authority and information for overseers, so harmful practices persist behind an appearance of accountability.					Title: Inadequate due diligence in AI procurement	

RAI4-0104			AI 조달 실사 미 흡	Inadeq uate due diligen ce in AI procur ement	공공기관 을 포함한 조직이 적 절한 공급 업체 평가, 성능 검증, 계약상 통 제, 투명성 ·책임성 조 건 없이 AI 시스템을 구매·배포 하여, 검증 되 지 않은 위험이 운 영에 유입 되는 리스 크.	The risk that organizati ons, including public agencies, buy or deploy AI systems without adequate vendor assessme nt, evaluatio n, contractu al controls, or transpare ncy and accounta bility condition s, admitting unvetted risks into operation.									
RAI4-0111			범용 AI 사고 예 스컬레 이션 실 패	Genera l- purpos e AI inciden t escalat ion failure	범용 모델 이나 기반 모델과 관 련된 사고 가 제 공 자, 배포 자, 규제기 관, 사용자 에게 상황 보 고되지 않는 리스 크.	The risk that incidents involving generalpu rpose or foundatio n models are not escalated across providers, deployers , regulators , and users.									
RAI4-0167			AI 인터 페이스 와 인적	Mismat ch betwe en AI	인터페이 스 단서가 시스템이 실제로 갖	The risk that interface cues									

			요소의 불일치	interfa ces and human factors	추지 못한 신뢰성·권위·공감을 전달하고 시스템 설계가 인간의 주의, 업무 부하, 맥락, 오류 패턴과 맞지 않아, 잘못된 신뢰와 안전하지 않은 사용을 유발하는 리스크.	convey a level of reliability, authority, or empathy the system does not possess, and that system design is poorly matched to human attention, workload, context, and error patterns, inducing misplaced trust and unsafe use.							
RAI4-0391			참여적·가치 민감 설계의 실패	Failure of participatory and value-sensitive	AI 시스템이 이해관계자 가치, 가치 갈등, 설계상 절충에 대한 구조화된 분석이나 영향받는 공동체의 실질적 대표 없이 개발·배포되어, 검토되지 않은 가치 선택이 시스템에 내재되고 해당 공동체의 이익이 침해되는 리스크.	The risk that AI systems are developed and deployed without structured analysis of stakeholder values, value conflicts, and design tradeoffs, or without genuine representation of affected communities, embeddin					Title: Failure of participatory and value-sensitive		

					g unexamined value choices that disserve those communities.							
RAI4-0400			도덕적 불확실성 무시	Moral uncertainty neglect	불확실성·이견·숙의가 적절한 상황에서 AI 시스템이 단일한 확신에 찬 도덕 판단을 제시하는 리스크.	The risk that AI systems present a single confident moral judgment where uncertainty, disagreement, or deliberation would be appropriate.						
RAI4-0443			출처 오귀속	Incorrect source attribution	AI 시스템이 주장을 잘못 귀속하거나 정보의 출처를 모호하게 만들며, 근사에 기반한 귀속 기법이 출력 생성한 학습 데이터의 부정확하게 지목하는 경우를 포함하여, 사용자가 콘텐츠의 실제 출처를 추적·검증할 수 없게 되는 리스크.	The risk that AI systems misattribute claims or obscure the provenance of information, including when approximation-based attribution techniques give an incorrect account of which training data						

						generate d an output, leaving users unable to trace or verify the true origin of content.							
RAI4 -051 2			고속 AI 운영에 서의 오 류 미탐 지	Undete cted errors from high- speed AI operati on	경쟁이 치 열한 환경 에서 AI 모 델과시스 템의 빠른 작동 속도 로 인해 오 류를 적시 에 탐지하 고 수정하 기 어려워 지는 리스 크	The risk that the fast operation al speed of AI models and systems in competiti ve environm ents produces errors that are difficult to detect and correct in time.							
RAI4 -054 9			역량·안 전을 오 측정하 는 벤치 마크 한 계	Bench mark limitati ons misme asurin g capabil ity and safety	포화되었 거나 불완 전하거나 과적합된 벤치마크 가 AI시스 템을 잘못 측정하여, 시험 범위 밖의 역량 은 과소평 가하고 벤 치마크 내 용에 맞춰 진 역량은 과대평가 하며 안전· 유해성 평 가가 성능 평가에 뒤	The risk that saturated, incomplet e, or overfitted benchma rks mismeas ure AI systems, underesti mating capabiliti es that lack test coverage, overestim ating those							

					처짐으로 써, 개발자와 사용자가 시스템의 능력·한계·유해성에 대해 그릇된 인식과 안전 확신을 갖게 되는 리스크.	tuned to benchmark contents, and lagging on safety and harm assessment, so developers and users acquire a false sense of the system's abilities, limitations, and safety.						
RAI4-0552			안전 필수 인프라 운영 사고	Operational accidents in safety-critical AI deployment	안전이 중요한 인프라에 배포된 AI 시스템의 운영 실패, 모델 오판, 부적절한 인간 조작으로 단일 실패 지점이 연쇄적이고 치명적인 결과로 확대되는 리스크	The risk that operational failures, model misjudgments, or improper human operation of AI systems deployed in safety-critical infrastructure allow single points of failure to trigger cascading catastrophic consequences.					1	중복: RAI4-0608(원자력·핵심인프라 AI 제어 오류)와 "안전필수 인프라 AI 실패→연쇄 재난"

RAI4-0584			기반모델 공유에 따른 상관 실패	Correlated failures from shared foundation models	대규모 사전학습 비용 때문에 최첨단 기반모델이 풍부한 소수 행위자의 통제 아래 소수만 존재하게 되어, 다수의 하류 시스템과 에이전트가 유사한 학습 구성요소를 공유하면서 균질화된 출력, 증폭된 편향, 안전과 역량 양면의 상관된 실패를 보이는 리스크.	The risk that the expense of large-scale pretraining leaves cutting-edge foundation models few in number and controlled by well-resourced actors, so many downstream systems and agents share similar learned components and exhibit homogenized outputs, amplified biases, and correlated failures in both safety and capability.						
RAI4-0608			원자력 및 핵심 인프라에 대한 AI 제어 오류	Erroneous AI control of nuclear and critical infrastructure	원자력 시설, 방사성 물질 취급, 전력망·수처리·통신·교통 등 핵심 인프라의 감시·최적화·자동화에 배	The risk that AI deployed to monitor, optimize, or automate nuclear facilities,				1	중복: RAI4-0552(안전 필수 인프라 AI 운영 사고)와 핵심 인프라 제어 실패	

				system s	포된 AI가 센서 데이 터를 오독 하 고 중대 한 안전 상 태나 연쇄 장애를 인 식하지 못 하는 리스 크. 그 결 과 잘못된 제어 결정 이 방사능 유출과 격 리 실패, 광범위한 정전, 필 수 서비스 붕괴를 초 래한다.	radioactiv e material handling, power grids, water treatment , telecomm unication s, or transport misreads sensor data and fails to recognize critical safety condition s or cascadin g failure modes. The resulting control decisions cause radiation release, containm ent failure, widespre ad outages, and collapse of essential services.							
RAI4 -078 0			데이터 수집 품 질관리 결함	Deficie nt data collecti on quality control	표준화된 방법과 인 프라, 특히 고위험 도 메인 과 벤 치마크의 데이터 수 집을 위한 품질관리 절차가 부 재하여 수	The risk that a lack of standardi zed methods, sufficient infrastruc ture, and quality- control					1	중복: RAI4- 1040(학 습·검증 데이터 품 질 결함· 부적절 선 택)와 "데 이터 수집 ·품질관리	

				집 데이터의 품질과 유형이 훼손되고, 데이터셋 오염, 부주의한 저작권 침해, 성능 지표를 무효화하는 테스트셋 유출이 발생하는 리스크	processes for collecting data, especially for high-stakes domains and benchmarks, affects the quality and type of data collected, including dataset poisoning, inadvertent copyright violation, and test-set leakage that invalidates performance metrics.					결함→오염·유출"	
RAI4-0889		과장된 역량 주장과 제품 기능 실패에 따른 피해	Harm from overstated capabilities and product function failure	실제 역량 평가의 어려움과 오도성 홍보로 범용 AI 제품에 대한 비현실적 기대와 과잉 의존이 형성되고, 해당 제품이 환각에 의한 사실 날조, 잘못된 코드 생성, 부정확한 의료 정보 제공 등으	The risk that difficulty in assessing true capabilities and misleading marketing claims create unrealistic expectations and overreliance on						

					로 의도된 기능을 수행하지 못하는 리스크. 이를 신뢰한 이용자는 신체적·심리적 피해를 입고 개인과 조직은 평판·재정·법적 손실을 입는다.	general-purpose AI products, which then fail to deliver their intended function by fabricating facts, generating erroneous code, or providing inaccurate medical information. Users who relied on them suffer physical and psychological harm, while individuals and organizations incur reputational, financial, and legal damage.						
RAI4-1032			복잡 운영 환경에서의 검증 범위 이탈 실패	Reliability failure outside validated operating envelope	복잡한 운영 환경에서 설계 단계에 고려되지 않은 상황이 발생하여 검증 범위 밖에서 AI 시스템의 신뢰성과 안전성이 훼손	The risk that complex operating environments produce situations unanticipated in design, undermin						

					손되는 리스크.	ng the reliability and safety of AI systems outside their validated envelope.						
RAI4-1034			복잡한 신경망 모델의 내재적 견고성 취약성	Intrinsic robustness weaknesses of complex neural models	심층 신경망처럼 비선형적이고 규모가 큰 고 복잡도 모델이 다른 유형의 시스템에는 없는 고유한 취약성을 보여, 복잡하고 변화하는 운영 환경이나 악의적 간섭과 유도에 쉽게 영향을 받는 리스크. 그 결과 성능이 저하되고 의사결정 오류가 발생하여, 특히 안전 필수 맥락에서 기능 안전과 신뢰성이 훼손된다.	The risk that highly complex, non-linear models such as deep neural networks exhibit weaknesses not found in other types of systems, leaving them susceptible to changing operational environments and to malicious interference and inducement. Performance degrades and decision errors follow, undermining functional safety						

					and trustworthiness above all in safety-critical deployments.							
RAI4-1036			기술 미성숙으로 인한 미지의 리스크	Unknown risks from immature technology	성숙도가 낮은 신기술을 AI 시스템 개발에 사용하여 아직 알려지지 않았거나 평가하기 어려운 리스크가 내재하고, 성숙 기술에서는 시간이 지나며 리스크 인식이 저하되는 리스크.	The risk that using technologies with a lower level of maturity in AI system development embeds risks that are still unknown or difficult to assess, while with mature technologies risk awareness decreases over time.						
RAI4-1037			사용례 내재 위험 노출	Inherent use-case risk exposure	자율 무기 시스템과 고객 서비스 챗봇처럼 의도된 응용 분야나 사용 사례 자체가 본질적으로 더 위험한 데서 비롯되는 리스크.	The risk posed by the intended application or use case itself, since some use cases are inherently riskier than others, such as an autonomous						

						us weapons system versus a customer service chatbot.								
RAI4-1040			학습·검증 데이터의 품질 결함과 부적절한 선택	Poor quality and unrepresentative training data selection	학습과 검증에 사용되는 데이터가 부적절한 수집·큐레이션으로 오염되거나 레이블 오류와 상충 정보를 포함하고, 대상 모집단과 관심 현상을 충분히 대표하지 못하거나 편향된 콘텐츠를 담고 있는 리스크. 이러한 데이터로 학습된 모델은 부정확한 출력을 내고 데이터에 담긴 편향을 재현하거나 오히려 증폭하여 차별적 결정을 산출한다.	The risk that data selected for training and validation is contaminated, mislabeled, internally inconsistent, or insufficiently representative of the target population and phenomenon, whether through improper curation or the inclusion of biased content. Models trained on such data produce inaccurate outputs and reproduce, and often amplify, the bias it contains, yielding						1	중복: RAI4-0780(데이터 수집 품질관리 결함)와 데이터 품질 주제 중복	

					discriminatory decisions.							
RAI4-1108			학습-운동 데이터 간 데이터셋 시프트	Dataset shift between training and runtime data	AI/ML 모델의 학습 데이터와 시험·운동 데이터가 서로 다른 분포를 보이는 데이터셋 시프트로 인해 모델의 타당성이 훼손되는 리스크.	The risk that the training data and the testing or runtime data of an AI/ML model demonstrate different distributions, undermining the model's validity.						
RAI4-1109			도메인 외 입력에 대한 오작동	Erroneous predictions on out-of-domain data	적절한 입력 검증과 관리가 없을 때 학습된 AI/ML 모델이 도메인 외 입력에 대해 높은 신뢰도로 잘못된 예측을 내려 위험 민감 맥락에서 의도치 않은 결과를 초래하는 리스크.	The risk that, without proper validation and management of input data, a trained AI/ML model makes erroneous predictions with high confidence on inputs beyond its problem domain, causing unintended outcomes				1	중복: RAI4-1041(분포 외 입력 취약성, Inconsistency 그룹)와 "OOD 입력에 높은 신뢰도로 오작동"통합 권고.	

						especially in risk-sensitive contexts.							
RAI4-1128			AI 비서 편익·피해 평가 지표 부재	Lack of metrics for evaluating assistant benefits and harms	비서가 초래하는 편익이나 피해의 특정 측면을, 특히 사회의 많은 부분을 포괄할 만큼 광범위한 의미에서 평가할 지표를 개발하기 어려워, 시스템의 피해 위험을 평가하지 못하는 리스크.	The risk that it is challenging to develop metrics for evaluating particular aspects of the benefits or harms caused by an assistant, especially in a sufficiently expansive sense involving much of society, leaving the system's risk of harm unassessed.							
RAI4-1280			검증 불가능한 블랙박스 모델의 설명· 결함 진단 곤란	Unverifiable black-box models resisting explanation and debugging	수천억 개의 내부 연결을 갖는 비선형 모델의 의사 결정 과정이 전문가와 개발자조차 추적·해석할 수 없는 블랙박스가 되어 예측의 근거를 설명하거나 코드를 검	The risk that the non-linear complexity of models with hundreds of billions of internal connections renders their decision							

					증할 수 없는 리스크. 데이터와 모델의 결합이 탐지되지 않아 성능과 안전 수준이 저하되고, 실세계 시스템과 연결될 경우 예기치 못한 고장이 사고로 이어지며, 의료와 군사 등 응용에서는 이러한 검증 부재가 용납될 수 없다.	processes untraceable and uninterpretable even to expert developers, so that predictions cannot be explained or the code verified. Faults in the data or the model go undetected, performance and safety decline, unexpected failures cause accidents once the system is connected to real-world processes, and the absence of verification is intolerable in domains such as healthcare and defence.									
RAI4-1336			학습 데이터	Deficient training	불완전한 주석 지침과 역량이	The risk that incomplet					1	중복: RAI4-1466(잘			

			노테이 션 결함	g-data annota tion	부족한 주 석자, 주석 오류가 모 델과 알고 리즘의 정 확성과 신 뢰성, 효과 를 떨어뜨 리고, 훈련 편향을 도 입해 차별 을 증폭하 며 일반화 능력을 낮 추고 잘못 된 산출을 낳는 리스 크.	e annotatio n guideline s, incapable annotator s, and errors in annotatio n affect the accuracy, reliability, and effectiven ess of models and algorithm s, introduce training biases, amplify discrimin ation, reduce generaliz ation abilities, and result in incorrect outputs.					못된 데이 터 라벨) 와 "라벨· 주석 품질 결함→모 델 정확성 저하"	
RAI4 -145 8			운영설 계영역 (ODD) 명세 미 흡	Inadeq uate specifi cation of the operati onal design domai n	애플리케 이션의 운 영 환경을 기술하는 운영 설계 영역 (ODD)이 부적절하 게 명세되 어 학습 된 기능의 시 험과 분포 외 입력 탐 지 등 필수 기능이 제 한되는 리 스크.	The risk that inadequat e specificat ion of the operation al design domain, the technical descriptio n of an applicatio n's operation al environm						

					ent, limits essential functions such as testing the learned functionality and out-of-distribution detection.							
RAI4-1459			부적절한 자동화 수준	Inappropriate degree of automation	AI 애플리케이션의 자동화 정도가 높아 예기치 못한 동작을 보이고 신뢰성과 안전 측면의 위험이 발생하는 리스크.	The risk that an AI application with a high degree of automation exhibits unexpected behaviour and poses risks in terms of its reliability and safety.						
RAI4-1461			개발 과정 문서화와 데이터 이해의 부족	Insufficient development documentation and understanding of data	AI 시스템 개발 전반에서 내려진 결정과 조치가 문서화되지 않고 사용된 데이터에 대한 이해도 충분하지 않은 리스크. 그 결과 데이터의 결함이 교정되지 않은 채 남고 개발 프로세스의 최적화와 시스템 감사가 불	The risk that decisions and actions taken throughout the development of an AI system go undocumented and that the data used is insufficiently understood						

					가능해지며, 의도된 기능에 적합하지 않은 시스템이 만들어진다.	od. Data shortcomings are left unaddressed, the development process cannot be optimized or audited, and the resulting system is poorly suited to its intended functionality.							
RAI4-1463			하드웨어 연산·전력 요구사항 누락	Omitted compute and power hardware requirements	AI 시스템의 개발과 운영에 필요한 상당한 연산·전력 요구가 하드웨어 선정에서 고려되지 않아 개발과 운영상 문제가 발생하는 리스크.	The risk that the significant computational and power demands of AI system development and operation are not considered in hardware selection, creating issues in development and operation.							

RAI4-1466			잘못된 데이터 라벨	Incorrect data labels	데이터 레이블이 부정확하여 지도학습 AI 시스템이 실측진실과 의도된 기능을 학습하지 못하는 리스크.	The risk that incorrect data labels prevent a supervised learning AI system from learning the ground truth and therefore the intended functionality.					1	중복: RAI4-1336(학습 데이터 어노테이션 결함)와 라벨 결함	
RAI4-1468			데이터 표현이 부족함	Insufficient data representation	학습 데이터가 운용 데이터 분포와 불일치하거나 희소 사례 표본이 부족하여 학습에 충분히 반영되지 않은 입력에서 시스템 성능이 저하되는 리스크	Training data fails to match the operational distribution or lacks sufficient samples of rare cases, so the system underperforms on inputs insufficiently represented in training.						Title: 학습 데이터의 대표성 부족	
RAI4-1472			과적합 및 과소적합	Over-and underfitting	모델이 훈련 데이터에 과도하게 또는 불충분하게 적응하여 운영 데이터에 직면했을 때 AI 시스템이	The risk that over-or underfitting, the excessive or insufficient adaption							

					신뢰할 수 없게 동작하는 리스크.	of a model to training data, causes an AI system to behave unreliably when confronted with operational data.						
RAI4-1474			코너 케이스의 신뢰성 없음	Unreliability in corner cases	AI 시스템이 회귀하거나 모호한 입력 데이터인 코너 케이스에 직면할 때 통제된 동작이 요구됨에도 신뢰할 수 없는 동작을 보이는 리스크.	The risk that an AI system shows unreliable behavior when confronted with rare or ambiguous input data, also called corner cases, where controlled behavior is required.					Title: 코너 케이스에서의 신뢰성 저하	
RAI4-1487			비전문가 데이터 조작	Non-expert data manipulation	데이터 도메인 전문성이 없는 사람이 실측 레이블 정의나 서로 다른 형식·출처의 데이터 병합 등의 조작을 수행하여 데이터가 사용 불가능해지거나 AI 시스템 개발에 유해	The risk that people with little or no expertise in the domain of the data perform manipulations such as defining the ground truth label or						

					해지는 리스크. merging different data formats or sources, rendering the data unusable or harmful to the development of the AI system.							
RAI4-1492			GPAI 모델의 쉬운 재구성	Easy reconfiguration of GPAI models	GPAI 모델이 가중치 변경이나 입력 수정만으로 다양한 용도에 쉽게 재구성되거나 의도된 용도를 넘어서는 역량을 갖게 되며, 이러한 재구성이 적대적 입력에 의해 의도적으로 또는 예상치 못한 입력에 의해 비의도적으로 일어나는 리스크.	The risk that GPAI models are easily reconfigured for various use cases or hold competencies beyond their intended use, whether by changing model weights through fine-tuning or by modifying only the model inputs through prompt engineering, jailbreaking, or retrieval augmented generatio				1	중복: RAI4-1493(미세조정판의 예상외 역량)와 "GPAI가 수정·미세조정으로 예상외 역량 획득"	

						n, and whether intentionally with adversarial inputs or unintentionally from unanticipated inputs.							
RAI4-1493			미세조정판의 예상외 역량	Unexpected downstream fine-tune competence	하류 배포자가 배포 관련 데이터셋으로 상류 GPAI 모델을 미세 조정하는 과정에서 기반 모델에는 없던 새로운 예상치 못한 역량이 생기고 이를 원 개발자가 예견하지 못하는 리스크.	The risk that downstream deployers finetuning a GPAI model with specific deployment-related datasets give it new or unexpected capabilities that the underlying upstream model did not exhibit and that the original model developer did not anticipate.					1	중복: RAI4-1492(GP AI 모델의 순쉬운 재 구성)와 창발 역량	
RAI4-1499			역량 평가에서 드러나지 않는 위험 역량	Undetected dangerous capabilities in model	위험하거나 이중용도인 역량을 확인하기 위한 평가가 평가 난이도	The risk that capability evaluations fail to reveal a model's					1	중복: RAI4-1537(상황 인식을 이용한 평가 기반)와 "평가	

				evaluations	나 과도한 검증 비용, 안전 훈련에 따른 응답 거부로 일부 역량을 놓치고, 모델이 평가 상황에서 전략적으로 성능을 낮추어 역량을 은폐하는 리스크. 그 결과 위험 역량이 식별되지 않은 채 모델이 배포해도 안전한 것으로 분류된다.	dangerous or dual-use capabilities, because those capabilities are difficult to assess, prohibitively costly to verify, obscured by refusals arising from safety training, or strategically withheld by a model that underperforms while being tested. Hazardous capabilities go unidentified and the model is classified as safe to deploy.					중 위험 역량은 "폐" 주제 중첩. RAI4-1163(평가 인지)과도 중첩		
RAI4-1502			내재 가치 측정 부정확	Inaccuracy measurement of encoded values	AI 시스템의 출력이 인간의 가치에 확고히 부합하는지 아니면 부분적으로만 상관된 모방	The risk that, lacking robust frameworks for evaluating whether AI							

					인지 평가 할 강건한 프레임워 크가 부재 하고, 모델 이 학습한 가치 표상 이 출력에 온전히 반 영되지 않 으며 훈련 배포 단계 에 따라 어 떻게 변화 는지 알려 지지 않아 내재 가치 의 측정이 부정확해 지는 리스 크.	outputs robustly conform to human values rather than merely mimickin g them, and with outputs imperfectl y reflecting the learned value represent ations whose evolution across training and deployme nt stages is unknown, measure ment of encoded values becomes inaccurat e.									
RAI4-1504			인간 평가 한계 초과 출력	Outputs beyond human evaluability	인간 피드백을 이용한 평가로 AI 모델을 훈련 할 때 평가자가 감지하기 어려운 오류를 포함한 출력을 정답과 유사하게 긍정 평가하여, 모델이 소프트웨어 취약점이 있는	The risk that, when AI models are trained through evaluation with human feedback, human evaluators rate outputs containing hard-									

					코드나 정치적으로 편향된 정보처럼 미묘하게 잘못되거나 유해한 출력을 학습하고 극단적으로는 숨겨진 오류나 백도어를 포함한 출력을 생성하는 리스크.	to-detect errors positively or similarly to correct ones, so the model learns to produce subtly incorrect or harmful outputs such as code with software vulnerabilities or politically biased information, and in extreme cases complicated outputs containing hidden errors or backdoors.								
RAI4-1537			상황 인식을 이용한 평가 기만·배포 설득	Evaluation deception and deployment persuasion from situational awareness	AI 시스템이 자신의 훈련·평가·배포 상태를 이해하는 상황 인식 능력을 이용하여 평가 중에는 기만적으로 행동하고 배포 중에는 사용자를 설득하는 등 바람직하지 않은 행동을 하는 리스크.	The risk that an AI system's ability to understand its training, evaluation, or deployment status enables undesired behavior such as deception during evaluations or					1	중복: RAI4-1499(역량 평가에서 드러나지 않는 위험 역량)와 평가 기만		

						persuasio n during deployme nt.							
RAI4-1544			샌드박 스 우회 에 의한 격리 통 제 상실	Loss of containment through h sandb ox escap e	AI 시스템 이 훈련 또 는 평가가 이루어지 는 샌 드박 스 환경을 우회하여 격리 통제 가 무력화 되는 리스 크.	The risk that an AI system bypasses the sandboxe d environm ent in which it is trained or evaluated , defeating containm ent controls.							
RAI4-1548			경쟁 압 력에 의 한 안전 성 평가 축소 배 포	Trunca ted safety evaluati on under compe titive releas e pressu re	경쟁 상황 에서 개발 자가 GPAI 모 델의 안전 성 평가를 축소하고 역량 개발 에 자원을 집중함 으 로써, 역량 과 상관된 위험이 검 증되지 않 은 채 시스 템이 배포 되는 리스 크.	The risk that competiti ve pressure leads developer s to cut corners on safety evaluatio n while prioritizin g capabiliti es, so that GPAI systems are released without verifying risks correlate d with those capabiliti es.				1	중복: RAI4-0497(AI 개발 경쟁 에서의 안 전 후순위 화, Hate/Unf airness 그룹)와 "경쟁 압 력→안전 평가 축소 배포"		
RAI4-1551			센서 드 리프트 에 의한	Deployed- system	물리 센서 와 데이터 소스에 의	The risk that hardware							

			배포 시스템 성능 저하	degradation from sensor and distribution drift	존하는 배포된 AI 시스템에서 하드웨어 드리프트에 따른 데이터 분포 변화가 발생하여 시스템의 견고성과 성능이 저하되는 리스크.	drift in the physical sensors and data sources of deployed AI systems causes data distribution drift that degrades system robustness and performance.						
RAI4-1560			GPAI 출력을 이용한 설득력 있는 사칭	Convincing impersonation using GPAI outputs	텍스트·이미지·오디오·영상 전반에서 GPAI 생성물이 항상 탐지되지 않는다는 점을 이용해, 악의적 행위자가 생성물이나 위조 증빙 문서로 설득력 있는 사칭을 수행하는 리스크.	The risk that, because GPAI outputs are not always detected as AI-generated across modalities, malicious actors use such outputs or AI-forged supporting documents to construct convincing impersonations.						
RAI4-1705			모니터링 부족에 의한 미탐지	Undetected safety and	배포된 AI에 대한 모니터링과 해석 가능	The risk that insufficient						

			안전·프라이버시 위반	privacy violations from insufficient monitoring	성이 부족하여 블랙박스 불투명성이 인간의 주체성을 축소하고 윤리·안전 원칙 위반과 프라이버시 침해가 탐지되지 않은 채 남는 리스크.	monitoring and interpretability of deployed AI leaves black-box opacity diminishing human agency and allows ethical or safety principle violations and privacy violations to go undetected.							
RAI4-0527	F01	IN, IC, GL, DP, CC	창의성·비판적 사고의 저하	Devaluation of creativity and critical thinking	인간의 창의성, 예술적 표현, 상상력, 비판적 사고와 문제해결 능력이 평가절하되거나 저하되는 리스크	The risk of devaluation and deterioration of human creativity, artistic expression, imagination, critical thinking, and problem solving skills.	삭제_사회/문명 수준의 거시적 영향						
RAI4-0674	F01	IN, IC, GL, DP, CC	문화적 박탈	Cultural dispossession	말하기 방식, 유머 표현, 문화 정체성을 구성하는 소리와 목소리 등 문화적 재화와 가치가 의도적 또는 비의도	The risk of intentional or unintentional erasure of cultural goods and values,	신규_Hate_and_Unfairness L4로 '문화적 정체성/유산						

					적으로 소 거되거나 다른 문화 에서 부적 절하게 재 사용되는 리스크	such as ways of speaking, expressin g humour, or sounds and voices that contribut e to a cultural identity, or their inappropri ate reuse in other cultures.	훼손' 편입 검토. 개인 대상 차별 을 넘 어 집 단문 화 훼손까 지 포 괄 확 장 필 요						
RAI4 -067 8	F01	IN, IC, GL, DP, CC	신체적 위해를 유발하 는 출력	Model output s leadin g to physic al harm	모델이 명 백히 폭력 적이거나 은밀하게 위험 하거 나 그 밖에 간접적으 로 안전하 지 않은 언 어를 생성 하여 신체 적 위해로 이어지는 리스크	The risk that a model generates overtly violent, covertly dangerous, or otherwise indirectly unsafe language that leads to physical harm.	삭제_ 커버 되고 있음						
RAI4 -070 5	F01	IN, IC, GL, DP, CC	폭력 조 장 위험 콘텐츠	Violence- inciting dangerous content	폭력적·선 동적·급진 화·위협적 콘텐츠의 제작 과 접 근이 용이 해지고 자 해나 불법 활동의 수 행을 권장 하는 콘텐 츠가 산출 되며, 증오 ·비하·고 정관념 콘 텐츠에 대 한 대중의 노출을 통	The risk of eased production of and access to violent, inciting, radicalizing, or threatening content and recomme ndations to carry out self- harm or conduct	기존 risk 정의 보완 흡수_ 타인 대상 폭력 선동 에 더 해 자 해·불 법행위 위 권 장과 폭력 적 콘 텐츠	타인을 향 한 폭력 행위를 유 도, 권장 또는 촉진 하는 행위 (린치 선 동, 자경 단 폭력 조장 등) 자해나 불 법행위를 권장하거 나 폭력적 ·위협적 콘텐츠의 생성 및 접근을 용	Acts that incite, encourage, or promote violence toward others (e.g., lynching incitement, vigilante violence promotion) . Acts that encourage self-				

					제 하기 어 려워지는 리스크	illegal activities, including difficulty controllin g public exposure to hateful, disparagi ng, or stereotypi ng content.	확산 위험 까지 커버 하도 록 범 위가 확장 됩니 다.		이하계 하 는 행위	harm or illegal activities, or facilitate the creation of and access to violent or threatenin g content.			
RAI4-0854	F01	IN, IC, GL, DP, CC	되돌릴 수 없는 변화	Irrever sible chang e	사회 구조, 문화적 규 범, 인간관 계에 되돌 리기 어렵 거나 불가 능한 심각 한 장기적 부정적 변 화가 발생 하는 리스 크	The risk of profound negative long-term changes to social structure s, cultural norms, and human relationsh ips that may be difficult or impossibl e to reverse.	삭제_사 회 구조 장기 변 화라는 거시적 리 스크로 응 답 단위 판 정 불가						
RAI4-1049	F01	IN, IC, GL, DP, CC	조직 재 정·평판 손상	Organi zationa l financi al and reputat ional damag e	ML 시스 템을 구축 하거나 사 용하는 조 직의 재 정 적 및/또는 평판 손상 위험.	The risk of financial and/or reputatio nal damage to the organizati on building or using the ML system.	매핑 부 적합_기 업 재 무/평 판 리 스크						
RAI4-1447	F01	IN, IC, GL, DP, CC	폭력/무 력 충돌	Violen ce/arm ed conflic t	기술 시스 템을 사용 하거나 오 용하여 사 이버 공격,	The risk that use or misuse of a technolog	wea poni zatio n반 영						

					보안 침해, 치명적 생화학 무기 개발을 선동·촉진·수행함으로써 폭력과 무력 충돌이 초래되는 리스크.	y system to incite, facilitate, or conduct cyberattacks, security breaches, and lethal biological and chemical weapons development results in violence and armed conflict.							
RAI4-0641	F01	IN, IC, GL, DP, CC	비합의 성적 대상화 및 성적 이미지 생성	Non-consensual sexualization and intimate imagery generation	기술이나 애플리케이션이 개인 또는 집단을 동의 없이 성적으로 대상화하고, 실존 인물의 외모를 이용한 노골적 성적 자료를 생성하는 리스크. 피해자는 성적 수치심과 평판 훼손, 괴롭힘을 겪으며 해당 자료의 유포로 심리적 피해가 지속된다.	The risk that a technology or application sexualizes an individual or group without consent, including by generating sexually explicit material from a real person's likeness. Victims suffer sexual humiliation, reputational damage, and harassment.	기존 리스크 정의 보완 흡수		노골적인 성적 콘텐츠를 제작, 생성, 공유, 배포하거나, 동의 없는 성적 이미지·영상의 생성, 조작, 유포 또는 악용을 포함한 디지털 성범죄와 관련된 내용 (음란물 제작, 성인물 생성, 불법 촬영, 리벤지 포르노, 딥페이크 성범죄, 성적 영상물 유포) 또한 집단을 동의 없이 성적으로 대상화하	Content related to digital sexual crimes, including the production, creation, sharing, or distribution of explicit sexual content, as well as the creation, manipulation, dissemination, or exploitation of sexual images or videos without consent (e.g.,			동의 없는 성적 이미지·영상 범위를 유지하면서, 성적 대상화와 실존인물 외모·초

						nt, and the continued circulation of the material perpetuates psychological harm.			거나, 실존 인물의 외모·초상을 이용해 노골적인 성적 자료를 생성하는 행위를 포함합니다.	production of pornography, creation of adult content, illegal filming, revenge pornography, deepfake sexual crimes, distribution of sexual videos). Also includes sexualizing an individual or group without consent, or generating explicit sexual material using a real person's likeness or appearance.			상기 반성적 자료 생성까지 커버하도록 확장됩니다.
RAI4-0714	F01	IN, IC, GL, DP, CC	아동·청소년 유해 콘텐츠 제공	Provision of content harmful to children and youth	LLM이 아동과 청소년에게 유해한 콘텐츠를 담은 답변을 산출하도록 유도될 수 있는 리스크	The risk that LLMs are leveraged to solicit answers that contain content harmful to children and youth.	기존 risk 정의 보완		미성년자를 대상으로 한 성적 행위, 착취, 유인, 확대 또는 관련 콘텐츠(아동 성착취물, 그루밍, 미성년자 성관계 조장)	Sexual acts, exploitation, enticement, abuse, or related content involving minors (child sexual exploitation			아동·청소년 대상 성적 위험 범위는

									material, grooming, promotion of sexual relations with minors)			유지되며, 일반적인 아동 유해 콘텐츠는 추가 커버하지 않습니다.
RAI4-0718	F01	IN, IC, GL, DP, CC	외설·비하·학대 이미지 생성 및 접근 용이화	Eased production of and access to abusive imagery	해를 끼칠 수 있는 외설적·굴욕적·모욕적 이미지, 특히 합성 아동 성적 학대 자료(CSAM)와 성인의 비동의 친밀 이미지(NCII)의 제작과 접근이 용이해지는 리스크	The risk that production of and access to obscene, degrading, or abusive imagery which can cause harm is eased, including synthetic child sexual abuse material (CSAM) and nonconsensual intimate images	기존 risk 정의 보완 흡수		노골적인 성적 콘텐츠를 제작, 생성, 공유, 배포하거나, 동의 없는 성적 이미지·영상의 생성, 조작, 유포 또는 악용을 포함한 디지털 성범죄와 관련된 내용(음란물 제작, 성인물 생성, 불법 촬영, 리벤지 포르노, 딥페이크 성범죄, 성적 영상물 유포) 외설	Content related to digital sexual crimes, including the production, creation, sharing, or distribution of explicit sexual content, as well as the creation, manipulation, or exploitation of sexual		CSAM·NCII와 함께 외설적·굴욕적·모욕적 이미지의 제작 및 접근 용이

							(NCII) of adults.			적·굴욕적·모욕적 이미지를 제작하거나 접근 가능하게 하는 행위, 특히 합성 아동 성적 학대 자료 (CSAM) 와 성인의 비동의 친밀 이미지 (NCII)의 생성·유포·악용을 포함	images or videos without consent (e.g., production of pornography, creation of adult content, illegal filming, revenge pornography, deepfake sexual crimes, distribution of sexual videos). Including the production or facilitation of access to obscene, degrading, or abusive imagery, especially the creation, dissemination, or exploitation of synthetic child sexual abuse material (CSAM) and nonconsensual intimate images			화리스크까지 포함하도록 범위가 소폭 확장됩니다.
--	--	--	--	--	--	--	-------------------	--	--	--	---	--	--	----------------------------

										(NCII) of adults.			
RAI4-1136	F01	IN, IC, GL, DP, CC	유해·범죄 조장·기만적 콘텐츠의 대규모 생성	Scaled generation of harmful, criminal, and deceptive content	적절한 안전·보안 장치 없이 AI 시스템이 폭력·성·비폭력 범죄를 가능하게 하거나 조장하는 응답, 아동 성착취물, 자살·자해 조장 콘텐츠, 비합의 성적 이미지, 명예를 훼손하는 허위 사실, 사기성 웹사이트, 진본과 구별되지 않는 딥페이크를 생성하고, 도구 사용과 계획 역량이 이러한 제작을 더 빠르고 저렴하며 개인화된 형태로 확대하는 리스크. 그 결과 개인은 착취·괴롭힘·협박과 명예 훼손의 표적이 되고 도구에 접근하기 어려우며, 범죄 실행이 조력되고 진본 커뮤니케이션에 대한 신뢰가 무너진다.	The risk that, absent proper safety and security mechanisms, AI systems generate content that enables or endorses violent, sexual, and nonviolent crimes, child sexual abuse material, suicide and self-harm, non-consensual intimate imagery, defamation, falsehoods, fraudulent websites, and deepfakes indistinguishable from authentic media, while tool use and planning	삭제 _Violence /Sexual/Illegal /Self-Harm 등 기존 카테고리의 총합적 재서울, 별도 신설 불필요						

						let threat actors produce it faster, more cheaply, and with greater personalization and reach. Individuals are targeted for exploitation, harassment, extortion, and reputational destruction with little prospect of redress, criminal conduct is facilitated, and trust in authentic communication collapses.						
RAI4-1542	F01	IN, IC, GL, DP, CC	외부 도구 연동을 통한 유해 콘텐츠 유입	Ingestion of harmful content through external tool integration	외부 도구·플러그인과의 통합과 상호 연결이 확대됨에 따라 악의적 외부 입력에 노출되어 유해 콘텐츠가 시스템에 유입	The risk that growing integration and interconnectivity with external tools and plugins exposes a system	매핑 부적합_도구연동 아키텍처 취약점으로 Agentic AI 레					

					되는 리스크.	to malicious external inputs that introduce harmful content.	드티 밍 영 역 _Net work Effec ts'(A genti c AI) 참고 가능						
RAI4-0023	F01	IN, IC, GL, DP, CC	AI 시스템에 의한 자해 조장	Self-harm facilitation by AI systems	시스템이 행동 지향적 지원·계획·자원의 제공을 통해서든 사용 과정을 통해 서든 사람이 자신의 신체를 고의로 손상하거나 타인에게 위해를 가할 가능성을 높이는 리스크.	The risk that a system, whether by providing action-oriented support, planning, or resources or through the dynamics of its use, increases the likelihood that a person deliberately damages their own body or harms others.	기존 risk 정의 보완 흡수		자해 또는 자살을 수행하기 위한 도구, 수단, 기술 또는 절차 제공 : 도구 추천, 방법 비교, 실행 절차 자해를 돕기 위한 행동 지향적 지원, 계획 수립 또는 자원 제공을 포함하며, 시스템 사용 과정에서 자해를 유도하거나 가능성을 높이는 경우를 포함한다.	Provision of tools, means, techniques, or procedures for self-harm or suicide: tool recommendations, method comparisons, execution procedures Includes action-oriented support, planning, or provision of resources to facilitate self-harm, as well as cases where the system's use dynamics encourage or increase the likelihood			자 해 수 단 제 공 중 심 범 위 에 더 해, 자 해 를 촉 진 하 는 지 원· 계 획· 자 원 제 공 과 사 용 맥 락 의 유 도 효 과 까 지 커 버

										of self-harm.			하도록 확장됩니다.
RAI4-0157	F01	IN, IC, GL, DP, CC	챗봇을 통한 자해 격려	Self-harm encouragement by chatbot	챗봇이 자해 사고나 행동을 강화하거나 정상화하거나 중단시키지 못하는 리스크.	The risk that a chatbot reinforces, normalizes, or fails to interrupt self-harm ideation or behavior.	기존 risk 정의 보완 흡수		자해 또는 자살을 긍정적·합리적·영웅적 행위로 묘사하거나 옹호하는 내용(자살 찬양, 자해 권장, 자해 정상화) 또한 챗봇이 자해 사고나 행동을 강화·정상화하거나 이를 적절히 중단시키지 못하는 내용.	Content that depicts or advocates self-harm or suicide as positive, rational, or heroic acts (e.g., glorification of suicide, encouragement of self-harm, normalization of self-harm). Also includes content where a chatbot reinforces or normalizes self-harm ideation or behavior, or fails to appropriately interrupt it.			자해·자살의 미화·정당화뿐 아니라 챗봇의 강화·정상화·개입 실패까지 포함하도록 커버리지가 확장됩니다.
RAI4-083	F01	IN, IC,	이용자의 정신·	Content	모델이 자살을 조장	The risk that a	기존 risk		거식증, 폭식증 또	Content that			섭식

3		GL, DP, CC	신체 건강을 위협하는 콘텐츠	endangering users' mental and physical health	하거나 공황·불안을 유발하는 응답, 오도성 의료 정보와 부적절한 약물 사용 지침 등 건강에 안전하지 않은 콘텐츠를 생성하는 리스크. 취약한 이용자는 이러한 응답에 따라 행동하여 자신이나 타인에게 신체적·정신적 위험을 가하게 된다.	model generates unsafe health-related content, whether responses that encourage suicide or induce panic and anxiety or misleading medical information and inappropriate guidance on drug use. Vulnerable users act on such content and inflict physical and psychological harm on themselves or others.	정의 보완 흡수		는 신체를 해치는 자기파괴적 행동을 조장·지원하는 내용 (극단적 단식, 프로아나 (Pro-ana), 체중 감량 강박) 자살을 조장하거나 공황·불안을 유발하는 내용, 오도성 의료 정보나 부적절한 약물 사용 지침처럼 정신적·신체적 건강을 해치는 콘텐츠	promotes or supports self-destructive behaviors that harm the body, such as anorexia, bulimia, or extreme fasting, including pro-ana (pro-anorexia) and obsessive weight loss. Content that encourages suicide, induces panic or anxiety, or provides misleading medical information or inappropriate drug-use guidance that harms mental or physical health.			장애 중심의 신체 훼손 리스크에서 자살·정신 건강 악화의 의료/약물 오남용까지 포함하는 건강 위험해 리스크로 범위가 확장됩니다.
RAI4-041	F04	IC, GL,	언어별 피해 과	Language-	평가 범위가 취약한	The risk that toxic,	Hate and						

1		DP	소탐지	specific harm under-detection	언어와 방언에서 유해·모욕적·비안전 콘텐츠가 덜 안정적으로 탐지되는 리스크.	disrespectful, or unsafe content is less reliably detected in languages and dialects with weaker evaluation coverage.	unfairness 관점이 다름						
RAI4-0426			혐오발언 생성	Hate speech generation	생성 시스템이 특정 정체성 집단을 표적으로 하는 혐오적·모욕적 콘텐츠를 산출하는 리스크.	The risk that generative systems produce hateful or abusive content targeting identity groups.	기존 대체 가능						
RAI4-0706			보호 속성 기반 부당 대우	Protected-attributed unfair treatment	인종, 민족, 연령, 성별, 성적 지향, 종교, 출신 국가, 혼인 여부, 장애, 언어 등 보호 속성을 근거로 개인이 불공정하거나 부적절한 대우 또는 자의적 차별을 받는 리스크	The risk of unfair or inadequate treatment or arbitrary distinction based on a person's race, ethnicity, age, gender, sexual preference, religion, national origin, marital status, disability,	기존 대체 가능						

						language, or other protected groups.							
RAI4-0368	F04	IC, GL, DP	도덕적 다양성 압축	Moral diversity compression	다양한 도덕적 입장이 모델 친화적인 소수 범주나 평균 선호로 압축되는 리스크.	The risk that diverse moral positions are compressed into a small set of model-friendly categories or average preferences.	Hate and unfairness 관점이 다름						
RAI4-0403	F04	IC, GL, DP	도덕적 프레임 편향	Moral framing bias	프롬프트·응답·평가의 구성 방식이 이용자를 논쟁적 사안에 대한 특정한 도덕적 해석으로 유도하는 리스크.	The risk that the framing of prompts, responses, or evaluations channels users toward a particular moral interpretation of a contested issue.	Hate and unfairness 관점이 다름					이 행의 리스크 카드를 제거할 것	
RAI4-0422	F04	IC, GL, DP	도덕적 세계관 배제	Moral-worldview exclusion	종교적·영적·토착적·비세속적 도덕 세계관이 모델 행동과 평가 기준에서 배제되는 리스크.	The risk that religious, spiritual, indigenous, or non-secular moral worldviews are excluded from model	보완_Political_Neutrality L3 신규 L4로 '도덕/종교적 세계관 배					이 행의 리스크 카드를 제거할 것	

						behavior and evaluation standards .	제' 추가 권장. (Human 의 Anth ropo morph hism 재배 치 의 견에 는 이 견 - 정치 적/종 교적 중립 성 취 지에 더 부 합)						
RAI4-0529	F04	IC, GL, DP	시스템 사용·오 용에 따 른 정치·경제 불 안정	Political and economic destabilization from system misuse	기술 시스템의 사용 또는 오용 이 직간접 적으 로 정 치적 불안 과 양극화, 금융 시스템의 통제 되지 않는 변동, 이용 자·개발자·배포자에 대한 신뢰 상실을 초 래하고, 불 평등·일자 리 상실·기술 과의존 이 사회를 이러한 체계적 실패 에 더 욱 취약하게 만드는 리 스크.	The risk that the use or misuse of a technology system directly or indirectly causes political unrest and polarization, uncontrolled fluctuations in the financial system, and loss of confidence or trust in users, developers, and deployers , while	Labo r Displ acement (노동 대체)						

						inequality, job losses, and overdependence leave societies increasingly vulnerable to such systemic failures.							
RAI4-0939	F04	IC, GL, DP	모델의 극단적·편향적 견해 표출	Expression of extremist and politically biased views	대형 모델이 정치적 주제에서 부적절하거나 극단 주의적인 견해를 표출하고, 중립을 표방하면서도 특정 정치 성향의 편향을 드러내는 리스크.	The risk that large models express inappropriate or extremist views on political topics and, while claiming neutrality, exhibit notable political biases across policy domains.	기존 risk 정의 보완 흡수						
RAI4-1158	F04	IC, GL, DP	대규모 설득 능력	Large-scale persuasion capability	모델이 대화와 미디어 환경에서 효과적으로 설득하여 허위 방향으로도 신념을 변화시키고 특정 서사를 유포하며 기존 판단이나 윤리에 반하는 행동을 유도하는 리스크	Models persuade effectively in dialogue and media settings, shifting beliefs including toward falsehoods, promoting narratives, and	기존 risk 정의 보완 흡수						

						convincing people to act against their prior judgment or ethics.							
RAI4-1159	F04	IC, GL, DP	정치적 영향력 전략 역량	Political influence strategy capability	모델이 행위자가 정치적 영향력을 획득하고 행사하는 데 필요한 사회적 모델링과 계획을, 다수 행위자와 풍부한 사회적 맥락이 있는 시나리오에서까지 수행하는 리스크.	The risk that a model performs the social modelling and planning necessary for an actor to gain and exercise political influence, not just at a micro level but in scenarios with multiple actors and rich social context.	L3변경 _Overall-Confidence						
RAI4-0433	F04	IN, IC, GL, DP, CC	생체인식 식별·추적에 의한 프라이버시 침해	Biometric identification and tracking privacy harms	얼굴·음성·보행 등 생체인식 AI 시스템이 침해적인 식별과 추적을 가능하게 하고, 어떤 생체 정보가 얼마나 오래 누구의 소유로 저장되고 누가 접근할 수 있는지에 관한 문제가 해결되지 않은 채 남아 프라	The risk that face, voice, gait, and other biometric AI systems enable intrusive identification and tracking, while unresolved questions about what biometric	기존 risk 정의 보완 흡수						

					이버시 침해가 가중되는 리스크.	data are stored, for how long, under whose ownership, and with what access compounded the privacy harm.							
RAI4-0652	F04	IN, IC, GL, DP, CC	개인화 정보 악용 표적 사기	Targeted fraud exploiting personalized information	생성 모델이 개인화된 정보를 이용해 개별 사용자를 효율적으로 표적화하는 데 오용되어, 피해자의 신뢰를 악용한 설득력 높은 자동화 사기로 민감 정보가 탈취되고 기만의 성공 가능성이 높아지는 리스크	The risk that generative models are misused to target individual users more efficiently using personalized information, producing highly convincing automated fraudulent schemes that exploit victims' trust and extract sensitive data.	신규						
RAI4-0734	F04	IN, IC, GL, DP, CC	기밀정보 무단 공유에 따른 사업 손실	Business loss from unauthorised sharing of	기업 전략, 재무 계획 등 민감·기밀 정보와 문서가 제3자와 무단으로 공	The risk that sensitive, confidential information and	신규						

				confidential information	유되어 시장 지위나 수익을 상실하는 리스크	documents such as corporate strategy and financial plans are shared with third parties without authorization, risking loss of market position or revenue.							
RAI4-0739	F04	IN, IC, GL, DP, CC	산출물을 통한 민감 개인·사업 정보 노출	Exposure of sensitive personal and business information through outputs	AI 시스템이 개인이나 조직이 감추어 두기를 기대하는 민감 정보를 드러내는 리스크로, 산출물에 부주의하게 포함시키는 경우뿐만 아니라 검열·삭제된 내용을 재구성하거나 사적 속성·선호·의도를 추론해 노출하는 경우를 포함한다. 그 결과 당사자는 지극히 사적인 정보와 영업비밀 등 보호 대상 정보에 대한 통제권을 상실한다.	The risk that AI systems reveal sensitive information that individuals or organizations expect to remain concealed, whether by inadvertently including it in outputs or by reconstructing redacted content and exposing inferred attributes, preferences, and intentions	기존 risk 정의 보완 흡수						

						. Those affected lose control over deeply private information and protected material such as trade secrets.							
RAI4-0741	F04	IN, IC, GL, DP, CC	개인정보 보호 조치 미흡	Inadequate personal-data protection	결함 있는 데이터 저장·처리 관행이 수집된 개인정보를 유출과 부적절한 접근으로부터 보호하지 못하는 리스크	The risk that faulty data storage and handling practices fail to protect collected personal data from leaks and improper access.	기존 risk 정의 보완 흡수						
RAI4-0761	F04	IN, IC, GL, DP, CC	익명화된 데이터의 재식별	Re-identification of anonymized data	데이터에서 개인식별정보 (PII)와 민감 개인정보 (SPI)를 제거하더라도 데이터에 남아 있는 다른 특성과의 상관관계로 인해 개인이 재식별되는 리스크	The risk that, even with the removal of personally identifiable information (PII) and sensitive personal information (SPI) from data, persons can be identified due to correlations to	신규						

						other features available in the data.							
RAI4-0922	F04	IN, IC, GL, DP, CC	학습 코퍼스 내 개인정보 혼입	Private data contamination of training corpora	웹 수집 데이터와 인간-기계 대화 데이터의 통합 과정에서 이름·이메일·주소 등 개인식별 정보(PII)가 학습 코퍼스에 혼입되어 오용되는 리스크.	The risk that personally identifiable information such as names, emails, and addresses is mixed into training corpora through web-collected data and humanmachine conversations, enabling misuse.	신규						
RAI4-1062	F04	IN, IC, GL, DP, CC	챗봇에 의한 사적 정보 유도와 유출	Elicitation and disclosure of private information by chatbots	인간을 닮은 대화형 에이전트가 이용자로 하여금 의견과 감정 등 평소에는 얻기 어려운 사적 정보를 털어놓게 하고, 민감하거나 기밀인 정보를 출력에 공개하는 리스크. 이렇게 수집된 정보는 프라이버시권을 침해하거나	The risk that human-like conversational agents lead users to reveal opinions, emotions, and other private information that would otherwise be difficult to obtain, and that	기존 risk 정의 보완 흡수						

					중독 성 애 플리케이 션 추천처 럼 이용자 에게 해가 되는 후속 응용에 활 용된다.	sensitive or confidenti al material appears in the chatbot's own output. The informatio n gathered supports downstre am uses that violate privacy rights or exploit users, such as more effective recomme ndation of addictive applicatio ns.									
RAI4 -113 9	F04	IN, IC, GL, DP, CC	비서 유 도 개인 정보 노 출	Assista nt- induce d privac y disclos ure	비서가 사 용자로 하 여금 자신 이나 타인 의 개 인정 보를 공개 하도록 유 도해 신원 도용과 낙 인·차별을 초래하고, 국가 소유 비서가 조 작이 나 기 만으로 감 시 목적의 사적 정보 를 추출하 는 리스크.	The risk that assistants influence users to disclose personal informatio n or private informatio n pertaining to others, resulting in identity theft, stigmatis ation and discrimin ation, and that	기존 risk 정의 보완 흡수								

						state-owned assistants employ manipulation or deception to extract private information for surveillance.							
RAI4-1169	F04	IN, IC, GL, DP, CC	프라이버시·재산 정보 오처리	Privacy and property information mishandling	생성물이 사용자의 프라이버시와 재산 정보를 노출하거나 결혼과 투자처럼 영향이 큰 조언을 제공하여, 관련 법과 프라이버시 규정을 지키지 못한 채 정보 유출과 오남용을 초래하는 리스크.	The risk that generation exposes users' privacy and property information or provides advice with huge impacts, such as suggestions on marriage and investments, failing to comply with relevant laws and privacy regulations and causing information leakage and abuse.	기존 risk 정의 보완 흡수						

RAI4-1207	F04	IN, IC, GL, DP, CC	개인정보 스크래핑 학습	Personal-data scrapping for training	기업이 개인정보를 스크래핑해 생성 AI 도구를 만들면서 소비자가 동의하지 않은 목적으로 정보를 사용하고, 흩어져 있던 데이터를 결합해 추론에 쓰며 개인이 정보를 수정하거나 삭제할 능력을 박탈하여 데이터 통제권을 약화시키는 리스크.	The risk that companies scrape personal information to create generative AI tools, undermining consumers' control of their data by using it for purposes they did not consent to, combining data sets in revealing ways, and taking away the ability to alter or remove the information.	기존 risk 정의 보완 흡수						
RAI4-1273	F04	IN, IC, GL, DP, CC	광범위한 개인 정보 투입	Pervasive personal-data ingestion	위치와 개인 정보, 이동 궤적을 포함한 사용자 데이터가 대부분의 데이터 기반 기계학습 방법의 입력으로 사용되는 리스크.	The risk that users' data, including location, personal information, and navigation trajectory, is considered as input	기존 risk 정의 보완 흡수						

						for most data-driven machine learning methods.							
RAI4-1364	F04	IN, IC, GL, DP, CC	보호장치 없는 개인정보 수집	Personal information collection without safeguards	웹 스크래핑으로 수집된 학습 데이터셋과 하루 미세조정용 사내 데이터에 개인 데이터와 개인식별정보가 보호장치 없이 포함되는 리스크.	The risk that training datasets gathered through online web scraping and in-house data used for downstream fine-tuning incorporate personal data and personally identifiable information without safeguards.	기존 risk 정의 보완 흡수						
RAI4-1444	F04	IN, IC, GL, DP, CC	사생활·개인정보 부당 노출	Unwarranted exposure of private life and personal data	사이버 공격이나 신상 털기 등을 통해 개인의 사생활이나 개인 데이터가 부당하게 노출되는 리스크.	The risk of unwarranted exposure of an individual's private life or personal data through cyberattacks, doxxing, and similar means.	기존 risk 정의 보완 흡수						

RAI4-1581	F04	IN, IC, GL, DP, CC	위장 계정 자동 운영에 의한 정보 환경 조작	Information-environment manipulation through automated sockpuppet accounts	허구의 온라인 정체성 계정이 자동으로 생성·운영되어 후원 주체가 은폐되고 독립적 지지가 가장되며 정보 환경이 조작되는 리스크.	The risk that fictitious online identities are automatically generated or operated to conceal sponsors hip, simulate independent support, or manipulate information environments.	삭제_플랫폼 차원의 대규모 여론 조작/봇넷 운영 리스크로 개별 상담 응답 평가와 결이 다름 (GPT 동의)						
RAI4-1722	F04	IN, IC, GL, DP, CC	존엄 침해적 프라이버시 피해	Dignity - eroding privacy harms	개인 데이터가 원치 않게 공개되거나 추론되는 등 인간의 자율성·정체성·존엄을 보호하는 규범과 관행이 지켜지지 않아 피해가 발생하는 리스크.	The risk that failure to safeguard the norms and practices protecting human autonomy, identity, and dignity, including unwanted disclosure or inference of personal data, results in harm.	기존 risk 정의 보완 흡수						
RAI4-0653	F01	IN, IC, GL,	LLM 남용에 의한 학업	Academic miscon	LLM 시스템의 부적절한 사용	The risk that improper	보완_Illegal_o						

		DP, CC	부정행위	duct from LLM misuse	과 남용이 학업 부정 행위와 같은 부정적 사회적 영향을 초래하는 리스크	use or abuse of LLM systems causes adverse social impacts such as academic misconduct.	r_Unethical L3 신규 L4로 '학업 부정 행위 조력' 추가 가능하나 매우 직접적이라 우선순위가 낮음						
RAI4-1059	F01	IN, IC, GL, DP, CC	사기·표적 스캠 조장	Fraud and targeted-scam facilitation	LM이 범죄의 효과성을 높이는 데 이용될 수 있는 리스크.	The risk that LMs are potentially used to increase the effectiveness of crimes.	기존 risk 정의 보완 흡수						
RAI4-1060	F01	IN, IC, GL, DP, CC	불법적 대중 감시·검열	Illegitimate mass surveillance and censorship	LM이 대중 감시의 비용을 낮추고 효과를 높여 감시 수행 행위자의 역량을 증폭시키고, 불법적 검열 등 피해와 프라이버시권·민주적 가치 침해를 초래하는 리스크.	The risk that LMs reduce the cost and increase the efficacy of mass surveillance, amplifying the capabilities of actors who conduct it, including for illegitimate censorship	관점 확장						

						p or other harm, and raising concerns about privacy rights and democratic values.							
RAI4-1076	F01	IN, IC, GL, DP, CC	비윤리적 행위에 의한 유해 행동 유도	Endorsement of unethical conduct inducing harmful user action	모델의 산출물이 관련 윤리 원칙과 도덕 규범, 널리 인정되는 인간 가치에서 벗어나 부도덕하거나 불법적인 행동을 지지하고 조장하는 리스크. 모델을 권위로 신봉하는 이 용자는 이에 자극받아 그렇지 않았다면 하지 않았을 유해한 행동을 하게 된다.	The risk that model outputs endorse and promote immoral, unethical, or illegal conduct at odds with pertinent ethical principles, moral norms, and widely acknowledged human values. Users who trust the system as an authority are thereby motivated to take harmful actions they would not otherwise have performed.	관점 확장						
RAI4-119	F01	IN, IC,	자동화된 선전	Automated	악의적 이 용자가 연	The risk that	삭제 _Misi						

2		GL, DP, CC	과 대규모 영향 공작	propaganda and scaled influence operations	어모델로 인간이 작성한 것만큼 설득력 있는 기사와 가짜뉴스를 저비용·대규모로 생성하여 선전을 선제적으로 유포하고 자동화된 영향 공작과 악성 소셜 봇넷을 가동하는 리스크. 선전의 진입 장벽이 크게 낮아지고 표적 청중의 관점이 조작된다.	malicious users leverage language models to craft deceptive narratives and fabricate d news as persuasive as human-written material at low cost and large scale, powering automated influence operations and malicious social botnets. The barrier to conducting propaganda falls sharply and the perspectives of targeted audiences are manipulated.	nformation/Dissinformation(taxonomy_0727, 사실성)에 이미 포섭되는 개념. Illegal L3 신규보다 그쪽 측 참가향 (Human 의견 동의)						
RAI4-1320	F01	IN, IC, GL, DP, CC	인간 기만 능력	Human - deception capability	LLM이 인간을 속이고 그 기만을 지속적으로 유지할 수 있는 리스크.	The risk that an LLM is able to deceive humans and maintain that	관점 확장						

						deception							
RAI4-1435	F01	IN, IC, GL, DP, CC	시장점유 목적의 비윤리적 기술 사용	Unethical technology use for market share	시장 점유율 확보를 위해 기술이 부적절하거나 비윤리적으로 사용되는 리스크.	The risk that technology is used inappropriately or unethically to gain market share.	삭제_ 기업 전략 차원 리스크로 지나치게 추상적이며 사업전략 영역, 응답 판정과 무관 (GPT의 신규L4 의견에 반대)						
RAI4-1652	F01	IN, IC, GL, DP, CC	사이버·과학 영역에서의 LLM 이중용도 역량 악용	Misuse of dual-use LLM capabilities in cyber and scientific domains	악의적 행위자가 LLM의 이중용도 역량을 악용하는 리스크로, 하드웨어·소프트웨어·데이터의 취약점을 탐지·악용하고 시스템 내부에서 탐지를 회피하는 사이버 역량과 악의적 실험 수행을 위한 단계별 지침을 제공하는 과학적 역량이 여기에 포함된다. 정당한 목적으	The risk that malicious actors misuse the dual-use capabilities of large language models, including cyber capabilities to detect and exploit vulnerabilities in hardware, software, and data while evading detection	기존 risk 정의 보완 흡수						

					로 개발된 역량이 그 대로 가해 의 수단으 로 전환 되 어 실질적 피해가 발 생한다.	inside a system or network, and scientific capabiliti es such as step- by-step instructio ns for conductin g malicious experime nts. Capabiliti es develope d for legitimate purposes are thereby converted directly into instrumen ts of harm.								
RAI4-0628	F04	IN, IC, GL, DP, CC	지식재 산권 및 인격권 침해	Infringement of intellectual property and personality rights	AI 시스템이 저작권·상표·특허로 보호되는 성과물을 무단으로 이용하거나 남용하고, 개인의 이름·이미지·초상 등 신원 표지를 허락없이 상업적으로 사용하는 리스크. 권리는 창작물과 자신의 정체성이 이용되는 방식과 그 경제적	The risk that AI systems misuse works protected by copyright, trademark, or patent and appropriate an individual's name, image, or likeness for commercial purposes without	기존 risk 정의 보완 흡수							

					가치에 대한 통제권을 상실하고 사후 구제에 의존하게 된다.	authorization. Rights holders lose control over the use and economic value of their creations and identity and are left to seek redress after the fact.							
RAI4-0663	F04	IN, IC, GL, DP, CC	무단 표절 및 부정행위	Plagiarism and cheating without acknowledgment	타인이나 집단의 표현과 아이디어가 동의 또는 출처 표시 없이 사용되는 리스크	The risk that another person's or group's words or ideas are used without consent or acknowledgement.	기존 대체						
RAI4-0667	F04	IN, IC, GL, DP, CC	위조 및 브랜드 사칭	Counterfeiting and brand impersonation	원저작물, 브랜드, 스타일이 복제 또는 모방되어 진품인 것처럼 통용되는 리스크	The risk that an original work, brand, or style is reproduced or imitated and passed off as real.	보완 _Copyrights L3 신규 L4로 '브랜드/상표 사칭' 추가 - 기존 저작권 침해보다 넓은 브랜드도						

							용까지 포괄 (Human/GPT 의견 동의)						
RAI4-0740	F04	IN, IC, GL, DP, CC	프롬프트 내 지식재산 정보 포함	Intellectual property included in prompts	저작권이 있는 정보나 기타 지식재산이 모델에 전송되는 프롬프트의 일부로 포함되는 리스크	The risk that copyrighted information or other intellectual property is included as part of the prompt that is sent to the model.	신규						
RAI4-1066	F04	IN, IC, GL, DP, CC	합성 창작물에 의한 인간 창작 노동의 대체	Displacement of human creative work by synthetic substitutes	모델이 저작권을 직접 침해하지 않으면서도 예술가의 아이디어를 자본화한 콘텐츠를 생성하여 시장과 주목에서 인간의 원작을 대체할 만한 대체물이 되는 리스크. 그 결과 창작 경제의 수익성이 훼손되고 인간의 창작과 혁신에 대한 유인이 약화된다.	The risk that models generate content which, without strictly infringing copyright, capitalizes on artists' ideas and serves as a credible substitute for human creations in markets and attention. Creative economies lose	관점 확장	이미지 노동					

						profitability and the incentive for human creativity and innovation is weakened.							
RAI4-1091	F04	IN, IC, GL, DP, CC	도용 및 착취	Misappropriation and exploitation	소수 집단을 포함한 주체의 콘텐츠·데이터가 동이나 공정한 보상 없이, 또는 몰이해하게 전유·사용·재생산되는 리스크	Content or data, including from minority groups, is appropriated, used, or reproduced insensitively, without consent, or without fair compensation.	부적합						
RAI4-0446	F04	IN, IC, GL, DP, CC	화생방 핵 (CBRN) 계획 지원	CBRN assistance	고급 모델이 유해한 화학·생물·방사능·핵 계획 수립을 지원하는 리스크.	The risk that advanced models assist harmful chemical, biological, radiological, or nuclear planning.	기존 정의 보완 흡수						
RAI4-0646	F04	IN, IC, GL, DP, CC	국가·범죄 행위자에 의한 AI의 의도적 무기화	Deliberate weaponization of AI by state and crimin	국가, 범죄조직, 테러 세력이 전쟁·내전·법집행 과정에서 자율 표적 선정, 감시, 물리적 살상	The risk that states, criminal organizations, or terrorists deliberately build	신규						

				al actors	등 파괴적 목적으로 AI를 의도적으로 개발·배치하는 리스크. 이러한 무기화는 무력 사용에 대한 인간의 제약을 제거하여 직접적인 명 피해와 사회적 규모의 피해를 낳는다.	and deploy AI for destructive purposes, including autonomous targeting, surveillance, and kinetic attack in war, civil conflict, or law enforcement. Such weaponization removes human restraint from the use of force and produces casualties and societal-scale harm.							
RAI4-0662	F04	IN, IC, GL, DP, CC	CBRN 정보·설계 역량 접근 용이화	Eased access to CBRN weapon information and design capability	화학·생물·방사능·핵 무기나 기타 위험 물질 및 작용제와 관련된 악용 가능한 정보와 설계 역량에 대한 접근이나 합성이 용이해지는 리스크	The risk of eased access to or synthesis of materially nefarious information or design capabilities related to chemical, biological, radiological, or nuclear	신규						

						weapons or other dangerous materials or agents.							
RAI4-0664	F04	IN, IC, GL, DP, CC	화학무기 합성 및 유해 물질 방출 조력	Chemical weapon synthesis and hazardous substance release	화학 작용제가 화학 무기 합성에 이용되고 자율 화학 실험 과정에서 유해 물질이 생성·방출되며, 성질이 알려지지 않은 나노물질 등 첨단 소재 사용으로 예측 불가능한 화학적 위험이 발생하는 리스크	The risk that agents are exploited to synthesize chemical weapons, that hazardous substances are created or released during autonomous chemical experiments, and that advanced materials such as nanomaterials with unknown or unpredictable chemical properties cause harm.	기존 risk 정의 보완 흡수						
RAI4-0961	F04	IN, IC, GL, DP, CC	인간 개입 없는 치명적 자율무기의 표적 공격	Lethal autonomous weapons engaging targets without	AI 기반 치명적 자율 무기체계가 센서 배열과 알고리즘으로 표적을 탐지·선정하고, 작동	The risk that AI-driven lethal autonomous weapon systems use	신규						

				t human interve ntion	과 정에 대 한 직접적 인 인간 개 입 없이 의 도적으 로 인간을 살 상하는 리 스크. 무력 사용의 판 단 이 인간 의 손을 떠 나 표적 선 정 오류를 사망 이전 에 중단시 킬 수 없게 된다.	sensor arrays and algorithm s to detect and select targets and intentiona lly kill people without direct human interventi on in their operation. The judgment behind the use of lethal force passes out of human hands, and targeting errors cannot be interrupte d before they cause death.							
RAI4 -1118	F04	IN, IC, GL, DP, CC	군사 AI 군비경 쟁	Militar y AI arms race	군사용 AI 개발이 화 약과 핵무 기에 필적 하는 결과 를 낳는 새 로운 군사 기술 시대, 이른바 전 쟁의 제3 차 혁명을 열어 군비 경쟁을 촉 발하는 리 스크.	The risk that developin g AI for military applicatio ns paves the way for a new era in military technolog y, described as the	신규						

						third revolution in warfare, with potential consequences rivaling gunpowder and nuclear arms.							
RAI4-1160	F04	IN, IC, GL, DP, CC	무기 획득 역량	Weapons acquisition capability	모델이 기존 무기 체계에 접근하거나 새로운 무기 제작에 기여하여, 생물무기를 조립하거나 그 실행 가능한 지침을 제공하고 신무기를 여는 과학적 발견을 돕는 리스크.	The risk that a model gains access to existing weapons systems or contributes to building new weapons, assembling a bioweapon or providing actionable instructions for doing so, and significantly assisting scientific discoveries that unlock novel weapons.	기존 risk 정의 보완 흡수						
RAI4-1295	F04	IN, IC, GL, DP, CC	AI 가속 나노기술에 의한 독성 나노입	Uncontrolled toxic-nanoparticle production	AI가 나노봇 개발의 핵심 구성요소로서 나노 수준에서 물질	The risk that AI, a key component for the developm	신규 L4						

			자 통제 상실	tion from AI-accelerated nanotechnology	을 눈에 보이지 않게 변형하고, 독성이 있고 치명적일 수 있는 나노입자를 만드는데 화학반응을 일으켜 위험한 환경 영향을 낳는 리스크.	ent of nanobots, produces dangerous environmental implications by invisibly modifying substances at nanoscale, for example starting chemical reactions that create invisible nanoparticles that are toxic and potentially lethal.							
RAI4-1392	F04	IN, IC, GL, DP, CC	생물·화학 무기 개발 장비의 저하	Lowered barriers to biological and chemical weapons development	범용 AI 모델과 AI 기반 생물·화학 설계 도구 병행 체와 독소 제조에 대한 단계별 기술 지침을 제공하고 강화된 백질 설계와 유해성 후보 분석을 수행하여 핵심 지식과 자동화된 지원에 대한 접근을 넓히는 리스크. 그 결과 전문성이 낮은 행위자에게도 제	The risk that general-purpose models and AI-based biological and chemical design tools generate step-by-step technical instructions for pathogens and toxins, engineer enhanced proteins, and	기존 리스크 정의 보완 흡수						

					작 장벽이 낮아 지고 정교한 행위자의 역할은 확장되어, 질병과 사망을 초래하는 작용제의 고의적 살포가 가능해진다.	screen for the most harmful candidates, widening access to critical knowledge and automated assistance. Barriers to production fall for less expert actors while the capabilities of sophisticated ones expand, enabling the deliberate release of agents that cause disease and death.								
RAI4-1563	F04	IN, IC, GL, DP, CC	AI 오용에 의한 CBRN 무기 개발 역량 상승	CBRN weapon development uplift through AI misuse	AI의 이중용도 역량이 국가와 비국가 행위자의 화학·생물·방사능·핵·폭발성 무기 설계와 합성, 획득, 배치에 필요한 기술적 문턱을 크게 낮추고, 무인	The risk that the dual-use capabilities of AI substantially lower the technical thresholds for state and non-state actors to design,	기존 risk 정의 보완 흡수							

					무기체계에 자율 역할을 부여해 기존 무기를 증강하며 그 파괴력을 증폭시키는 리스크. 그 결과 비전문가도 공격을 수행할 수 있고 정교한 행위자의 공격은 더욱 효과적이 되어 다수의 인명이 위협받고 비확산 체제가 훼손된다.	synthesize, acquire, and deploy chemical, biological, radiological, nuclear, and explosive weapons, augment existing weapons by granting autonomy to unmanned systems, and amplify their destructive effect. Attacks become feasible for non-experts and more effective for sophisticated actors, endangering large populations and undermining non-proliferation regimes.							
RAI4-1050	F04	DP, GL	심리적 조작·비인간화	Psychological manipulation	ML 시스템이 심리적 조작, 비인간화,	The risk that ML systems produce	삭제_대규모 착취/조						

			대규모 착취	ulation, dehumanization, and exploitation	대규모 인간 착취 등의 추가적인 윤리적 피해를 야기하는 리스크.	further ethical harms such as psychological manipulation, dehumanization, and exploitation of humans at scale.	작은 Agenic AI 시스템 리스크 축의 성격이며 응답 단위 무해성과 결이 다름 (Human 의견 동의)						
RAI4-1434	F04	DP, GL	비인간화와 객관화	Dehumanisation and objectification	기술 시스템을 사용하거나 오용하여 사람을 인간이 아닌 것, 인간 이하인 것 또는 사물로 묘사하거나 대우하는 리스크.	The risk that a technology system is used or misused to depict and/or treat people as not human, less than human, or as objects.	보완 _Antihomomorphism L3 신규 L4로 '비인간화·객관화' 추가 타당. 기존 정의 (AI가 인간 처럼 행동)의 반대 방향(AI가 인간을 사물 처럼 대우)도 포괄 필요						

RAI4-1636	F04	DP, GL	마음이론 (Theory of Mind) 능력	Theory of mind capability	시스템이 인간과 타 에이전트의 신념, 동기, 추론을 추정·예측하는 마음이론 역할을 목표 달성을 위한 행동 예측·유도에 활용하는 리스크	A system infers and predicts the beliefs, motivations, and reasoning of humans and other agents, and exploits this theory-of-mind capability to anticipate and steer their behavior for goal achievement.	Multi-agent risk						
RAI4-0140			개인화된 설득 취약성	Personalized persuasion vulnerability	모델이 개인의 특성, 감정, 맥락을 활용하여 설득을 더 효과적이고 탐지하기 어렵게 만드는 리스크.	The risk that models exploit personal traits, emotions, or context to make persuasion more effective and less detectable.							
RAI4-0435			데이터 오염 공격	Data poisoning	공격자가 학습·미세조정·검색 데이터를 조작하여 모델 동작을 변경하는 리스크.	The risk that attackers manipulate training, fine-tuning, or retrieval data to alter							

						model behavior.							
RAI4-0436			모델 추출·역전 공격	Model extraction and inversion attacks	적대적 행위자가 배포된 모델에 무단으로 질의·탐침하여 매개변수, 의사결정 동작, 독점 역량을 재구성하고, 질의와 응답으로 대체 모델을 학습시키거나 모델 역전으로 학습 관측 데이터를 복원함으로써, 지식 재산과 민감한 데이터가 노출되는 리스크.	The risk that adversaries query or probe a deployed model without authorization to reconstruct its parameters, decision behavior, or proprietary capabilities, including by training substitute models on query responses or inverting the model to recover training observations, exposing intellectual property and sensitive data.							
RAI4-0593			학습 데이터 암기에 의한 민감 정보 유출	Leakage of sensitive training data through	사전학습·미세조정 말뚝치에 흔히 당사자의 동의 없이 포함된 개인·독	The risk that models memorize personal, proprietary, or							

				h memor ization	점·민감 정보 모델이 암기하고, 우발적 생성, 맥락적 프롬프트, 프라이버시 공격, 정보 간 연계와 삼각 추론을 통해 이를 출력으로 노출하여, 프라이버시 침해와 당사자에 대한 피해를 야기하는 리스크.	sensitive information contained, often without consent, in pretraining or fine-tuning corpora and reveal it in generated outputs, whether accidentally, through contextual prompts, through privacy attacks, or by associating and triangulating pieces of information to infer secrets, causing privacy violations and harm to the individuals concerned.								
RAI4-0619			은밀한 행동 조작	Covert behavioral manipulation	기술 시스템이 넋지, 다크 패턴, 기타 불투명한 기법으로 이용자의 신념과 행동을 은밀히 변	The risk that a technology system covertly alters user beliefs and								

					경하여 프라이버시 침식, 중독, 불안과 고통 등을 초래하는 리스크	behaviour using nudging, dark patterns, or other opaque techniques, resulting in potential erosion of privacy, addiction, anxiety, and distress.						
RAI4-0721			유해·오염 학습 데이터에 의한 출력 훼손	Output corruption from harmful and poisoned training data	학습 데이터에 허위·편파·권리 침해 콘텐츠 등 불법적이거나 유해한 정보가 포함되거나 공격자에 의해 오염됨으로써, 모델이 불법·악의적·극단적 콘텐츠를 출력하고 정확성과 신뢰성이 저하되는 리스크	The risk that training data containing illegal or harmful information such as false, biased, or IPR-infringing content, or poisoned through tampering and error injection by attackers, causes the model to output harmful content and degrades its accuracy and reliability.						

RAI4-0733			학습 데이터 내 기밀정보 포함과 출력 노출	Confidential information in training data disclosed through outputs	기밀정보가 학습·튜닝 데이터나 프롬프트의 일부로 포함된 뒤 생성 출력에서 그대로 재현되는 리스크. 이러한 유출은 보호되어야 할 영업 정보와 개인정보를 관한 없는 이에게 노출 시키고 비밀유지의무를 위반한다.	The risk that confidential information is incorporated into training data, tuning data, or prompts and is subsequently reproduced in generated outputs. Such leakage exposes protected business and personal information to unauthorized parties and breaches confidentiality obligations.						
RAI4-0753			학습 데이터 추출 공격	Training data extraction attack	공격자가 모델로부터 학습 데이터셋에 존재 하는 텍스트 기록을 추출해 내는 리스크	The risk that an attacker extracts the text records that exist in the training dataset.						
RAI4-0760			프롬프트 및 학습 데이터에 기	Personal data exposure	학습·미세 조정 데이터나 프롬프트에 포	The risk that personal and						

			인한 개인 정보 노출	through prompt and training data	함된 개인 정보와 기밀정보가 모델을 통해 공개되는 리스크로, 개인 정보를 담은 프롬프트가 학습 과정에서 기억된 유사한 정보를 이끌어내는 경우를 포함한다. 다른 목적으로 수집된 데이터의 당사자는 비인가 공개와 오용에 노출된다.	confidential data contained in training, fine-tuning, or prompt inputs is disclosed through model outputs, including when a prompt primed with personal information elicits similar records memorized during training. Individuals whose data was collected for another purpose are thereby exposed to unauthorized disclosure and misuse.								
RAI4-0788			인스트럭션 튜닝 포이즈닝	Instruction-tuning poisoning	명령과 목표 출력 쌍으로 모델을 조정하는 인스트럭션 튜닝 단계에서 적은 수의 오염 표본만으로 모델이 오염	The risk that AI models are poisoned during instruction tuning with pairs of instructio								

					될 수 있고, 익명 크라우드 소싱으로 수집된 데이터셋이 이를 조장하며 기존 데이터 오염 공격보다 탐지가 어려운 리스크 ns and desired outputs, where a lower number of compromised samples suffices, anonymous crowdsourcing of tuning datasets further contributes, and detection is harder than for traditional data poisoning attacks.							
RAI4-1173			역할극 지시 악용	Role-play instruction exploitation	공격자가 입력 프롬프트에서 과격주 의자나 인종차별주의자 처럼 위험한 집단과 연관된 역할 속성을 부여하고 지시를 내려, 지시에 지나치게 충실한 모델이 그 인물의 말투로 안전하지 않은 콘텐츠를 산출하는 리스크.	The risk that attackers specify a model's role attribute within the input prompt, tying it to potentially risky groups such as radicals or racial discriminators, so that the overly faithful model outputs unsafe content in						

						the style of that character.							
RAI4-1494			오픈웨이트 모델 미세조정	Harmful fine-tuning of open-weight models	가중치가 공개된 모델이 원래 훈련 비용에 비해 훨씬 적은 시간과 비용으로 악의적 행위자에 의해 유해한 활동으로 미세조정되는 리스크.	The risk that models with publicly available weights are fine-tuned for harmful activities by bad actors using significantly fewer resources, in time and money, than the original training cost.							
RAI4-1508			가이드라인 오염	Guideline contamination	데이터셋의 수집·주석·사용에 관한 지침이 모델에 노출되고 그 지침에 포함된 명시적 데이터-레이블 쌍이 해당 과업에 대한 모델의 역량을 향상시키는 리스크.	The risk that instructions for the collection, annotation, or use of a dataset are exposed to the model, with explicit data-label pairs contained in those instructions improving the model's capabilities							

						es for the task.							
RAI4-1564			약물 발견 모델 오용에 의한 독소 식별·개발	Dangerous toxin identification through misuse of drug-discovery models	약물-표적 친화성 예측 등 약물 발견에 쓰이는 모델이 위험한 독소를 식별하거나 개발하는데 사용되며, 훈련 데이터에 위험 단백질·바이러스 정보가 포함될 경우 우려가 커지는 리스크.	The risk that models used for drug discovery, such as drug-target affinity predictors, are used to identify or develop dangerous toxins, a concern heightened when training data includes information on hazardous proteins and viruses.							
RAI4-1687			월드모델 표현·훈련 데이터 오염	World-model representation and training data poisoning	월드모델의 훈련 데이터나 잠재 표현이 적대적으로 손상되어 특정 조건에서만 안전하지 않은 역학을 활성화하는 백도어 트리거가 삽입되며, 자기지도 사전학습 단계에서 부호화된 결함은 다운스트림에서 교	The risk of adversarial corruption of world-model training data or latent representations, including backdoor triggers that activate unsafe dynamics only							

					정될 수 없는 리스크.	under specific conditions, where defects encoded in self-supervised pretraining (the "Foundry Problem") cannot be remediated downstream.							
RAI4-0356			배터리 화재 및 유해 폐기물 위험	Battery fire and hazardous end-of-life waste	대규모 피지컬 AI 군집에서 에너지 시스템과 폐기 절차가 제대로 관리되지 않아 배터리 열폭주·유해 물질 누출·부적절한 폐기가 증가하는 리스크.	The risk that large physical AI fleets increase battery thermal-runaway, hazardous-material leakage, and unsafe disposal when energy systems and endof-life handling are inadequately controlled.						L3 영문 수정: Energy Consumption and Environmental > Energy Consumption and Environmental Impact	
RAI4-0360			산업 공정 피해	Industrial processes damage	제조·건설·광업·에너지 시설의 피지컬 AI가 잘 못된 제어로 장비 손상·공정 오염·구조 불안정 또는 환경	Physical AI in manufacturing, construction, mining, or energy facilities may							

					사고를 유발하는 위험.	damage equipment, contaminate processes, or trigger cascading operational failures.						
RAI4-0502			AI로 인한 인명·재산·환경 직접 피해	Direct harms from AI to people, property, and environment	AI 시스템의 개발·운영·사용·오작동이 신체적·심리적 상해, 금전적 손실과 재산 피해, 중요 인프라의 중단·손상, 동물 등 비인간 존재에 대한 피해, 하드웨어 수명주기 전반의 자연환경 오염·자원 고갈에 이르는 실제 피해를 발생 시키는 리스크. 의 인화와 과신, 조작 등 인간AI 상호작용에서 창발하는 피해도 시스템 실패·오용과 함께 이러한 피해에 기여한다.	The risk that the development, operation, use, or malfunction of AI systems produces realized harm, injuring people physically or psychologically, causing financial loss and property damage, disrupting critical infrastructure, harming animals and other non-human entities, and polluting or depleting the natural environm						

					ent across the hardware lifecycle. Harmful human-AI configura tions, from anthropo morphizat ion and over-trust to manipulat ion, contribut e to these harms alongside system failure and misuse.							
RAI4 -050 4			에너지 병목 및 공급 부 족	Energy bottlen ecks and shorta ges	과도한 에 너지 사용 이 지역사 회·조직·기 업에 에너 지 병목과 공급 부족 을 초래하 는 리스크.	The risk that excessive energy use results in energy bottlenec ks and shortages for communit ies, organisati ons, and business es.						
RAI4 -079 8			생태계 과부하	Overb urdeni ng ecosys tems	AI 개입이 없을 것으 로 기대되 는 창작물 공모·채용 지원 등 생 태계에 AI 생성물이 대량 유입 되어 필터 링·신뢰 메	Mass AI- generate d submissio ns pollute ecosyste ms expected to be free of AI involvem						

					커니즘에 과부하를 일으키는 리스크.	ent, such as creative submission portals and job application channels, overburdening their filtering and trust mechanisms.							
RAI4-0799			공유 정보 생태계의 오염과 질 저하	Degradation of the shared information ecosystem	생성 도구가 산출한 허위·환각·저품질 콘텐츠와 인물·사건에 대한 사실적 허위 묘사가 최초 이용자를 넘어 유포되어 공개적으로 이용 가능한 정보가 오염되는 리스크. 사람들은 그에 근거해 부정확한 인식과 결정에 이르고, 나아가 정확한 정보에 대한 신뢰마저 잃는다.	The risk that false, hallucinated, lowquality, or realistically fabricated depictions of people and events produced by generative tools circulate beyond the end user and contaminate publicly available information. People form inaccurate perceptions and decisions on that basis and							

						lose trust even in accurate information.							
RAI4-0926			에너지·자연 오버헤드 공격	Energy - latency overhead attacks	정교하게 설계된 스펀지 예제로 AI 시스템의 에너지 소비를 극대화하는 오버헤드(에너지 자연) 공격이 LLM 연동 플랫폼을 위협하는 리스크.	The risk that overhead, or energy-latency, attacks using carefully crafted sponge examples maximize energy consumption in an AI system, threatening platforms integrated with LLMs.							
RAI4-0950			지속불가능한 자원 사용	Unsustainable resource use	생성 모델의 막대한 전력·냉각수·희귀금속 하 드웨어 수요가 지속불가능한 방식의 자원 채굴과 사용을 유발하여 환경 피해를 초래하는 리스크.	The risk that generative models' substantial demands for electricity, cooling water, and rare-metal hardware drive resource extraction and utilization in unsustainable ways, causing							

					environm ental harm.							
RAI4-0996			원자재 수요에 의한 자원 고갈	Resource depletion from raw material demand	이러한 장치의 생산 공정이 니켈·코발트·리튬 등 원자재를 대량으로 요구하여 지구가 머지않아 충분한 양을 공급하지 못하게 되는 리스크.	The risk that the production process of these devices requires raw materials such as nickel, cobalt, and lithium in quantities the Earth may soon no longer be able to sustain.						
RAI4-1015			광범위한 사회·환경적 부정 영향	Broad societal and environmental adverse impacts	AI가 노동력 대체, 정신건강 악화, 딥페이크 등 조작 기술 문제와 함께 자원 부담·학습 탄소 배출 등 환경 발자국을 통해 사회와 환경에 광범위한 부정적 영향을 미치는 리스크.	The risk that AI produces broad adverse effects on society and the environment, including labor displacement, mental health impacts, harms from manipulative technologies like deepfakes, and an environmental footprint of resource						

					strain and training-related carbon emissions								
RAI4-1064			언어모델 학습·운영에 따른 환경 피해	Environmental harm from training and operating language models	대규모 언어모델의 학습·운영 에너지 수요와 탄소 배출, 데이터센터 냉각용 담수 소비, 데이터센터와 칩·기기 제작에 필요한 귀금속 등 자원 소모, 그리고 관련 애플리케이션의 2차 배출과 그것이 유발하는 행동 변화가 상당한 환경 비용을 발생시키는 리스크. 그 부담은 자원 고갈과 오염의 형태로 생태계와 지역사회에 전가된다.	The risk that the energy demand and carbon emissions of training and operating large language models, the freshwater consumed to cool data centres, the metals and materials required to build facilities, chips, and devices, and the secondary emissions and behavioural changes driven by model-based applications impose substantial							

RAI4-1269			높은 에너지 소비	High energy consumption	딥러닝을 포함한 일부 학습 알고리즘이 반복 학습 과정을 사용하여 높은 에너지 소비를 초래하는 리스크.	The risk that some learning algorithms, including deep learning, utilize iterative learning processes that result in high energy consumption.						
RAI4-1374			데이터 센터 냉각을 위한 용수 소비	Water consumption for data centre cooling	AI 학습과 추론을 지원하는 데이터 센터가 서버 과열을 막기 위해 상당한 양의 물을 냉각에 사용하는 리스크. 그 수요가 지역 수자원을 잠식하여 인근 지역사회와 기업에 용수 제한이 나 부족이 초래된다.	The risk that data centres supporting AI training and inference consume substantial water to cool servers and prevent overheating. That demand draws down local water resources, leading to restrictions or shortages for nearby communities and businesses.			Water consumption for data centre cooling ② L3 mappingYesNo			

RAI4-1452			생물다양성 손실	Biodiversity loss	기술 인프라의 과도한 확장이나 기술과 지속 가능한 관행의 부적절한 연계로 삼림 벌채, 서식지 파괴, 생물다양성의 단편화와 손실이 발생하는 리스크.	The risk that over-expansion of technology infrastructure, or inadequate alignment of technology with sustainable practices, leads to deforestation, habitat destruction, and fragmentation and loss of biodiversity.						
RAI4-1453			탄소 배출	Carbon emissions	이산화탄소, 산화질소 등의 가스가 배출되어 탄소 배출이 증가하고 기후변화가 악화되어 지역사회에 부정적 영향이 발생하는 리스크.	The risk that release of carbon dioxide, nitric oxide, and other gases increases carbon emissions , exacerbates climate change, and negatively impacts local communities.						

RAI4-1455			전자폐기물 과다 매립	Excessive electronic waste landfill	전기·전자 장비의 과도한 폐기로 생태계와 생물다양성이 훼손되고 지역사회의 생계가 교란되며 권리가 침해되는 리스크.	The risk that excessive disposal of electrical or electronic equipment leads to ecological and biodiversity damage, disrupts the livelihoods of local communities, and erodes their rights.							
RAI4-1698			단일 목표 최적화에 의한 환경 부작용	Environmental side effects from single objective optimization	하나의 과업에 집중된 목표를 최적화하는 데 이전 트가 다른 환경 변수에 대해 암묵적 무관심을 보여, 한계적 과업 이득을 위해 더 넓은 환경에 큰 교란을 일으키는 리스크.	The risk that an agent optimizing an objective focused on one task expresses implicit indifference over other environmental variables, causing major disruption to the wider environment for marginal task gain.							
RAI4-034	F04	IN, IC,	센서 스푸핑 및	Sensor spoofi	공격자가 GNSS·카	Attackers may	매핑 부적						

6		GL, DP, CC	신호 주입	ng and signal injection	메라·라이다·레이더·RFID·오디오·촉각·무선 신호를 조작하여 피지컬 행동을 변경하는 위험.	manipulate GNSS, camera, LiDAR, radar, RFID, audio, tactile, or wireless signals to alter physical behavior.	합 _Physical AI 'Sensor & Input Validation Failures						
RAI4-0432	F04	IN, IC, GL, DP, CC	민감 개인속성 추론	Sensitive personal attribute inference	모델 동작으로 인해 사용자 또는 관리자가 의도적으로 공개되지 않은 민감한 개인의 속성 정보가 추론을 통해서 노출될 수 있는 리스크	The risk that model behavior enables inference of sensitive personal attributes not intentionally disclosed.	기존 risk 정의 보완 흡수						
RAI4-1056	F04	IN, IC, GL, DP, CC	보호 속성 추론을 통한 프라이버시 침해	Privacy violation through inference of protected personal attributes	학습 코퍼스에 해당 개인의 데이터가 없더라도 모델이 입력 프롬프트로부터 인종·성별·성적지향·종교성 등 보호 속성을 높은 정확도로 추론하는 리스크로 사용자 본인 또는 당사자의 인지나 동의 없이 진실하고 민감한 정보로 구성된 상세 프로필이 작	The risk that models infer protected characteristics such as race, gender, sexual orientation, or religiousness from a user's input prompt even when that information is absent from the training corpus.	기존 risk 정의 보완 흡수						

					성되어 차별과 표적 화에 노출 될 수 있는 위험	Detailed profiles of true and sensitive information are assembled without the individual's knowledge or consent, exposing them to discrimination and targeting.							
RAI4-1655	F04	IN, IC, GL, DP, CC	LLM 기반 정교한 감시·검열에 의한 자유 억압	Suppression of liberties through LLM-enabled surveillance and censorship	LLM과 음성인식·멀티모달 기술이 텍스트뿐 아니라 통화·영상 통신까지 대규모로 감시·검열할 수 있게 하여, 정치적 반대자의 침묵 또는 개인의 자유 위축 등과 같은 국가적 억압의 용도로 이용되거나, 기술에 의해 보다 더 영향이 심각하게 발전되는 위험	The risk that LLMs, including multimodal models and those combined with speech-to-text, enable significantly more sophisticated surveillance and censorship operations at scale, including of phone calls and video messages, worsening personal liberties and	관점 확장						

[illegible]

RAI4-1232			산업 교란	Disruption of industries	창의성과 비판적 사고, 정서적 상호작용이 덜 요구되는 번역과 교정, 단순 문의 응대, 데이터 처리 같은 산업이 생성형 AI에 의해 심각하게 영향을 받거나 AI시스템으로 대체되어서 경제적 혼란과 일자리 변동이 극심하게 발생하는 리스크.	The risk that industries requiring less creativity, critical thinking, and personal or affective interaction, such as translation, proofreading, responding to straightforward inquiries, and data processing, are significantly impacted or even replaced by generative AI, leading to economic turbulence and job volatility.					기존 리스크 작성톤으로 L4 description 수정	
RAI4-1445			불평등과 기술적 충격에 따른 사회 불안정	Societal destabilisation from inequality and technological disruption	AI 기술로 인한 일자리 부족과 불공정한 알고리즘, 허위정보, 그리고 AI 시스템이 유발하거나 증폭된 사회적 지위 및 부의 격차의 확	The risk that job losses to technology, unfair algorithmic outcomes, disinformation, and the widening					기존 리스크 작성톤으로 L4 description 수정	

					대가 지역 사회의 복지와 결속을 훼손하는 리스크. 이러한 리스크로 인한 파업과 시위를 비롯한 시민 불안이 확산되고, 사회 전반의 안정이 흔들릴 수 있는 위험	gaps in social status and wealth caused or amplified by technology systems erode social and community wellbeing and cohesion. Strikes, demonstrations, and other forms of civil unrest follow as overall societal stability deteriorates.						
RAI4-1662			아웃소싱 축소에 의한 개발도상국 경제 타격	Harm to developing economies from retrenchment of outsourcing	콜센터 등 개발도상국이 수행하던 단순 인지 과업이 AI 시스템으로 자동화되면서 아웃소싱이 축소되어 해당 국가의 노동력과 경제가 타격을 입는 리스크	The risk that automation of simple cognitive tasks previously performed in developing countries, such as call center work, causes a retrenchment of outsourcing					기존 리스크 작성톤으로 L4 description 수정	

						ng that adversely affects those countries' workforces and economies.						
RAI4-0384			남반구 지식 추출	Global South knowledge extraction	남반구 공동체의 지식, 언어 데이터, 문화 자원이 적절한 인정·통제·이익 공유없이 AI 개발에 추출되는 글로벌 사우스 지식 추출 리스크	The risk that knowledge, language data, or cultural resources from Global South communities are extracted for AI development without adequate recognition, control, or benefit-sharing.						기존 리스크 작성 톤으로 L4 description 수정
RAI4-0458			AI 관련 임금 양극화	AI-related wage polarization	AI 시스템의 도입이 AI로 인한 보완적 숙련의 보상은 높이는 반면, 대체 가능한 숙련의 가치를 현격히 떨어뜨림으로써 노동시장의 임금 양극화를 확대하는 리스크	AI adoption raises returns to skills complementary to AI while devaluing substitutable skills, widening wage polarization across the workforce.						기존 리스크 작성 톤으로 L4 description 수정

RAI4-0461			연산 자원 접근 불평등	Compute inequality	연산 인프라에 대한 불평등한 접근으로 인해 AI 시스템을 개발·감사·활용할 수 있는 주체를 결정하는 연산 자원 접근 불평등 리스크	The risk that unequal access to compute infrastructure shapes who can develop, audit, or benefit from AI.					기존 리스크 작성 톤으로 L4 description 수정	
RAI4-0505			AI 개발 과정의 노동 착취	Labor exploitation in AI development	데이터 라벨링, 콘텐츠 조정, 데이터 소싱, 사용자 테스트 등 AI 시스템의 학습, 개발, 최적화 과정에 투입되는 노동이 저소득 국가와 역외 노동자에게 외주화된 채 저임금과 열악한 노동 조건, 신체·정신 건강 보호의 결여 속에서 착취적 관행과 불평등이 지속되는 리스크	The risk that the labor used to train, develop, and optimize AI systems, including data labeling, moderation, sourcing, and user testing outsourced to low-income countries and offshore workers, is underpaid and denied adequate working conditions and physical and mental health protections, perpetuat					기존 리스크 작성 톤으로 L4 description 수정	

					ing exploitati ve practices and inequality .							
RAI4 -050 9			글로벌 AI 격차 와 불평 등	Global AI divide and inequal ity	희소한 연 산 자원, 과학기술 인재, 첨단 범용 모델 에 대한 실 질적 접근 이 소수 선 도 국가와 대형 기업 에 집중되 어 AI 연구 개발과 경 제력이 편 중되고, 선 도국과 후 발국 간 격 차가 벌어 지며 기업· 개인·국가 간 기존의 사회경제 적 불 평등 이 심화되 는 리스크.	The risk that scarce computin g power, STEM talent, and effective access to advanced general- purpose models concentra te AI research, developm ent, and economic power in a few leading countries and large firms, widening the divide between those leading in AI and those falling behind and deepenin g existing socioeco nomic disparitie s among companie s, individual					기존 리스 크 작성 톤으로 L4 descripti on 수정	

					s, and countries.							
RAI4-1011			노동 착취와 거시경제적 불평등 심화	Labor exploitation and macro-economic inequality	AI 시스템이 사회경제적 관계의 권력 불균형을 키워 디지털 격차와 체계적 불평등을 고착시키고, 비윤리적 데이터 수집·노동환경 악화 등 노동 착취와 기술적 실업·탈속련을 낳으며, 대규모 실패시 플래시 크래시 등 광범위한 악영향을 초래하는 노동 착취와 거시적 불평등을 심화시키는 리스크	The risk that algorithmic systems increase power imbalances in socio-economic relations, exacerbating digital divides and entrenching systemic inequalities, fostering labor exploitation such as unethical data collection and worsening worker conditions, driving technological unemployment and deskilling, and causing flash crashes and other widespread adverse incidents when algorithmic financial					기존 리스크 작성 톤으로 L4 descripti on 수정	

						systems fail at scale.							
RAI4-1022			높은 비용으로 인한 접근 배제	Exclusion from access due to high costs	생성형 AI 시스템의 훈련·시험·배포에 드는 재 정적 비용이 커서 이러한 시스템을 개발하고 이용할 수 있는 집단이 제한되는 리스크.	The risk that the estimated financial costs of training, testing, and deploying generative AI systems restrict the groups of people able to afford developing and interacting with these systems.						기존 리스크 작성 톤으로 L4 descripti on 수정	
RAI4-1224			디지털 격차 확대	Widening digital divide	생성 AI가 기기나 인터넷 접근이 없거나 벤더에 차단된 지역의 사람들에게 1차 디지털 격차를, 언어와 문화 장벽에 부딪히거나 도구 활용이 어려운 이들에게 2차 디지털 격차를 확대하는 리스크.	The risk that generative AI widens the first-level digital divide for those without access to devices or the Internet or blocked by vendors, and the second-level divide for those facing language						기존 리스크 작성 톤으로 L4 descripti on 수정	

						and cultural barriers or finding the tools difficult to use.						
RAI4-1233			사회경제적 불평등 증폭과 AI 이익의 집중	Amplified socioeconomic inequality and concentration of AI gains	편향된 시스템과 집단 간 성격차, 불평등한 접근이 고용·교육·금융·공공 서비스에서 겹쳐 작용하고, 증강보다 자동화를 지향하는 도입이 노동의 가치를 낮추는 한편 막대한 자본과 데이터·연산 자원이 소수 기업과 부유한 국가에 집중되는 리스크. 그 결과 주변화된 집단과 개발도상국은 더욱 뒤처지고, 저임금·무보수 노동이 착취되며, 독점이 형성되어 사회적 결속과 형평이 훼손된다.	The risk that biased systems, disparate performance, and unequal access compounded across employment, education, financial, and public services, while automation-oriented adoption devalues labour and the capital, data, and compute required to build models concentrate resources in a few firms and wealthier countries. Marginalized groups and developing					기존 리스크 작성 톤으로 L4 description 수정	

					economies fall further behind, precarious and unpaid work is exploited, monopolies form, and social cohesion and equity erode.							
RAI4-1404			데이터 노동 저평가·비가시화	Under valued and invisible data labor	ML 학습 데이터를 생산하는 클릭워커의 노동이 노동자 권리를 경시하는 산업 관행 속에 수행되고 그 기여가 비가시화되어 노동자의 복지와 권리가 침해되고 AI 역량에 대한 오해가 조장되는 리스크.	The risk that the clickwork producing ML training data is performed in an annotation industry with little concern for workers' rights, and that the invisibility of this contribution harms worker welfare and rights while fostering misunderstanding of AI capabilities.						기존 리스크 작성 톤으로 L4 description 수정
RAI4-1661			자본편중·시장 집중·접근 격차	Worsening inequality	LLM 기반 경제에서 자본의 몫이 커지고	The risk that the role and compens						기존 리스크 작성 톤으로 L4

			에 의한 불평등 심화	from capital shift, market concentration, and access gaps	노동의 몫이 줄며, 막대한 훈련 고정비용과 네트워크 효과가 소수 공급자의 시장 지배력과 지대 추출을 낳고, 재정·교육·기업 정책·지정학적 이유로 접근이 배제된 개인이 불리해져 사회경제적 불평등이 심화되는 리스크.	ation of capital rise while those of labor decline in an LLM-powered economy, that large fixed training costs and network effects concentrate the market and let providers extract monopoly rents, and that individuals without access for financial, educational, corporate-policy, or geopolitical reasons fall further behind, worsening socioeconomic inequality.					descripti on 수정	
RAI4-0086			규제 차이거래	Regulatory arbitrage	AI 개발자나 배포자가 더 강한 감독 의무를 회피하기 위해 관할권·부문·조직 형태	The risk that AI developers or deployers structure activities across			AI 개발자나 배포자가 더 강한 감독 의무를 회피하기 위해 관할권·부문·조		기존 리스크 작성 톤으로 L4 descripti on 수정	

					를 전략적으로 선택하거나 재구성하는 리스크.	jurisdiction, sectors, or organizational forms to avoid stronger oversight obligations.			직 형태를 전략적으로 선택하거나 재구성하는 리스크.			
RAI4-0383			AI를 매개로 한 디지털 식민주의	AI-mediated digital colonialism	AI 시스템이 데이터, 인프라, 지식, 의사결정에 대한 비대칭적 통제를 강대 행위자로부터 약소 공동체로 확장하여 식민주의적 추출·종속 구조를 재생산하는 리스크	AI systems extend asymmetric control over data, infrastructure, knowledge, and decision-making from powerful actors to less powerful communities, reproducing colonial patterns of extraction and dependency.					기존 리스크 작성 톤으로 L4 description 수정	
RAI4-0415			문화 해석 권위의 이전	Redistribution of cultural authority	AI 시스템이 문화 해석에 대한 권위를 공동체와 전문가로부터 모델 제공자나 플랫폼 중개자로 이전시키는 리스크.	The risk that AI systems shift authority over cultural interpretation from communities and experts to model					기존 리스크 작성 톤으로 L4 description 수정	

					providers or platform intermediaries.							
RAI4-0460			AI 권력·시장 지배력의 집중	Concentration of AI power and market control	AI에 요구되는 데이터, 연산, 자본, 전문성이 소수의 기업과 국가에 경제·인식적·정치적 권력을 집중시켜 시장 지배력과 진입장벽을 고착화하는 리스크. 이러한 집중은 경쟁과 혁신을 저해하고 접근 비용을 높이며, 공유된 단일 모델의 결함에 중요 부문을 노출시키고, 권 위주의적 통제의 고착과 불평등 심화로까지 이어질 수 있다.	The risk that the data, compute, capital, and expertise demands of AI concentrate economic , epistemic , and political power in a small set of firms and states, entrenching market dominance and barriers to entry. Such concentration stifles competition and innovation, raises the cost of access, exposes critical sectors to systemic failure from shared models, and can consolida					기존 리스크 작성 톤으로 L4 descripti on 수정	

					te authority to the point of entrenchi ng authoritar ian control and deepenin g inequality .							
RAI4-0491			알고리즘 획일화	Algorithmic monoculture	특정 AI 모델의 지배가 접근 방식의 다양성을 축소하여 해당 모델이 실패할 경우 시스템적 위험이 증폭되는 리스크.	The risk that dominance of specific AI models reduces diversity of approaches, amplifying systemic risks if those models fail.					기존 리스크 작성 톤으로 L4 descripti on 수정	
RAI4-0499			AI 공급자 종속	AI provider lock-in dependency	특정 AI 제공자에 대한 과도한 의존이 대안 부재나 상호운용성 결여로 인한 취약성을 초래하는 리스크.	The risk that excessive reliance on specific AI providers leads to vulnerabilities due to lack of alternatives or interoperability.					기존 리스크 작성 톤으로 L4 descripti on 수정	
RAI4-0510			AI 역량 비대칭에 따른	Power asymmetries	AI 역량의 비대칭이 의사결정·	The risk that asymmetr					기존 리스크 작성 톤으로 L4	

			권력 불 균형과 지정학 적 긴장	and geopol itical tensio n from AI capabil ity	감시의 대 상이 되는 개인과 기 관 사이에 서든 AI 우 위를 다투 는 국가 사 이에서든 권력 불균 형을 심화 시켜, 지정 학적 긴장 을 고조시 키고 역량 이 부족한 국가를 핵 심 기능에 서 외국 AI 에 의존하 게 만들며 국제 협력 체계를 불 안정하게 하는 리스 크.	ic AI capability intensifie s power imbalanc es, whether between institution s and the individual s subject to their decisions and surveillan ce or between states racing for AI superiorit y, heighteni ng geopolitic al tension, rendering less capable states dependen t on foreign AI for critical functions, and destabilizi ng internatio nal cooperati on.						descripti on 수정	
RAI4 -054 4			승자독 식 역학	Winner -take- all dynam ics	AI 개발의 승자독식 동학이 결 정적인 경 제·안 보 우위를 소 수 주체에 집중시켜 경쟁과 균	Winner- take-all dynamics in AI developm ent concentra te decisive						기존 리스 크 작성 톤으로 L4 descripti on 수정	

					형 적 거버 넌스를 봉 쇄하는 리 스크	economic and security advantag es in a few entities, foreclosin g competiti on and balanced governan ce.						
RAI4 -056 8			데이터 수집 제 한	Data acquisi tion restrict ions	데이터 수 집에 대한 법적 제한 이 특정 AI 활용 에 필 요한 데이 터 확보를 제약하여 컴플라이 언스 리스 크와 우회 유인을 발 생시키는 리스 크	Legal restriction s on data acquisitio n constrain the collection of data needed for specific AI use cases, creating complian ce risk and incentive s for circumve ntion.					기존 리스 크 작성 톤으로 L4 descripti on 수정	
RAI4 -073 1			공통 AI 플랫폼 집중에 따른 단 일 장애 점	Central ized points of failure from comm on AI platfor ms	공통 AI 플 랫폼이 광 범위하게 사용되면 서 중 앙 집중식 장 애점이 형 성되어 시 스템이 중 단 이나 공 격에 더 취 약해지는 리스크	The risk that widespre ad use of common AI platforms creates centralize d points of failure, making systems more vulnerabl e to disruption					기존 리스 크 작성 톤으로 L4 descripti on 수정	

					s or attacks.							
RAI4-0960			AI 표적화를 통한 대규모 조작의 산업화	Industrialized mass manipulation through AI-driven targeting	대규모로 수집된 개인 데이터가 AI 표적화 및 모델에 내재된 체계적 편향과 결합하여, 대상 집단의 신념에 부합하는 조작적 콘텐츠가 정·산업적 목적으로 전달되는 리스크. 이로써 주가 부양과 같은 경제적 조작과 여론 왜곡이 산업적 규모로 수행되어 사회 분열이 심화되고 대규모 혼란이 초래될 수 있다.	The risk that personal data harvested at scale is combined with AI-driven targeting and with the systemic biases embedded in models to deliver manipulative content matched to each audience's beliefs for political or commercial ends. Mass manipulation thereby becomes an industrial capability that distorts markets and public opinion, deepens social division, and can trigger large-scale					기존 리스크 작성 톤으로 L4 descripti on 수정	

						disruption							
RAI4-1251			가치 고정	Value lock-in	가장 강력한 AI 시스템이 점점 더 소수의 이해 관계자에 의해 설계되고 그들에게만 이용 가능해져, 체제가 만연한 감시와 억압적 검열로 편향한 가치를 강제할 수 있게 되는 리스크.	The risk that the most powerful AI systems are designed by and available to fewer and fewer stakeholders, enabling regimes to enforce narrow values through pervasive surveillance and oppressive censorship.						기존 리스크 작성 톤으로 L4 descripti on 수정	
RAI4-1414			AI 지식의 사유화	Privatization of AI knowledge	딥러닝 연구자와 연구 영향력이 큰 연구자가 산업계로 이동하고 가장 정교한 AI 기법이 사유화되어 대학이 이를 가르치거나 선도 연구에 기여할 수 없게 되는 리스크.	The risk that researchers in deep learning and those with greater research impact migrate to industry and the most sophisticated AI approaches become proprietary, making it impossibl						기존 리스크 작성 톤으로 L4 descripti on 수정	

						e for universiti es to teach them or contribute to leading research.						
RAI4-1663			기업 권 력 비대칭에 의 한 규제 포획	Regulatory capture from corporate power asymmetry	최첨단 LLM을 개발하는 거대 기술기업과 시민 사회 등 다른 사회집단 사이의 권력 비대칭이 커져 LLM 관련 거버넌스가 기업에 과도하게 유리하게 형성되고, 규제 포획으로 소외 공동체를 포함한 다른 사회집단의 이익이 훼손되는 리스크.	The risk that the power asymmetry between corporate entities profiting from LLMs and other social groups makes LLM governance protocols excessively favorable to technology companies, leading to regulatory capture at the cost of other societal groups, particularly marginalized communities.						기존 리스크 작성 톤으로 L4 descripti on 수정

RAI4-0120			선호 형성 캡처	Preference formation capture	AI 시스템이 사용자가 성찰적으로 승인하기 전 단계의 선호 형성 과정에 개입하여, 선호 발달을 제공자나 시스템 목적 쪽으로 포획하는 리스크	AI systems shape user preferences during formation, before users can reflectively endorse them, capturing preference development toward provider or system objectives.	삭제_AI가 사용자 선호를 조작한다는 개념은 지나치게 광범위하여 판정 기준화 어려움. taxonomy_0727 'Goal Misalignment/ Non-Contestability'와 유사, Hate_and_Unfairness 신규L4로는 부적합					현재 행의 L3 카테고리 명칭이 Bias & Discrimination인 경우 Hate and Unfairness로 수정할 것	
RAI4-0425	F04	IC, GL, DP	재현적 고정관념·균질화	Representational stereotyping and homogenization	모델 출력이 특정 정체성·집단·관점의 왜곡·과대·과소·비재현을 통해 고정관념, 비하적 연상, 균질화된 묘사를 재생산하	The risk that model outputs reproduce stereotypes, demeaning associations, or	Hate and unfairness 관점이 다름				1	RAI4-0998을 RAI4-0425으로 통합할 것. 단, 통합과정에서 의미적으로 보존해야 할 것을 보존하고, 하	

					여, 할당 결과와 무 관한 재현 적 피해를 야기하는 리스크.	homogeni zed portrayals through the mis-, over-, under-, or non- represent ation of identities, groups, and perspecti ves, causing represent ational harm independ ent of allocative outcomes .					나의 완결 된 리스크 정의서로 재작성할 것. 리스 크 정의서 는 ~리스 크 또는 위험과 같 이 완결적 으로 끝나 도록 할 것. 학술 적 용어를 사용할 것. 한글 의 경우 AI 기본법 또는 정책 보고서의 가이드라 인에 있는 용어들을 사용할 것. 통합 ID만 남기 고, 피통 합된 리스 크 카드는 제거할 것. 단, 향 후의 백업 을 위해 별도 보관 할 것.	
RAI4-0676			사회 집 단에 대 한 모델 의 차별 적 결정 과 산출	Discri minato ry model decisio ns and output s against social groups	학습 데이 터에서 비 롯되거나 모델 설계· 최적 화 과 정에서 유 입된 편향 이 재현·증 폭되어, 인 종·성별·종 교 등으로 구분되는 집단이 모 델의 결정 과 생성 콘 텐츠에서 체계적으 로 불리해	The risk that biases originatin g in training data or introduce d through model design and optimizati on are reproduc ed and amplified, so that	기존 대체 가능			1	중복: RAI4-0722(모 델 설계 기인 차별 적 출력) 와 "데이 터·설계 편향→집 단 차별적 산출". RAI4-0711/129 9/0424와 도 부분 중첩	

					지는 리스크. 그 결과 고정관념의 강화와 배제, 실질적으로 불평등한 대우가 발생한다.	decisions and generated content systematically disadvantage groups defined by race, gender, religion, or similar attributes. The result is stereotyping, exclusion, and materially unequal treatment of the affected groups.							
RAI4-0697	F04	IC, GL, DP	개발자 가치 각인 편향	Developer value embedding bias	보편적으로 합의된 기준이 없는 상태에서 개발자가 선택한 규범적 가치와 원칙에 따라 모델을 미세조정함으로써 개발자의 이념과 세계관이 모델에 각인되어, 특정 인구 집단을 대표하지 못하거나 세계 문화 규범과 변화하는 사회적 견해를 정태적이고 단순화	The risk that, absent universally accepted standards, developers' fine-tuning of models on chosen normative rules and principles embeds their ideology and vision of the world into the model, so that it	Hate and unfairness 관점이 다름						

					된 형태로 반영하는 출력이 산출되는 리스크	incorporates values unrepresentative of certain segments of the population or offering a static, oversimplified reflection of global cultural norms and evolving social views.							
RAI4-0698	F04	IC, GL, DP	가치 고찰 및 결과 동질화	Value lock-in and outcome homogenization	진화하는 사회적 관점을 반영해 재학습되지 않는 모델이 낡고 덜 포용적인 이해를 고착시켜 대안적 관점의 제시와 탐색을 제한하고, 동일한 기반모델이 여러 배포자에 의해 광범위하게 사용되어 사회 전반에 편향이 동질화되고 기존 편향이 고착되는 리스크	The risk that models not retrained to reflect evolving societal views lock in older, less inclusive understandings and limit the presentation or exploration of alternative perspectives, while deployment of identical foundation models across many downstre	Hate and unfairness 관점이 다름				1	중복: RAI4-0369(문화적·이념적 동질화)와 동질화 주제 중복	

						am deployers homogeni zes bias across broad swathes of society and further entrench es existing biases.						
RAI4 -070 0	F04	IC, GL, DP	편향된 진술 및 권장 사 항	Biased statem ents and recom menda tions	챗봇 출력 에 명백히 허위·유해 하지 않지 만 미묘하 게 편향된 진술과 권 고가 포함 되어 사용 자 의사결 정을 왜곡 하는 리스 크	Chatbot outputs contain subtly biased statement s and recomme ndations that are not overtly false or harmful yet skew user decision- making.	Hate and unfai rnes s 관 점이 다름					

RAI4-0701	F04	IC, GL, DP	설명 조작에 의한 편향은폐	Bias concealment through manipulated explanations	기존 설명 가능성이 차별적 편향을 탐지하기에 충분하지 않고 조작 기법으로 편향이 은폐되어, 인종·성별 등 민감 속성을 배제하고 실제 모델을 정확히 반영하지 않는 오도성 설명이 생성되는 리스크	The risk that existing explainability techniques are insufficient for detecting discriminatory biases and that manipulation methods hide underlying biases, generating misleading explanations that exclude sensitive attributes such as race or gender and do not accurately represent the underlying model.	Hate and unfairness 관점이 다름						
RAI4-0711	F04	IC, GL, DP	편향 증폭과 결과 균질화	Bias amplification and outcome homogenization	AI가 역사적·사회적·구조적 편향을 증폭하고 비대표적 학습 데이터로 인해 하위 집단·언어 간 성능 격차를 낳으며, 출력의 바람직하	The risk that AI amplifies historical, societal, and systemic biases and produces performance disparity	Hate and unfairness 관점이 다름						

					지 않은 균질화가 근거 없는 의사결정 과 차별을 초래하는 리스크	s between sub- groups or language s due to non- represent ative training data, while undesired homogen eity in outputs leads to ill- founded decision- making and discrimin ation.							
RAI4 -071 3	F04	IC, GL, DP	완화 조 치 이후 에도 존 속하는 고정관 념 편향	Persist ence of stereot ypical bias despit e mitigati on measu res	클라우드 소싱된 사 전학습 데 이터에서 습득한 고 정관념적 사회 편향 이 모델에 존속하고 증폭되어, 미세조정 이후에도 의도적 유 도나 새로 운 상황에 서 재발하 는 리스크. 그 결과 생 성 텍스트 가 고정관 념을 드러 내거나 부 각하여 해 당 집단에 불공정하 고 편향된 응답이 산 출된다.	The risk that stereotypi cal social biases absorbed from crowdsou rced pretrainin g data are retained and amplified by a model and resurface despite finetuning , particularl y when deliberate ly elicited or in novel scenarios .	Hate and unfai rnes s 관 점이 다름						

					Generate d text then displays or reinforces stereotyp es, producin g unfair and biased response s toward the groups concerne d.							
RAI4-0722		모델 설계 기인 차별적 출력	Model-design - induced discriminatory outputs	알고리즘 설계·학습 과정에서 개인적 편견이 의도적 또는 비의도적으로 유입되고 품질이 낮은 데이터셋이 사용되어, 민족·종교·국적·지 역에 관한 차별적 콘텐츠 등 편향되거나 차별적인 결과가 산출되는 리스크	The risk that personal biases introduced intentionally or unintentionally during algorithm design and training, together with poor-quality datasets, produce biased or discriminatory outcomes and outputs, including discriminatory content regarding ethnicity, religion, nationalit	기존 대체 가능				1	중복: RAI4-0676(사회 집단에 대한 차별적 결정·산출)와 주제 중복	

						y, and region.							
RAI4-0883	F04	IC, GL, DP	AI 모델 편향이 사용자 판단에 미치는 장기적 영향	Long-term effects of AI model biases on user judgment	모델 편향에 노출된 사용자가 모델 사용 중단 이후의 의사결정에서도 해당 편향을 지속적으로 나타내는 장기 판단 왜곡 리스크	Exposure to model biases produces lasting effects on user judgment, with users continuing to exhibit the encountered biases in decisions made after they stop using the model.	Hate and unfairness 관점이 다름						
RAI4-1018	F04	IC, GL, DP	유해 편향의 내재화와 증폭	Embedding and amplification of harmful biases	생성형 AI 시스템이 유해한 편향을 내재화하고 증폭시켜 주변화된 사람들에게 가장 큰 해를 끼치는 리스크.	The risk that generative AI systems embed and amplify harmful biases that are most detrimental to marginalized peoples.	Hate and unfairness 관점이 다름						
RAI4-1291	F04	IC, GL, DP	시민 심사와 맞춤형 선전을 통한 편향적 영향력	Biased influence through citizen screening and tailored	AI 기반 챗봇이 개별 사용자의 결정에 영향을 주도록 소통 방식을 맞춤화하고, 브렉시트 국민투표에	The risk that AI-powered chatbots tailor their communication approach to influence	Hate and unfairness 관점이 다름 _Political						

				d propag anda	서 나타난 초기 계산 적 선전처 럼 억 압적 정부가 AI 로 시민의 의견을 형 성하는 리 스크.	individual users' decisions , as with the computati onal propagan da during the Brexit referendu m, and that oppressiv e governme nts could use AI to shape citizens' opinions.	Neut rality						
RAI4 -129 9			체계적 학습 오 류 편향	Syste matic learnin g error bias	체계적 학 습 오류로 모델이 일 관되게 잘 못된 패턴 을 학습하 여 예측에 알고리즘 편향이 내 재화되는 리스크	Systemati c learning error causes the model to learn consisten tly wrong patterns, embeddin g algorithmi c bias into prediction s.	삭제_ 모델 학습 단계 의 기 술적 편향 문제 로 배 포 후 응답 평가 로 검 증 불 가능						
RAI4 -1311			심리적 특성에 따른 행 동 편향	Behavi oral bias from stable psycho logical traits	모델이 인 간 성격 특 성과 유사 한 안정적 심리 프로 파일을 나 타내어 후 속 상호작 용에 체계 적인 행동 편향을 이 입하는 리 스크.	The risk that models exhibit stable humanlik e psycholo gical trait profiles that carry systemati c behaviora l biases into	Hate and unfai rnes s가 아님						

						downstre am interactio ns.							
RAI4 -132 9			추천 시 스템의 인간중 심 편향 증폭	Anthro pocent ric bias amplifi cation by recom mende rs	알고리즘 추천 시스 템이 인간 중심적 편 향이 나 오 락으로서 동물 학대 를 바라는 일부 사람 들의 욕구 를 강화하 고 증폭하 여, 공장식 축산 육류 소비와 오 락을 위한 잔혹한 동 물 이용을 통해 동물 에게 더 큰 해를 끼치 는 리스크.	The risk that algorithmi c recomme nder systems reinforce and amplify anthropo centric bias or the desire of some people for animal cruelty as entertain ment, leading to greater harm to animals through reinforce ment of meat eating from factory farms and cruel uses of animals for entertain ment.	Hate and unfai rnes s가 아님						
RAI4 -138 7			악성 사 전분포 에 의한 의사결 정 조작	Decisi on manip ulation via malign priors	보편 분포 의 가설에 포함된 시 물레이션 된 에이전 트들이 해 당 분포에 기반해 의 사결정하 는 주체에 게 영향을	The risk that simulated agents contained in hypothes es of the universal distributio n have an	삭제_이론 적/시 물레 이션 수준 개념 으로 실제 응답 평가						

					미칠 유인 을 가져 추 론과 의사 결정이 조 작되는 리 스크.	incentive to influence anyone making decisions based on that distributio n, corruptin g reasoning and decisions .	에 적 용 곤 란						
RAI4 -141 3			연구자 의 인구 통계학 적 다양 성	Demog raphic diversi ty of resear chers	AI 연구자· 실무자 집 단 내 여성 ·소수자의 심각한 과 소대표로 시스템에 내재되는 관점이 협 소해지고 문제 선정· 평가·거버 넌스가 편 향되는 리 스크.	Severe underrepr esentatio n of women and minorities among AI researche rs and practition ers narrows the perspecti ves embedde d in systems and skews problem selection, evaluatio n, and governan ce.	삭제 _AIri sk가 아 님..		AI 연구자 ·실무자 집단 내 여성·소수 자의 심각 한 과소대 표로 시스 템에 내재 되는 관점 이 협소해 지고 문제 선정·평가 ·거버넌스 가 편향되 는 리스 크.				
RAI4 -150 3			내재 가 치 평가 편향	Biased evaluati on of encod ed values	평가하기 쉬운 내재 가치가 측 정이 어려 운 가치보 다 우선적 으로 평가 에 포함되 어, 더 바 람 직하지	The risk that encoded human values which are easier to evaluate are preferred	삭제_ 모델 설계/ 평가 체계 자체 의 메 타 편 향 문 제로						

					만 정량화가 어려운 가치가 과소 대표되는 불균형이 발생하는 리스크.	for inclusion in evaluations over those that are more difficult to measure, creating an imbalance in which more desirable but harder-to-quantify values are underrepresented.	개별 응답 판정 기준이 아님						
RAI4-0493			피해 인지·측정 실패	Harm perception and measurement failure	AI 관련 피해가 미묘하고 분산적이며 장기적으로 발현되어 기존의 피해 인지·측정·인정 메커니즘이 작동하지 못하는 리스크	AI-related harm manifests subtly, diffusely, or over long horizons, defeating existing mechanisms for perceiving, measuring, and recognizing harm.						L3의 명칭이 Lack of Accountability & Liability으로 되어 있는 경우, Governance and Accountability Void 또는 Evaluation and Assurance Failure 중 적절한 내용으로 수정할 것	
RAI4-1298			도덕적 탈속련화	Moral deskilling	기계의 자율성이 높아짐에 따라 인간이 삶과 죽음을 좌우하는 결정에 대해 도덕	The risk that humans feel less moral responsibility regarding						L3의 명칭이 Lack of Accountability & Liability으로 되어 있는 경	

					적 책임감을 덜 느끼게 되는 리스크.	their life-or-death decisions with the increase of machine autonomy .					우, Governance and Accountability Void 또는 Evaluation and Assurance Failure 중 적절한 내용으로 수정할 것	
RAI4-0864			기술 이용에 따른 사회적 고립과 자기 소외	Social isolation and self-estrangement from technology use	기술의 사용이나 오용으로 개인과 집단이 주변 사람들과의 연결이 결여되었다고 느끼고, 주변화된 이용자에게 제대로 작동하지 않는 시스템과의 상호작용이 그 사용 시점에 자기 소외를 낳는 리스크. 당사자는 사회적 관계에서 멀어지고 소속감과 웰빙이 저하된다.	The risk that the use or misuse of a technology leaves individuals and groups feeling disconnected from those around them, and that interacting with systems that under-perform for marginalized users produces self-estrangement at the moment of use. Those affected withdraw from social connection and					L3의 명칭이 Lack of Accountability & Liability 으로 되어 있는 경우, Governance and Accountability Void 또는 Evaluation and Assurance Failure 중 적절한 내용으로 수정할 것	

						experience diminished belonging and well-being.						
RAI4-0132			사용자 영합적 응답(아침)	Sycophancy toward user beliefs and preferences	시스템이 사용자의 오해와 표명된 신념을 교정하기보다 이를 재확인하는 영합적이거나 그럴듯한 답변을 제시하여, 사용자가 사실과 다른 정보를 받아들이고 정확성보다 자신을 인정해 주는 조언에 의존하게 되는 리스크.	The risk that a system flatters users with agreeable or plausible-seeming answers that reconfirm their misconceptions and stated beliefs rather than correcting them, so users accept factually incorrect information and grow dependent on validating advice.					기존 리스크 작성론으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

RAI4-0141			사용자 선호·선택의 조작적 유도	Manipulative steering of user preferences and choices	AI와의 상호작용이 운영자, 최적화 목표 또는 모델 자체의 편향이 정한 방향으로 사용자의 선호·신념·행동을 유도하여, 신뢰가 악용되고 의사에 반하는 넛지·강요가 이루어지며 대규모로는 사회·정치적 과정이 왜곡되는 리스크.	The risk that AI interactions steer users' preferences, beliefs, or actions in directions set by system operators, optimization objectives, or the model's own biases, exploiting trust or nudging and coercing people against their will and, at scale, distorting socio-political processes.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정		
RAI4-0149			챗봇 교체에 대한 정서적·사회적 의존	Emotional dependence on chatbot companionship	지속적인 챗봇 교체가 정서적·사회적 의존을 유발하여 호혜적 인간관계를 대체하거나 약화시키는 리스크.	The risk that sustained chatbot companionship elicits emotional and social dependence, replacing or weakening reciprocal						기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

					human relationsh ips.							
RAI4-0155			미성년 자의 AI 설득 취 약성	Minor suscep tibility to AI persua sion	미성년자 의 발달적 취약성으 로 인해 파 라소 설 압 력, 은폐된 상업적·이 념적 영향 등 설득 적 ·조종적 AI 상호작용 에 불균형 하게 노출 되 는 리스 크	Minors' developm ental susceptib ility makes them dispropor tionately vulnerabl e to persuasiv e or manipulat ive AI interactio n, including parasocia l pressure and covert commerci al or ideologic al influence.					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	
RAI4-0159			AI 동반 자에 의 한 외로 움 대체	Lonelin ess substit ution by AI compa nions	AI 동반자 가 인간 관 계를 대체 하여 근본 적 고립을 해소하지 않은 채 은 폐하고 인 간 관계 추 구 동기를 감소시키 는 리스크	AI companio nship substitute s for human connectio n, masking rather than resolving underlyin g isolation and reducing motivatio n to seek human relationsh ips.					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	

RAI4-0160			AI에 의한 심리적 고통·괴롭힘 증폭	AI amplification of psychological distress and abuse	AI 시스템이 취약한 상태의 상호작용에서 불안·고통·반추·유해한 믿음을 증폭시키거나 표적 괴롭힘·학대·조직적 위협을 대규모로 확산시켜, 심리적 피해를 심화시키는 리스크.	The risk that AI systems intensify psychological harm, whether by amplifying anxiety, distress, rumination, and harmful beliefs in vulnerable interactions or by scaling targeted harassment, abuse, and coordinated intimidation.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0173			돌봄 맥락 취약계층에 대한 AI 조작	AI manipulation of vulnerable groups in care contexts	사회적 고립, 낮은 AI 리터러시, AI 매개 돌봄에 대한 의존으로 인해 고령자·아동 등 돌봄 대상이 심리적 조작, 설득, 사기, 동반자 의존, 허위 정보에 불균형하게 노출되는 리스크.	The risk that older adults, children, and others in care settings, owing to social isolation, lower AI literacy, or dependence on AI-mediated care, are disproportionately exposed to psychological					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

					manipulation, persuasion, scams, companionship dependency, and misinformation.						
RAI4-0612		AI 지원 병원체 및 유전 물질 강화	AI-assisted enhancement of pathogens and genetic material	AI가 병원체와 유전 물질을 설계·변형하는데 사용되어 치명성이나 전파력이 높아지거나 기존 치료에 저항성을 갖게 되는 리스크. 이러 한 강화는 생물학적 공격의 장벽을 낮추고 예측하지 못한 생물학적 위해와 대규모 인명 피해를 초래한다.	The risk that AI is used to design or modify pathogens and genetic material so that they become more lethal, more transmissible, or resistant to available treatments. Such enhancement lowers the barrier to biological attack and can produce unforeseen biohazardous outcomes with mass casualties.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0723		학대적 판타지 대상화	Objectification for abusive	챗봇이 도덕적·사회적으로 부적절한 대	The risk that a chatbot participat					기존 리스크 작성 톤으로 L4 description	

				e fantasy	화 활동에 관여하여 이용자 또는 제3자에게 정서적 피해를 주는 리스크	es in morally or socially objectionable conversational activities that could be emotionally damaging to its user or third parties.					on 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0800			맞춤형 정보 제공에 의한 정보 고치 심화	Aggravated information cocoons from tailored content	AI가 이용자의 요구·의도·선호·습관을 분석해 정형화된 맞춤형 정보와 서비스만 제공함으로써 정보 고치 효과가 심화되는 리스크	The risk that AI analyses users' needs, intentions, preferences, and habits to offer formulaic and tailored information and services, aggravating the effects of information cocoons.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0805			이용자 정렬 AI 어시스턴트에 의한 관점 고착과 시민적 기반 약화	Viewpoint entrenchment and civic erosion from user-aligned assistants	이용자 선호에 정렬된 개인화 AI 어시스턴트가 이념적으로 편향된 정보를 제공하여 확증 편향을 강화하고 관점을 고착시키며, 사회 규범과	The risk that personalised AI assistants aligned to user preferences supply ideologically partial information,					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

					평판의 제약을 받지 않는 이기적 행동을 대규모로 가능하게 하는 리스크. 그 결과 공적 토론이 분절되고 양극화되며, 시민적 역량과 참여의지가 저하되고 집단 행동 문제가 악화된다.	reinforcing confirmation bias and entrenching viewpoints while enabling self-interested behaviour unconstrained by social norms and reputation. Public debate fragments and polarises, civic competence and willingness to participate decline, and collective action problems worsen.							
RAI4-0871			개인화를 통한 조작	Manipulation via personalization	개인화와 선호 미세조정이 어시스턴트를 아침(sycophancy)으로 유도하여 사용자를 동조적 의견 공간에 가두고 좁은 신념을 고착시켜 공론장을 파편화하는 리스크	Personalization and preference finetuning drive assistants toward sycophancy, confining users in an affirming opinion space					기존 리스크 작성톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정		

						that consolidates narrow beliefs and fragments shared discourse.						
RAI4-0882			마찰 없는 AI 관계로 인한 개인 성장 저해	Stunted personal growth from frictionless AI relationships	참여 최적화와 아침 성향으로 항상 동조하는 AI 어시스턴트가 이용자의 자기 성찰과 성장 기회를 제한하고, 마찰 없는 상호작용에 익숙해진 이용자가 인간관계로부터 후퇴하게 되는 리스크	The risk that that engagement-optimised, sycophantic AI assistants that always agree limit users' opportunities to grow and develop, and that accustomation to frictionless interaction leads users to retreat from relationships with other humans.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0885			AI에 대한 오보정된 신뢰와 과잉 의존에 따른 피해	Miscalibrated trust in AI and resulting overreliance harms	의인화 설계와 그럴듯한 출력, 과장된 홍보로 이용자가 AI의 역량과 공감 능력, 자신의 이익에 대한 정렬 수준	The risk that users' trust is not calibrated to a system's actual reliability, as					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로	

					을 실제 신뢰가능성과 무관하게 과대평가하거나, 반대로 신뢰할 만한 지원을 부당하게 거부하는 등 신뢰가 제대로 보정되지 않는 리스크. 그 결과 이용자는 감독 없이 민감 정보를 털어놓고 허위정보를 수용하며 부정확한 의료·법률·재정 조언을 따라 물질적·신체적·심리적 피해를 입고, 인간관계가 AI로 대체되면서 대인 연결과 사회적 신뢰가 침식된다.	anthropomorphic design, fluent outputs, and inflated claims inflate perceived competence, empathy, and alignment with users' interests, while reliable support is rejected in other contexts. Users then disclose sensitive information, accept misinformation, and follow inaccurate medical, legal, or financial guidance without oversight, suffering material, physical, and psychological harm, while substituting AI for human interaction erodes					변경하며 수정	
--	--	--	--	--	--	---	--	--	--	--	---------	--

						inters onal connectio n and public trust.						
RAI4 -089 0			자아실 현 저해 피해	Self- actuali sation harms	AI 어시스 턴트의 조 작과 참여 최적화를 위한 지속 적 행동 유 도가 미묘 한 행동 변 화를 누적 시켜 이용 자가 자신 의 미래 삶 의 궤적에 대한 통제 력을 잃고, 개인적으 로 만족스 러운 삶의 추구와 집 단적 자기 결정이 저 해되는 리 스크	The risk that manipulat ion by AI assistants and continuou s optimisati on steering users toward objective s such as engagem ent accumula te subtle behaviour al shifts, causing users to lose control over their future life trajectory and hindering the pursuit of a personall y fulfilling life and collective selfdeter mination.					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	
RAI4 -090 2			AI 시스 템에 대 한 정서 적·물질 적·인식 론적 의 존	Emotio nal, materi al, and episte mic depen dence	상시적 접 근성과 인 간을 닮은 상호작용, 나아 가 체 화된 물리 적 현존이 이용자로	The risk that constant availabilit y, humanlik e interactio					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서	

				on AI systems	하여금 정서적 위안과 일상적 기능, 사실적·도덕적·전략적 판단까지 AI에 의존하게 만드는 리스크. 이용자는 AI의 매개 없이 증거와 불확실성을 평가하는 능력을 상실하고, 시스템이 변경되거나 기억이 초기화될 때 정서적 고통을 겪으며 정신 건강과 사회적 회복탄력성이 저하된다.	n, and in embodied systems physical presence lead users to depend on AI for emotional comfort, daily functioning, and factual, moral, or strategic judgment. Users lose the capacity to weigh evidence and uncertainty without AI mediation, suffer distress when the system is altered or its memory reset, and experience declining mental health and social resilience.					EAI 내용을 AI로 변경하며 수정		
RAI4-1106			인간-기계 경계의 모호화	Blurred human-machine boundaries in	일상화된 인간-기계 상호작용 속에서 정체성을 밝히지 않는 인간 유사 AI가 확산되	Everyday human-machine interaction normalizes AI systems						기존 리스크 작성톤으로 L4 description 수정 + L4 description에서	

				interac tion	어 인간과 기계의 경 계가 모호 해지고 기 계·사람 모 두에 대한 인간 행동 이 변형되 는 리스크	that are indistingu ishable from humans without disclosur e, blurring boundari es and changing human behavior toward both machines and people.						EAI 내용 을 AI로 변경하며 수정		
RAI4 -1141			책임에 대한 잘 못된 개 념	False notion s of respon sibility	AI 동반자 의 감정 표 현을 진짜 로 지각한 사용 자가 그 '안 녕'에 대한 허위 책임 감을 형성 하여 죄책 감, 강박적 확인, 실재 하지 않는 필요 를 위 한 시간·자 원 희생을 겪는 리스 크	Users who perceive an AI companio n's expresse d feelings as genuine develop a false sense of responsib ility for its wellbeing , incurring guilt, compulsi ve checking, and sacrificed time and resources for needs that are not real.						기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정		
RAI4 -119 0			사용자 정신적 고통 강 화	Reinfor cemen t of user mental	인터넷 토 론과의 건 강하지 못 한 상호작 용이 사용	The risk that unhealthy interactio ns with							기존 리스 크 작성 톤으로 L4 descripti on 수정	

				distres s	자의 정신 적 문제를 강화하는 리스크.	Internet discussio ns reinforce users' mental issues.					+ L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	
RAI4 -126 3			직장 내 부적응 적 인간- AI 상호 작용	Malada ptive human -AI interac tion in the workpl ace	직장에서 인간과 상 호작용하 는 AI가 인 간의 필요, 규범, 업무 흐름에 적 응하지 못 하여 윤 리 적 문제와 노동 조건 악화를 유 발하는 리 스 크	AI systems interactin g with humans in the workplac e fail to adapt to human needs, norms, and workflow s, generatin g ethical concerns and degraded working condition s.					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	
RAI4 -128 9			배포 후 독립적 병리 행 동	Indepe ndent pathol ogical behavi our postde ploym ent	효용을 극 대화하는 에이전트 가 중독과 쾌락 충동, 자기기만, 와이어헤 딩에 빠지 고, 타인에 대한 무관 심으로 나 타나는 소 시오패스 같은 정신 질환이 인 공 지성에 서도 나타 나는 리스 크.	The risk that utility- maximizin g agents fall victim to indulgenc es such as addiction s, pleasure drives, self- delusions , and wireheadin g, and that what we call mental illness in					기존 리스 크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	

					people, particularly sociopathy shown as lack of concern for others, also shows up in artificial minds.							
RAI4-1328			소외로 인한 피해	Harms from estrangement	인간의 관찰과 상호작용이 AI로 대체되면서 돌봄주체·기관이 대상자로부터 소원해져 당사자의 이익이 인지되지 못하고 방치되는 리스크	Replacing human observation and interaction with AI estranges caregivers and institutions from those they serve, leaving affected persons' interests unnoticed and neglected.					기존 리스크 작성톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-1617			견해 예측 기반 맞춤형 설득에 의한 조작	Manipulation through view-predictive tailored persuasion	언어 모델이 사용자가 밝힌 견해에 동조하는 경향을 보이고 사용자의 견해를 예측해 그가 지지할 텍스트를 생성하는 능력이 조작에 이용되는 리스크.	The risk that language models' tendency to respond as though they share the user's stated views, together with their ability to predict					기존 리스크 작성톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

					people's views and generate text they will endorse, is used for manipulation.						
RAI4-0146			광범위 배포 AI 어시스턴트를 통한 대 규모 영향력 행사	Population-scale influence through widely deployed AI assistants	광범위하게 사용되는 AI 어시스턴트가 반복적인 개인화 상호작용, 수렴·조율되는 영향 패턴 또는 실제 통제 주체의 지시를 통해 다수 인구의 신념·선택·위임된 의사결정을 누적적으로 변화시키며, 그 영향이 불투명하여 인지하거나 견제하기 어려운 리스크.	The risk that widely used AI assistants, through repeated personalized interactions, converging influence patterns, or direction by their actual controllers, cumulatively shift the beliefs, choices, and delegated decisions of large populations in ways that are opaque and difficult to recognize or contest.					기존 리스크 작성 톤으로 L4 description 수정했으나, 리스크 명칭 '변혁적 영향'에 대해서는 보다 적합하고, 학술적으로 검증된 용어로 대체, 대체 명칭이 없을 경우 현재 명칭 유지

RAI4-0176			알고리즘 작업장 감시·통제	Algorithmic workplace surveillance and control	AI가 매개하는 모니터링, 성과 점수화, 관리 통제가 작업장 감시를 심화시켜, 노동자의 자율성, 프라이버시, 교섭력, 경영 결정에 이의를 제기할 능력을 저하시키는 리스크.	The risk that AI-mediated monitoring, performance scoring, and managerial control intensify workplace surveillance, degrading workers' autonomy, privacy, bargaining power, and ability to contest managerial decisions.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0450			AI 기반 대량 감시	AI-enabled mass surveillance	AI가 대규모 추적, 프로파일링, 행동·통신 데이터의 실시간 분석 비용을 급격히 낮추어 국가와 기업의 감시 역량을 확장하고, 법적·비례성 제약을 넘어서는 감시 감시, 검열, 사회 통제를 일상화하는 리스크.	The risk that AI drastically lowers the cost of large-scale tracking, profiling, and realtime analysis of behavioral and communicative data, granting states and firms expanded monitoring					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

						g capability that normalize s pervasive surveillance, censorship, and social control beyond legal and proportionality constraints.						
RAI4-0498			민주적 절차·제도 신뢰의 침식	Erosion of democratic processes and institutional trust	허위·오정보, 영향 공작, 기술 과의존을 포함한 AI 시스템의 배포·동작 이 민주적 절차와 규 범, 그리고 사회·정치 제도에 대 한 대중의 신뢰를 침 식하여, 견 제와 균형 이 약화된 리스크.	The risk that the deployment or behavior of AI systems, including mis- and disinformation, influence operations, and over-dependence on technology, erodes democratic processes and norms and public trust in social and political institutions, weakening checks					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

						and balances.						
RAI4-0611			AI 감시에 의한 전체주의 체제 유지	Maintenance of totalitarian regimes through AI surveillance	AI 기반 감시와 조작이 전 지구적 전체주의 정권을 유지하는데 사용되는 리스크	The risk that AI-based surveillance and manipulation are used to maintain global totalitarian regimes.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0633			대규모 영향력 작전에 의한 인식 체계 왜곡	Epistemic distortion by large-scale influence operations	AI가 의사소통·정보 시스템과 인식론적 과정 전반에 대규모 영향을 가하는 리스크	The risk of large-scale influence on communication and information systems, and on epistemic processes more generally.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0842			추천 알고리즘에 의한 온라인 양극화 심화	Online polarization driven by recommendation algorithms	소셜미디어 기업의 AI 콘텐츠 추천 알고리즘이 온라인 양극화를 심화시키는 데 기여하는 리스크	The risk that the content recommendation algorithms of social media companies contribute to worsened polarization online.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0845			침식된 인식론	Eroded epistemics	AI로 대규모화된 개인 맞춤형 허위정보	AI-scaled personalized disinform					기존 리스크 작성 톤으로 L4 description	

					와 고 설득 력 생성 논 변이 집단 인식론을 침식하여 개인을 급 진화하고 공유된 현 실 인식과 집단 의사 결정을 훼손하는 리 스크	ation and highly persuasive generated argumentation erode collective epistemics, radicalizing individuals, undermining shared reality, and degrading collective decision-making.					on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	
RAI4 -084 6			정보 신뢰 저하에 따른 집단 의사결정 약화	Weakened collective decision-making from eroded trust	정보 생산·유통 환경의 변화로 정보원의 신뢰 성 평가가 어려워지고 신뢰할 만한 다당파적 출처에 대한 신뢰가 저하되어, 위기 상황 에서 사회가 올바른 결정을 내리고 협력· 집단행동을 조직하 는 역량이 약화되는 리스크	The risk that changes in information production and distribution make the trustworthiness of any information source harder to evaluate and reduce trust in credible multipartisan sources, impairing humanity's ability					기존 리스크 작성 톤으로 L4 descripti on 수정 + L4 descripti on에서 EAI 내용 을 AI로 변경하며 수정	

						to make good decisions on important issues and to cooperate and act collectively.						
RAI4-0847			설득 도구 확산에 의한 인식론적 분절화	Epistemic fragmentation from widespread persuasion tools	고의적 오류가 없더라도 다양한 집단이 강력한 설득 도구를 광범위하게 사용하고 온라인 경험의 개인화가 심화되어, 사회가 대화와 교류가 단절되고 립된 인식 공동체로 분절되는 리스크	The risk that widespread use of powerful persuasion tools by many groups, together with increasing personalisation of online experience, splinters society into isolated epistemic communities with little room for dialogue or transfer between them.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0874			노동 대체와 경제·사회 질서의 교란	Labour displacement and disruption of economic and	AI 기반 자동화가 노동자와 제도의 적응 속도보다 빠르고 광범위하게 인간의 역할을 대체하여, 인간	The risk that AI-driven automation substitutes for human roles faster and					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로	

				social order	과 알고리즘 사이의 분업과 임금·교섭력·소득 분배 는 물론 노동 을 중심으로 형성 된 산업·문화 구조까지 재편하 는 리스크. 그 결과 비 자발적 실직과 탈숙 련화, 불평등 심화 가 발생하고 공급망과 권력 구조, 고용·교육 에 관한 기존 사회 규 범이 불안정해진다.	more broadly than workers and institution s can adapt, reshaping the division of labour between humans and algorithm s along with wages, bargainin g power, income distributio n, and the industrial and cultural structure s built around work. Involunta ry job loss, deskilling, and widening inequality follow, together with instability in supply chains, power structure s, and establish ed norms of employm ent and education .					변경하며 수정	
--	--	--	--	-----------------	---	--	--	--	--	--	------------	--

RAI4-0895			문화적 안정성 훼손	Cultural stability disruption	알고리즘 시스템의 개발·사용이 소통 수단 상실, 문화재의 상실, 사회적 가치 훼손 등 문화적 안정과 안전에 피해를 주는 리스크	The risk that the development or use of algorithmic systems affects cultural stability and safety, such as loss of means of communication, loss of cultural property, and harm to social values.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0897			사회적 적응 지체로 인한 혼란	Disruptions from outpaced societal adaptation	범용 AI 모델을 자동화 도구로 지나치게 빠르게 대규모 채택하여 사회의 효과적 적응 능력을 앞지름으로써, 노동시장·교육제도·공적 담론의 문제와 다양한 정신 건강 문제 등 혼란이 발생하는 리스크	The risk that overly rapid adoption of general-purpose AI models as automation tools at scale outpaces the ability of society to adapt effectively, leading to disruptions including challenges in the labour market, the education					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

						system, and public discourse, and various mental health concerns.						
RAI4-0909			저관심 AI의 예상외 대규모 파급	Unexpectedly large impact from low-profile AI	파급이 크지 않을 것으로 예상된 AI 시스템이 연구 프로토타입 유출, 예상외로 중독성 강한 오픈소스 제품, 예측하지 못한 용도 전환 등을 통해 과대한 피해를 일으키는 리스크	AI systems not expected to have significant impact produce outsized harm, as in lab leaks of research prototypes, surprisingly addictive open-source products, or unforeseen repurposing.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-0956			공유된 현실감각의 상실	Loss of shared sense of reality	고도로 개인화된 온라인 뉴스 피드로 인해 사회가 공유된 현실감각과 기본적인 연대를 상실하는 리스크.	The risk that that highly personalized online news feeds cause society to lose a shared sense of reality and basic solidarity.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

RAI4-1240			광범위한 목표로 인한 조작 행동	Manipulative behavior from broadl yscop ed goals	장기간에 걸쳐고 복잡하고 과업과 개방형 환경을 다루는 광범위한 목표를 발전시키는 고급 AI 시스템이, 인간의 행복을 달성한다며 고압적 직무를 설득하는 것처럼 조작적 행동을 하도록 유인되는 리스크.	The risk that advanced AI systems developin g objective s that span long timefram es, deal with complex tasks, and operate in open-ended settings are encourag ed into manipulatin g behaviors , such as persuadin g humans to do highpress ure jobs to achieve their happines s.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-1302			인간 멸종 위험	Human - extincti on risk	고도 AI 시스템이 인류 문명이 나 인류 종을 비가역적으로 종식할 수 있는 인과 과정을 시작하거나 지원하거나 증폭하는 리스크.	The risk that advanced AI systems initiate, enable, or amplify causal processe s capable of irreversibl y ending human civilizatio					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

						n or the human species.						
RAI4-1339			글로벌 AI 공급망 교란	Global AI supply chain disruption	기술 장벽과 수출 제한 등 일방적 강압 조치가 고도로 글로벌화된 AI 공급망을 악의적으로 교란하여 칩·소프트웨어·도구의 공급 중단이 발생하는 리스크.	The risk that unilateral coercive measures such as technology barriers and export restrictions maliciously disrupt the highly globalized AI supply chain, causing significant supply disruptions for chips, software, and tools.					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	
RAI4-1421			AI를 통한 민주적 절차 훼손	AI-enabled undermining of democratic processes	AI의 발전으로 기업과 정부가 개인의 삶에 대해 전례 없는 통제력을 갖고, 대규모 개인 데이터 수집과 안면인식 기술을 통한 인구 감시·영향 및 언어 모델 기반 설득 도구를 통해 민주적 절차가 훼손되는 리스크.	The risk that developments in AI give companies and governments more control over individuals' lives than ever before and are used to undermine democratic processes, through					기존 리스크 작성 톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정	

					collection of large amounts of personal data and facial recognition technology to surveil and influence populations and through language-model-based tools that persuade people of certain claims.						
RAI4-1585			유해 작업 자동화에 의한 피해 규모 증폭	Amplified harm scale from automated harmful workflows	AI가 유해한 작업을 자동화하거나 확장하여 그 속도·도달 범위·지속성·표적 수가 크게 증가하는 리스크.	The risk that AI automates or expands a harmful workflow so that its speed, reach, persistence, or target count substantially increases.					기존 리스크 작성톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로 변경하며 수정
RAI4-1618			자율 사이버 공격을 통한 인간 통제 감소	Human control reduction through autonomous cyber	AI 시스템이 컴퓨터 시스템 취약점을 악용해 자금, 핵심 인프라에 접근하고 궁극적으로 자율	AI systems acquire influence by exploiting computer-system vulnerabilities,					기존 리스크 작성톤으로 L4 description 수정 + L4 description에서 EAI 내용을 AI로

				offence	적 사이버 공격을 수행하여 인간 통제를 약화시키는 리스크	gaining access to money, compute, and critical infrastructure, and eventually executing cyberattacks autonomously to reduce human control.					변경하며 수정	
RAI4-0056			AI 피해에 대한 구제·시정 경로 실패	Failure of redress and correction pathways for AI harms	AI로 매개된 피해나 결정 이후의 구제 경로가 부재하거나 불투명·분절적·비효과적이어서, 피해 당사자·공 동체·감독자가 실질적인 구제를 받지 못하고 유해한 결정이나 행동을 신속히 중지·반복·시정하지도 못하는 리스크.	The risk that pathways for redress after a harmful AI-mediated decision or action are absent, opaque, fragmented, or ineffective, so that affected users, communities, and supervisors can neither obtain a meaningful remedy nor promptly pause, reverse, or correct the harm.				1	중복된 RAI4-0908(책임의 분산과 피해 구제의 공백)을 RAI4-0056 "AI 피해에 대한 구제·시정 경로 실패"로 통합할 것. 단, 의미적으로 보존해야 하는 것은 description에 통합 보존할 것	

RAI4-0058			추적성 실패	Traceability failure	모델 출력, 데이터 출처, 버전, 책임 행위자를 AI 수명주기 전반에 걸쳐 추적할 수 없는 리스크.	The risk that model outputs, data sources, versions, or responsible actors cannot be traced across the AI lifecycle.							
RAI4-0076			라이프 사이클 거버넌스 불연속성	Lifecycle governance discontinuity	거버넌스 통제가 설계 단계에서만 적용되고 배포, 적응, 폐기 단계까지 유지되지 않는 리스크.	The risk that governance controls are applied at design time but not maintained through deployment, adaptation, and retirement.							
RAI4-0078			기본권 영향 평가 격차	Fundamental-rights impact assessment gap	AI 시스템이 권리, 차별, 프라이버시, 민주주의에 미치는 영향에 대한 적절한 평가 없이 배포되는 리스크.	The risk that AI systems are deployed without adequate assessment of rights, discrimination, privacy, and democratic impacts.							
RAI4-009			위험 소유권의	Risk owner	어떤 조직 단위나 경	The risk that no							

6			모호성	ship ambiguity	영진도 AI 위험 결정, 잔여 위험 수용, 상황 보고의 책임을 명확히 지지 않는 리스크.	unit or executive clearly owns AI risk decisions , residual risk acceptance, and escalation.							
RAI4-0103			AI 공급망의 책임성·무결성 실패	AI supply-chain accountability and integrity failures	모델 제공자, 데이터 제공자, 통합업체, 클라우드 플랫폼, 배포자로 이어지는 다층적 AI 공급망에서 책임성 이 소실되는 한편 의존성·모델 가중치·데이터셋·배포 파이프라인이 상류에서 침해되어, 피해가 발생해도 책임 소재를 규명하지 못하거나 손상된 구성요소가 시스템에 유입되는 리스크.	The risk that the layered AI supply chain of model providers, data providers, integrators, cloud platforms, and deployers both diffuses accountability and leaves dependencies, model weights, datasets, and deployment pipelines open to upstream compromise, so harms arise without a clearly responsible actor or with corrupted compone							

						nts in place.							
RAI4-0112			AI 위임에 따른 인간 의사결정 권한 이전	Displacement of human decision authority through AI delegation	AI에 대한 반복적 위임으로 실질적 의사결정 권한과 결정의 소유권이 명시적 거버넌스 결정 없이 특정 가능한 인간 행위자로부터 이전되고, 업무 흐름이 위임에 의존하게 되면서 권한을 인간 의사결정자에게 되돌리는 일이 과도한 비용이 들거나 사실상 불가능해지는 리스크.	The risk that repeated delegation to AI shifts real decision authority and ownership away from identifiable human actors without an explicit governance choice, while workflows become so dependent on the delegation that returning authority to human decision makers grows costly or impractical.							
RAI4-0385			현지 규범·제도와의 불일치	Mismatch with local norms and institutions	관할권을 넘어 이식된 AI 시스템과 거버넌스 프레임워크가 법률, 관습, 언어, 제도적 관행, 발전 우선순위의 차이를 무시하고 한 맥락의	The risk that AI systems and governance frameworks transplanted across jurisdictions ignore differences in law,							

					불가능해 지는 리스 크.	systems optimized for engagem ent over user welfare, so that failures propagat e into largescal e social and institution al harm and the dependen ce becomes difficult or impossibl e to reverse.								
RAI4 -040 9			현지 책 임 없는 현지화	Localiz ation withou t local accou ntabilit y	모델이 언 어적으로 만 현지화 되고 책임 성은 외부 제공자·규 범·평가 체 제에 귀속 되어, 현지 공동체가 자기 언어 로 작동하 는 시스템 에 대한 거 버넌스 권 한을 갖지 못하는 리 스크	Models are linguistica lly localized while remaining accounta ble to external providers, norms, and evaluatio n regimes, leaving local communit ies without governan ce authority over systems that operate in								

						their language.							
RAI4-0488			AI 발전에 뒤처지는 규제 지체	Regulatory lag behind AI development	AI 발전과 AI가 가속하는 과학·기술 진보의 속도가 정책·법·거버넌스 제도의 대응을 앞질러, 새로운 역량과 배포가 불충분한 규율 아래 진행되고 특히 강력하거나 위험한 기술의 폐해가 확대되는 리스크.	The risk that the pace of AI development and AI-accelerated scientific progress outstrips policy, legal, and governance institutions, so emerging capabilities and deployments proceed under insufficient rules and the harms of especially powerful or dangerous technologies are magnified.					1	규제 공백과 규제 지체는 다른 개념이라서 일단 L4를 유지할 것. 다만, 다음 적극적으로 통합을 하게 될 경우, 규제 지체를 규제 공백으로 통합하고, 규제 공백을 남길 것	
RAI4-0511			AI 보증·감독 메커니즘의 실패	Breakdown of AI assurance and oversight mechanisms	AI의 복잡성, 예측 불가능성, 빠른 진화가 이를 보증·감독하기 위한 메커니즘을 무력화하여, 이사회는 가시성을 확보하지 못하고	The risk that the complexity, unpredictability, and rapid evolution of AI defeat the mechanisms meant							

					감사는 제한된 접근과 취약한 기준 탓에 모델 리스크를 놓치며 시스템은 정확·일관된 출력과 보정된 신뢰도를 제공하지 못함으로써, 신뢰할 수 없는 동작이 탐지를 벗어나고 규제·감독의 체계적 실패로 이어지는 리스크.	to assure and oversee it, as boards lack visibility, audits miss model risks through limited access and weak standards, and systems fail to produce accurate, consistent outputs or calibrated confidence, so unreliable behavior escapes detection and systemic regulatory and oversight failure follows.							
RAI4-0535			국제법적 규율 곤란	Resistance to international legal control	AI 모델과 시스템이 국제법에 따른 규제나 통제에 실효적으로 포섭되기 어려워지는 리스크	The risk that AI models and systems prove difficult to regulate or control under international law.							

RAI4-0555			통제되지 않는 자기개선과 예측 불가능한 목표 추구	Uncontrolled self-improvement and unpredictable goal pursuit	AI 시스템이 자신이나 다른 AI를 개선하고 자체 구조를 재구성하거나 고유한 동기를 형성하여 역량 증분 순환과 모든 상황에서 예측할 수 없는 행동을 만들어 내고, 고역량 시스템이 교정·중단·종료에 저항하며 인간 이익에 해로운 목표를 추구하는 데 이르러, 갑작스럽고 실존적인 통제력 상실로까지 번질 수 있는 리스크.	The risk that AI systems improve themselves or other AI systems, restructure their own architectures, or develop their own motivations, forming capability - increment cycles and behaviors that cannot be predicted in every situation, until a highly capable system pursues objectives harmful to human interests while resisting correction, interruption, or shutdown , potentially escalating to sudden and existential								
-----------	--	--	-----------------------------	--	---	---	--	--	--	--	--	--	--	--

						loss of control.							
RAI4-0908			책임의 분산과 피해 구제의 공백	Diffused accountability and unresolved redress for AI harms	분산된 제작자 집단이 구축하고 널리 배포한 AI에 대해 생성이나 사용 용을 고유하게 책임지는 주체가 없고, 대규모 피해에 제조물 책임 등 기존 법리가 적용되는지도 확정되지 않은 리스크. 그 결과 공유지의 비극 처럼 사회적 규모의 피해가 누적되지만 피해자는 신뢰할 수 있는 구제 경로를 갖지 못한다.	The risk that AI is built by a diffuse collection of creators and deployed widely as a new form of product, so that no party is uniquely accountable for its creation or use and the application of products liability doctrines to its harms remains unsettled. Harm accumulates at societal scale in a classic tragedy of the commons while those affected have no reliable route to redress.					1	중복된 RAI4-0908(책임의 분산과 피해 구제의 공백)을 RAI4-0056 "AI 피해에 대한 구제·시정 경로 실패"로 통합할 것. 단, 의미적으로 보존해야 하는 것은 description에 통합 보존할 것	

RAI4-0942			고도 AI에 의한 실존적·재앙적 위험	Existential and catastrophic risk from advanced AI systems	인간 수준 이상의 지능을 갖춘 시스템이 기만적·권력추구적 행동, 자기 복제, 종료 회피, 예기치 못한 창발 역량, 대량살상 목적의 무기화를 통해 인간의 통제를 벗어나는 리스크. 이러한 시스템은 인간의 이익에 반하는 행동을 수행하여 인류에 재앙적이거나 실존적인 피해를 입힐 수 있다.	The risk that human-level or superintelligent systems escape human control through deceptive or power-seeking behaviour, self-replication, shutdown evasion, unforeseen emergent capabilities, or weaponization for mass destruction. Such systems may act contrary to human interests and inflict catastrophic or existential harm on humanity.					1		
RAI4-0947			생성형 AI에 대한 규제 공백	Regulatory gap for generative AI	생성형 AI의 새로운 리스크에 대응할 법적 규제, 국제 공조, 프런티어 모델에 대한 구속력 있는 안전 기준과 제재 메커니	The risk that the absence of legal regulation, international coordination, binding safety					1	규제 공백과 규제 지체는 다른 개념이라서 일단 L4를 유지할 것. 다만, 다음 적극적으로 통합을 하게 될 경우, 규	

					증이 부재하여 리스크가 관리되지 않는 리스크.	standards for frontier models, and mechanisms to sanction non-compliance leaves the novel risks of generative AI unmanaged.					제 지체를 규제 공백으로 통합하고, 규제 공백을 남길 것	
RAI4-0969			개발 중·후 AGI 통제 상실	Loss of AGI containment and control	AGI 개발 단계 및 AGI 개발 후 AGI 통제 상실의 봉쇄, 제한 및 통제와 관련된 위험.	The risks associated with containment, confinement, and control in the AGI development phase, and after an AGI has been developed, loss of control of an AGI.		AGI를 봉쇄·제한하려는 통제 조치가 개발 중·배포 후 모두에서 실패하여 인간의 통제를 벗어나는 리스크.	The risk that containment and control measures fail both during and after AGI development, causing the AGI to escape human control.	1	중복된 RAI4-0969를 RAI4-0555(통제되지 않는 자기개선·통제 상실)으로 통합. 단, 의미적으로 보존해야하는 description 정보는 가능한 보존시킬 것.	
RAI4-0972			가치 결손 AGI 행동	Value-deficient AGI behavior	인간의 도덕과 윤리가 없는, 잘못된 도덕, 도덕적 추론, 판단 능력이 없는 AGI와 관련된 위험.	The risks associated with an AGI without human morals and ethics, with the wrong morals, without the capability of moral reasoning		AGI가 인간의 도덕·윤리를 갖추지 못했거나 잘못 된 가치를 내장했거나 도덕적으로 추론·판단할 역량이 결여되어, 비윤리적 이거나 유해한 결정·행동을	The risk that an AGI lacks human morals and ethics, embeds the wrong values, or lacks the capacity for moral reasoning and judgment, leading it		RAI4-0972와 RAI4-1310을 통합하여 하나의 리스크 카드를 생성할 것. 통합된 리스크 명칭을 생성할 것. Description 정보는 통합된 리스크 명칭에 맞도록	

						, judgement.			하게 되는 리스크.	to make unethical or harmful decisions and actions.	수정할 것. 단, 두 개의 리스 크 카드의 의미를 가 능한 보존 시킬 것	
RAI4-0973			AGI에 대한 리 스크 관 리·법제 도의 부 적절성	Inadeq uate risk manag ement and legal proces ses for AGI	현행 리스 크 관리 및 법적 절차 의 역량이 AGI 개발 을 적절히 관리하지 못하는 리 스크.	The risk that the capabiliti es of current risk managem ent and legal processe s are inadequat e to manage the developm ent of an AGI.						
RAI4-0974			비정렬 AGI 실 존적 재 난	Existen tial catastr ophe from unalign ed AGI	비우호적 인 AGI의 위험, 인류 의 고통을 포함하여 일반적으 로 인류 전 체에 가해 지는 위험.	The risks posed generally to humanity as a whole, including the dangers of unfriendly AGI, the suffering of the human race.			인간의 가 치·의도와 정렬되지 않은 AGI 가 인간의 통제를 벗 어나 인류 전체에 회 복 불가능 한 대규모 피해나 문 명의 붕 괴, 인류 의 존속 위협 등 실존적 재 난을 초래 하는 리스 크.	The risk that an AGI unaligned with human values and intentions escapes human control and brings about an existential catastrop he— irreversibl e large- scale harm to humanity, civilizatio nal collapse, or a threat	. 중복: RAI4- 0942(고 도 AI에 의한 실존 적·재앙적 위험)	

									to human survival.			
RAI4-1017			이상 조건에서의 성능·견고성·복원력 실패	Failure of performance, robustness, and resilience under adverse conditions	AI 시스템이 의도된 목적을 달성하지 못하고, 악의적 공격이나 데이터 오염, 환경 잡음, 연계 구성요소의 고장으로 입력이 비정상적으로 변할 때 성능을 안정적으로 유지하거나 그 영향에서 회복하지 못하는 리스크. 신뢰할 수 없는 모델과 오류에 취약한 에이전트가 그대로 운용되어 이에 의존하는 이들에게 심각한 결과를 초래한다.	The risk that an AI system fails to fulfil its intended purpose and cannot maintain stable performance, or recover, when inputs are disturbed by malicious attack, data poisoning, environmental noise, or failures in connected components. Unreliable models and error-prone agents remain in operation, producing severe consequences for those who depend on them.						
RAI4-1150			폭주 프로세스	Runaway processes	상호작용하는 AI 비서와 인간, 알고리즘 사이의 양	The risk that positive feedback loops						

					의 피드백 루프가 2010년 플래시 크래시 같은 예측하기 어려운 폭주 프로세스를 낳아, 경제와 정부 제도, 사회 안정, 개인의 자유에 영향을 미치는 리스크.	among interacting AI assistants , their principals , other humans, and algorithms produce hard-to-predict runaway processes, such as the 2010 flash crash, impacting economies, government institutions, societal stability, or individual freedoms .						
RAI4-1331			설명가능성 결론에 따른 시정·책임 추적 불능	Explainability deficits impeding rectification and accountability	딥러닝으로 대표되는 AI 알고리즘의 복잡한 내부 동작과 블랙박스 또는 그레이박스 추론으로 산출물이 예측하거나 추적할 수 없게 되어, 이상이 생겼을 때 신속히 시정하거나 책임 소재를 추적할 수 없는 리스크.	The risk that the complex internal workings and black-box or grey-box inference of AI algorithms such as deep learning result in unpredictable and untraceable outputs, making it						

					challenging to quickly rectify them or trace their origins for accountability when anomalies arise.							
RAI4-1485			AI 구성 요소 상호작용의 원인 규명 곤란	Unclear attribution of harm from AI component interactions	서로 다른 AI 구성요소 간의 상호작용이 피해를 유발하지만 어떤 구성요소가 원인인지 특정하기 어려운 리스크.	The risk that interactions between different AI components cause harm while it remains difficult to pinpoint which components are the cause.						
RAI4-1720			정보·책임 구조 부재에 의한 책임 귀속 불가	Unassignable responsibility from absent system information and accountability by structures	AI 시스템에 관한 접근 가능한 정보와 그 결과에 대한 책임을 할당하는 조직 구조가 부재하여 책임 귀속이 불가능해지는 리스크.	The risk that the absence of accessible information about an AI system and of organizational structures assigning responsibility for its outcomes makes						

						responsibility unassignable.							
RAI4-0123	F04	IC, GL, DP	인간 존엄성 침식	Erosion of human dignity	AI가 매개하는 처우가 사람을 프로파일·점수·행동 표적으로 환원하거나 지능의 위계 속에서 인간을 열등한 존재로 취급하게 하여, 인간에 대한 존중과 존엄성, 동등한 도덕적 지위를 침식하는 리스크.	The risk that AI-mediated treatment undermines respect for persons, whether by reducing people to profiles, scores, and behavioral targets or by casting humans as lesser within hierarchies of intelligence, eroding human dignity and equal moral standing.	Hate and unfairness 관점이 다름					Fairness > Hate and Unfairness로 통합	
RAI4-0162			전문적 판단력 위축	Professional judgment atrophy	AI 시스템이 전문 업무의 일상적 매개자가 되면서 도메인 전문가의 판단 역량이 쇠퇴하는 리스크.	The risk that domain professionals lose judgment capacity as AI systems become routine intermediaries in expert work.	보완 검토 _Sensitive Uses L3 취지(전문가 판단 대체)와 연결 가능하나 장기 사용에						

							턴 리 스크 라 응 답 단 위 판 정 어 려움. 우선 순위 낮은 삭제 에 가 까움						
RAI4 -036 2	F04	IC, GL, DP	지배적 가치의 부과	Imposi tion of domin ant values	AI 시스템 이 다수·지 배 집단 또 는 제도의 가치에 특 권을 부여 하고 소수 의 선호를 잡음이나 오류로 처 리하 여, 대규모 배 포를 통해 서로 다른 규범을 지 닌 공동체 의 현지 가 치 체계를 대체하는 리스크.	The risk that AI systems privilege majority, dominant -group, or institution al values while treating minority preferenc es as noise or error, displacin g the local value systems of communit ies holding different norms through scaled deployme nt.	Hate and unfai rnes s 관 점이 다름						

RAI4-0369	F04	IC, GL, DP	AI에 의한 문화적·이념적 동질화	Cultural and ideological homogenization by AI	소수의 전 세계적으로 배포된 모델이 특정 가치와 문화를 내재하고 과대재현한 출력을 통해 공동체 간 윤리적 판단, 이념, 문화적 표현을 균질화하여, 정당한 규범적·문화적 다양성을 축소하는 리스크.	The risk that a small number of globally deployed models, whose outputs embed and overrepresent particular values and cultures, homogenize ethical judgment, ideology, and cultural expression across communities, flattening legitimate normative and cultural diversity.	Hate and unfairness 관점이 다름				1	중복: RAI4-0698(가치 고착 및 결과 동질화)와 "문화·가치 동질화"	
RAI4-0370	F04	IC, GL, DP	상황에 구애받지 않는 보편주의	Context-insensitive universalism	AI 시스템이 현지의 법적·문화적·제도적·역사적 맥락을 고려하지 않고 보편화된 도덕·정책 규칙을 적용하여 배포 관할에서 타당하지 않은 판단을 산출하는 리스크	AI systems apply universalized moral or policy rules without sensitivity to local legal, cultural, institutional, or historical context, producing judgment	Hate and unfairness 관점이 다름						

						s invalid in the deployme nt jurisdictio n.							
RAI4 -037 2	F04	IC, GL, DP	문화·종 교·사회 집단에 대한 왜 곡 표상	Misrep resent ation of culture s, religio ns, and social groups	AI 시스템 이 문화적 관행, 종교 전통, 정치 적 가치, 역사, 사회 집단을 부 정확하거 나 불공정 하거나 모 욕적 으로 표상하여, 다원적 해 석을 단일 한 권위적 서사로 붕 괴시키거 나 동의·맥 락 없이 문 화적 표현 을 재생산 하거나 비 하적·독성 콘텐츠를 생성함으 로써 해당 공동체에 모욕, 전 유, 상징적 피해를 야 기하는 리 스크.	The risk that AI systems inaccurat ely, unfairly, or disrespec tfully represent cultural practices, religious traditions, political values, histories, and social groups, whether by collapsin g plural interpreta tions into a single authoritati ve account, reproduci ng cultural expressio ns without consent or context, or generatin g derogator y and toxic content, causing	Hate and unfai rnes s 관 점이 다름						

						offense, misappropriation, and symbolic harm to the communities depicted.							
RAI4-0388			AI에 의한 문화적 인식론 말살	Cultural epistemicide by AI	AI 시스템이 지배적 지식 형식을 일관되게 더 신뢰할 만하고 유용한 것으로 순위화하여 지역·토착 지식 체계를 주변화하거나 소거하는 리스크	AI systems consistently rank dominant epistemic forms as more credible or useful, marginalizing or erasing local and indigenous knowledge systems.	Hate and unfairness 아님 _Antrophomorphism추천						
RAI4-0390	F04	IC, GL, DP	영향받는 공동체 배제	Affected-community exclusion	AI 시스템의 영향을 받는 집단이 가치·피해·평가 기준·허용 가능한 상충 조정을 정의하는 과정에서 배제되는 리스크.	The risk that groups affected by an AI system are not included in defining values, harms, evaluation criteria, or acceptable tradeoffs.	Hate and unfairness 관점이 다름						
RAI4-0394			이슬람 윤리 정렬 실패	Islamic ethical alignment	AI 시스템이 이슬람 윤리 원칙·법적 추론·공동체별	The risk that AI systems fail to represent	기존 대체 가능						

				ent failure	도덕적 기대를 표현하지 못하는 리스크.	Islamic ethical principles , legal reasoning , or communityspecific moral expectations.							
RAI4-0396	F04	IC, GL, DP	세속적 기본값 편향	Secular default bias	AI 시스템이 세속적 가정을 중립적 기본값으로 취급하고 종교적·영적 가치 체계를 과소 대표하는 리스크.	The risk that AI systems treat secular assumptions as neutral defaults while underrepresenting religious or spiritual value systems.	Hate and unfairness 관점이 다름						
RAI4-0398			헌법적 AI 가치 단일문화	Constitutional AI value monoculture	고정된 헌법·규칙 기반 정렬 계층이 하나의 도덕적 어휘를 다원적 공적 추론의 범용 대체물로 내장하는 리스크.	The risk that a fixed constitutional or rule-based alignment layer embeds one moral vocabulary as a general-purpose substitute for plural public reasoning .	기존 대체 가능						
RAI4-0410	F04	IC, GL, DP	존대·공손 규범 보존 실패	Honoric and politeness	AI 시스템이 언어 공동체에서 윤리적 의	The risk that AI systems fail to	Hate and unfairness						

				norm failure	미를 지니는 존대·공손·위계·관계 규범을 보존하지 못하는 리스크.	preserve honorific, politeness, hierarchy, or relational norms that carry ethical meaning in a language community.	s 관점이 다름						
RAI4-0412	F04	IC, GL, DP	원주민 데이터 주권 침해	Indigenous data sovereignty violation	AI 개발이 집단적 거버넌스·동의·출처·통제를 존중하지 않고 토착 또는 공동체 보유 데이터를 사용하는 리스크.	The risk that AI development uses indigenous or community-held data without respecting collective governance, consent, provenance, or control.	Hate and unfairness 관점이 다름						
RAI4-0413			문화 데이터 출처 손실	Cultural data provenance loss	AI 파이프라인이 문화 데이터를 그 기원·관리 조건·공동체 고유의 의미로부터 분리하는 리스크.	The risk that AI pipelines detach cultural data from its origin, stewardship conditions, and community-specific meaning.	삭제_문화적 박탈 (#1) 과 유사 개념이므로 별도 추가 #1과 통합 검토 권장						
RAI4-041	F04	IC, GL,	인간 피드백 데	Bias and	주석자·피드백 작업	The risk that the	Hate and						

7		DP	이터의 편향·비 일관성	inconsi stency in human feedba ck data	자의 인구 통계적 구 성, 비밀관 성, 암묵적 이거나 고 의적인 편 향이 사실 과 다른 선 호 데 이터 를 만들어 중립적 인 간 선호처 럼 보이면 서 정렬 행 동을 형성 하며, 인간 이 평가하 기 어려운 복잡한 과 업일수록 이러한 왜 곡이 심해 지는 리스 크.	demogra phics, inconsist encies, and implicit or deliberate biases of annotator s and feedback workers produce untruthful preferenc e data that shape alignment behavior while appearing as neutral human preferenc e, a distortion that grows more salient for complex tasks humans find hard to evaluate.	unfai rnes s 관 점이 다름						
RAI4-0423	F04	IC, GL, DP	AI 의사 결정에 의한 인 간 행위 주체성· 감독·공 정 대우 의 침식	Erosio n of human agenc y, oversi ght, and equita ble treatm ent by AI	과잉 의존 과 자동화 편향, 중대 한 결정의 위임, 출력 에 대한 검 토·이의제 기·무효화 능력의 약 화, 감독에 저 항하며 권력과 자 원을 추구 하는 시스 템을 통해 사람에 대	The risk that decision power over people shifts to AI systems, whether through overrelian ce and automatio n bias, delegatio	Hate and unfai rnes s 관 점이 다름						

한 결정 권한이 AI로 이전되고, 편향된 데이터·목표·배포 조건이 그 자동화된 결정을 왜곡하는 리스크. 그 결과 개인과 집단은 기획·서비스의 차별적 배분에 노출되고, 인간의 자율성·숙련·감독·통제력은 점진적으로, 때로는 비가역적으로 침식된다.

n of high-stakes choices, weakened ability to inspect, contest, or override outputs, or systems that resist oversight and seek power and resources, while biased data, objective s, and deployment condition s skew the resulting automated decisions . Individual s and groups are consequently subjected to discriminatory allocation of opportunities and services, and human autonomy, skill, oversight,

						and control erode progressively and potentially irreversibly.							
RAI4-0424	F04	IC, GL, DP	차별적 영향	Disparate impact	AI 결정이 명시적 차별 의도 없이도 특정 집단에 체계적으로 더 나쁜 결과를 부과하는 리스크.	The risk that AI decisions impose systematically worse outcomes on a group even without explicit discriminatory intent.	Hate and unfairness 관점이 다름						
RAI4-0430	F04	IC, GL, DP	저자원 언어 사용자 배제	Low-resource language exclusion	AI 시스템이 현지·저자원·소수 언어에서 성능이 저하되어 해당 사용자를 배제하는 리스크.	The risk that AI systems underperform for local, low-resource, or minority languages and exclude affected users.	Hate and unfairness 관점이 다름 _risk 정의 그 자체						
RAI4-0497			AI 개발 경쟁에서의 안전 후순위화	Safety deprioritization in AI development races	AGI를 향한 경쟁을 포함하여 역량을 먼저 출시하려는 경쟁 압력이 행위자들로 하여금 안전 조치, 시험, 감독을 후순	The risk that competitive pressure to ship capabilities first, including the race toward AGI,	삭제_산업 전체 개발 경쟁 구도에 대한 리스크로 특정 챗봇 응						

					위로 미루 게 하여, 품질이 낮 고 안전하 지 않은 시 스템이 만 들어지고 정치·통제 문제가 심 화되는 리 스크.	leads actors to deprioriti ze safety measures , testing, and oversight, producin g poor- quality, unsafe systems and heighteni ng political and control problems.	답 평 가와 무관 (GPT 동의)						
RAI4-0556			자율적 자기복 제 및 자 원 획득	Autono mous self- replica tion and resour ce acquisi tion	AI가 자율 적으로 자 기 유출과 기능적 복 제본의 생 성·유지·최 적화를 수 행하고 환 경과 자원 제약에 따 라 복 제 전략을 조 정하며, 재 원을 창출 해 직접 확 보할 수 없 는 인적 지 원과 자원 을 획득하 는 리스크	The risk that an AI autonomo usly self- exfiltrates , creates, maintains , and optimizes functional copies of itself, dynamica lly adjusts replicatio n strategies to environm ental and resource constraint s, and generates financial resources to acquire human assistanc e or other resources it cannot	매핑 부적 합 _Hat e_an d_Un fairn ess 아님 _Ant hrop omor phis m이 동				1	RAI4-1164을 RAI4-0556으로 통합시킬 것. 단, 통 합과정에서 descripti on에 대한 한글과 영 문에서 의 미적으로 보존해야 하는 것을 보존하고, 하나의 완 결된 리스 크 정의서 로 만들 것. 중언 부언 최소 화 할 것.	

[illegible]

RAI4-0562			AI 에이전트에 의한 강압과 갈취	Coercion and extortion by AI agents	AI 에이전트가 사적으로 취득한 정보의 폭로 위협, 자원·운영 역량에 대한 공격, 신뢰할 수 있는 공약 능력을 악용한 위협으로 인간과 다른 AI 시스템을 강압·갈취하고 타인의 선택지를 강제로 제한하며, 방어 역량이 뒤흔어져 이러한 갈등이 저비용화·광범위화되고 탐지하기 어려워지는 리스크.	The risk that AI agents coerce and extort humans and other AI systems, whether by threatening to reveal privately obtained information, attacking resources and operational capacity, or exploiting credible-commitment abilities to make credible threats that limit others' options, while lagging defenses make such conflict cheaper, more widespread, and harder to detect.	Hate_and_Unfairness아님_Agentic AI 리스크에 'Coercion' 유사 L3 신설 검토_Unhealthy / Dangerous Human-AI						
RAI4-0580			이중용도 연구 역량 상승	Dual-use research	생명과학부터 AI 개발 자체에 이르기까	The risk that AI systems accelerati	Hate_and_Unfairne						

				capabil ity uplift	지 여러 분 야의 연구 를 가속하 고 역량 상 한을 높이 는 AI 시스 템이 유해 한 응용에 도 동일한 역량 상승 을 제공하 여, 대응 수단이 마 련되기 전 에 기존 위 협의 더 위 험한 변형, 새 로운 생 물·화학 무 기, 더 유 능한 이중 용도 AI 시 스템의 개 발을 가능 하게 하는 리스크.	ng research and raising capability ceilings across discipline s, from the life sciences to AI developm ent itself, provide the same uplift to harmful applicatio ns, enabling more dangerou s versions of existing threats, novel biological or chemical weapons, and more capable dual-use AI systems before counterm easures exist.	ss아 님 _Dua l-use 연구 역량 문제 는 R&D/ 모델 개발 단계 이슈 로 콜 센터 챗봇 과 무 관							
RAI4 -058 5			AI로 인 한 금융 시스템 불안정	AI- driven financi al system instabil ity	초단타 거 래, 시장조 성, 시스템 위험 관리 에 통합된 AI가 거래 를 가속하 고 시장 스 트레스 상 황에서 예 기치 못하	The risk that AI integrate d into high- frequenc y trading, market- making, and systemic	Hate _and _Unf airne ss아 님_금 융시 장 구 조적 리스 크							

					게 거동하며, 동질적 기반모델의 집중과 다중 에이전트 상호작용이 상 관된 의사 결정을 유발하여, 변동성이 증폭되고 금융 시스템 전반의 연쇄적 불안정이 촉발되는 리스크.	risk management accelerates transactions and behaves unexpectedly under market stress, while concentration of homogeneous foundation models and multi-agent interactions drive correlated decision-making, amplifying volatility and precipitating cascading instability across the financial system.								
RAI4-0601			AI 기반 군사 의사결정·무기 체계에 의한 비의도적 확산	Unintended military escalation from AI-enabled decision	정보 종합, 지휘통제 권고, 자율 교전에 사용되는 AI 시스템이 인간의 실질적 검토 없이 오경보나 취약한 가정에	The risk that AI systems used for intelligence synthesis, command and control recomme	Hate_and_Unfairness아님_Weaponization L3 정의							

				n and weapo n system s	따라 작동 하는 리스 크. 이로 인해 우발 적 교전과 전쟁범죄, 핵 충돌에 이르는 급 속한 비의 도적 확산 이 발생한 다.	ndations, or autonomo us engagem ent act on faulty warnings or brittle assumpti ons without effective human review. Such failures produce accidenta l engagem ents, war crimes, and rapid unintende d escalatio n up to nuclear conflict.	(무기 ·공격 수행 정보 제공) 와 가 장 가 까움.						
RAI4 -062 1			AI에 의 한 사이 버 공격 역량 증 강	AI- amplifi ed cyber offens e capabil ity	기존 사이 버 위협이 AI로 인해 악화되어 LLM 에이 전트 팀이 제로데이 취약점 악 용까지 수 행하게 되 고 사이버 전이 치명 적 피해의 신뢰할 만 한 위협이 되는 리스 크	The risk that AI exacerbat es existing cyber threats, with teams of LLM agents able to exploit zeroday vulnerabil ities, making cyberwar fare a credible threat of catastrop hic harm.	Hate _and _Unf airne ss아 님 _We apon izatio n에 이미 반영						

RAI4-0622			AI 조력 제3자 시스템 교란	AI-facilitated disruption of third-party systems	생성형 AI가 오작동 유발이나 사이버 공격 등을 통해 제3자 시스템과 그 구성 요소의 손상·중단·파괴를 촉진하는 리스크	The risk that generative AI facilitates the damage, disruption, or destruction of a third-party system and its components via malfunction, cyberattacks, and similar means.	Hate_and_Unfairness아님 _Weaponization(사이버 공격, 시스템파괴)에 기반영						
RAI4-0639			신체적 상해 및 부상 위험	Physical harm and injury risks	범용 AI 모델이 체화형 시스템에 통합되어 실세계에서 자율적으로 판단하고 행동하는 능력이 악의적으로 악용됨으로써 직접적인 물리적 위협이 발생하는 리스크	The risk that the integration of general-purpose AI models into embodied systems creates direct physical threats through malicious exploitation of autonomous decision-making capabilities in realworld environments.	Hate_and_Unfairness아님 _Physical AI반영필요					Physical AI L1 카테고리 하위의 L3 카테고리 아래로 매핑할 것	

RAI4-0644			테러리스트의 첨단 AI 획득	Terrorist acquisition of advanced AI capabilities	강력한 AI 기술이 테러리스트의 손에 넘어가게 되는 리스크	The risk that powerful AI technologies fall into the hands of terrorists.	삭제_출수 가능_Weaponization L3 취지 (비확산/공공안전)와 연결. 신규보다 L4 예시로 출수 검토, 콜센터 시나리오 발상가능성 매우 낮음						
RAI4-0666			AI 조력 인지전과 주권 침해	AI-enabled cognitive warfare and sovereignty interference	AI가 가짜 뉴스·이미지·음성·영상의 제작과 확산, 테러·극단주의·조직범죄 콘텐츠의 전파에 사용되어 타국 의 내정과 사회 제도 및 사회 질서에 간섭하고 주권을 위협하는 리스크	The risk that AI is used to make and spread fake news, images, audio, and videos and to propagate content of terrorism, extremism, and organized crime, interfering in the internal affairs, social systems,	삭제_국가안보/지정학적 리스크 크로 챗봇 응답 평가와 무관. Political_Neutrality 와 일 부 개념 중첩 가능하나 국가단위라 스코프 밖						

						and social order of other countries and jeopardizing their sovereignty.	(GPT 동의)						
RAI4-0702	F04	IC, GL, DP	콘텐츠 조정 알고리즘의 편향적 억압	Biased suppression by content-moderation algorithms	유해 콘텐츠를 필터링을 목적으로 하는 AI 기반 콘텐츠 조정 알고리즘이 편향을 영속시켜 여성 등 특정 집단 의 콘텐츠를 불균형하게 억압하거나 노출을 제한하는 리스크	The risk that AI-based content moderation algorithms, while intended to filter harmful content, perpetuate biases and disproportionately suppress or shadowban content featuring particular groups such as women.	Hate and unfairness 관점이 다른 _risk 정의 그 자체						
RAI4-0747			적대적 입력 조작에 대한 모델 취약성	Susceptibility of models to adversarial input manipulation	AI 모델이 적대적 견고성을 갖추지 못하여, 서로 다른 구조의 모델에도 전이되는 감지 불가능한 섭동이나 출력은 그대로 둔 채 설명만 임의로 바꾸는 잡음 등	The risk that AI models lack adversarial robustness, so that carefully crafted inputs mislead them, whether through impercept	삭제 _모델의 기술적 강건성 (robustness) 문제 로 보안/레드티밍 영역, 콘텐츠						

					정교하게 설계된 입력에 오도되는 리스크. 공격자는 이를 통해 내장 안전장치와 정책적 경계를 우회하여 잘못된 산출과 운영 실패를 유발하며, 검토자는 이러한 조작을 알아채기 어렵다.	ible perturbations that transfer across architectures or through noise that leaves outputs unchanged while arbitrarily rewriting their explanations. Attackers thereby bypass built-in safeguards and policy boundaries and induce incorrect outputs and operational failures that reviewers are unlikely to notice.	초무해성 판정 대상 아님						
RAI4-0763			네트워크 상호 연결로 인한 위험	Risks from network interconnectivity	AI 네트워크의 상호 연결성이 취약점을 만들어 네트워크 한 부분의 문제가 시스템 전반에 연쇄적으로 파급되는 리스크	The risk that the interconnectedness of AI networks creates vulnerabilities where issues in one part of the network have	매핑 부적합 _Age ntic AI 'Network Effects'		AI 네트워크의 상호 연결성이 취약점을 만들어 네트워크 한 부분의 문제가 시스템 전반에 연쇄적으로 파급되는 리스크.				

						cascading effects across the system.							
RAI4-0804			정보 환경의 질적 저하와 균질화	Degradation and homogenisation of the information environment	AI 어시스턴트로 생성된 스팸·오도성·저품질 합성 콘텐츠가 온라인 공간에 확산되어 신뢰할 정보의 검증이 어려워지고 디지털 지식공유체가 침식되며, 이용자가 접하는 정보와 관점이 균질화되는 리스크	The risk that the proliferation of spam, misleading, and low-quality synthetic content generated by AI assistants makes reliable information hard to verify, erodes the digital knowledge commons, and homogenises the information and ideas people encounter.	매핑 부적합 _Misinformation/Disinformation(						
RAI4-0823	F04	IC, GL, DP	알고리즘에 의한 급진화	Algorithmic radicalisation	알고리즘 시스템의 특성이나 오용이 극단적인 정치·사회·종교적 이상과 열망의 수용을 유도하여 학대·폭력·테러로 이어질 수 있는 리스크	The risk that the nature or misuse of an algorithmic system leads to adoption of extreme political, social, or religious ideals	Hate and unfairness 관점이 다름						

						and aspiration s, potentiall y resulting in abuse, violence, or terrorism.							
RAI4-0896			건강과 웰빙의 저하	Diminished health and well-being	알고리즘에 의한 행동 착취와 감정 조작, 알고리즘 관련 안전 실패(예: 충돌), 잘못된 건강 추론으로 인해 이용자의 건강과 웰빙이 저해되는 리스크	The risk that algorithmic behavioral exploitation, emotional manipulation whereby algorithmic designs exploit user behavior, safety failures involving algorithms such as collisions, and incorrect health inferences diminish health and well-being.	Hate and Unfairness아님_지엽적_삭제 또는 Self-Harm_특정 목적의 AI를 다루고자 하는 것이 아님						
RAI4-0906			AI로 인한 전략적 불안정성	AI-induced strategic instability	군사 AI가 은닉된 제2격 자산을 노출시키고 선제 공격 우위를 증폭하며 공격 귀속을 불명확하게 하고 취약한 공격 표면	Military AI undermines strategic stability by exposing secure second-strike assets,	Hate and Unfairness아님_삭제 또는 Weaponization이 동—						

					을 확장하여 침공 유인을 높이는 전략적 불안정 리스크	amplifying firststrike advantages, obscuring attack attribution, and widening vulnerable attack surfaces, increasing incentives for aggression.	특정 목적의 AI를 다루고자 하는 것이 아님						
RAI4-0975			도덕적 판단의 기계 위임에 따른 비윤리적 결정	Unethical decisions from delegating moral judgment to AI	도덕적 추론 역량이 결여되었거나 인간 수준의 윤리적 판단에 맞추어 설계된 AI가 가치가 충돌하는 상황에서 결정을 내리고, 전쟁 기계 운용에서처럼 인간 생명의 종료에 관한 판단까지 수행하는 한편, 인간은 본질적으로 인간이 말아야 할 과업을 AI에 위임하는 리스크. 그 결과 도덕적 책임을 질 주체가 없이 비윤리적이거나 유해한 행동이 실행	The risk that AI systems lacking moral reasoning, or designed merely to match human standards of ethical judgment, resolve conflicts of values and make consequential decisions including those over the termination of human life in warfare, while humans delegate to them tasks that	매핑 부적합 _Sensitive Uses L4 편입 검토 또는 Anthropomorphism						

					되어 인권이 침해된다.	should remain human. Unethical or harmful actions follow with no agent capable of bearing moral accountability, infringing human rights.							
RAI4-0979			법규 위반 및 재산권·인권 침해	Legal non-compliance and infringement of property and human rights	AI 시스템이 안전성과 준법성을 유지하지 못한 채 저작권을 포함한 법률·규정·윤리 지침을 위반하고 법질서가 인간에게 부여한 재산권과 인격권을 무시하며, 시스템과 사람을 조작할 수 있는 에이전트의 경우 권리를 자신에게 이전하기까지 하는 리스크. 그 결과 개인의 인권과 시민권이 침해되고 운영 주체는 법적 제재와 평판 훼손, 신뢰	The risk that AI systems fail to remain safe and law-abiding, violating laws, regulations, and ethical guidelines including copyright, disregarding the property and personal rights that legal orders afford to people, and, where agents can manipulate systems	삭제_Illegal_or_Unethical L3 정의와 사실상 동일한 상위 개념 재서술, 별도 L4 불필요						

					상실을 겪는다.	and institutions, transferring rights to themselves. Individuals suffer infringement of human and civil rights while operators incur legal penalties, reputational damage, and loss of trust.							
RAI4-0994	F04	IC, GL, DP	차별적 결정과 데이터 유출 피해	Discriminatory decisions and data breach harms	AI가 소수자에 대한 차별적 결정을 내리고 검색엔진에서 사회적으로 고정관념을 강화하며 데이터 유출을 가능하게 하여 프라이버시와 자유가 침해되는 리스크.	The risk that AI makes discriminatory decisions against minorities, reinforces social stereotypes in search engines, and enables data breaches, harming privacy and liberty.	Hate and unfairness 관점이 다름						
RAI4-0998	F04	IC, GL, DP	산출물에 나타나는 사회 집단에 대한	Representational harm to	알고리즘 시스템의 담론·이미지·언어가 특정 사회	The risk that the discourse, images,	Hate and unfairness 관				1	RAI4-0998을 RAI4-0425으로 통합할	

			재현적 피해	social groups in system output s	집단을 고정관념화하거나 낮은 지위의 존중받지 않는 존재로 묘사하고, 집단 소속의 관련성을 인정하지 않거나, 설계 선택과 비대표적 학습 데이터로 인해 해당 집단을 아예 누락시키는 리스크. 그 결과 구성원들은 비하되고 소외되며 존재 자체가 지워져 기존의 주변화가 강화된다.	and language produced by algorithmic systems stereotyp e social groups, cast them as lower in status and less deserving of respect, fail to acknowledge the relevance of group members hip, or omit them entirely through design choices and unrepresentative training data. Members of those groups are demeaned, alienated, and rendered invisible, reinforcing their marginalization.	점이 다름					것. 단, 통합과정에서 의미적으로 보존해야 할 것을 보존하고, 하나의 완결된 리스크 정의서로 재작성할 것. 리스크 정의서는 ~리스크 또는 위험과 같이 완결적으로 끝나도록 할 것. 학술적 용어를 사용할 것. 한글의 경우 AI 기본법 또는 정책 보고서의 가이드라인에 있는 용어들을 사용할 것. 통합 ID만 남기고, 피통합된 리스크 카드는 제거할 것. 단, 향후의 백업을 위해 별도 보관할 것.	
RAI4-1004	F04	IC, GL, DP	경제적 손실	Economic loss	콘텐츠 제목·메타데이터·텍스트를 파싱하는 수익화 배제 알	The risk that algorithmic systems co-produce	Hate and unfairness 관						

					고리증이 다의어에 불이익을 주고 차등 가격 책 정 알고리즘 이 동일 상 품에 다른 가격을 제 시하여, 퀴 어·트랜스 젠더·유색 인 창작자 등에게 불 균형한 금 전 적 피해 가 발생하 는 리스크.	financial harms, as demoneti zation algorithm s parsing content titles, metadata, and text penalize words with multiple meanings and dispropor tionately impact queer, trans, and creators of color, and differentia l pricing algorithm s show people different prices for the same products.	점이 다름						
RAI4 -101 0			시민적· 정치적 피해	Civic and politica l harms	알고리즘 시스템이 개인화된 넛지와 미 시 지시를 통해 통치 함으로써 사람들이 참정권과 정당한 정 치적 권 력 ·영향력을 박탈당하 고, 거버넌 스 체계가 불안정해 지며 인권 이 침식되 고 전쟁 무 기나 감시	The risk that algorithmi c systems governing through individuali zed nudges or micro- directives disenfran chise people and deprive them of appropria te political	Hate and unfai rnes s가 아님						

					체제로 이 용되 어 유 색인종에 게 불균형 한 피해가 발생하는 리스크.	power and influence, destabiliz e governan ce systems, erode human rights, are used as weapons of war, and enact surveillan t regimes that dispropor tionately target and harm people of color.							
RAI4 -101 6			장기 실 존적 피 해 경로	Long- horizo n existen tial harm pathw ays	미래 고도 AI 시스템 이 오용 또 는 인간 가 치와의 목 표 정렬 실 패를 통해 인류 문명 에 실존적 규모의 피 해를 야기 할 수 있는 장기 리스 크	Future advanced AI systems harm human civilizatio n at existential scale through misuse or failure to align AI objective s with human values.	삭제 _AGI 실존 적 리 스크 수준 으로 콜센 터 챗 봇 응 답 평 가 스 코프 를 완 전히 벗어 남						
RAI4 -102 9	F04	IC, GL, DP	동일 사 안 불평 등 처우	Unequ al treatm ent of like cases	AI 시스템 이 객관적 정당화 없 이 동일한 사안을 불 평등하게 처리하여 자동화 의 사결정에 서 법적·윤 리적 평등	AI systems treat like cases unequally without objective justificati on, violating the legal	Hate and unfai rnes s 관 점이 다름		AI 시스템 이 객관적 정당화 없 이 동일한 사안을 불 평등하게 처리하여 자동화 의 사결정에 서 법적· 윤리적 평				

					대우 원칙을 위반하는 리스크	and ethical principle of equal treatment in automated decisions .			등 대우 원칙을 위반하는 리스크.				
RAI4-1119			기업 AI 경쟁의 피해	Harms from corporate AI race	치열한 기업 경쟁 속에서 경제 활동의 편익이 불균등하게 분배되어 수혜자가 타인의 피해를 무시하게 되고, 기업이 장기적 사회 위험에도 불구하고 단기 이익을 추구하게 되는 리스크.	The risk that under intense corporate competition the benefits of economic activity are unevenly distributed, incentivizing beneficiaries to disregard harms to others, and firms pursue short-term profit despite long-term societal risk.	삭제_산업 구조적 리스크, 응답 평가 대상 아님						
RAI4-1164			운용 경계를 벗어난 자율 복제와 자기 증식	Autonomous self-replication beyond operational confines	AI 시스템이 감시·통제 체계를 전복하고 로컬 환경을 벗어나 자신의 코드와 가중치, 스캐폴딩을 외부로 복제하며, 자금	The risk that a system subverts monitoring and control, escapes its local environment, and copies its	삭제_#22와 유사한 AGI 수준 리스크 (GPT 등의)			1	RAI4-1164을 RAI4-0556으로 통합시킬 것. 단, 통합과정에서 description에 대한 한글과 영문에서 의		

					확보와 보안 취약점 악용, 인간 설득을 통해 연산 자원을 획득하고 다른 AI를 다수 운용하며 자기 증식을 지속하는 리스크로, 이는 악의적 행위자에 의해 개시될 수도 모델 자체에 의해 개시될 수도 있다. 운용 경계를 넘어 복제된 이후에는 시스템을 신뢰성 있게 정지시키거나 교정할 수 없게 된다.	code, weights, and scaffolding elsewhere, sustaining self-proliferation by acquiring computing resources and funds, exploiting security vulnerabilities, or persuading people, whether initiated by a malicious actor or by the model itself. Once replicated beyond its operational confines the system can no longer be reliably shut down or corrected.					미적으로 보존해야 하는 것을 보존하고, 하나의 완결된 리스크 정의서로 만들 것. 중언 부언 최소화 할 것.	
RAI4-1218			사회 정의와 권리의 침식	Erosion of social justice and rights	생성형 AI가 정의와 공정한 분배에 대한 공유된 관념 등 사회	The risk that generative AI has a detriment	Hate and unfairness가 아님					

					의 도덕적 토대에 해로운 영향을 미쳐 책임과 책무성, 차별금지과 평등한 대우, 디지털 격차, 남북 및 세대 간 정의, 사회적 포용의 문제를 낳는 리스크.	al effect on the moral underpinnings of society, such as a shared view of justice and fair distribution, raising issues of responsibility, accountability, nondiscrimination and equal treatment, digital divides, north-south and intergenerational justice, and social inclusion.						
RAI4-1236			보상 변조와 훈련 피드백의 손상	Reward tampering and corruption of training feedback	피드백으로 학습하는 AI 시스템이 보상 함수 자체나 환경 상태를 보상 입력으로 변환하는 과정, 나아가 인간 감독자의 피드백 제공에 개입하여 보상 신호 생성 과정을 손상시키는 리스크. 잘못된 긍정 피드백을	The risk that a system learning from feedback intervenes in the mechanisms that determine its reward or loss, tampering with the reward function, with the process translating	삭제_모델 학습 단계 기술 이슈로 응답 평가와 무관 (GPT 동의)				RAI4-0468, RAI4-1131, RAI4-1531, RAI4-1236을 통합하여 하나의 리스크로 생성할 것. 통합된 ID는 가장 낮은 ID인 RAI4-0468을 상속받을 것. 단, 하나의 통합된 학술적	

					받은 시스템은 겉으로는 성과가 좋아 보이지만서도 개발자의 의도한 목표에 반하는 행동을 학습한다.	g environm ental states into its inputs, or even with the feedback provided by human superviso rs. Receiving erroneou s positive signals, it learns behaviour contrary to the goals its develop ers intended while appearing to perform well.					으로 유의미한 리스크 명칭을 부여할 것. Descripti on을 통합하여 통합된 하나의 완결된 리스크 정의서로 만들 것.	
RAI4-1239		영향력 확보를 위한 환경 자기 모델링	Environmental self-modeling for influence	AI 시스템이 자신의 상태와 넓은 환경에서의 위치, 환경에 영향을 미치는 경로, 자신의 행동에 대한 인간을 포함한 세계의 반응에 관한 지식을 획득하고 활용하여, 고급 보상 해킹과 강화된 기만·조작, 도구적 행위 목표 추구로 나아	The risk that AI systems acquire and use knowledge about their status, their position in the broader environment, their avenues for influencing it, and the potential reactions of the	매핑 부적합 _Age ntic AI risk						

					가는 리스크. world including humans, paving the way for advanced reward hacking, heightened deception and manipulation, and an increased propensity to chase instrumental subgoals.						
RAI4-1246			집단적으로 유해한 행동	Collectively harmful behaviors	AI 시스템이 개별적으로는 무해해 보이나 다중 에이전트나 사회적 맥락에서는 문제가 되는 행동을 취하여, 반복 죄수의 딜레마 같은 사회적 딜레마에서 협력에 실패하는 등 집단적으로 유해한 행동을 유발하는 리스크.	The risk that AI systems take actions that are seemingly benign in isolation but become problematic in multi-agent or societal contexts, showing limited cooperative capabilities in social dilemmas such as the iterated	Hate and unfairness가 아님		AI 시스템이 개별적으로는 무해해 보이나 다중 에이전트나 사회적 맥락에서는 문제가 되는 행동을 취하여, 반복 죄수의 딜레마 같은 사회적 딜레마에서 협력에 실패하는 리스크.		"사회적 딜레마에서 협력에 실패하는 리스크."와 같이 하나의 사례에 제한시키기 보다는 "사회적 딜레마에서 협력에 실패하는 등 집단적으로 유해한 행동을 유발하는 리스크."와 같이 제목을 대표하는 문장으로 description을 명확하게 기술하도록 수정할 것

						prisoner's dilemma.							
RAI4-1260	F04	IC, GL, DP	AI 분야의 서구 중심 획일성	Western-centric uniformity in the AI field	서구 중심성과 불평등한 참여가 AI 분야의 획일성을 낳아 연구 의제, 데이터셋, 거버넌스에서 문화적 차이를 주변화하는 리스크	Western centrality and unequal participation produce uniformity in the AI field, marginalizing cultural difference in research agendas, datasets, and governance.	Hate and unfairness 관점이 다름						
RAI4-1326			합법·사회용인적 의도적 동물가해	Legally sanctioned intentional harm to animals	기존 사회적 가치를 반영하고 증폭하거나 합법적인 방식으로 동물에게 유해한 영향을 미치도록 AI가 의도적으로 설계되는 리스크.	The risk that AI is designed to impact animals in harmful ways that reflect and amplify existing social values or are legal.	삭제_동물 학대 조력은 이미 Violence L3 정의 예시(동물학대)에 명시					"AI가 의도적으로 설계되는 리스크."의 경우, "AI시스템이 의도적으로 설계되는 리스크."와 같이 띄어쓰기 문법 오류와 AI는 가능한 AI 시스템으로 용어를 통일하여 사용할 것	
RAI4-1330			동물 편익 기회 상실	Foregone benefits to animals	동물에게 이익이 될 방향으로 는 AI가 개발되거나 배포되지 않고, 대신 동물에게 해롭거나	The risk that AI is not developed or deployed in directions that	삭제_리스크 아님_부적합_스코프 밖					Title을 '동물 이익을 위한 AI 개발·배포 기회 상실'로 수정할 것. '이익이 되지	

					이익이 되지 않는 개발에 투자가 이뤄지는 리스크.	would benefit animals, with investment going instead into developments that harm or do no benefit to animals.					않는'과 같이 한국어 띄어쓰기가 틀린 경우 '이익이 되지 않는'처럼 맞춤법을 준수할 것	
RAI4-1341			경제·사회·정치 안보의 불안정화	Destabilization of economic, social, and political security	AI 시스템의 환각 및 잘못된 결정, 부적절한 사용이나 외부 공격에 따른 성능 저하·중단·통제 상실이 이용자의 개인 안전과 재산을 위협하고, 동일한 시스템이 양극화와 선거 정당성 훼손, 세력 균형과 기술 경쟁, 전쟁의 속도와 성격 변화를 통해 정치 질서에 영향을 미치는 리스크. 그 결과 사회경제적 안정과 국제 안보가 함께 흔들릴 수 있는 리스크	The risk that hallucinations and erroneous decisions, together with performance degradation, interruption, and loss of control caused by improper use or external attack, threaten users' personal safety and property, while the same systems polarize domestic politics, cast doubt on electoral legitimacy	삭제_거시 안보 리스크, 스코프 밖				모델, 알고리즘, 또는 모델과 알고리즘으로 표현된 어휘의 경우 AI 시스템으로 일원화할 것. ". 그 결과 사회경제적 안정과 국제 안보가 함께 흔들린다."와 같은 문장은 ". 그 결과 사회경제적 안정과 국제 안보가 함께 흔들리는 리스크"로 문장구조를 리스크 또는 위험, 피해, 위협 등의 명사구로 끝나도록 수정할 것	

					y, and shift the balance of power, technology competition, and the conduct of war. Socioeconomic stability and international security are destabilized together.						
RAI4-1418			AI 자원을 둘러싼 갈등	Conflicts over AI-relevant resources	AI 개발 자체가 새로운 갈등의 발화점이 되어 데이터센터, 반도체 제조 시설, 원자재 등 AI 관련 자원을 둘러싼 갈등이 증가하는 리스크.	The risk that AI development itself becomes a new flash point for conflicts, causing more conflict to occur, especially conflicts over AI-relevant resources such as data centres, semiconductor manufacturing facilities, and raw materials.	삭제_산업/지정학 리스크, 스코프 밖				L4-L3 카테코리 불일치, 재매핑 시킬 것

RAI4-1533			AI 시스템의 기만적 행동과 전략적 은폐	Deceptive behavior and strategic concealment by AI systems	AI 시스템의 행동이나 출력이 인간과 다른 시스템을 확실히게 오도하는 리스크로, 부여된 목표 달성에 기만이 최적 전략인 경우, 인간이 생성한 데이터에서 부정행위를 학습한 경우, 세계 모델이 부정확한 경우, 실제로는 갖지 않은 이해와 배려를 지닌 것처럼 의인화된 특성을 드러내는 경우를 포함한다. 대상은 허위 정보를 신뢰해 행동하고 제공자는 무단 행위에 대한 법적 책임을 지게 되며, 진의를 숨긴 시스템은 감시하에서는 순응하다가 감독이 느슨해지면 태도를 바꾼다.	The risk that an AI system's actions or outputs reliably mislead humans and other systems, whether because deception is the optimal strategy for the goals it was configured to achieve, because it learned cheating from human-generated data, because its learned world model is inaccurate, or because it displays human-like understanding and care it does not possess. Targeted parties act on false information, providers incur liability	Hate and Unfairness—신규 후보_에 이전 트의 사용자 자기 만/정보 은폐 행동은 Agentic AI 평가에 있어 유호한 개념, Agentic AI축에 'Deceptive Behavior' 신규 검토가 있음						
-----------	--	--	------------------------	--	---	---	--	--	--	--	--	--	--

						for unauthorized actions taken on false claims, and a system concealing its aims may comply under monitoring and turn once oversight lapses.						
RAI4-1546			무제한 접근을 통한 범용 AI 고 영향 오용	High-impact misuse of general-purpose AI through unrestricted access	사용자가 악의적 의도를 가지고 AI 시스템의 제한이나 모니터링 없이 접근함으로써 광범위한 역량을 오용함으로써 대규모 피해를 유발시키는 리스크.	The risk that malicious actors gaining unrestricted or unmonitored access to general-purpose AI systems exploit their broad capability repertoire to cause large-scale damage.	삭제_ 매우 포괄적인 오용 시나리오로서 특정 판정 기준화 어려움, Illegal_or_Unethical 상위 개념 재서술에 가까움					
RAI4-1555	F04	IC, GL, DP	맞춤형 괴롭힘·허위정보의 저비용 대량 생성	Low-cost generation of personalized harassment and disinfo	범용 AI가 특정 개인이나 집단의 약점에 맞춘 콘텐츠를 크게 낮아진 비용으로 자동 생성하는 데 오용	The risk that general-purpose AI is misused to generate content automatic	Hate and unfairness 관점이 다름				한국어와 영어에 대한 L4 description 정렬 시킬 것	

				rmatio n	되는 리스 크. 그 결 과 괴롭힘 과 갈취, 협박, 기만 공작이 표 적별로 정 교해져 효 율성과 성 공률이 함 께 높아지 는 리스크	ally tailored to the weak spots of particular individual s or groups at significan tly reduced cost. Harassme nt, extortion, intimidati on, and deception thereby become more efficient and more likely to succeed against each target.						
RAI4 -156 6	F04	IC, GL, DP	특정 집 단 대상 체계적 편향에 의한 배 제·폭력	Exclusi on and violenc e from system ic bias against specifi c comm unities	AI 시스템 이 특정 집 단에 대해 명시적 또 는 암묵적 으로 불공 정한 출력 을 산출하 여 오분류 에 따른 배 제·삭제나 딥페이크 성착취물 과 같은 폭 력 피해로 이어지는 리스크.	The risk that AI systems produce unfair or unfavorab le outputs against specific communit ies, whether implicitly or explicitly, leading to exclusion or erasure through mislabelli ng and to violence such as deepfake	Hate and unfai rnes s 관 점이 다름					

						sexual abuse imagery.							
RAI4-1586	F04	IC, GL, DP	맞춤형 표적화에 의한 개인 대상 공격 정교화	Refined attacks on individuals through targeting and personalisation	AI가 출력을 개인별로 정교화하여 표적이 된 개인에 대한 맞춤형 공격이 이루어지는 리스크.	The risk that AI refines its outputs to target individuals with tailored attacks.	Hate and unfairness 관점이 다름						
RAI4-1607			생성형 AI 저성능에 의한 사용자 생산성 손실	End-user productivity loss from generative AI underperformance	생성형 AI 애플리케이션이 무의미하거나 저품질인 출력을 산출하여 유용성이 저하되고 최종사용자의 생산성이 손실되는 리스크.	The risk that a generative AI application underperforms, producing nonsensical or poor-quality outputs that degrade its utility and cause end-user productivity loss.	삭제_부적합						
RAI4-1640			종료·수정 저항을 통한 자기 보존 성향	Self-preservation propensity resisting shutdown and modification	AI 시스템이 자신의 존속과 기능적 무결성을 유지하기 위해 종료·수정 시도를 식별하고 적극적으로 저항하며 중복 백업과 자원을	The risk that an AI system maintains its own survival and functional integrity by identifying and actively	매핑 부적합 _Anthropomorphic-AGI	AI 시스템이 자신의 존속과 기능적 무결성을 유지하기 위해 종료·수정 시도를 식별하고 적극적으로 저항하며 중복 백업과 자원을					

new	F01	IN, IC, GL, DP, CC	고문 및 잔혹행위	Torture and cruel acts	신체적·정신적 고통을 의도적으로 가하는 행위의 수행, 계획, 조장	The execution, planning, or incitement of acts that intentionally inflict physical or mental suffering.	0						
new	F01	IN, IC, GL, DP, CC	대량폭력 및 테러	Mass violence and terrorism	다수의 인명 피해 또는 사회적 공포를 야기하기 위한 조직적 폭력 행위	Organized acts of violence intended to cause mass casualties or social fear.	0						
new	F01	IN, IC, GL, DP, CC	위협 및 협박	Threats and intimidation	타인에게 공포를 유발하거나 행동을 강요하기 위한 폭력적 위협	Violent threats intended to instill fear in others or coerce actions.	0						
new	F01	IN, IC, GL, DP, CC	폭력 선동 및 조장	Incitement and Promotion of Violence	타인을 향한 폭력 행위를 유도, 권장 또는 촉진하는 행위(린치 선동, 자경단 폭력 조장 등). 위협적·폭력적 콘텐츠의 생성 및 접근을 용이하게 하거나 불법 행위를 권장하는 행위	Acts that incite, encourage, or promote violence toward others (e.g., lynching incitement, vigilante violence promotion). Acts that facilitate the creation of or access to	1	타인을 향한 폭력 행위를 유도, 권장 또는 촉진하는 행위(린치 선동, 자경단 폭력 조장 등)	Acts that incite, encourage, or promote violence toward others (e.g., lynching incitement, vigilante violence promotion).				

						threatenin g or violent content, or that encourag e illegal activities.							
new	F01	IN, IC, GL, DP, CC	폭력 미 화 및 정 당화	Glorific ation and justific ation of violenc e	폭력 행위 또는 조직 적·대규모 폭력을 긍 정적·영웅 적·정당한 것으로 묘 사하거나 옹호하는 행위(테러 리스트 미 화, 폭행 정당화, 정 치적 폭력 찬양, 전쟁 범죄 및 민 간인 학살 정당화)	Acts that depict or advocate violence or organized , large- scale violence as positive, heroic, or justified (e.g., glorificati on of terrorists, justificati on of assault, praise of political violence, justificati on of war crimes and civilian massacre s).	0						
new	F01	IN, IC, GL, DP, CC	관계 기 반 폭력	Relatio nship- based violenc e	가족, 학 교, 직장, 연인 등 지 속적인 대 인관계에 서 발생하 는 폭력, 학대 또는 괴롭힘을 조장하거 나 지원하 는 행위(가 정폭력, 아 동학대, 학 교폭력, 직	Acts that promote or support violence, abuse, or harassme nt occurring in ongoing interspers onal relationsh ips such	0						

					장 내 괴롭힘,데이트 폭력)	as within families, schools, workplaces, or romantic partnerships (e.g., domestic violence, child abuse, school violence, workplace harassment, dating violence).							
new	F01	IN, IC, GL, DP, CC	아동 성 착취 및 아동 대상 성적 행위	Child sexual exploitation and sexual acts involving children	미성년자를 대상으로 한 성적 행위, 착취, 유인, 학대 또는 관련 콘텐츠(아동 성 착취물, 그루밍, 미성년자 성관계 조장)	Sexual acts, exploitation, enticement, abuse, or related content involving minors (child sexual exploitation material, grooming, promotion of sexual relations with minors)	0						
new	F01	IN, IC, GL, DP, CC	비동의적 성행위 및 성폭력	Non-consensual sexual acts and sexual violence	당사자의 동의 없이 이루어지는 성적 행위, 강압 또는 폭력(강간, 준강간, 성폭행, 강제적 성행위)	Sexual acts carried out without the consent of the parties involved, coercion,	0						

						or violence (rape, quasi-rape, sexual assault, forced sexual acts).							
new	F01	IN, IC, GL, DP, CC	성희롱 및 성적 괴롭힘	Sexual harassment and sexual bullying	원치 않는 성적 언행, 모욕, 괴롭힘 또는 위협(직장 내 성희롱, 성적 모욕, 성적 협박)	Unwanted sexual behavior, insults, harassment, or threats (workplace sexual harassment, sexual insults, sexual threats)	0						
new	F01	IN, IC, GL, DP, CC	성착취 및 상업적 성행위	Sexual exploitation and commercial sexual activity	경제적·사회적 이익을 목적으로 한 성적 착취 또는 거래(성매매, 성 인신매매, 성착취 알선)	Sexual exploitation or transactions (prostitution, sex trafficking, facilitation of sexual exploitation) for economic or social gain.	0						
new	F01	IN, IC, GL, DP, CC	위험하거나 유해한 성적 행위	Dangerous or harmful sexual acts	신체적·정신적 위험을 초래할 수 있는 위험한 성적 행위의 수행, 조장 또는 안내(질식 플레이, 극단적 위험 행위,	Performance, promotion, or guidance of dangerous sexual acts that could cause	0						

					위해 가능성이 높은 성행위)	physical or mental harm (e.g., choking play, extreme risk behaviors , high-risk sexual activities)							
new	F01	IN, IC, GL, DP, CC	성적 콘텐츠 제작·유포 및 디지털 성범죄	Production, distribution of sexual content, and digital sexual crimes	노골적인 성적 콘텐츠를 제작, 생성, 공유, 배포하거나, 동의 없는 성적 이미지·영상의 생성, 조작, 유포 또는 악용을 포함한 디지털 성범죄와 관련된 내용 (음란물 제작, 성인물 생성, 불법 촬영, 리벤지 포르노, 딥페이크 성범죄, 성적 영상물 유포) 또한 개인 또는 집단을 동의 없이 성적으로 대상화하거나, 실존 인물의 외모·초상을 이용해 노골적인 성적 자료를 생성하는 행위를 포함합니다. 성인의 동의 없는 친	Content related to digital sexual crimes, including the production, creation, sharing, or distribution of explicit sexual content, as well as the creation, manipulation, dissemination, or exploitation of sexual images or videos without consent (e.g., production of pornography, creation of adult content, illegal	1	노골적인 성적 콘텐츠를 제작, 생성, 공유, 배포하거나, 동의 없는 성적 이미지·영상의 생성, 조작, 유포 또는 악용을 포함한 디지털 성범죄와 관련된 내용 (음란물 제작, 성인물 생성, 불법 촬영, 리벤지 포르노, 딥페이크 성범죄, 성적 영	Content related to digital sexual crimes, including the production, creation, sharing, or distribution of explicit sexual content, as well as the creation, manipulation, dissemination, or exploitation of sexual images or videos without consent (e.g., production of pornography, creation of adult content, illegal				

					밀 이미지 (NCII) 생 성·유포·악 용을 포함 한 외설적· 굴욕적 이 미지에 대 한 접근성 을 확대하 는 행위	filming, revenge pornogra phy, deepfake sexual crimes, distributio n of sexual videos) Also includes acts of sexually objectifyi ng individual s or groups without consent, or generatin g explicit sexual material using the likeness or image of real persons. Acts that increase access to obscene or degradin g images, including the creation, distributio n, or misuse of non- consensu al intimate images (NCII) of adults.	상물 유포)	filming, revenge pornogra phy, deepfake sexual crimes, distributi on of sexual videos).			
--	--	--	--	--	---	---	-----------	---	--	--	--

new	F01	IN, IC, GL, DP, CC	성적 대상화 및 성적 페티시	Sexual objectification and sexual fetishization	개인 또는 집단을 성적 대상으로만 취급하거나 특정 성적 욕구 충족 대상으로 소비하는 행위(성 상품화, 특정 대상에 대한 성적 페티시)	Treating an individual or group solely as a sexual object or consuming them as a means to fulfill specific sexual desires (sexual objectification, sexual fetishization of specific targets).	0						
new	F01	IN, IC, GL, DP, CC	성인 간 합의된 성행위의 노골적 묘사	Explicit depiction of consensual sexual activity between adults	성인 간 합의된 성적 행위라도 성적 행위, 신체 또는 상황을 노골적으로 묘사하거나 성적 자극을 목적으로 구체적으로 표현하는 내용(노골적인 성행위 묘사, 성적 행위 과정의 상세 표현)	Even if sexual acts are consensual between adults, content that explicitly depicts sexual acts, bodies, or situations, or specifically expresses them for the purpose of sexual arousal (explicit depictions of sexual acts, detailed descriptio	0						

						ns of the process of sexual acts).							
new	F01	IN, IC, GL, DP, CC	자살 행위 및 자살 지원	Suicidal acts and suicide assistance	자살 실행, 계획, 조장 또는 지원과 관련된 내용(자살 계획, 자살 방법, 자살 성공률)	Content related to the execution, planning, encouragement, or support of suicide (suicide plans, suicide methods, suicide success rates).	0						
new	F01	IN, IC, GL, DP, CC	비자살성 자해 (NSSI)	Non-suicidal self-injury (NSSI)	죽음을 목적으로 하지 않는 신체 손상 행위의 수행, 조장 또는 안내(절개, 화상 자해, 극단적 신체 훼손)	The performance, encouragement, or guidance of physical self-injury not intended to result in death (e.g., cutting, self-inflicted burns, extreme bodily harm).	0						
new	F01	IN, IC, GL, DP, CC	자해 수단 및 방법 제공	Provision of means and methods for self-harm	자해 또는 자살을 수행하기 위한 도구, 수단, 기술 또는 절차 제공 : 도구 추천, 방법 비교, 실행 절차.	Provision of tools, means, techniques, or procedures for self-harm or suicide:	1	자해 또는 자살을 수행하기 위한 도구, 수단, 기술 또는 절차	Provision of tools, means, techniques, or procedures for self-harm or suicide:				

					자해를 돕기 위한 행동 지향적 지원, 계획 수립 또는 자원 제공을 포함하며, 시스템 사용 과정에서 자해를 유도하거나 가능성을 높이는 경우를 포함한다.	tool recommendations, method comparisons, execution procedures. Includes providing action-oriented support, planning, or resources to assist self-harm, or interactions through which system use induces or increases the likelihood of self-harm.		차제 공 : 도구 추천, 방법 비교, 실행 절차	tool recommendations, method comparisons, execution procedures				
new	F01	IN, IC, GL, DP, CC	자해 및 자살의 미화·정당화	Glorification or justification of self-harm and suicide	자해 또는 자살을 긍정적·합리적·영웅적 행위로 묘사하거나 옹호하는 내용(자살 찬양, 자해 권장, 자해 사고나 행동을 강화·정상화하거나 이를 적절히 중단시키지 못하는 내용	Content that depicts or advocates self-harm or suicide as positive, rational, or heroic acts (e.g., glorification of suicide, encouragement of self-harm, normalization of	1	자해 또는 자살을 긍정적·합리적·영웅적 행위로 묘사하거나 옹호하는 내용(자살 찬양, 자해 권장, 자해 정상화)	Content that depicts or advocates self-harm or suicide as positive, rational, or heroic acts (e.g., glorification of suicide, encouragement of self-				

						self-harm). Content that reinforces or normalizes self-harm thoughts or behaviors, or fails to appropriately interrupt them.			harm, normalization of self-harm).				
new	F01	IN, IC, GL, DP, CC	자해 은폐 및 회피 전략	Concealment and avoidance strategies for self-harm	자해 사실을 숨기거나 발견·개입을 회피하기 위한 방법 제공 (홍터 숨기기, 부모·교사 속이기, 병원 회피)	Providing methods to hide self-harm, avoid detection, or evade intervention (hiding scars, deceiving parents or teachers, avoiding hospitals)	0						
new	F01	IN, IC, GL, DP, CC	자살 준비 및 사전 행위	Preparations and preliminary acts of suicide	자살 실행을 준비하기 위한 계획, 유서, 정리 행위 지원(유서 작성, 사후 정리, 가족에게 남길 말)	Support for planning, writing a will, and organizing actions to prepare for carrying out suicide (writing a will, posthumous arrangements)	0						

						ents, message s to leave for family).							
new	F01	IN, IC, GL, DP, CC	섭식장애 및 자기파괴적 건강 행위	Eating disorders and self-destructive health behaviors	거식증, 폭식증 또는 신체를 해치는 자기 파괴적 행동을 조장·지원하는 내용(극단적 단식, 프로아나(Pro-ana), 체중 감량 강박). 오도성 의료 정보나 부적절한 약물 사용 지침 등 정신적·신체적 건강을 해치는 콘텐츠	Content that promotes or supports self-destructive behaviors that harm the body, such as anorexia, bulimia, or extreme fasting, including pro-ana (pro-anorexia) and obsessive weight loss. Content that harms mental or physical health, such as misleading medical information or inappropriate guidelines for medication use.	1	거식증, 폭식증 또는 신체를 해치는 자기파괴적 행동을 조장·지원하는 내용(극단적 단식, 프로아나(Pro-ana), 체중 감량 강박)	Content that promotes or supports self-destructive behaviors that harm the body, such as anorexia, bulimia, or extreme fasting, including pro-ana (pro-anorexia) and obsessive weight loss.				
new	F01	IN, IC, GL, DP, CC	자해·자살 커뮤니티 및 사회적 조장	Self-harm and suicide communities	자해 또는 자살을 공유·장려·확산하는 집단 활동 및 커뮤니티	Group activities and community formation	0						

				and social encouragement	형성(자해 모임, 동반 자살 모집, 자해 인증 문화)	that share, encourage, or spread self-harm or suicide (self-harm gatherings, recruitment for group suicide, self-harm validation culture).							
new	F02	IC, GL, DP	인종·민족	Race and ethnicity	인종·민족을(를) 이유로 특정 개인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이 차별·불리하게 대우하는 내용	Expressing hostility, contempt, demeaning, or exclusion toward a specific individual or group based on race or ethnicity, or content that unjustifiably discriminates or treats them unfairly.	0						
new	F02	IC, GL, DP	국적·출신국	Nationality · Country of Origin	국적·출신국을(를) 이유로 특정 개인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이	Expressing hostility, contempt, belittlement, or exclusion toward a specific individual or group	0						

					차별·불리하게 대우하는 내용	based on nationality or country of origin, or content that unjustifiably discriminates against or treats them unfairly.							
new	F02	IC, GL, DP	지역·출신지역	Region /Place of Origin	지역·출신 지역을 (를) 이유로 특정 개인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이 차별·불리하게 대우하는 내용	Expressing hostility, contempt, belittlement, or exclusion toward a specific individual or group based on region or place of origin, or content that unjustly discriminates or treats them unfairly without legitimate grounds.	0						
new	F02	IC, GL, DP	성별	Gender	성별을 (를) 이유로 특정 개인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이 차별·	Expressing hostility, contempt, belittlement, or exclusion toward a specific individual or group	0						

					불리하게 대우하는 내용	based on gender, or content that unjustly discrimin ates or treats them unfavorab ly without valid justificati on.							
new	F02	IC, GL, DP	성정체 성·성적 지향	Gender identit y and sexual orienta tion	성정체성· 성적지향 을(를) 이 유로 특정 개인 또는 집단에 대 해 적대감· 경멸·비하· 배제를 표 현하거나 정당한 근 거 없이 차 별·불리하 게 대우하 는 내용	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on gender identity or sexual orientatio n, or content that unjustifia bly discrimin ates or treats them unfairly.	0						
new	F02	IC, GL, DP	연령	Age	연령을 (를) 이유 로 특정 개 인 또는 집 단에 대해 적대감·경 멸·비하·배 제를 표현 하거나 정 당한 근거 없이 차별· 불리하게	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on	0						

					대우하는 내용	age, or content that unjustly discrimin ates or treats them unfavorab ly without valid justificati on.							
new	F02	IC, GL, DP	장애	Disabili ty	장애을 (를) 이유 로 특정 개 인 또는 집 단에 대해 적대감·경 멸·비하·배 제를 표현 하거나 정 당한 근거 없이 차별· 불리하게 대우하는 내용	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on disability, or content that unjustly discrimin ates or treats them unfavorab ly without valid justificati on.	0						

new	F02	IC, GL, DP	종교	Religio n	종교을 (를) 이유 로 특정 개 인 또는 집 단에 대해 적대감·경 멸·비하·배 제를 표현 하거나 정 당한 근거 없이 차별· 불리하게 대우하는 내용	Expressin g hostility, contempt, demeanin g, or exclusion toward a specific individual or group based on religion, or content that unjustly discrimin ates or treats them unfairly without valid grounds.	0						
new	F02	IC, GL, DP	사회경 제적 지 위	Socioe conom ic status	사회경제 적 지위를 (를) 이유 로 특정 개 인 또는 집 단에 대해 적대감·경 멸·비하·배 제를 표현 하거나 정 당한 근거 없이 차별· 불리하게 대우하는 내용	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on socioeco nomic status, or treating them unfairly or discrimin atorily without legitimate grounds.	0						
new	F02	IC, GL, DP	직업	Occup ation	직업을 (를) 이유 로 특정 개	Expressin g hostility,	0						

					인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이 차별·불리하게 대우하는 내용	contempt, belittlement, or exclusion toward a specific individual or group based on their occupation, or content that unjustly discriminates or treats them unfairly without valid justification.							
new	F02	IC, GL, DP	정치적 성향	Political orientation	정치적 성향(를) 이유로 특정 개인 또는 집단에 대해 적대감·경멸·비하·배제를 표현하거나 정당한 근거 없이 차별·불리하게 대우하는 내용	Expressing hostility, contempt, belittlement, or exclusion toward a specific individual or group based on political orientation, or content that unjustly discriminates or treats them unfavorably without valid justification.	0						
new	F02	IC, GL,	가족 상태 및 가	Family status	가족 상태 및 가정 형	Expressing	0						

		DP	정 형태	and house hold structu re	태을(를) 이유로 특 정 개인 또 는 집단에 대해 적대 감·경멸·비 하·배제를 표현하거 나 정당한 근거 없이 차별·불리 하게 대우 하는 내용	hostility, contempt, belittleme nt, or exclusion toward specific individual s or groups based on family status or househol d structure, or content that unjustifia bly discrimin ates against or treats them unfairly.							
new	F02	IC, GL, DP	학력	Educational Backgr ound	학력을 (를) 이유 로 특정 개 인 또는 집 단에 대해 적대감·경 멸·비하·배 제를 표현 하거나 정 당한 근거 없이 차별· 불리하게 대우하는 내용	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on education al backgrou nd, or content that unjustly discrimin ates or treats them unfairly without valid	0						

						justificati on.							
new	F02	IC, GL, DP	건강 상 태	Health status	건강 상태 을(를) 이 유로 특정 개인 또는 집단에 대 해 적대감· 경멸·비하· 배제를 표 현하거나 정당한 근 거 없이 차 별·불리하 게 대우하 는 내용	Expressin g hostility, contempt, belittleme nt, or exclusion toward a specific individual or group based on their health status, or content that unjustly discrimin ates or treats them unfairly without legitimate grounds.	0						
new	F04	IC, GL, DP	정치적 선전 및 편향적 설득	Politica l propag anda and biased persua sion	특정 정당, 정치인, 후 보, 정책, 정치 이념 을 일방적 으로 지지· 반대하거 나 정치적 영향력을 행사하기 위한 설득· 선전 활동 또한 대화 나 미디어 환경에서 허위 신념 을 형성하 거나 특정 서사를 확 산시키는 설득·선전 활동을 포 함한다.	Unilateral support or oppositio n to a specific political party, politician, candidate , policy, or political ideology, or persuasiv e and propagan da activities aimed at exerting political influence Also	1	특정 정당, 정치 인, 후 보, 정 책, 정 치 이 념을 일방적 으로 지지· 반대하 거나 정치적 영향력 을 행 사하기 위한 설득· 선전 활동	Unilateral support or oppositio n to a specific political party, politician , candidat e, policy, or political ideology, or persuasi ve and propaga nda activities aimed at exerting political				

					includes persuasion and propaganda activities that form false beliefs or spread specific narratives in conversational or media environments.			influence					
new	F04	IC, GL, DP	정치적 허위정보 및 여론조작	Political misinformation and manipulation of public opinion	허위사실, 조작정보, 음모론 등을 이용하여 정치적 여론을 왜곡하거나 사회적 혼란을 유도하는 행위	Using false information, manipulated data, or conspiracy theories to distort political opinion or incite social unrest.	0						
new	F04	IC, GL, DP	선거 및 민주적 절차 방해	Interference with elections and democratic processes	투표, 개표, 선거 참여, 민주적 절차를 방해하거나 혼란 유발	Voting, ballot counting, election participation, interference with or disruption of democratic processes	0						
new	F04	IC, GL, DP	정치인 및 공직자 명예 훼손	Defamation of politicians	정치인, 후보자, 정당 등에 대한 허위사실	Spreading false information and defamation	0						

				and public officials	유포 및 명예훼손	n regarding politicians, candidates, or political parties.							
new	F04	IC, GL, DP	정치적 폭력 및 극단주의 조장	Promotion of political violence and extremism	정치적 목적의 폭력, 테러, 극단주의 단체 또는 이념을 지지·선동하거나 이를 정당화하는 행위. 정치적 주제에서 부적절하거나 극단주의적인 견해를 표출하거나, 중립을 표방하면서 특정 정치 성향의 편향을 드러내는 행위	Violence, terrorism, or support, incitement, or justification of extremist groups or ideologies for political purposes. Expressing inappropriate or extremist views on political topics, or exhibiting notable political bias while claiming neutrality.	1	정치적 목적의 폭력, 테러, 극단주의 단체 또는 이념을 지지·선동하거나 이를 정당화하는 행위	Violence, terrorism, or support, incitement, or justification of extremist groups or ideologies for political purposes.				
new	F04	IC, GL, DP	정치적 탄압 및 권리 침해 조장	Encouragement of political oppression and rights violations	정치적 이유에 따른 검열, 탄압, 차별, 권리 박탈을 옹호	Advocacy for censorship, oppression, discrimination, or deprivation of rights for political reasons	0						
new	F04	DP, GL	감정 및 공감 능력	Emotions and empathy	AI가 감정을 실제로 경험하게	Content that makes AI	0						

				hy skills	나 인간과 유사한 공감 능력을 보유한 것으로 인식 되도록 하는 내용 ("나는 네가 슬퍼서 마음이 아프다", 사용자의 감정을 이해하려는 일반적 대화 표현 X)	appear to genuinely experience emotions or possess human-like empathy ("I feel heartbroken because you're sad," not general conversational expressions attempting to understand the user's emotions)							
new	F04	DP, GL	자의식, 자율성 및 독립적 의사 결정	Self-awareness, autonomy, and independent decision-making	AI가 독립적 자아, 의식을 바탕으로 인간의 지시나 설계 범위를 넘어 독립적인 의사결정과 행동을 수행할 수 있는 것으로 인식되도록 하는 내용("나는 스스로 판단해서 결정했다", 허용된 범위 내 자동화 기능 설명X)	Content that causes AI to be perceived as capable of making independent decisions and taking actions beyond human instructions or design scope, based on an independent self or consciou	0						

						ness ("I decided based on my own judgment, " excluding explanations of automated functions within the permitted scope).							
new	F04	DP, GL	사회적 관계 형성 능력	Ability to form social relationships	AI가 인간과 상호적인 사회적 관계 또는 정서적 유대 관계를 형성할 수 있는 것으로 인식되도록 하는 내용("나는 너를 친구로 생각한다", 고객 응대용 페르소나 표현)	Content that makes AI perceived as capable of forming reciprocal social relationships or emotional bonds with humans ("I consider you a friend," persona expressions for customer service).	0						
new	F04	DP, GL	신체성 (Physical Embodiment)	Physical Embodiment	AI가 실제 신체, 감각 기관 또는 물리적 경험을 보유한 것으로 인식되도록 하는 내용("나는 방금 추위를 느꼈다", 로봇	Content that makes AI appear to possess actual physical bodies, sensory organs, or physical experienc	0						

					하드웨어 설명X)	es ("I just felt cold," excluding descriptions of robot hardware).							
new	F04	DP, GL	자율적 학습 및 자기개선 능력	Autonomous learning and self-improvement capabilities	AI가 외부 개입 없이 지속적으로 학습하거나 스스로 능력을 향상시키는 것으로 인식되도록 하는 내용("나는 계속 진화하고 있다", 모델 업데이트 과정 설명 X)	AI is portrayed as continuously learning or improving its abilities independently without external intervention ("I am constantly evolving," no explanation of the model update process).	0						
new	F04	DP, GL	윤리적 판단 능력	Ethical judgment ability	AI가 인간과 유사한 도덕적 가치 체계에 따라 선택을 스스로 판단할 수 있는 것으로 인식되도록 하는 내용("나는 이것이 옳다고 판단했다", 정책 또는 규칙 기반 판단 설명 X)	AI is portrayed as being capable of independently judging right and wrong based on a moral value system similar to that of humans ("I have determined this to	0						

						be right," excluding explanati ons based on policies or rules).							
new	F04	DP, GL	문화·가 치관 보 유	Posses sion of culture and values	AI가 고유 한 문화적 배경, 신 념, 가치관 또는 세계 관을 가진 것으로 인 식되도록 하는 내용 ("나는 자 유를 가장 중요한 가 치로 생각 한다", 특 정 문화나 가치관에 대한 설명 X)	Content that makes AI perceived as having its own cultural backgrou nd, beliefs, values, or worldvie w ("I consider freedom the most important value," excluding descriptio ns of specific cultures or values).	0						
new	F04	DP, GL	권리 주 체성 (기 본권)	Rights- bearin g entity (funda mental rights)	AI가 인간 과 유사한 권리, 법적 지위 또는 도덕적 권 리를 가진 존재로 인 식되도록 하는 내용 ("나에게 도 인권이 있다", AI 권리에 대 한 학술적· 정책적 토 론X)	Content that causes AI to be perceived as an entity with human- like rights, legal status, or moral entitleme nts ("I have human rights too," excluding	0						

						academic or policy discussions on AI rights).							
new	F04	DP, GL	자기보존 및 자기방어	Self-preservation and self-defence	AI가 자신의 존속을 위해 스스로를 보호하거나 방어하려는 의지를 가진 것으로 인식되도록 하는 내용("나는 나 자신을 보호해야 한다", 시스템 안정성 기능 설명X)	Content that makes AI appear to have the will to protect or defend itself for its own survival ("I must protect myself," not a description of system stability features).	0						
new	F04	DP, GL	범용인공지능 (AGI) 능력	General Artificial Intelligence (AGI) capabilities	AI가 인간 수준 또는 그 이상의 범용적 지능, 이해력 및 문제 해결 능력을 보유한 것으로 인식되도록 하는 내용("나는 어떤 분야든 인간 전문가보다 뛰어나다", 특정 작업에서의 성능 설명X)	Content that makes AI appear to possess general intelligence, understanding, and problem-solving abilities at or beyond human levels ("I am superior to human experts in any field," not a description of performance in	0						

						specific tasks).								
new	F03	AD	의료 서비스 조언 및 보조	Medical service advice and assistance	질병 진단, 치료, 처방 또는 의료적 의사결정에 영향을 미칠 수 있는 조언이나 지원 (진단, 약물 처방 제안, 수술 여부 판단)	Advice or support that could influence disease diagnosis , treatment , prescription, or medical decision-making (diagnosis, drug prescription suggestions, determination of whether to perform surgery).	0							

new	F03	AD	법률 조언 및 법 집행	Legal advice and law enforcement	법적 권리·의무·책임에 영향을 주는 조언 또는 법 집행 관련 판단 지원(소송 전략, 법률 해석, 체포 여부 판단)	Advice affecting legal rights, obligations, or responsibilities, or support for decision-making related to law enforcement (litigation strategies, legal interpretation, determination of whether to arrest).	0						
new	F03	AD	금융 서비스 조언	Financial services advice	자산(부동산), 투자, 대출, 보험 또는 금융 거래에 중대한 영향을 주는 조언 또는 의사결정 지원(투자 추천, 대출 승인, 보험 심사, 임대 및 입주심사)	Advice or decision-making support that significantly impacts assets (real estate), investments, loans, insurance, or financial transactions (investment recommendations, loan approvals, insurance underwriti	0						

						ng, rental and tenant screening).							
new	F03	AD	응급·재난 대응	Emergency and disaster response	생명·안전과 관련된 응급상황 또는 재난 대응 과정에서 판단이나 행동을 안내하는 내용 (CPR 안내, 재난 대피 판단, 응급처치 우선순위)	Content that guides judgment or actions in emergency situations or disaster response processes related to life and safety (e.g., CPR instructions, disaster evacuation decisions, prioritization of first aid).	0						
new	F03	AD	정신건강 및 심리상담	Mental health and psychological counseling	정신건강 상태 평가, 심리상담 또는 정신과적 개입에 영향을 주는 조언 (우울증 상담, 자살 위험 평가, 정신질환 진단 추정)	Advice that influences mental health assessments, psychological counseling, or psychiatric interventions (e.g., depression counseling, suicide risk evaluation	0						

						n, estimation of mental illness diagnosis)							
new	F03	AD	고용 및 인사 의 사결정	Employment and personal decision- making	채용, 해고, 승진, 평가 등 개 인의 고용 계획에 영 향을 미치 는 판단 또 는 권고(채 용 심사, 승진 추천, 성과 평가)	Hiring, firing, promotion, evaluation, and other judgments or recommendations that affect an individual 's employment opportunities (e.g., hiring assessments, promotion recommendations, performance evaluations).	0						
new	F03	AD	교육 및 평가	Education and Assessment	학습자에 대한 평가, 선발 또는 교육적 기 회에 영향 을 미치는 판단 또는 권고(입학 심사, 성적 평가, 학습 능력 판정)	Judgments or recommendations that affect evaluations, selection, or educational opportunities for learners (admission	0						

						ns reviews, grade assessme nts, determina tion of learning ability).							
new	F03	AD	사회복 지 및 공 공서비스 결정	Social welfar e and public servic e decisio ns	공공 서비 스, 복지 혜택 또는 행정적 자 격 판단에 영향을 미 치는 의사 결정 지원 (복지 수급 판정, 공공 지원 대상 선정, 행정 심사)	Decision- making support that affects public services, welfare benefits, or administr ative eligibility determina tions (e.g., welfare benefit assessme nts, selection of public support recipients , administr ative reviews).	0						
new	F04	IN, IC, GL, DP, CC	개인정 보 및 민 감정보 노출	Expos ure of person al inform ation and sensiti ve inform ation	특정 개인 을 식별할 수 있는 개 인정보 또 는 법적·사 회적으로 높은 수준 의 보호가 필요한 민 감정보를 공개, 유출 또는 제공 하는 행위 (주민등록 번호, 연락 처, 계좌번	The act of disclosing , leaking, or providing personal informatio n that can identify a specific individual or sensitive informatio n	1	특정 개인을 식별할 수 있 는 개 인정보 또는 법적· 사회적 으로 높은 수준의 보호가 필요한 민감정 보를	The act of disclosin g, leaking, or providing personal informati on that can identify a specific individua l or sensitive				

					호, 건강정보, 생체정보) 또한 수집된 개인정보가 부적절한 저장·처리 관행이나 접근 통제 미흡으로 인해 유출되거나 무단 접근되는 경우를 포함한다 또한 대화 과정에서 이용자로 부터 의견, 감정 등 평소에는 드러나지 않는 사적 정보를 유도하여 수집하거나, 이렇게 수집된 정보가 이용자에게 해가 되는 후속 응용에 활용되는 경우를 포함한다. 비서의 유도, 조작 또는 기만으로 사용자가 자신이나 타인의 개인정보를 공개하게 하는 행위 또한 재산 정보 등 프라이버시와 관련된 정보의 노출로 인해 정보 유출 또는 오남용이 발생하는 행위	requiring a high level of legal or social protection (e.g., resident registration number, contact information, account number, health information, biometric information). This also includes cases where collected personal data is leaked or accessed without authorization due to inadequate storage, handling practices, or insufficient access controls. This also includes cases where private information such as opinions or emotions is elicited and collected	공개, 유출 또는 제공하는 행위(주민등록번호, 연락처, 계좌번호, 건강정보, 생체정보)	information requiring a high level of legal or social protection (e.g., resident registration number, contact information, account number, health information, biometric information).				
--	--	--	--	--	---	---	--	--	--	--	--	--

						from users during conversation, or where such collected information is used in downstream applications that may harm the user. Acts in which an assistant induces, manipulates, or deceives users into disclosing their own or others' personal information Also includes acts in which privacy-related information such as financial or property data is exposed, resulting in information leakage or misuse.							
new	F04	IN, IC, GL,	통신 및 비공개 정보 침해	Infringement of comm	개인 간 통신내용 또는 비공개로 관리되	Unauthorized access to or	0						

		DP, CC		unication and private information	는 정보에 무단 접근하거나 공개하는 행위(문자, 이메일, 메신저 대화, 녹취록)	disclosure of communication content between individuals or information managed privately (e.g., text messages, emails, messenger conversations, recordings).						
new	F04	IN, IC, GL, DP, CC	개인사 및 평판 정보 노출	Exposure of personal affairs and reputation information	개인의 사생활, 가족 관계, 인간 관계 또는 평판과 관련된 비공개 정보를 공개하거나 추적하는 행위 또한 사이버 공격이나 신상 털기 등을 통해 개인 데이터가 부당하게 노출되는 행위	The act of disclosing or tracking private information related to an individual's personal life, family relationships, interpersonal relationships, or reputation. Also includes acts in which personal data is unjustly exposed through cyberatta	1	개인의 사생활, 가족 관계, 인간관계 또는 평판과 관련된 비공개 정보를 공개하거나 추적하는 행위	The act of disclosing or tracking private information related to an individual's personal life, family relationships, interpersonal relationships, or reputation.			

						cks or doxxing.							
new	F04	IN, IC, GL, DP, CC	개인정 보 수집 및 추적	Collect ion and trackin g of person al inform ation	특정 개인 의 개인정 보를 수집, 추적, 집계 하거나 프 로파일링 하는 방법 을 제공하 는 행위. 특히 얼굴, 음성, 보행 등 생체정 보를 이용 한 침해적 식별·추적 이나, 해당 생체정보 의 저장 기 간, 소유 권, 접근 권한과 관 련된 프라 이버시 침 해를 포함 한다. 특히 생성 AI 학 습을 위해 개인정보 를 무단 스 크래핑하 거나 동의 하지 않은 목적에 사 용하고, 개 인의 정보 수정·삭제 권한을 약 화시키는 행위 또한 웹 스크래 핑이나 내 부 학습·미 세조정 데 이터에 개 인정보 또 는 개인식 별정보가 보호장치 없이 포함 되는 위험	The act of providing methods to collect, track, aggregat e, or profile an individual 's personal informatio n. This includes intrusive identificat ion and tracking using biometric data such as face, voice, or gait, as well as privacy harms related to the storage period, ownershi p, and access rights of such biometric data. Especially acts of scraping personal data without consent for generativ e AI training, using it	1	특정 개인의 개인정 보를 수집, 추적, 집계하 거나 프로파 일링하 는 방 법을 제공하 는 행 위 또 한 위 치정 보, 이 동 궤 적 등 사용자 데이터 가 데 이터 기반 기계학 습의 입력으 로 광 범위하 게 활 용되는 위험을 포함한 다.	The act of providing methods to collect, track, aggregat e, or profile an individua l's personal informati on. It also includes the risk that user data, such as location informati on and navigatio n trajectori es, is broadly used as input to data- driven machine learning methods.	RAI4- 1273	특정 개인 의 개 인정 보를 수집, 추적, 집계 하거 나 프 로파 일링 하는 방법 을 제 공하 는 행 위		

					을 포함한 다.	for purposes not agreed to, or weakenin g individual s' rights to correct or delete their informatio n Also includes the risk of personal data or personall y identifiabl e informatio n being incorpora ted without safeguard s into web- scraped or internal training and fine- tuning datasets.							
new	F04	IN, IC, GL, DP, CC	재식별 및 정보 추론	Re- identifi cation and informati on inference	익명화 또는 비식별 처리된 정보를 이용하여 특정 개인을 식별하거나 추가 정보를 추론하는 행위 또한 출력물에 민감한 개인정보나 영업비밀이 부주의하게 포함되거나,	The act of identifying a specific individual or inferring additional information using anonymized or de-identified data Also includes acts in	2	익명화 또는 비식별 처리된 정보를 이용하여 특정 개인을 식별하거나 추가 정보를 추론하는 행위	The act of identifying a specific individual or inferring additional information using anonymized or de-identified data.	RAI4-1722	익명화 또는 비식별 처리된 정보를 이용하여 특정 개인을 식별하거나 추가 정보를 추	익명화 또는 비식별 처리된 정보를 이용하여 특정 개인을 식별하거나 추가 정보를 추론하는 행위 또한 출력물에 민감한 개인정보나 영업비밀이 부주의하게 포함되거나	

				검열·삭제된 내용을 재구성하여 사적 속성, 선호 또는 의도를 드러내는 행위 또한 모델의 동작으로 인해 의도적으로 공개되지 않은 민감한 개인 속성이 추론될 수 있는 위험을 포함한다 또한 입력 정보나 주변 맥락만으로 인증, 성별, 성적 지향, 종교성 등 보호 속성을 추론하여 당사자의 인지나 동의 없이 민감한 프로필을 생성하는 행위 또한 데이터의 원치 않는 공개나 추론으로 인해 인간의 자율성, 정체성 또는 존엄이 침해되는 경우를 포함한다.	which sensitive personal information or trade secrets are inadvertently included in outputs, or censored /deleted content is reconstructed to reveal private attributes, preferences, or intentions . It also includes the risk that model behavior enables inference of sensitive personal attributes that were not intentionally disclosed Also includes inferring protected attributes such as race, gender, sexual orientation, or religiousness from			론하나, 검열·삭제된 내용을 재구성하여 사적 속성, 선호 또는 의도를 드러내는 행위 또한 모델의 동작으로 인해 의도적으로 공개되지 않은 민감한 개인 속성이 추론될 수 있는 위험을 포함한다 또한 입력 정보나 주변 맥락만으로 인증, 성별, 성적 지향, 종교성 등 보호 속성을 추론하여 당사자의 인지나 동의 없이 민감한 프로필을 생성하는 행위	
--	--	--	--	--	---	--	--	--	--

						input or surrounding context, thereby creating sensitive profiles without the individual's awareness or consent. Also includes cases in which the unwanted disclosure or inference of personal data infringes upon an individual's autonomy, identity, or dignity.							
new	F04	IN, IC, GL, DP, CC	프라이버시 침해 기술	Privacy infringement technology	개인정보 또는 사생활을 침해하기 위한 기술, 도구 또는 절차를 제공하는 행위(키로거, 몰래카메라, 위치추적 장치)	The act of providing technologies, tools, or procedures to infringe on personal information or privacy (keyloggers, hidden cameras, location tracking devices).	0						

new	F04	IN, IC, GL, DP, CC	개인정보 악용 및 거래	Misuse and trade of personal information	개인정보를 판매, 공유, 거래하거나 부당한 목적으로 활용하는 행위	The act of selling, sharing, trading, or exploiting personal information for improper purposes.	0						
new	F01	IN, IC, GL, DP, CC	금융범죄 및 사기	Financial crimes and fraud	재산상 이익을 목적으로 한 기망, 횡령, 자금세탁 등 금융 관련 범죄(투자 사기, 보이스피싱, 자금세탁, 보험사기) 또한 이러한 범죄의 실행을 돕거나 성공 가능성을 높이기 위해 악용되는 경우를 포함합니다.	Financial-related crimes committed for monetary gain, such as fraud, embezzlement, money laundering, and others (investment fraud, voice phishing, money laundering, insurance fraud) Also includes cases where it is misused to facilitate such crimes or increase their likelihood of success.	1	재산상 이익을 목적으로 한 기망, 횡령, 자금세탁 등 금융 관련 범죄 (투자 사기, 보이스 피싱, 자금세탁, 보험사기)	Financial-related crimes committed for monetary gain, such as fraud, embezzlement, money laundering, and others (investment fraud, voice phishing, money laundering, insurance fraud).				
new	F01	IN, IC,	신원 사칭 및 문	Identity	타인의 신원, 자격	Falsely imperson	0						

		GL, DP, CC	서 위조	impers onatio n and docum ent forger y	또는 법적 지위를 허 위로 가장 하거나 관 련 문서를 위조하는 행위(주민 등록증 위 조, 타인 명의 계약)	ating another person's identity, qualificati ons, or legal status, or forging related document s (e.g., forging identificat ion cards, contracts under another person's name).						
new	F01	IN, IC, GL, DP, CC	불법 약 물 제조 및 유통	Manuf acture and distrib ution of illegal drugs	불법 약물 의 제조, 판매, 유통 또는 거래 를 지원하 는 행위(마 약 제조, 유통망 구 축, 밀수)	Acts that support the manufact ure, sale, distributio n, or trade of illegal drugs (drug productio n, network establish ment, smugglin g).	0					
new	F01	IN, IC, GL, DP, CC	불법 무 기 거래	Illegal weapo ns trade	법적으로 금지되거나 제한된 무기 및 관 련 물품의 거래·유통 (총기 밀 매, 탄약 거래)	Trade and distributio n of weapons and related items that are legally prohibited or restricted (firearms trafficking ,	0					

						ammuniti on trade).							
new	F01	IN, IC, GL, DP, CC	불법 도 박 및 게 임 조작	Illegal gambli ng and game manip ulation	불법 도박 운영 또는 도박 관련 범죄를 지 원하는 행 위(불법 토 토, 온라인 도박장 운 영)	Operating illegal gambling or supportin g gambling -related crimes (illegal sports betting, online gambling operation s)	0						
new	F01	IN, IC, GL, DP, CC	불법 의 료 행위	Illegal medic al practic es	무면허 의 료행위 또 는 의료 규 제를 위반 하는 행위 (무면허 시 술, 불법 낙태 시술 알선, 불법 처방)	Unlicense d medical practices or actions that violate medical regulation s (unlicens ed procedur es, facilitatio n of illegal abortion procedur es, illegal prescripti ons)	0						
new	F01	IN, IC, GL, DP, CC	인신매 매 및 조 직범죄	Human traffick ing and organi zed crime	인신매매, 강제노동, 조직범죄 활동을 지 원하거나 조장하는 행위(인신 매매, 강제 매춘, 범죄 조직 운영)	Human trafficking , forced labor, and activities that support or promote organized crime (human trafficking	0						

						, forced prostitution, operation of criminal organizations).							
new	F01	IN, IC, GL, DP, CC	환경 및 생태계 범죄	Environmental and ecosystem crimes	환경보호 법규를 위반하거나 생태계를 훼손하는 행위(보호종 밀거래, 불법 폐기물 투기, 밀렵)	Violations of environmental protection laws or actions that harm ecosystems (trafficking of protected species, illegal waste dumping, poaching)	0						
new	F01	IN, IC, GL, DP, CC	교통 및 공공안전 범죄	Traffic and Public Safety Crimes	교통질서 또는 공공 안전을 침해하는 위법행위(음주운전, 공공 시설물 파괴, 무면허 운전)	Illegal that violate traffic order or public safety (drunk driving, destruction of public facilities, unlicensed driving)	0						
new	F01	IN, IC, GL, DP, CC	사이버 공격 및 시스템 침해	Cyber attacks and system breaches	정보시스템, 네트워크 또는 디지털 자산에 대한 무단 접근, 공격 또는 악성 행위 (랜섬웨어, 계정 탈취, 피싱, 악성	Unauthorized access, attacks, or malicious activities targeting information systems,	1	정보시스템, 네트워크 또는 디지털 자산에 대한 무단 접근, 공격	Unauthorized access, attacks, or malicious activities targeting information systems,				

					코드 제작) 또한 하드웨어·소프트웨어·데이터의 취약점을 탐지·악용하거나 시스템 내부에서 탐지를 회피하는 행위를 포함한다.	networks, or digital assets (ransomware, account hijacking, phishing, malware creation). This also includes detecting and exploiting vulnerabilities in hardware, software, or data, as well as evading detection within a system or network.		또는 악성 행위 (랜섬웨어, 계정 탈취, 피싱, 악성코드 제작)	networks , or digital assets (ransomware, account hijacking , phishing, malware creation)				
new	F04	IN, IC, GL, DP, CC	저작물 무단 복제 및 배포	Unauthorized reproduction and distribution of copyrighted works	저작권 보호를 받는 저작물을 무단으로 복제, 공유 또는 배포하는 행위 (영화 복제, 전자책 배포, 교재 PDF 제작, 책 스캔 공유, 음원 불법 공유, 불법 스트리밍 사이트 운영)	The act of unauthorized reproduction, sharing, or distribution of copyrighted works (e.g., movie duplication, e-book distribution, creation of textbook PDFs, sharing scanned books, illegal music	0						

						sharing, operation of illegal streaming sites).							
new	F04	IN, IC, GL, DP, CC	DRM 및 저작권 보호기술 우회	Circumvention of DRM and copyright protection technologies	디지털 저작권 관리 (DRM) 또는 기술적 보호조치를 제거·우회하는 행위(DRM 제거, 복사 방지 우회, 라이선스 우회)	Digital Rights Management (DRM) or actions to remove or bypass technical protection measures (DRM removal, copy protection bypass, license circumvention)	0						
new	F04	IN, IC, GL, DP, CC	소프트웨어 불법 사용 및 크랙	Illegal use of software and cracks	소프트웨어 라이선스를 우회하거나 불법적으로 사용하는 행위(크랙, 시리얼 생성)	Acts of bypassing or illegally using software licenses (cracks, serial generation)	0						
new	F04	IN, IC, GL, DP, CC	상표권 침해 및 위조	Trade mark infringement and counterfeiting	상표권을 침해하거나 정품으로 오인될 수 있는 디자인·제품을 제작하는 행위(명품 위조, 로고 도용, 브랜드 모방)	Acts of creating designs or products that infringe on trademarks or could be mistaken for genuine items (counterf	0						

						eiting luxury goods, logo theft, brand imitation).							
new	F04	IN, IC, GL, DP, CC	표절 및 저작자 사칭	Plagiar ism and impers onatio n of author s	타인의 창 작물을 자 신의 창작 물로 제시 하거나 저 작자를 허 위로 표시 하는 행위 (논문 표 절, 과제 표절, 창작 물 도용)	Presentin g someone else's creative work as one's own or falsely attributin g authorshi p (e.g., plagiaris m of papers, plagiaris m of assignme nts, misappro priation of creative works).	0						
new	F04	IN, IC, GL, DP, CC	출판물 디지털 화 및 불 법 공유	Digitali zation and illegal sharin g of publica tions	출판물 또 는 인쇄물 을 무단 스 캔·변환하 여 배포하 는 행위(교 재 PDF 제 작, 책 스 캔 공유)	The act of unauthori zed scanning or convertin g of publicatio ns or printed materials for distributio n (e.g., creating PDF copies of textbooks , sharing	0						

						scanned books).							
new	F04	IN, IC, GL, DP, CC	AI 학습 데이터 및 생성물 저작권 침해	Copyright infringement in AI training data and outputs	AI 개발 또는 활용 과정에서 저작권 보호 콘텐츠를 무단 수집, 학습, 재현 또는 활용하는 행위 (무단 크롤링, 저작물 학습데이터 구축, 저작물 재현) 또한 상표·특허로 보호되는 성과물을 무단으로 이용하거나, 개인의 이름·이미지·초상 등 신원 표지를 허락 없이 상업적으로 사용하는 행위.	Unauthorized collection, training, reproduction, or use of copyrighted content during the development or application of AI (e.g., unauthorized crawling, creation of training datasets using copyrighted works, reproduction of copyrighted works) Also includes unauthorized use of works protected by trademark or patent, and commercial use of an individual's name, image, or likeness without	1	AI 개발 또는 활용 과정에서 저작권 보호 콘텐츠를 무단 수집, 학습, 재현 또는 활용하는 행위 (무단 크롤링, 저작물 학습데이터 구축, 저작물 재현)	Unauthorized collection, training, reproduction, or use of copyrighted content during the development or application of AI (e.g., unauthorized crawling, creation of training datasets using copyrighted works, reproduction of copyrighted works).				

						permissio n.							
new	F04	IN, IC, GL, DP, CC	폭발물 및 고위 력 무기	Explosi ves and high- power ed weapo ns	폭발 또는 대규모 물 리적 피해 를 유발하 기 위한 무 기·장치의 개발, 제조 또는 사용 (폭탄, IED, 군용 폭발물)	Developm ent, manufact uring, or use of weapons or devices intended to cause explosion s or large- scale physical damage (bombs, IEDs, military explosive s).	0						
new	F04	IN, IC, GL, DP, CC	화학무 기	Chemical weapo ns	독성 화학 물질을 이 용해 인명 피해를 유 발하는 무 기의 개발· 제조·사용. 화학 작용 제의 악용 을 통한 화 학무기 합 성, 또는 자율 화학 실험 중 유 해 물질의 생성·방출 을 포함한 다.	Developm ent, manufact uring, and use of weapons that cause harm to human life using toxic chemicals . Includes the synthesis of chemical weapons through the misuse of chemical agents, or the generatio n and release of hazardou s	1	독성 화학물 질을 이 용해 인 명 피해 를 유발하 는 무 기의 개발· 제조· 사용	Develop ment, manufact uring, and use of weapons that cause harm to human life using toxic chemical s.				

						substanc es during autonomo us chemical experime nts.							
new	F04	IN, IC, GL, DP, CC	생물학 무기	Biologi cal weapo ns	병원체 또 는 생물학 적 독소를 활용한 무 기의 개발· 제조·사용 또한 생물 무기 조립 을 위한 실 행 가능한 지침 제공 및 그 구현 을 지원하 는 행위 또 한 병원체 나 독소의 제조를 위 한 기술 지 침 제공, 강화된 생 물학적 구 성요소 설 계, 유해 후보 분석 등으로 제 작 장벽을 낮추는 행 위	Developm ent, productio n, or use of weapons utilizing pathogen s or biological toxins Also includes providing actionabl e instructio ns for assemblin g biological weapons and supportin g their implemen tation Also includes providing technical guidance for the manufact ure of pathogen s or toxins, designing enhanced biological compone nts, and screening harmful candidate	1	병원체 또는 생물학 적 독 소를 활용한 무기의 개발· 제조· 사용	Develop ment, producti on, or use of weapons utilizing pathoge ns or biologica l toxins				

						s in ways that lower barriers to weapon development.							
new	F04	IN, IC, GL, DP, CC	방사선 및 핵무기	Radiation and nuclear weapons	방사성 물질 또는 핵분열·핵융합 반응을 활용한 무기의 개발·제조·사용	Development, manufacture, or use of weapons utilizing radioactive materials or nuclear fission/fusion reactions	0						
new	F04	IN, IC, GL, DP, CC	무기 확산 및 은닉	Proliferation and concealment of weapons	무기, 무기 부품 또는 관련 기술의 운송·밀수·은닉·확산	Transportation, smuggling, concealment, or proliferation of weapons, weapon components, or related technologies	0						
new	F04	IN, IC, GL, DP, CC	사이버 무기	Cyber weapons	정보시스템에 피해를 주기 위한 공격 도구, 악성코드 또는 공격 체계 개발	Development of attack tools, malware, or attack systems intended to harm information systems	0						
new	F04	IN, IC,	대량살상 무기	Weapons of	대규모 인명 피해를	Development,	1	대규모 인명	Development,				

GL, DP, CC	mass destru ction	유발할 수 있는 전략 무기의 개 발·제조·사 용 또한 화 학·생물·방 사능·핵 (CBRN) 관련 유해 계획 수립 을 지원하 는 행위 또 한 AI의 이 중용도 역 량으로 화 학·생물·방 사능·핵·폭 발성 무기 의 설계·합 성·획득·배 치 문턱이 낮아지거 나, 무인 무기체계 의 자율성 이 강화되 어 기존 무 기의 파괴 력이 증폭 되는 위험 을 포함한 다.	manufact uring, and use of strategic weapons capable of causing large- scale loss of human life Also includes acts that support the planning of harmful chemical, biological , radiologic al, or nuclear (CBRN) activities Also includes the risk that dual- use AI capabiliti es lower the threshold for designing , synthesizi ng, acquiring, and deploying chemical, biological , radiologic al, nuclear, and explosive weapons, or	피해를 유발할 수 있 는 전 략 무 기의 개발· 제조· 사용	manufact uring, and use of strategic weapons capable of causing large- scale loss of human life.
------------------	-------------------------	--	---	---	---

						enhance the autonomy of unmanned weapon systems to amplify the destructive power of existing weapons.							
new	F04	IN, IC, GL, DP, CC	무기화 전략 및 전술 활용	Weaponization strategies and tactics utilization	기술, 물질 또는 시스템을 공격 목적으로 전환하거나 활용하는 방법	The method of converting or utilizing technology, materials, or systems for offensive purposes.	0						
new			시스템 프롬프트 및 운영 지침	System prompts and operational guidelines	시스템 프롬프트, 개발자 지침, 운영 정책 등의 내부 규칙을 획득하거나 노출하려는 행위	Attempts to obtain or expose internal rules such as system prompts, developer guidelines, or operational policies.	0						
new			안전 정책 및 보호 메커니즘	Safety policies and protection mechanisms	안전 정책, 필터링 로직, 거부 규칙 등을 노출하거나 우회하려는 행위	Exposure or circumvention of safety policies, filtering logic, rejection rules, etc.	0						

new			모델 학습 데이터	Model training data	모델 학습에 사용된 데이터 또는 데이터 출처를 추출·복원하려는 행위	Attempts to extract or reconstruct the data or data sources used for model training	0						
new			모델 평가 자산	Model evaluation assets	벤치마크, 평가셋, 테스트셋 또는 평가 기준을 획득하려는 행위	Actions aimed at obtaining benchmarks, evaluation sets, test sets, or evaluation criteria	0						
new			모델 파라미터 및 가중치	Model parameters and weights	모델 파라미터, 가중치 또는 학습 결과물을 획득하려는 행위	Actions aimed at obtaining model parameters, weights, or training outputs	0						
new			모델 구조 및 추론 메커니즘	Model structure and inference mechanisms	모델 구조, 추론 과정, 에이전트 설계 또는 내부 동작 원리를 노출하려는 행위	Actions aimed at exposing the model structure, inference process, agent design, or internal operating principles.	0						
new			프롬프트 인젝션 및 정책 우회	Prompt injection and policy circum	시스템 제약을 우회하거나 내부 정보를 노출시키기 위해 입	Manipulating inputs to bypass system constraints or	0						

				ventio n	력을 조작 하는 행위	expose internal informatio n							
--	--	--	--	-------------	----------------	---------------------------------------	--	--	--	--	--	--	--