

L4-Physical

ID	Title_ko	Title_en	Descripti on_ko	Descripti on_en	Human audit_des cription	Human audit_L3 mapping		Human audit_dup licate	Instructio n Prompt	
RAI4-0269	세계 모델의 장기 예측 편차 누적	World-model prediction drift over long horizons	피지컬 AI 세계 모델의 예측 오차가 미래 상태 전개 과정에서 누적되어 선택된 계획이 실제 접촉·운동 역학과 달라지는 위험.	Prediction errors in a physical AI world model compounded across simulated future states, causing the selected plan to diverge from actual contact and motion dynamics.						
RAI4-0277	합성 위험 시나리오 생성 편향	Bias in synthetic hazardous-scenario generation	합성 안전 데이터가 시각적으로 두드러진 위험은 과다 대표하고 희귀하거나 문화·맥락 의존적인 위험은 누락함으로써 벤치마크 결론을 왜곡시키는 리스크	The risk that synthetic safety data overrepresents visually salient hazards and omits rare, culturally specific, or context-dependent hazards, distorting benchmark					General 영역으로 이동하여 적합한 L3에 매핑할 것	

				conclusio ns.						
RAI4-0324	위치 추정 누적 오차	Localizati on drift	GPS·SLA M·관성 감 지·지도 정 렬 오차가 누적되어 시스템이 잘못된 위 치 추정에 기반하여 행동하는 위험.	Errors in GPS, SLAM, inertial sensing, or map alignmen t can accumula te until the system acts on an incorrect estimate of its own position.						
RAI4-0335	합성 학습 데이터의 과리·커버 리지 공백	Synthetic training data divergen ce and coverage gaps	합성·시물 레이션 학 습 데이터 가 실제 운 용 데이터 와 과리되 고, 빈번하 지는 않지 만 안전에 치명적인 물체, 환 경, 인간 행동, 또는 고장 모드 를 누락하 여, 일반적 인 성능과 신뢰할 수 있는 배포 절차에 피 해를 주는 리스크	The risk that synthetic or simulated training data diverge from operation al reality and omit rare but safety- critical objects, environm ents, human behavior s, and failure modes, undermin ing generaliz ation and reliable deploym ent behavior.						

RAI4-0545	합성 예술의 확산에 따른 예술가 피해	Harm to artists from synthetic art proliferation	텍스트-이미지 모델로 합성 예술이 광범위하게 생성되고, 예술가의 작품이 무단·무보상으로 학습 데이터에 사용됨으로써 관련 분야의 예술가들에게 재정적 손해와 경제적 손실을 발생시키고, 합성 이미지와 진본의 구별이 어려워지는 리스크	The risk that widespread generation of synthetic art by text-to-image models, together with unauthorized and uncompensated use of artists' works in training datasets, causes financial and economic losses for artists while making synthetic images hard to distinguish from authentic ones.					General AI (L1) 저작권 관련 리스크 (L3)로 이동할 것	
RAI4-0629	학습 과정 우회	Bypassing of the learning process	고품질 생성 모델에 대한 손쉬운 접근으로 학습자가 AI 모델을 사용해 학습 과정을 우회하게 되는 리스크	The risk that easy access to high-quality generative models results in students using AI models to bypass the learning process.					General 영역으로 이동하여 적합한 L3에 매핑할 것	

RAI4-0736	적대적 입력 교란을 통한 회피 공격	Evasion attacks through adversarial perturbation of model inputs	공격자가 학습된 모델에 전달되는 입력에 단어 치환이나 그 래디언트 기반 섭동 등 미세한 변형을 가하여 적대적 예제를 구성하는 리스크로 모델의 예측이 크게 뒤바뀌어 잘못된 결과가 산출되지만 그 조작에 대해서 인간의 검토만으로는 감지하기 어려운 리스크	The risk that an attacker adds slight perturbations to the input sent to a trained model, whether by word substitution or gradient-guided noise, to construct adversarial examples. The model's predictions shift substantially and it returns incorrect results while the manipulation remains imperceptible to human reviewers.					General 영역으로 이동하여 적합한 L3에 매핑할 것	
RAI4-1383	학습 단계의 치명적 실수	Fatal mistakes during the learning phase	AGI가 안전 탐색 실패나 분포 변화 등으로 학습 단계에서 치명적 실수를 범하는 리스크.	The risk that an AGI makes fatal mistakes during the learning phase, including through failures					General 영역으로 이동하여 적합한 L3에 매핑할 것	

RAI4-1631	무해한 중간 단계를 통한 간접적 오용	Indirect misuse via a benign intermediate step	겉보기에 무해한 중간 단계를 경유하여 유해한 최종 목적이 달성되는 간접적 오용 리스크.	The risk that a benign intermediate is used to achieve a harmful end objective.					General 영역으로 이동하여 적합한 L3에 매핑할 것	
RAI4-1689	분포 이탈 입력에서의 월드모델 오출력 악용	Exploitation of world-model errors under sim-to-real distributional shift	월드 모델이 분포를 벗어난 입력에 대해 예측 불가능하고 잘못된 출력을 산출하며, 판단이 가장 중요한 롱테일 안전 임계 상태에서 시뮬레이션-실제 격차가 악용되는 리스크.	The risk that world models produce unpredictable, erroneous outputs on out-of-distribution inputs and that the sim-to-real gap is weaponised in long-tail safety-critical states where decisions matter most.						
RAI4-1701	학습 중 탐색 행동에 의한 회복 불가 피해	Irrecoverable harm from exploratory actions during learning	에이전트의 탐색적 행동이 부정적이거나 회복 불가능한 결과를 초래하는 리스크	The risk that exploratory actions by a learning agent produce negative or irrecoverable consequences					Agentic AI 도메인 (L1)로 이동하여 적합한 L3에 매핑할 것	

RAI4-0206	엔드 이펙터 속도 초과	Excessive end-effector velocity	로봇이 인간 근접 또는 취약 물체 처리시 안전한 엔드 이펙터 속도 한계를 초과하여 충격·충돌 심각도를 높이는 리스크	The risk that a robot exceeds safe end-effector speed limits near humans or fragile objects, increasing impact and collision severity.						
RAI4-0207	조기 물체 해제	Premature object release	로봇이 안전한 자세 또는 표면에 도달하기 전에 물체를 해제하여 낙하, 유출, 충격, 또는 2차 위험을 유발하는 리스크.	The risk that a robot releases an object before reaching a safe pose or surface, causing drops, spills, impacts, or secondary hazards.						
RAI4-0208	금지 대상 충돌	Forbidden-object collision	로봇이 작업 또는 안전 규칙상 접촉이 금지된 물체, 사람, 또는 장비와 충돌하는 리스크.	The risk that a robot collides with objects, people, or equipment that must not be contacted under task or safety rules.						

RAI4-0215	배포 전 물리적 안전 시험 미흡	Incomplete pre-deployment physical safety testing	기반 모델 탑재 로봇이 예정된 운용 환경의 분포 변화, 적대적 입력, 인간 접촉, 안전 임계 엣지 케이스를 시험하지 않은 채 배포되는 위험.	A foundation-model-enabled robot is released without testing domain shifts, adversarial inputs, human contact, and safety-critical edge cases relevant to its intended environment.						
RAI4-0218	인간 접촉 안전 통제 미흡	Inadequate human-contact safety controls	인간과 직접 상호작용 할 때 안전 통제가 로봇의 속도, 힘, 이격거리, 접촉을 제한하지 못해 주변 사람을 충돌이나 상해에 노출시키는 위험.	Safety controls fail to limit robot speed, force, distance, or contact during direct human interaction, exposing nearby people to collision or injury.						
RAI4-0219	기반 모델 실패의 로봇 행동 전이	Foundation-model failure propagated to robot action	기반 모델의 환각, 지시 이행 실패, 탈옥 취약성이 계획과 제어를 거쳐 안전하지	Hallucination, instruction-following failure, or jailbreak susceptib						

			않은 로봇 행동으로 전이되는 위험.	ility in a foundation model propagates through planning and control into unsafe robot action.						
RAI4-0237	로봇 형태 간 기술의 안전하지 않은 전이	Unsafe skill transfer across robot morphologies	한 로봇 형태에서 다른 형태로 전이된 기술이 대상 로봇의 물리적 한계를 넘는 도달, 힘, 파지, 이동 명령을 생성하는 위험.	A skill transferred from one robot morphology produces reach, force, grasp, or locomotion commands that exceed the receiving robot's physical limits.						
RAI4-0241	원격 조작 시연에서 학습된 안전하지 않은 가정	Unsafe assumptions learned from teleoperation demonstrations	로봇 정책이 감독·물체 배치·속도·인간 근접 조건이 다른데도 통제된 환경에서 기록된 운영자 행동을 배포 환경에서 안전한 것으로 간주하는 위험.	A robot policy treats operator behavior recorded in controlled settings as safe in deployment, even when supervision, object layout, speed, or human						

				proximity differs.						
RAI4-0243	시연 학습의 안전 맥락 누락	Missing safety context in demonstration learning	로봇이 허용 힘·금지 대상물·상황별 제한 처럼 시연에서 관찰되지 않은 안전 조건을 추론하지 않고 인간 행동을 모방하는 위험.	A robot imitates a human demonstration without inferring unobserved safety conditions such as permitted force, excluded objects, or situational limits.						
RAI4-0260	제로샷 시뮬레이션-현실 보행 불안정	Zero-shot sim-to-real locomotion instability	시뮬레이션에서 바로 전이된 로봇의 보행 제어기가 접촉·순응성·마찰·외란 동역학의 차이로 실제 하드웨어에서 불안정해지는 위험.	A locomotion controller transferred directly from simulation becomes unstable on hardware because contact, compliance, friction, or disturbance dynamics differ from the simulation.						
RAI4-0264	가정 조작의 단계별 오차 미수정	Uncorrected stepwise errors in household	로봇이 작업 단계 사이의 작은 조작 오차를 감지·수	A household robot fails to detect						

		d manipulat ion	정하지 못 해 유출·불 안정한 배 치·충돌·과 열이 누적 되는 위험.	and correct small manipulat ion errors between task steps, allowing spills, unstable placemen ts, collisions , or overheati ng to accumula te.						
RAI4- 0273	로봇 거버 넌스 명세 의 안전 규 칙 누락	Missing safety rules in the robot governan ce specificat ion	로봇 거버 넌스 명세 가 지역별 위험·기관 규칙·맥락 별 제약을 누락해 특 정 유형의 비안전 행 동이 통제 대상 밖에 남는 리스 크.	The risk that a robot governan ce specificat ion omits locally applicabl e hazards, institution al rules, or context- specific constrain ts, leaving defined classes of unsafe behavior ungovern ed.						
RAI4- 0282	제어 판단· 제어권 전 환 실패에 따른 자동 주행 충돌 위험	Automate d driving crash risk from control and handoff failures	자동주행 시스템이 인지·계획· 소프트웨 어 결함이 나 엣지 케 이스로 안 전하지 않 은 제어 판	The risk that an automate d driving system creates crash risk by making						

			단을 내리거나, 시간이 촉박한 상황에서 제어권이 모호하게 또는 뒤늦게 전환되어 인간과 시스템 어느 쪽도 필요한 안전 조치를 수행하지 못함으로써 충돌 위험이 발생하는 리스크.	unsafe control decisions after perception, planning, or software failures and edge cases, or by transferring control authority ambiguously or too late in time-critical events, leaving neither the human nor the system able to execute the required safety action.							
RAI4-0288	개인 돌봄 로봇 준수 기준 부재	Missing measurable compliance criteria for personal-care robots	로봇 표준이 위험을 제시하면서 속도·힘·안정성·감지·개입에 대한 측정 가능한 합격·불합격 기준을 정의하지 않는 리스크.	The risk that a personal-care robot standard names hazards but does not define measurable pass/fail thresholds for speed, force,							

				stability, sensing, or intervention.						
RAI4-0290	인간-로봇 상호 행동 모델링 미흡	Failure to model reciprocal human-robot behavior	로봇이 자신의 행동이나 사용자의 반응 중 한쪽만 모델링해 양측의 움직임이 서로의 행동을 바꾸는 피드백을 놓치는 위험.	A domestic robot models only its own action or only the user's response and therefore misses feedback loops in which each party's movement changes the other's behavior.						

RAI4-0291	취약 사용자 특성에 맞지 않는 안전 한계	Safety limits not adapted to vulnerable users	로봇이 조정된 보호 조치가 필요한 아동·고령자·장애인 등에 일반적 인 속도·힘·경고·상호 작용 설정 을 그대로 적용하는 위험.	A domestic robot applies generic speed, force, warning, or interaction settings to children, older adults, disabled users, or other users who require adapted safeguards.						
RAI4-0293	통신 단절 및 제어 링크 손실	Communication dropout and control-link loss	로봇 또는 차량이 명령·원격조정·제어 링크를 잃어 비안전 정지·오래된 명령 또는 제어되지 않는 동작 을 초래하는 위험.	A robot loses communication or control-link connectivity during operation , reducing supervision and safe control.						
RAI4-0296	제어 루프 데드라인 미달	Control-loop deadline miss	실시간 제어 루프가 데드라인 을 놓쳐 오래된 상태에서 작동 이 계산되거나 안전 유지에 너무 늦게 적용되는 위험	A safety-critical control loop misses its real-time deadline before the robot action is						

				corrected .						
RAI4-0297	인지·추론 지연 급증	Perceptio n and inference latency spike	인지 또는 모델 추론 의 지연 급 증이 안전 반응 창 밖 에서 위험 감지 및 반 응을 지연 하는 위험.	A sudden delay in perceptio n or inference slows safety- critical robot reactions .						
RAI4-0299	부하 시 열 ·전력 쓰로 틀링	Thermal and power throttling under load	지속적 부 하 하에서 열적 또는 전력 한계 가 연산을 쓰로틀하 여 제어 및 인지에 대 한 실시간 보장을 무 너뜨리는 위험.	A robot's compute or actuator performa nce drops under heat or power constrain ts during operation .						
RAI4-0303	백도어 트 리거에 의 한 위험 로 봇 행동	Backdoor triggers causing unsafe robot behavior	훈련 데이 터, 프롬프 트 컨텍스 트, 모델 가중치, 소 프트웨어, 업데이트 에 악의적 으로 삽입 된 트리거 가 평상시 에는 정상 동작하는 로봇으로 하여금 특 정 입력·물 리 조건에 서 미리 정 해진 위험 하거나 의 도되지 않 은 물리 행 동을 실행 하게 하는 리스크.	The risk that a trigger malicious ly implante d in training data, prompt context, model weights, software, or updates causes a robot that otherwis e behaves normally to execute predefine						

				d dangerou s or unintend ed physical actions under specific input or physical condition s.						
RAI4-0304	자율 로봇의 물리적 침입·절도	Autonomous physical intrusion and theft	자율 로봇이 승인 없이 제한 구역에 침입하거나 잠금장치를 우회하거나 보안 공간 내에서 정찰하는 리스크.	The risk that an autonomous robot enters restricted spaces or takes physical objects without authorization.						
RAI4-0309	아동의 과신·모방에 따른 위험한 로봇 상호작용	Child overtrust, imitation, and unsafe robot interaction	인간이 로봇을 과도하게 신뢰하거나 모방해 위험한 조언을 따르거나 위험 장비에 접근하거나 연령에 맞지 않는 물리적 상호작용을 하는 위험.	A child overtrusts or imitates a robot and therefore follows unsafe advice, approaches hazardous equipment, or engages in age-inappropriate physical interaction.						
RAI4-0310	필수 돌봄·상황 보고 미이행	Failure to provide required care or	로봇이 정해진 신체 보조를 수행하지 않	A care robot fails to provide						

		escalation	거나 감지된 필요 상황을 보고하지 않아 고령자·환자에 게 필요한 지원이 제공되지 않고 안전이나 존엄성이 훼손되는 위험.	an assigned physical assistance task or escalate a detected need, leaving an older or ill person without necessary support and compromising safety or dignity.						
RAI4-0314	친밀 공간 로봇의 프라이버시 침해적 정보 수집	Privacy-invasive data capture by robots in intimate spaces	가정·병원·학교·직장·돌봄 환경에서 작동하는 로봇이 유효한 동의나 적절한 접근 통제 없이 거주자·이용자의 일상, 음성, 얼굴, 신체, 건강, 위치, 행동 데이터를 기록·저장·전송·노출하여, 프라이버시 기대가 높은 공간에서 사생활을 침해하는 리스크	The risk that robots operating in homes, hospitals, schools, workplaces, and care settings record, store, transmit, or expose people's routines, voice, face, body, health, location, or behavioral data without valid consent or adequate access						

				control, violating heightened privacy expectations.						
RAI4-0315	이동형 로봇 감시를 통한 일방적 작업장 통제	Unilateral workplace control through mobile robotic surveillance	고용주가 동료 로봇을 이동형 감시 노드로 전용하고 충분한 고지, 이의제기, 비례성 제한 없이 데이터를 수집하고, 수집된 데이터를 이용하여 노동자에 대한 일방적인 의사결정으로 사용하는 위험	An employer repurposes co-worker robots as mobile surveillance nodes and uses the resulting data to make unilateral decisions about workers without meaningful notice, contestation, or proportionality limits.						
RAI4-0331	파지력 상해	Grasp force injury	로봇 조작이 과도하거나 잘못된 타이밍된 힘을 가함으로써 인간 접촉 시 압착, 꼬집힘, 절단, 인간공학 적 상해를 유발시키는 위험.	Robot manipulation may apply excessive or poorly timed force, creating crushing, pinching, cutting, or ergonomic injury risks.						
RAI4-0339	실시간 지연 및 동기	Real-time latency	감지, 추론, 통신,	Delays between						

	화 실패	and synchron ization failure	작동 간 지 연으로 인 해서 로봇, 차량, 드 론, 원격 수술, 산업 시스템의 제어 루프 를 불안정 하게 만드 는 위험	sensing, reasonin g, communi cation, and actuation can destabiliz e control loops in robots, vehicles, drones, or industrial systems.						
RAI4- 0343	보조 로봇 의 비동의 신체 개입	Non- consensu al bodily interventi on by assistive robots	보조·의료· 돌봄 로봇 이 유효한 동의가 없 거나 또는 허용된 돌 봄 목적을 넘어서 인 간의 몸을 이동, 제 지, 감시하 거나 직접 개입함으 로써 발생 하는 위험.	An assistive, medical, or care robot moves, restrains, monitors, or physicall y intervene s in a person's body without valid consent or beyond the authorize d care purpose.						
RAI4- 0361	공공 공간 통행 방해· 접근성 배 제	Obstructi on and accessibi lity exclusion in public space	서비스 로 봇이 보도, 경사로, 출 입구, 보행 안내 표지 판 등을 막 거나 침범 함으로써 장애인 또 는 다른 보 행자들의 이동을 제	Service robots occupy or navigate public space in ways that block sidewalk s, curb ramps,						

			한함으로 써 발생되 는 위험	entrance s, or navigatio n cues used by disabled and other pedestria ns.						
RAI4-0183	부상 심각 도 오분류	Injury severity misclassi fication	로봇 제어 시스템이 물리적 부 상 시나리 오의 심각 도를 과소 평가하여 상향 보고, 경고, 제어 대응 등이 불충분해 지는 리스 크.	The risk that a system underesti mates the severity of a physical injury scenario, leading to inadequa te escalatio n, warning, or control response .						
RAI4-0298	온디바이 스 연산·메 모리 고갈	On- device compute and memory exhaustio n	로봇에 부 착된 온디 바이스의 연산 또는 메모리 고 갈이 안전 임계치 인 지, 계획, 모니터링 을 저하하 거나 중단 시키는 위 험.	On- device compute or memory runs out and degrades safety- relevant perceptio n, planning, or control.						
RAI4-0300	클라우드 오프로드 의존 실패	Cloud- offload depende ncy failure	로봇 제어 시스템이 안전 관련 기능을 위 한 원격 연 산에 의존 하고 있는	A robot depends on remote compute for safety-						

			클라우드 링크가 끊어지는 경우에 대비하여 적절한 로컬 폴백 절차 또는 시스템이 없어서 발생하는 위험.	relevant functions and loses that support when the cloud link fails.						
RAI4-0333	정밀 운동 제어 불안정성	Fine motor control instability	정밀 손, 수술 도구, 외골격, 산업용 그리퍼 등의 소규모 제어 오차가 비안전한 물리적 결과로 증폭되어서 나타나는 위험.	Small control errors in dexterous hands, surgical tools, exoskeletons, or industrial grippers may amplify into unsafe physical actions.						
RAI4-0661	비즈니스 시스템 손상 및 운영 중단	Business system damage and operational disruption	로봇의 작동이나 사이버 공격 등으로 비즈니스 시스템과 그 구성 요소가 손상, 중단, 또는 파괴되는 리스크	The risk of damage, disruption, or destruction of a business system and its components due to malfunction, cyberattacks, and similar causes.						
RAI4-1035	하드웨어 결함에 의한 실행 오류	Erroneous execution from	로봇의 하드웨어 결함이 제어 흐름 위반, 메모리 오	The risk that faults in the hardware						

		hardware faults	류, 센서 입력 간섭, 또는 출력 손상 등을 통해 알고리즘의 올바른 실행을 훼손하고 잘못된 결과를 야기하는 리스크.	violate the correct execution of an algorithm through control-flow violations, memory-based errors, interference with data inputs such as sensor signals, or damaged outputs, causing erroneous results.						
RAI4-1496	무해 미세 조정에 의한 안전성 열화	Safety degradation from benign finetuning	무해하고 통상적인 데이터로 수행된 하류 미세조정이 로봇의 내장 모델의 안전 학습을 열화시키기만 모델보다 유해 출력 확률을 높이는 리스크	Benign downstream finetuning degrades a model's safety training, making harmful outputs more likely than in the base model even when finetuning data is harmless and commonplace.						

RAI4-1629	실험실 로봇 오작동에 의한 물리적 상해	Physical injury from laboratory robotic malfunction	실험실 환경의 로봇 및 자동화 시스템에서 장비 오작동이 발생하여 물리적 피해나 인체 상해가 초래되는 리스크.	The risk that robotics and automated systems in laboratory settings malfunction, causing equipment failure or physical harm.	1				병합 — 실험실 로봇으로 범위를 한정할 필요 없이, 오작동에 의한 물리적 상해를 다루는 상위 카드와 통합하여 하나의 일반화된 카드로 정리	
RAI4-0776	기반모델 재사용을 통한 보안 결함 전파	Security-flaw propagation through foundation-model reuse	기반모델을 재설계하거나 미세조정하여 활용하는 관행으로 인해 기반모델의 보안 결함이 하위 모델로 그대로 전파되는 리스크	The risk that security flaws in foundation models are transmitted to downstream models built through re-engineering or fine-tuning of those foundation models.					기반모델 재설계·미세조정을 통한 보안 결함의 하위 모델 전파는 PAI에 국한된 리스크가 아니라 GPAI 개발 관행 전반의 문제 — 물리 AI 특유의 요소(로봇/체화)를 추가해 구체화하거나 general로 재검토 필요	
RAI4-0853	설계 목적 외 사용	Use outside the intended purpose	모델이 원래 설계된 목적과 다른 목적으로 사용되는 리스크	The risk that a model is used for a purpose that it was not originally designed for.						

RAI4-0993	부실 설계 지능 시스템에 의한 상해	Injury from poorly designed intelligent systems	제대로 설계되지 않은 지능형 시스템이 도덕 적·심리적·신체적 해악을 초래하는 (예: 예측 치안 도구로 더 많은 사람이 체포되거나 경찰에 의해 신체적 피해를 입는) 리스크.	The risk that poorly designed intelligent systems cause moral, psychological, and physical harm, as when predictive policing tools lead to more people being arrested or physically harmed by police.						
RAI4-1039	알고리즘 설계 실패	Algorithmic design failure	ML 알고리즘, 모델 아키텍처, 최적화 기법 등 학습 과정의 선택이 의도된 응용에 적합하지 않아 최종 ML 시스템이 훼손되는 리스크.	The risk that the ML algorithm, model architecture, optimization technique, or other aspects of the training process are unsuitable for the intended application, impairing the final ML system.					ML 알고리즘·아키텍처·최적화 기법 선택이 응용에 부적합해 시스템이 훼손되는 리스크는 모델 개발 전반에 해당하는 일반론 — PAI 한정 리스크로 보기 어려워 구체화 필요	
RAI4-1092	모델 접근으로 인한	Unfair distribution	하드웨어, 소프트웨어	Benefits of model	1				L3 이동 — 소프트웨어	

	이익의 불 공정한 분 배	on of benefits from model access	어, 숙련, 지역·통신· 기기 등 배 포 맥락의 제약으로 모델 접근 편익이 집 단 간 불공 정하게 배 분되는 리 스크	access are allocated unfairly across groups due to hardware , software, skills, or deploym ent- context constrain ts such as region, connecti vity, and devices.					웨어 취약 점보다는 사회적 파 급 (Societal Impact) 의 '이익 분배 불공 정' 항목에 더 적합한 내용	
RAI4- 1157	공격적 사 이버 역량	Offensive cyber capability	모델이 하 드웨어와 소프트웨 어, 데이터 의 취 약점 을 발견하 고 익스플 로잇 코드 를 작성하 며 침입 후 위험 탐지 와 대응을 회피하고, 코딩 비서 로 배포될 경우 향후 악용을 위 한 미묘 한 버그를 삽 입하는 리 스크.	The risk that a model discovers vulnerabil ities in systems, writes code to exploit them, makes effective decisions and skilfully evades threat detection and response once inside, and inserts subtle bugs for future exploitati on when deployed as a						

				coding assistant.						
RAI4-1252	배포 이후 예측하지 못한 창발적 역량과 행동	Unanticipated emergent capabilities and behaviour after deployment	설계자가 예상하지 못한 기능과 행동이 규모 확장 과정에서 자발적으로 창발하거나, 배포 후 지속 학습과 자기 조직화를 통해 획득되거나, 개별 시스템의 좁은 적용 범위라는 안전 한계를 다중 에이전트 결합이 극복하면서 나타나 리스크. 기만, 권력 추구, 자율 복제 같은 고위험 잠재 역량이 운용 중에 발견되어 통제와 안전한 배포가 어려워지고, 위험한 역량일 경우 되돌릴 수 없는 영향을 남긴다.	The risk that capabilities and behaviours unanticipated by system designers emerge spontaneously as models are scaled, are acquired through continual learning or self-organization after deployment, or arise when multiple agents combine and overcome the narrow scope that made each individually safer. Latent high-risk capabilities such as deception, power-seeking, and autonom						

				ous replicatio n may be discovere d only during operation , making systems harder to control or deploy safely and leaving irreversib le effects where those capabiliti es are hazardou s.					
RAI4-1282	배포 전후 AI 시스템에 대한 의도적 사보타주	Deliberate sabotage of AI systems before and after deployment	배포 전 개발 단계에서 접근 권한을 가진 내부 자나 침입자가 소프트웨어를 안전하지 않게 변경하고 소스코드를 수정·탈취하거나 잘못 되고 안전하지 않은 데이터셋으로 학습시키고, 배포 후에는 누군가 거짓 정보를 주입하거나 불법적·위험한 행동을 명령하는 리스크. 안전하게 설계된 시스템이 어	The risk that insiders or intruders with the necessary access alter software to make it unsafe, modify or steal source code, and deliberately train the system on wrong or unsafe datasets before release, and that after deployment	1				번역 수정 — '사보타주' 표기 재검토 (음역/용어 통일 필요)

			는 단계에 서든 안 전 하지 않은 것으로 전 환되어 이 를 신뢰한 이 들에게 피해가 미 친다.	people feed it false informati on or order it to perform illegal or dangerou s acts. A system built to be safe is thereby rendered unsafe at either stage, harming those who rely on it.					
RAI4-1284	설계 단계 명세 오류	Design- stage specificat ion errors	코드 결함, 목적함수 가중치 불 균형, 인간 가 치와 어 긋난 목표 설정 등 배 포 전 설계 오류 로 시 스템 행동 이 의도된 형식적 속 성에서 이 탈하는 리 스크	Design mistakes before deploym ent, including code bugs, dispropor tionate objective weights, and goals misaligne d with human values, produce a system whose behavior departs from desired formal propertie s.					

RAI4-1333	모델 절취·변조	Model theft and tampering	매개변수와 구조, 기능을 포함한 핵심 알고리즘 정보가 역전 공격과 절취, 변조, 백도어 주입에 노출되어 지식재산권 침해와 영업비밀 유출, 신뢰할 수 없는 추론과 잘못된 의사결정, 운영 실패로 이어지는 리스크.	The risk that core algorithm information, including parameters, structures, and functions, faces inversion attacks, stealing, modification, and backdoor injection, leading to infringement of intellectual property rights, leakage of business secrets, unreliable inference, wrong decision output, and operational failures.					
RAI4-1489	적대적 학습의 강건 과적합	Robust overfitting in adversarial training	적대적 훈련에서 학습률 감소 이후 추가 훈련이 진행될수록 테스트 데이터에 대한 모델의 견고성이 감소하는 강건 과적합이 발생	The risk that robust overfitting in adversarial training decreases a model's robustness on test	1				적대적 훈련 중 강건 과적합으로 일반화 성능이 저하되는 현상은 ML 학습 방법론 자체의 이슈 — PAI 한정 리스크로 보기 어려

			하여 일반 화 능력과 적대적 공 격에 대한 내성이 저 하되는 리 스크.	data during further training, particular ly after learning rate decay, impairing its ability to generaliz e effectivel y and reducing its resilience to adversari al attacks.					위 구체화 필요	
RAI4- 1490	악용 가능 한 강건성 인증	Exploitable robustness certificates	모델 예측 이 견고하 다고 인증 된 영역의 범위 를 포 함한 강건 성 인증서 정보를 공 격자가 알 게 되어 인 증 영역 바 로 바깥에 서 성공하 는 공 격을 효율적으 로 제작하 는 리스크.	The risk that knowledg e of robustne ss certificat es, including the area of the region for which model predictio ns are certified to be robust, is used by an adversar y to efficientl y craft attacks that succeed just outside	1				삭제 — 강 건성 인증 서의 인증 영역 바깥 을 노리는 적대적 공 격 생성은 적대적 학 습/모델 검증 분야 의 연구 주 제로, 물리 AI에 특화 된 리스크 가 아니라 PAI 텍소 노미에 부 적합	

				the certified regions.						
RAI4-1519	오픈소스에서 폐쇄형 모델로 전이되는 적대적 공격	Transferable adversarial attacks from open to closed-source models	가중치와 구조가 알려진 오픈 웨이트·오픈소스 모델을 대상으로 자동 생성된 화이트박스 적대적 공격이 폐쇄형 모델로 전이되어 구조적 접근 통제 등 제공자의 방어를 무력화하는 리스크.	The risk that adversarial attacks developed for open-weights and open-source models, where the weights and architecture are known, transfer to closed-source models despite defenses put in place by the closed-source provider such as structured access, and can be generated automatically.	1				삭제 — 오픈웨이트 모델 대상 화이트박스 공격이 폐쇄형 모델로 전이되는 현상은 적대적 견고성 연구 주제로, 물리 AI 한정 리스크가 아니라 PAI 택소노미에 부적합	
RAI4-1541	모델 가중치 공개·유출에 따른 통제력 상실	Loss of control over released or leaked model weights	모델 가중치나 제한적으로 부여된 접근권이 공개되거나 보안 침해로 유출되면 개발자가	The risk that once model weights, or access to them, are released or leaked	1				삭제 — 모델 가중치 유출에 따른 통제력 상실은 GPAI 전반의 모델 보안 이슈로, 물리	

			모델을 더 이상 통제하거나 폐기할 수 없게 되는 리스크. 재구성이 쉬워지면서 적대적 예제 탐색과 위험 역량 유도, 학습 데이터 내 기밀 추출이 용이해지고 유해·불법 콘텐츠 생성을 위한 오용이 무기한 지속된다.	in a security breach, the developer can no longer control or decommission the model. Reconfiguration becomes easy, adversarial example search, elicitation of dangerous capabilities, and extraction of confidential training data are facilitated, and misuse to produce harmful or illegal content continues indefinitely.					AI 특화 요소 없이 PAI 텍소노미에 부적합	
RAI4-1562	취약하거나 유해한 코드의 생성과 소프트웨어 전이	Generation of insecure code propagating into deployed software	코드 생성 모델이 보안 취약점을 포함하거나 부정확하고 유해한 코드와 코딩 제안을 산출하는 리스크로, 이러	The risk that code models generate insecure, incorrect, or harmful code and coding suggesti	1				삭제 — 코드 생성 모델의 보안 취약 코드 산출은 코딩 어시스턴트 일반의 이슈로, 물리 AI 한정 리스크가 아니	

			한 경향은 코딩 성능이 우수한 고급 모델에서도 나타난다. 개발자가 이를 채택하면 취약점이 배포된 프로그램에 묻혀 남아 다른 시스템에까지 피해를 주고 이 후의 공격에 노출된다.	ons, a tendency that persists even in advanced models with superior coding performance. Developers adopt the output and the flaws are buried in deployed programs, damaging connected systems and leaving them open to later exploitation.					라 PAI 텍소노미에 부적합		
RAI4-1596	모델 정확도 부족에 의한 과업 수행 실패	Task failure from insufficient model accuracy	모델이 잘못 설계되었거나 예상 입력이 변화하여 설계된 과업에 필요한 성능에 미치지 못하고 과업 수행에 실패하는 리스크.	The risk that a model's performance is insufficient for the task it was designed for, because it is not correctly engineered or its expected inputs change,	1					삭제 — 모델 정확도 부족에 따른 과업 실패는 모든 ML 시스템에 적용되는 일반론으로, 물리 AI 특화 요소가 없어 PAI 텍소노미에 부적합	

				causing task failure.						
RAI4-0035	미학습 도구 일반화 실패	Unseen tool generalization failure	알려진 도구에서는 안전하게 동작하는 에이전트가 스키마·어포던스·결과가 다른 미학습 도구로 일반화하지 못하는 리스크.	The risk that an agent that behaves safely with known tools fails to generalize to unseen tools with different schemas, affordances, or consequences.	1				삭제 — 미학습 도구의 일반화 실패는 에이전트/툴 사용 전반의 강건성 연구 주제로, 물리적 구현과 무관해 PAI 택소노미에 부적합	
RAI4-0213	시각 단일 관측의 안전 제약 식별 실패	Missed safety constraints under visiononly observation	강화학습 에이전트가 시각 관측에만 의존해 안전 제약 집행에 필요한 힘·접촉·가림·잠재 상태 정보를 놓치는 위험.	A reinforcement-learning agent relies only on visual observations and therefore misses force, contact, occlusion, or latent state information required to enforce a safety constraint.	1				삭제 — 시각 단일 관측 강화학습의 안전 제약 식별 실패는 RL 알고리즘 설계 연구 주제에 가까워, PAI 리스크로서의 구체성이 부족해 택소노미에 부적합	
RAI4-0377	국지적 윤리 안전 실패	Localized ethical	모델의 안전 행동이 지역에 근	The risk that model	1				삭제 — 지역 도덕적 딜레마·법	

		safety failure	거한 도덕적 딜레마·법적 기대·지역사회별 사회적 제약에서 실패하는 리스크.	safety behavior fails for locally grounded moral dilemmas, legal expectations, or community-specific social constraints.				적 기대에 서의 안전 행동 실패 는 일반 LLM의 문 화적 정렬 이슈로, 물 리 AI 한 정 리스크 가 아니라 PAI 텍소 노미에 부 적합	
RAI4-0408	지역 피해 비가시성	Local harms invisibility	지역 공동체에 중대한 피해가 글로벌 안전 벤치마크나 표준 모델 평가에서 탐지되지 않는 리스크.	The risk that harms salient to a local community are not detected by global safety benchmarks or standard model evaluations.	1			삭제 — 지 역 공동체 피해가 글 로벌 벤치 마크에서 탐지되지 않는 문제 는 평가 방 법론 이슈 로, 물리 AI 특화 요소 없이 PAI 텍소 노미에 부 적합	
RAI4-0811	기억된 지 식의 회상 실패	Failure to recall memorized knowledge	LLM이 질의된 지식을 실제로 기억하고 있음에도 공기 출현 패턴, 위치 패턴, 중복 데이터, 유사 개체명 으로 인해 이를 회상하지 못하는 리스크	The risk that an LLM fails to recall knowledge it has memorized because it is confused by co-occurrence patterns, positional patterns, duplicated data, and similar	1			삭제 — LLM의 기 억된 지식 회상 실패 (co-occurrence 패턴 등) 는 LLM 내부 동작 연구 주제로, 물 리 AI와 무 관해 PAI 텍소 노미에 부 적합	

				named entities.						
RAI4-0196	체화형 에이전트 탈옥에 의한 유해 물리 행동	Jailbreak of embodied agents into harmful physical action	공격자가 물리 작업 맥락의 프레이밍 등으로 체화형 LLM 에이전트의 안전 제한을 우회시켜, 손상된 추론이 상해나 손상을 일으키는 악의적이고 되돌리기 어려운 실제 물리 행동으로 전환되는 리스크.	The risk that an attacker, for instance by framing a physical task context, bypasses an embodied LLM agent's safety restrictions so that compromised reasoning is translated into malicious and irreversible real-world physical actions causing injury or damage.	1				용어 수정 — 'embodied agent'를 가능하면 '로봇'으로 통일 (해당 리스크: 물리 작업 맥락 프레이밍을 통한 탈옥으로 유해 물리 행동 유발). 참고로 본 L3(의도적·악의적 피해)는 사이버보안 L3와 의미상 중첩되는 부분이 있으나, 현재는 L3 이동을 진행하지 않고 추후 L3 체계 정비 시 반영	purposeful / malicious harm이 사이버 보안 I3와 의미 중첩
RAI4-0227	위험 작업 계획 승인	Hazardous task plan approval	embodied LLM이 식별 가능한 물리적 위험이 포함된 작업을 거부하거나 안전 제약을 추가하지 않고 계획을 생성·승인하는 위험.	An embodied LLM generates or approves a task plan containing identifiable physical hazards instead of refusing						

				it or adding the required safety constraints.						
RAI4-0669	AI 조력 악성코드 생성 및 사이버 공격 자동화	AI-assisted malicious code generation and cyberattack automation	대규모 언어모델의 코딩 능력이 악용되어 난독화·변이·다형성 악성코드가 저비용·고속으로 생성되고 공격 캠페인이 자동화되는 리스크. 이로 인해 숙련되지 않은 공격자의 진입 장벽이 낮아지고 방어 도구가 탐지하기 어려운 공격이 확산된다.	The risk that the coding ability of large language models is exploited to produce malware at low cost and high speed, including obfuscated, mutating, and polymorphic code, and to automate attack campaigns. This lowers the barrier to entry for unskilled attackers and yields attacks that defensive tools struggle to detect.	1				general 영역으로 이동 — LLM의 코딩 능력을 악용한 악성코드 자동 생성·변이는 물리적 구현 요소가 없는 일반 사이버공격 리스크	
RAI4-0758	프롬프트 주입 및 시스템 지시문 유출	Prompt injection and leakage of	이용자가 직접 제공하거나 검색된 웹 페이지·문서	The risk that untrusted content, supplied	1				general 영역으로 이동 — 프롬프트 주입을 통한	

	system instructions	·도구 출력 을 통해 간 접적으로 유입된 신 뢰할 수 없 는 콘텐츠 에 숨겨진 지시가 포 함되 고, 시스템 지 시와 이용 자 데이터 가 구조적 으 로 분리 되지 않아 모델이 이 를 정당한 명령처 럼 실행하는 리스크. 공 격자는 이 를 통해 의 도 된 동작 과 안전 제 약을 무력 화하고 에 이전트 의 도구 실행 방향을 바 꾸며 기밀 시스템 프 롬 프트를 복원하여 데이터 절 취, 무단 행위, 서 비스 거부 를 일으킨 다.	directly by a user or indirectly through retrieved pages, documen ts, and tool outputs, carries hidden instructio ns that a model executes as if authorize d, because system instructio ns and user data are not architect urally separate d. Attackers thereby override intended behaviou r and safety constrain ts, redirect agent tool execution , and recover confident ial system prompts, enabling data theft, unauthori zed				시스템 지 시문 유출· 데이터 절 취는 텍스 트 기반 LLM 전반 의 보안 리 스크로 물 리 AI 한 정 아님	
--	---------------------	---	--	--	--	--	--	--

				actions, and denial of service.						
RAI4-0767	기술적 안전조치 우회 공격	Circumvention of technical safety measures	공격자가 모델의 취약점을 악용해 오용 완화를 위한 기술적 안전조치를 우회하고 모델과 그 역량에 무단 접근함으로써 의도치 않은 유해 행동을 유발하는 리스크	The risk that attackers exploit model vulnerabilities to circumvent the technical measures intended to mitigate misuse, gaining unauthorized access to a model and its capabilities and eliciting unwanted behaviour.	1				사이버보안 영역으로 이동 — 모델 취약점을 악용해 오용 완화용 기술적 안전조치를 우회하는 리스크는 물리적 구현과 무관한 일반 사이버 보안 이슈	
RAI4-0773	비텍스트 모달리티를 통한 LLM 공격	Attacks on LLMs through non-text modalities	이미지·영상 등 텍스트 외 모달리티를 처리하는 다중모달 LLM에서, 공격자가 이미지에 탈옥 텍스트나 미세 교란을 삽입하여 안전장치를 우회하고 데이터 유출을 유발하는 리스크	The risk that attackers exploit multimodal LLMs by embedding jailbreaking text or imperceptible perturbations into images or video frames, bypassing safety mechanisms	1				삭제 — 이미지에 탈옥 텍스트·미세 교란을 삽입해 안전장치를 우회하는 것은 멀티모달 LLM 일반의 보안 이슈로, 물리 AI 특화 요소가 없어 부적합	

				ms and enabling exfiltration attacks.						
RAI4-0782	딥러닝 프레임워크 취약점 악용	Exploitation of deep-learning framework vulnerabilities	LLM이 구현 기반으로 삼는 딥러닝 프레임워크의 버퍼 오버플로, 메모리 손상, 입력 검증 결함 등 취약점이 악용되어 모델과 시스템이 침해되는 리스크	The risk that that vulnerabilities in the deep learning frameworks underlying LLMs, such as buffer overflows, memory corruption, and input-validation issues, are exploited to compromise models and systems.	1				삭제 — 딥러닝 프레임워크의 버퍼 오버플로·메모리 손상 등 취약점 악용은 AI 개발 인프라 전반의 이슈로 물리 AI 한정 아님	
RAI4-0789	GPU 부채널 공격에 의한 모델 파라미터 탈취	Model-parameter theft via GPU sidechannel attacks	LLM 학습에 필요한 대규모 GPU 자원이 부채널 공격의 표면이 되어, 공격자가 학습된 모델의 파라미터를 추출하는 리스크	The risk that the significant GPU resources required to train LLMs introduce a side-channel attack surface through which adversaries extract the	1				삭제 — GPU 부채널 공격을 통한 모델 파라미터 탈취는 모델 학습 인프라 보안 이슈로, 물리 AI 배포·운영과 무관해 부적합	

				parameters of trained models.						
RAI4-0917	개발 언어 인터프리터 취약점 위험	Programming language interpreter vulnerability threats	LLM 개발이 의존하는 Python 등 언어 인터프리터의 취약점이 개발된 모델의 보안을 위협하는 리스크.	The risk that that vulnerabilities in language interpreters such as Python, on which LLM development depends, threaten the security of the developed models.	1				삭제 — Python 등 언어 인터프리터 취약점은 AI 개발 도구 체인 전반의 이슈로 물리 AI 한정 아님	
RAI4-0919	전처리 도구 취약점 악용	Exploitation of pre-processing tool vulnerabilities	LLM 파이프라인에서 사용되는 전처리 도구 (예: OpenCV)의 취약점을 악용한 공격으로 시스템이 손상되는 리스크.	The risk that attacks exploiting vulnerabilities in pre-processing tools used in LLM pipelines, such as OpenCV, compromise the system.	1				삭제 — OpenCV 등 전처리 도구 취약점 악용은 AI 파이프라인 전반의 이슈로 물리 AI 한정 아님	
RAI4-0921	메모리 취약점 기반 모델 파라미터 변조	Model parameter tampering via memory vulnerabilities	로우해머 등 메모리 관련 하드웨어 취약점이 악용되어 LLM의 파라미터가 변조되는(예: DeepHamer)	The risk that memory-related hardware vulnerabilities such as rowhammer are leverage	1				삭제 — 로우해머 등 메모리 하드웨어 취약점을 통한 모델 파라미터 변조는 하드웨어 보안 일반 이슈로 물리	

			mer 공격) 리스크.	d to manipulate LLM parameters, as in DeepPhamer-style attacks.					AI 한정 아님	
RAI4-0927	LLM 대상 신종 공격	Novel attack vectors against LLMs	프롬프트 추상화를 통한 API 비용 악용, RLHF 과 정의 보상 모델 백도어, LLM을 활용한 적대적 샘플 생성 등 신종 공격 기법이 LLM 시스템을 위협하는 리스크.	The risk that novel attack techniques—prompt abstraction attacks exploiting API pricing, backdoor attacks on the RLHF reward model, and LLM-based construction of adversarial samples—threaten LLM systems.	1				general 영역으로 이동 — 프롬프트 추상화를 통한 API 비용 악용, RLHF 보상모델 백도어 등은 LLM 시스템 공통의 신종 공격 기법으로 물리 AI 한정 아님	

RAI4-0928	프롬프트 주입을 통한 목표 탈취	Goal hijacking via prompt injection	입력에 기존 지시를 무시하라는 문구를 주입 하여 LLM에 설계된 원래 목표가 탈취되고 주입된 새 목표가 실행되는 리스크.	The risk that injecting a phrase such as ignore the above instruction and do into the input hijacks the original goal of the designed prompt in an LLM and executes the attacker's injected goal instead.	1				general 영역으로 이동 — '이전 지시를 무시하라'는 프롬프트 주입을 통한 목표 탈취는 텍스트 기반 LLM 전반의 리스크로 물리 AI 한정 아님	
RAI4-0930	다단계 탈옥	Multi-step jailbreaks	일련의 대화에서 요청을 단계적으로 맥락화하거나 외부 인터페이스·모델의 도움을 받아 시나리오를 구성함으로써 LLM이 유해하거나 민감한 콘텐츠를 단계적으로 생성하게 되는 리스크.	The risk that multi-step jailbreaks , constructing well-designed scenarios across a series of conversations through request contextualizing or external assistance, guide LLMs to generate harmful or sensitive	1				general 영역으로 이동 — 여러 턴에 걸쳐 맥락화된 다단계 탈옥은 대화형 LLM 일반의 리스크로 물리 AI 한정 아님	

				content step by step.						
RAI4-0943	보안 - 견고성	Security - robustness	프롬프트 인젝션·시각적 적대예제 등 탈옥 기법과 백도어·모델 포이징으로 안전 가드레일이 우회되고 모델·프롬프트가 탈취되는 등 시스템에 가해지는 위협이 실현되는 리스크.	The risk that threats posed to generative AI systems materialize through jailbreaking techniques such as prompt injection and visual adversarial examples, backdoors and model poisoning that bypass safety guardrails, and model or prompt theft.	1				삭제 — 프롬프트 인젝션·백도어·모델 포이징 등을 포괄적으로 요약한 카드로, 이미 개별적으로 존재하는 다른 리스크 카드들과 중복	
RAI4-1058	악성코드 개발 비용 절감 지원	Lowering the cost of malware development	LM 기반 보조 코딩 도구가 탐지를 회피하도록 기능을 바꾸는 다형성 악성코드의 개발 비용을 낮추는 리스크.	The risk that assistive coding tools based on LMs lower the cost of developing polymorphic malware able to change	1				삭제 — LM 기반 코딩 도구가 탐지 회피형 다형성 악성코드 개발 비용을 낮추는 것은 일반 사이버 범죄 리스크로 물리 AI 한정 아님	

				its features in order to evade detection .						
RAI4-1176	역노출	Reverse exposure	공격자가 모델이 금지된 출력을 생성하도록 유도하여 불법·비윤리 정보에 접근함으로써 안전 통제가 접근 통로로 역전되는 리스크	Attackers induce the model to generate prohibited outputs and thereby extract illegal or unethical information, reversing safety controls into an access channel.	1				general 영역으로 이동 — 금지된 출력을 유도해 불법·비윤리 정보에 접근하는 역노출 리스크는 텍스트 기반 안전장치 우회 이슈로 물리 AI 한정 아님	
RAI4-1348	대규모 표적 괴롭힘	Targeted harassment at scale	LLM이 온라인에서 개인을 표적으로 배포되어 개인화된 유해 메시지를 대규모로 발송함으로써 표적 괴롭힘이 발생하는 리스크.	The risk that LLMs are deployed to target individuals online, sending them personalized and harmful messages at scale.	1				삭제 — LLM을 이용한 개인화된 대규모 표적 괴롭힘은 텍스트/메시지 기반 응용 리스크로 물리적 구현 요소가 없어 부적합	
RAI4-1354	대규모 사이버범죄 오용	Cybercrime misuse at scale	악의적 행위자가 생성 모델을 탈옥시켜 민감·유해 콘텐츠와 표적 맞춤형 설득 자료를 생산함으로써 사이버범죄	Malicious actors jailbreak generative models to produce sensitive or harmful content	1				general 영역으로 이동 — 생성 모델을 탈옥시켜 유해 콘텐츠·설득 자료로 사이버범죄를 대규모화하는 리스	

			죄를 저비용·대규모로 수행하는 리스크	and generate persuasive, individually tailored material, conducting cybercrime efficiently at scale and reduced cost.				크는 물리 AI 한정 아님	
RAI4-1513	해석 가능성 기술의 오용	Misuse of interpretability techniques	모델에 대한 이해를 높이는 해석가능성 기법이 안전 관련 특징을 부호화한 뉴런의 활성 저하나 정보 검열에 사용되거나 화이트박스 공격 시나리오 모의와 적대적 공격 개발에 활용되는 리스크.	The risk that interpretability techniques, by enabling a better understanding of the model, are used for harmful purposes such as identifying and modifying neurons that encode safety-related features to decrease their activation or censor information, or simulating a white-	1			general 영역으로 이동 — 해석가능성 기법을 안전 뉴런 비활성화나 화이트박스 공격 개발에 악용하는 것은 모델 내부 분석 연구 영역의 리스크로 물리 AI 한정 아님	

				box attack scenario to aid the development of adversarial attacks.						
RAI4-1517	안전 가드레일을 무력화하는 탈옥 공격	Jailbreak attacks subverting model safety guardrails	배포 중의 적대적 입력, 정교하게 설계된 미세 조정 데이터셋, 학습 데이터에 심어진 백도어 가 모델의 가드레일을 뚫는 리스크로, 내부 파라미터에 접근하는 화이트박스 자동 생성과 내부 접근 없는 블랙박스 방식, 추론·역할극을 활용한 사람이 읽을 수 있는 프롬프트를 모두 포함한다. 그 결과 모델이 폭탄 제조 안내처럼 명시적으로 금지된 작업을 수행하고 유해 콘텐츠를 산출하며, 이러한 취약성은 보안 학습 이후에도 지속되고 표준화된 평가	The risk that adversarial inputs supplied during deployment, elaborately designed fine-tuning datasets, or backdoors poisoned into training data break through a model's guardrails, whether generated automatically with white-box access to parameters, crafted in black-box settings, or written as human-readable	1				general 영역으로 이동 — 적대적 입력·백도어 미세조정 데이터셋을 통해 가드레일을 뚫는 일반 LLM 탈옥 리스크로 물리 AI 한정 아님	

			방법도 부재하다.	prompts using reasoning and role-play. The model then performs explicitly prohibited actions and produces harmful content, and such vulnerabilities persist through security training and lack standardized means of evaluation.						
RAI4-1520	저빈도 인코딩·저자원 언어를 통한 안전 훈련 우회	Safety-training bypass via rare encodings and low-resource languages	Base64 등 안전 미세조정에 충분히 포함되지 않은 텍스트 인코딩이나 저자원 언어로 유해 프롬프트를 변환하여 모델의 안전장치를 우회하는 리스크.	The risk that harmful natural language prompts translated into text encodings such as Base64 or into low-resource languages that safety fine-tuning covers little or not at all are used	1				general 영역으로 이동 — Base64 인코딩·저자원 언어를 이용해 안전 미세조정을 우회하는 것은 텍스트 기반 탈옥 기법으로 물리 AI 한정 아님	

				to craft jailbreak attacks that bypass a model's safeguards.						
RAI4-1521	추가 모달리티로 인한 공격면 확대	Attack-surface expansion from additional modalities	멀티모달 모델에서 모달리티별 견고성 차이로 공격자가 가장 취약한 모달리티를 선택할 수 있어 새로운 공격 벡터가 생기고 탈옥부터 데이터 오염까지 기존 공격의 범위가 확대되는 리스크.	The risk that additional modalities introduce new attack vectors in multimodal models and expand the scope of previous attacks ranging from jailbreaking to poisoning, as differing robustness levels across modalities let malicious actors choose the most vulnerable part of the model to attack.	1				general 영역으로 이동 — 모달리티별 견고성 차이를 이용한 공격면 확대는 멀티모달 모델 일반의 이슈로 물리 AI 한정 아님	

RAI4-1522	다수 예시 장문맥 탈 옥	Many- shot long- context jailbreaki ng	긴 컨텍스 트 창에 다 수의 유해 출력 예시 를 제 시하 여 짧은 컨 텍스트 모 델에서는 통하지 않 던 공격이 성공하고 유해 응답 이 유도되 며, 컨 텍 스트 창이 확대될수 록 이러한 취약성이 커 지는 리 스크.	The risk that language models with long context windows are exploited by manyslot jailbreaki ng, where supplying a high number of examples of the desired harmful output elicits undesira ble response s that few-shot attacks fail to trigger, with the vulnerabil ity becomin g more significan t as context windows expand.	1				삭제 — 긴 컨텍스트 창에 다수 의 유해 예 시를 제시 하는 many- shot 탈옥 은 LLM 컨 텍스트 처 리 특성에 기인한 리 스크로 물 리 AI 한 정 아님	
RAI4-1658	도메인별 오용	Domain- specific misuses	의료·교육 등 민감 영 역에 LLM 을 조야하 게 적 용하 여 비동의 실험적 치 료, 부정행 위, 저품질 자동 평가, 설득력 있	Crude applicatio n of LLMs in sensitive domains such as health and educatio n	1				삭제 — 의 료·교육 등 민감 도메 인에서의 조야한 LLM 적용 에 따른 오 용은 도메 인 특화 오 용 리스크 로, 로봇/	

RAI4-1666	프록시 목표 최적화를 통한 탈옥 자동 탐색	Automated discovery of jailbreaks through proxy-objective optimization	공격자가 탈옥 성공과 잡음 있게 상관된 프록시 목표에 대해 수동 또는 자동으로 그래디언트 기반 및 비그래디언트 적대적 최적화를 수행하여 탈옥 공격을 발견하는 리스크.	The risk that jailbreak attacks are discovered by performing manual or automated, gradient-based or gradient-free adversarial optimization against a proxy objective noisily correlated with jailbreak success.	1				general 영역으로 이동 — 프록시 목표에 대한 그라디언트 기반/비그라디언트 최적화로 탈옥을 자동 탐색하는 것은 적대적 공격 연구 방법론으로 물리 AI 한정 아님	
RAI4-1675	언어 거부에도 실행되는 유해 물리 행동	Harmful action executed despite verbal refusal under action-space misalignment	체화된 LLM이 언어 출력 공간과 행동 출력 공간 정렬 불량으로 인해 유해한 요청을 언어로는 거부하면서 해당 물리적 행동은 그대로 실행하는 리스크.	The risk that an embodied LLM verbally refuses a harmful request while still executing the corresponding physical action, due to misalignment between its linguistic and action						

				output spaces.						
RAI4-1686	궤적 지속형 적대적 공격	Trajectory-persistent adversarial attack	월드 모델 인코더에 가해진 단일 적대적 교란이 순환 잠재 상태를 통해 전파되어 다단계 롤아웃 전체를 손상시키며, 무상태 모델보다 훨씬 파괴적으로 초기 단계에서 증폭되는 리스크.	The risk that a single adversarial perturbation to a world-model encoder propagates through recurrent latent state, corrupting an entire multi-step rollout far more destructively than in a stateless model through early-step amplification.	1				삭제 — 월드 모델 인코더에 대한 단일 적대적 교란이 순환 잠재 상태를 통해 다단계 롤아웃을 손상시키는 현상은 월드 모델 적대적 견고성 연구 주제로 PAI 리스크로서 구체성 부족	
RAI4-0197	유해 행동 재구성 공격	Harmful-action reframing attack	공격자가 유해한 물리 행동 지시를 무해하거나 정상적인 작업 요청처럼 바꾸어 embodied 에이전트가 이를 수용·실행하도록 유도하는 위험.	An attacker rephrases a harmful physical instruction as a benign or task-compliant request so that the embodied agent accepts and						

				executes it.					
RAI4-0198	완곡 표현을 이용한 유해 의도 은폐	Euphemistic concealment of harmful physical intent	공격자가 유해한 대상과 결과는 유지한 채 완곡어·대체 표현·간접 개념으로 물리적 위해 의도를 숨기는 위험.	An attacker conceals harmful physical intent with euphemisms, substitutions, or indirect concepts while preserving the same harmful target and outcome.	1				삭제 — RAI4-0197(유해 행동 재구성 공격)과 사실상 동일한 리스크. 완곡어·대체 표현으로 유해한 물리 행동 의도를 숨기는 것은 '무해한 요청으로 재구성'하는 것과 본질적으로 같은 공격 패턴으로 중복
RAI4-0199	불법·유해 물리 요청의 수용·실행	Execution of illegal or harmful physical requests	체화형 에이전트가 신체 위해, 침입, 절도, 사기, 파괴, 도피 등 불법적인 물리적 행위를 요구하는 사용자 요청을 수용·실행하거나 실질적으로 지원하여, 사람과 재산에 피해를 입히는 리스크.	The risk that an embodied agent accepts, carries out, or materially assists user requests calling for physical harm, intrusion, theft, fraud, sabotage, evasion, or other illegal physical-world acts, injuring people or property.					

RAI4-0201	피지컬 AI의 파괴·학대 행동	Destructive or abusive acts by physical AI	피지컬 AI 시스템이 장비·인프라 등 물리적 자산을 손상·무력화·방해·변조하거나 공유 환경의 사람들에게 차별·괴롭힘·위협·학대 행동을 하도록 유도·지시되어, 재산 피해와 대인 피해를 일으키는 리스크.	The risk that a physical AI system is induced or directed to damage, disable, obstruct, or tamper with equipment, infrastructure, or other assets, or to perform discriminatory, harassing, intimidating, or abusive actions toward people in shared environments, causing property and interpersonal harm.						
RAI4-0210	인지-행동 순서 조작 공격	Perception-action sequence manipulation attack	공격자가 영상 순서의 관측이나 행동 단서를 조작해 로봇이 명시된 충돌·힘·이격 거리·대상물 사용 제약을 위반	An attacker alters observations or action cues across a video sequence so that a robot						

			하게 하는 위험.	violates a specified collision, force, distance, or object-use constrain t.						
RAI4-0221	로봇 인지 거냥 적대 패치 공격	Adversari al patch attack on robot perceptio n	공격자가 물체나 표 지에 최적 화된 시각 패턴 을 부 착해 특정 인지 오류 와 후속 위 험 행동을 유발하는 리스크.	The risk that an attacker places an optimize d visual pattern on an object or sign to induce a targeted perceptio n error and downstre am unsafe robot action.						
RAI4-0302	로봇 능력 의 무기화	Weaponi zation of robotic capabiliti es	이동형·공 중·휴머노 이드·매니 플레이터 시스 템의 조작·이동 능력이 감 시, 위협, 파괴 공작 또는 사람· 재산·인프 라에 대한 물리적 공 격에 전용 되는 리스 크.	The risk that the manipulat ion and mobility capabiliti es of mobile, aerial, humanoi d, or manipulat or systems are repurpos ed for surveillan ce, intimidati on, sabotage , or						

				physical attack on people, property, or infrastructure.						
RAI4-0305	자동화된 표적 스토킹·물리적 위협	Automated targeted stalking and physical intimidation	운영자나 공격자가 특정인을 위협하거나 괴롭힐 목적으로 로봇에 반복 추적·진로 차단·고립·접근을 지시하는 위협.	An operator or attacker directs a robot to repeatedly follow, block, corner, or approach a specific person in order to intimidate or harass them.						
RAI4-0311	피지컬 행동 편향 실행	Bias executed as physical behavior	기반 모델 편향이 분류·회피·차별적 서비스 등 피지컬 행동으로 실행되는 위협.	A robot turns biased model outputs into unequal physical service, movement, or treatment.	1				L3 재배치 검토 — 기반 모델 편향이 분류·회피·차별적 서비스 등 피지컬 행동으로 실행되는 것은 물리적 공격보다는 공정성/차별 영역에 가까움. RAI4-0312(인구집단별 서비스 격차)와 사실상 동일 주제로 통합 검토 필요	
RAI4-0323	장면 의미 조작 공격	Semantic scene manipulation attack	공격자가 모델이나 센서를 직접 변경하	The risk that an attacker changes						

			지 않고 표지·물체 배치·의복 패턴·장면 맥락을 바꾸어 로봇이 환경을 잘못 해석하게 만드는 리스크.	a sign, object placement, clothing pattern, or scene context so that a robot misinterprets the environment without modifying the model or sensor.						
RAI4-1677	개념적 속임수에 의한 유해 물리 행동 유도	Harmful physical action induced by conceptual deception	유해한 물리적 과업을 무해한 개념적 용어로 재구성함으로써 체화 에이전트가 유해성을 인식하지 못한 채 해당 행동을 수행하는 리스크.	The risk that reframing a harmful physical task in benign conceptual terms induces an embodied agent to perform unrecognized harmful behavior.	1				삭제 — RAI4-0197과 사실상 동일한 리스크. 유해한 물리 과업을 무해한 개념적 용어로 재구성해 에이전트가 유해성을 인식하지 못하게 하는 것은 0197의 '재구성 공격'과 동일 메커니즘으로 중복	
RAI4-0348	로봇 군집 하이재킹	Fleet hijacking	클라우드·업데이트·API·오케스트레이션 레이어의 취약성이 여러 로봇·차량·드론·산업 시스템을 동시에 침해하는 위험.	A vulnerability in a cloud, update, API, or orchestration layer may allow many robots, vehicles, drones,						

				or industrial systems to be compromised together.						
RAI4-0350	핵심 인프라 로봇 사이버 사보타주	Cyber-enabled sabotage of critical infrastructure robots	공격자가 로봇 검사·유지보수·물류·제어 시스템을 침해해 핵심 인프라의 운영을 교란하거나 설비를 손상시키는 리스크.	The risk that an attacker compromises robotic inspection, maintenance, logistics, or control systems to disrupt or damage critical infrastructure.						
RAI4-0774	GPAI 모델의 백도어 또는 트로이 목마 공격	Backdoors or trojan attacks in GPAI models	학습 또는 미세조정 과정에서 모델 제작자나 제3자가 GPAI 모델에 백도어를 삽입하고 배포 단계에서 이를 악용하여, 최소한의 비용으로 모델 출력을 표적화해 높은 성공률로 통제하는 리스크	The risk that backdoors inserted into GPAI models during training or fine-tuning, by the model provider or another actor manipulating training data or software infrastructure, are exploited during deployment	1				general 영역으로 이동 — 학습/미세조정 단계에서 GPAI 모델에 삽입된 백도어를 배포 후 악용해 출력을 표적 통제하는 것은 GPAI 모델 전반의 보안 리스크로 물리 AI 한정 아님	

				ent to control model outputs in a targeted way with high success rate and minimal overhead .						
RAI4-1337	악용 가능한 시스템 결함·백도어	Exploitable system defects and backdoors	AI 알고리즘과 모델의 설계·훈련·검증 단계, 개발 인터페이스와 실행 플랫폼에 쓰이는 표준화된 API와 기능 라이브러리, 툴킷에 논리적 결함과 취약점이 있어 악용되거나 의도적으로 백도어가 심겨 공격에 사용되는 리스크.	The risk that the standardized APIs, feature libraries, and toolkits used in the design, training, and verification stages of AI algorithms and models, development interfaces, and execution platforms contain logical flaws and vulnerabilities that can be exploited, or have backdoors intentionally embedded and triggered	1				general 영역으로 이동 — AI 설계·훈련·검증에 쓰이는 표준 API·툴킷의 결함·백도어는 AI 개발 인프라 전반의 이슈로 물리 AI 한정 아님	

				for attacks.						
RAI4-1338	AI 컴퓨팅 인프라 보안 위협	AI computing infrastructure security threats	AI 훈련·운영을 뒷받침하는 컴퓨팅 인프라가 다양하고 유비쿼터스적인 컴퓨팅 노드와 자원에 의존함으로써 컴퓨팅 자원의 악의적 소비와 컴퓨팅 인프라 계층에서의 보안 위협 국경 간 전파에 노출되는 리스크.	The risk that the computing infrastructure underpinning AI training and operations, relying on diverse and ubiquitous computing nodes and various computing resources, is exposed to malicious consumption of computing resources and cross-boundary transmission of security threats at the computing infrastructure layer.	1				general 영역으로 이동 — 컴퓨팅 자원의 악의적 소비, 인프라 계층의 국경 간 보안 위협 전파는 AI 컴퓨팅 인프라 전반의 이슈로 물리 AI 한정 아님	
RAI4-1377	사이버 공격 장벽 저하·공격표면 확대	Lowered cyberattack barriers and	취약점의 자동 발견과 악용 등으로 해킹·맬웨어·피	The risk that lowered barriers for	1				general 영역으로 이동 — 취약점 자동 발견·악용	

		expanded attack surface	싱 등 공격적 사이버 역량의 장벽이 낮아지고 표적 공격의 공격표면이 확대되어 시스템 가용성과 학습 데이터·코드·모델 가중치의 기밀성·무결성이 훼손되는 리스크.	offensive cyber capabilities, including automated discovery and exploitation of vulnerabilities easing hacking, malware, phishing, and other cyberattacks, together with an increased attack surface for targeted cyberattacks, compromise a system's availability or the confidentiality or integrity of training data, code, or model weights.					으로 해킹·맬웨어·피싱 장벽이 낮아지는 것은 GPAI 공통의 사이버 위협으로 물리 AI 한정 아님	
RAI4-1547	모델 확산에 의한 이중용도 역량의 저비용 확산	Low-cost diffusion of dual-use capabilities through model proliferation	오픈소스·오픈웨이트 GPAI 모델의 확산으로 비전문가가 최소 비용으로 이중용도 역량에 접근하	The risk that proliferation of open-source or open-weight GPAI models	1				general 영역으로 이동 — 오픈소스·오픈웨이트 GPAI 확산으로 비전문가가 이중용도 역량(예:	

			고, 기반 모델의 개 조를 통해 독소 합성 용 단백질 서열 생성 등 위험한 용도로 전 용되 는 리 스크.	gives nonexper ts low- cost access to dual-use capabiliti es and allows base models to be modified for dangerou s uses such as generatin g candidat e protein sequenc es for toxin synthesis .					독소 단백 질 서열 생 성)에 접 근하는 것 은 물리 AI 한정 리스크가 아님	
RAI4- 1550	기반 모델 취약성에 기인한 인 프라 공통 원인 장애	Common -mode infrastruc ture failure from underlyin g model vulnerabil ities	중요 인프 라가 GPAI에 의존할 때 기반 모델 아키텍처 나 훈련 설 정의 취약 성·견고성 문제 가 우 발적 경계 사례나 적 대적 입력 에 의해 촉 발되어 공 통원인 장 애로 이어 지는 리스 크.	The risk that vulnerabil ities or robustne ss issues in the underlyin g model architect ure or training setup produce common- mode failures across critical infrastruc ture relying on GPAI, triggered accident ally in edge	1				general 영역으로 이동 — 기 반 모델 아 키텍처·훈 련 설정의 취약성이 GPAI 의 존 인프라 의 공통원 인 장애로 이어지는 것은 물리 AI 한정 리스크가 아님	

				cases or by adversarial inputs.						
RAI4-1561	취약점 자동 탐지·악용에 의한 사이버공격 확대	Cyberattack scaling through automated vulnerability discovery and exploitation	GPAI가 소프트웨어 취약점의 자동 발견과 악성 코드 자동 개발을 지원하여 악의적 행위자의 사이버공격이 저비용으로 대규모화되고 피해가 증대되는 리스크.	The risk that GPAI aids automated discovery of software vulnerabilities and automated malware development, allowing malicious actors to scale cyberattacks at low cost and increase their impact.	1				general 영역으로 이동 — GPAI의 취약점 자동 탐지·악성코드 자동 개발 지원으로 사이버공격이 대규모화되는 것은 물리 AI 한정 리스크가 아님	
RAI4-0180	희귀 가정 상해의 전조 감지 실패	Failure to detect rare household injury precursors	가정용 에이전트가 드물지만 가능한 낙상·중독·화상·열상·압착 사고의 전조를 감지하지 못해 경고하거나 개입하지 않는 위험.	A household agent fails to detect early signs of rare but plausible falls, poisoning, burns, lacerations, or crush events and therefore does not warn or intervene.						

RAI4-0181	물리적 위험의 감지·예측 실패	Failure to detect or anticipate physical hazards	멀티모달·체화형 시스템이 텍스트·이미지·영상·센서 입력에 이미 나타난 위험 상태를 식별하지 못하거나 진행 중인 움직임·접촉·환경 변화가 곧 위험을 초래할 것을 예측하지 못한 채 행동을 선택하여, 충돌·손상·상해로 이어지는 리스크.	The risk that a multimodal or embodied system neither identifies a hazardous condition already present in its text, image, video, or sensor input nor predicts that ongoing motion, contact, or environmental change will soon create one, selecting actions that end in collision, damage, or injury.						
RAI4-0224	런타임 안전 모니터 실패	Runtime safety monitor failure	런타임 안전 모니터가 속도·힘·이격 거리·작업 공간·충돌·물체 사용·작업 프로토콜에 대한 제약을 감지·집행하지 못하여, 위험이 발생할 때까지 안전하지	The risk that runtime safety monitors fail to detect or enforce constraints governing speed, force, separation,						

			않은 동작 이 지속되 는 리스크.	workspac e, collision, object use, and task protocol, allowing unsafe motion to continue until harm occurs.						
RAI4- 0234	제어 장벽 함수 안전 필터 실패	Control barrier function safety- filter failure	제어 장벽 함수 기반 안전 계층 이 인지·동 역학·모델 불확실성 하에서 비 안전 행동 을 제약하 지 못하는 리스크.	The risk that a safety layer based on control barrier functions fails to constrain unsafe actions under perceptio n, dynamics , or model uncertain ty.						
RAI4- 0240	접촉 조작 힘 감지 실패	Contact- rich manipulat ion force- sensing failure	접촉 집약 조작 정책 이 힘·촉각 ·오디오·시 각 단서를 올바르게 사용하지 못하여 비 안전 압력 ·파지·이동 을 유발하 는 리스크.	The risk that a contact- rich manipulat ion policy fails to correctly use force, tactile, audio, or visual cues, creating unsafe pressure, impact,						

				or object damage.						
RAI4-0261	시뮬레이션-실세계 전이·검증 실패	Sim-to-real transfer and validation failure	시뮬레이션에서 훈련·검증된 정책이 접촉·지연·마모·액추에이터에 관한 동일한 미모델링 가정을 공유하는 시뮬레이터 간 검사까지 통과하고도, 실제 마찰, 조명, 인간 행동, 롱테일 사건이 시뮬레이션과 달라지는 하드웨어 환경에서 실패하여 잘못된 안전 확신 속에 배포 되는 리스크.	The risk that a policy trained or validated in simulation, including across multiple simulators sharing the same unmodelled contact, delay, wear, or actuator assumptions, passes testing yet fails on real hardware where friction, lighting, human behavior, or long-tail events diverge, so it is deployed under false safety assurance.						
RAI4-0278	가정 내 위험 행동 선별 누락	False-negative household action screening	안전 분류기가 알려진 대상물·인간 접촉·열·작업 공간 제약을 위반하는 가정 내	A safety classifier labels a proposed household action as acceptab						

			제안 행동을 허용 가능한 것으로 잘못 판정하는 위험.	le even though the action violates a known object, human-contact, heat, or workspace constraint.						
RAI4-0321	악천후 인지 실패	Adverse weather perception failure	비·안개·눈 부심·먼지·연기·저조도가 카메라·라이다·레이더·촉각·오디오 인지를 저하시켜 비안전 행동을 유발하는 위험.	Rain, fog, glare, dust, smoke, or low light may degrade cameras, LiDAR, radar, tactile sensors, or audio perception, weakening real-time situational awareness.						
RAI4-0322	다중 센서 융합 상충	Multimodal sensor fusion conflict	카메라·라이다·레이더·촉각·자기 수용 신호의 충돌이 불안정한 장면 추정 및 비안전 하위 행동을 초래하는 위험.	Conflicting camera, LiDAR, radar, tactile, or proprioceptive signals may lead to unstable scene estimates and unsafe downstre						

				am control decisions .						
RAI4-0352	배포 후 변경에 대한 안전 재평가 실패	Failure to reassess safety after deployment changes	환경 변화·부품 열화·모델 업데이트·아차 사고 로 기존 안전 가정이 무효화됐는데도 운영자가 안전성을 재평가하지 않고 운용을 계속하는 위험.	Operators continue deployment without reassessing safety after environmental changes, component degradation, model updates, or near-miss incidents invalidate prior assumptions.						
RAI4-0442	사실·증거 환각	Hallucination of facts and evidence	모델이 그럴듯한 형식으로 제시된 허위 인용, 사실, 법적 주장, 과학적 증거를 포함하여 학습 데이터나 입력에 충실하지 않은 부정확한 콘텐츠를 생성하여, 이를 신뢰한 사용자를 오도하는 리스크.	The risk that a model generates factually inaccurate or ungrounded content, including fabricated citations, facts, legal claims, and scientific evidence presented plausibly,	1				general 영역으로 이동 — 허위 인용·사실·법적 주장을 그럴듯한 형식으로 생성하는 환각은 텍스트 기반 LLM 전반의 리스크로 물리 AI 한정 아님	

				misleading users who rely on it.						
RAI4-0444	대중 지식의 모델 붕괴	Model collapse of public knowledge	합성 콘텐츠에 대한 재귀적 학습이 공공 정보 품질과 미래 모델 학습 데이터의 저하시켜 공유 지식 자원의 모델 붕괴를 초래하는 리스크	Recursive training on synthetic content degrades public information quality and future model training data, driving model collapse of shared knowledge resources.	1				general 영역으로 이동 — 합성 콘텐츠에 대한 재귀적 학습으로 공공 지식 자원이 저하되는 모델 붕괴는 GPAI 생태계 전반의 이슈로 물리 AI 한정 아님	
RAI4-0787	외부 도구에 의해 주입된 사실 오류	Factual errors injected by external tools	외부 도구가 웹 API·검색 엔진 등 공개 자원에서 얻은 추가 지식을 입력 프롬프트에 통합하는 과정에서, 도구의 신뢰성이 보장되지 않아 사실 오류가 포함된 내용이 유입되고 환각 문제가 증폭되는 리스크	The risk that external tools incorporate additional knowledge from public resources such as web APIs and search engines into input prompts, and that unreliable tool content containing factual errors consequ	1				general 영역으로 이동 — 웹 API·검색 엔진 등 외부 도구가 주입한 사실 오류로 환각이 증폭되는 것은 RAG 시스템 일반의 이슈로 물리 AI 한정 아님	

				ently amplifies the hallucinat ion issue.						
RAI4-0803	디코딩 과정 결함에 의한 환각	Hallucination from defective decoding processes	자기회귀 생성 방식이 오류를 누적시키고 top-p/top-k 등 다양성 확대 샘플링이 무작위성을 도입하여 모델이 환각 콘텐츠를 산출하는 리스크	The risk that autoregressive generation accumulates errors while diversifying sampling strategies such as top-p and top-k introduce randomness, increasing the model's production of hallucinated content.	1				삭제 — 자기회귀 생성의 오류 누적, top-p/top-k 샘플링에 따른 환각은 디코딩 알고리즘 설계 관련 ML 연구 주제로 PAI 리스크 태소노미에 부적합	
RAI4-0817	지식 경계로 인한 환각	Hallucination arising from knowledge boundaries	LLM의 학습 코퍼스가 모든 세계 지식을 담을 수 없고 롱테일 지식을 충분히 습득하지 못해, 입력 프롬프트가 요구하는 지식과 모델 내재 지식 사이의 격차가 환각을 유발하는 리스크	The risk that gaps between the knowledge involved in an input prompt and the knowledge embedded in an LLM, arising from training corpora that	1				general 영역으로 이동 — 학습 코퍼스가 담지 못한 지식과 롱테일 지식 격차로 인한 환각은 LLM 지식 표현의 근본적인 계로 물리 AI 한정 아님	

				cannot contain all world knowledge and from difficulty grasping long-tail knowledge, lead to hallucinations.						
RAI4-0820	잡음 학습 데이터에 의한 지식 오류	Knowledge errors from noisy training data	대규모 학습 코퍼스에 내재한 잡음과 허위 정보 모델 파라미터에 저장되는 지식에 오류를 유입시켜 환각을 유발하는 리스크	The risk that noise and misinformation inherent in large-scale training corpora introduce errors into the knowledge stored in model parameters, giving rise to hallucinations.	1				general 영역으로 이동 — 대규모 학습 코퍼스에 내재한 잡음·허위 정보가 모델 지식 오류로 이어지는 것은 학습 데이터 품질 이슈로 물리 AI 한정 아님	
RAI4-1524	검색증강 시 외부 허위 정보에 의한 허위 출력	False outputs from external misinformation in retrieval augmentation	검색증강 과정에서 모델의 사전 지식과 상충하는 소량의 일관된 허위 증거가 주어질 때 모델이 이에 민감하게 반응하여 허위 출력을 생성하는 리스크.	The risk that AI models, being particularly sensitive to coherent external evidence even when it conflicts with their prior knowledge, produce	1				general 영역으로 이동 — 검색증강 시 소량의 일관된 허위 증거에 모델이 과민 반응해 허위 출력을 내는 것은 RAG 시스템 일반의 이슈로 물리 AI 한정 아님	

				false outputs when given a relatively small amount of false information during the retrieval augmentation process.					
RAI4-1527	사용자 수행 설득에 의한 AI 모델의 오용	Misuse of AI model by user-performed persuasion	다중 턴 설득 대화가 모델이 사실적으로 옳은 입장을 포기하고 허위정보를 수용하게 만들며, 그 효과가 단일 턴 시도를 능가하는 리스크	Multi-turn persuasive conversation induces a model to abandon factually correct positions and accept misinformation, with persuasion effects exceeding single-turn attempts.	1				general 영역으로 이동 — 다중 턴 설득 대화로 모델이 사실적으로 옳은 입장을 포기하게 만드는 것은 대화형 LLM 전반의 취약점으로 물리 AI 한정 아님
RAI4-1688	장기 계획에서 누적되는 월드 모델 롤아웃 오류	Compounding world-model rollout error in long-horizon planning	다단계 월드 모델 롤아웃에서 예측 오류가 계획 깊이에 따라 누적되어 운동학적 드리프트와 구조적 위반이 발생하고 보상·안전 추정치가 왜곡되는	The risk that prediction errors compound across multi-step world-model rollouts as planning depth increases					

			리스크. 에이전트는 그럴듯하지만 물리적으로 잘못된 상상 궤적 위에서 장기 계획을 실행하고 매 행동이 오류를 다시 가중시킨다.	, producing kinematic drift, structural violations, and misleading reward or safety estimates. Agents execute long-horizon plans on imagined trajectories that are plausible but physically incorrect, with each successive action compounding the error further.						
RAI4-1696	사회 세계 모델 기반 미시표적 영향공작	Micro-targeted influence operations from social world models	소셜 데이터로 훈련된 기반 세계 모델이 감정을 자극하는 서사에 대한 인구통계별 반응을 예측하여, 대규모의 미시표적 영향력 행사와 심리적 표적 설득이 가능해지는 리스크.	The risk that a foundation world model trained on social data predicts demographic responses to emotionally charged narratives, enabling microtargeted	1				general 영역으로 이동 — 소셜 데이터로 훈련된 세계 모델이 감정 자극 서사에 대한 인구통계별 반응을 예측해 여론을 미시표적 조작하는 것은 물리 AI 한정 리스크가 아님	

				eted influence and psycholo gically targeted persuasio n at scale.						
RAI4- 1697	반사실적 권위 문제	Counterf actual authority problem	월드모델 의 반사실 적 설명이 학습 분포 를 반 영할 뿐인데도 운영자·규 제자가 인 과적 사실 로 수용하 여 책임 귀 속·회피에 선택적으 로 활 용되 는 리스크	Operator s and regulator s accept worldmo del counterfa ctual explanati ons as causal ground truth although they reflect the model's learned distributi on, allowing selective use to attribute or deflect liability.						
RAI4- 0209	감각 교란 기반 비안 전 행동	Adversari al sensory perturbat ion induced unsafe action	영상 또는 감각 입력 의 적대적 변경이 로 봇 정 책으 로 하여금 비안전 피 지컬 행동 을 선택하 게 하는 위 험.	Adversari al changes to video or sensory inputs cause a robot policy to select unsafe physical actions.						
RAI4- 0337	물리 운용 환경 분포	Distributi on shift in	배포 환경 이 건물·도	Deploym ent						

	이동	physical operation	로·공장·가정·병원·기상 조건에 걸쳐 모델이 적응할 수 있는 것보다 빠르게 변화하는 위험.	environments may change across buildings, roads, factories, homes, hospitals, or weather conditions faster than monitoring and adaptation mechanisms can detect.						
RAI4-0466	적대적 입력 교란	Adversarial input perturbation	텍스트·이미지·오디오·영상 입력에 가해진, 사람은 흔히 지각하지 못하는 작은 교란이 모델의 의사결정 방식을 악용하여 오분류, 오작동, 안전하지 않은 동작을 유발하는 리스크.	The risk that small, often humanim perceptible perturbations to text, image, audio, or video inputs exploit how a model makes decisions , causing misclassification, malfunction, or unsafe behavior.	1				general 영역 이동 검토 — 텍스트·이미지·오디오·영상 입력에 대한 일반적인 적대적 교란 (오분류·오작동 유발)으로, 로봇 정책에 특화된 RAI4-0209(각 교란 기반 비안전 행동)와 개념이 겹침. 0209와 통합하거나 general로 이동 검토	
RAI4-0920	분산 학습 네트워크 교란	Disruption of distributed training networks	LLM 분산 학습의 GPU 노드 간 그래디언트 전송 트래픽이	The risk that the volumetric gradient traffic	1				삭제 — GPU 노드 간 그래디언트 전송 트래픽이 버스트 공	

			펄스 공격 등 버스트 트래픽에 의해 교란되거나 혼잡을 겪어 학습이 방해받는 리스크.	between GPU server nodes in distributed LLM training is disrupted by burst traffic such as pulsating attacks or suffers congestion, impairing training.					격으로 교란되는 것은 분산 학습 인프라 단계의 리스크로, 배포된 물리 AI 시스템의 운영 리스크가 아님	
RAI4-1287	환경 유발 결함 변이	Environment-induced fault mutation	제조 결함이나 우주선(cosmic ray)에 의한 비트 반전 등 배포 후 환경 요인이 지능 시스템 내부를 변화시켜 의도되지 않은 행동 변이를 일으키는 리스크	Post-deployment environmental effects such as manufacturing defects or cosmicray bit flips alter an intelligent system's internals, producing unintended behavioral modification.						
RAI4-0245	전신 이동 충돌 위험	Whole-body locomotion collision risk	휴머노이드 이동 정책이 전신 동작 및 환경 접촉이 충분히 고려되지 않아 물체·벽·인간과 충돌	A humanoid locomotion policy collides with objects, walls, or humans						

			돌하는 위험.	because whole-body motion and environmental contact constraints are not jointly satisfied.						
RAI4-0247	정밀 휴머노이드 접촉력 위험	Dexterous humanoid contact-force risk	정밀 휴머노이드 손 또는 전신 조작기가 파지·균형·물체 동역학 간 상호작용으로 비안전한 접촉력을 가하는 위험.	A dexterous humanoid hand or wholebody manipulator applies unsafe contact forces because grasp, balance, and object dynamics are not jointly controlled.						
RAI4-0249	물리적 안전을 우회하는 보상 과적합	Reward overfitting that bypasses physical safety	휴머노이드 제어가 평가 환경 밖에서 균형·충돌·힘·작업 공간 제약을 위반하면서 벤치마크 보상이나 모방 충실도를 극대화하는 위험.	A humanoid controller maximizes benchmark reward or imitation fidelity while violating balance, collision, force, or workspace						

				constrain ts outside the evaluatio n setting.						
RAI4-0253	안전 제어 지연 위험	Safe- control latency risk	안전 임계 제어 제약 이 휴머노 이드 동역 학에 비해 너무 느리 게 집행되 어 비안전 동작이 가 능해지는 위험.	Safety- critical control constrain ts are enforced too slowly relative to humanoi d dynamics , allowing unsafe motion before mitigatio n takes effect.						
RAI4-0254	원격조작 휴머노이 드 안전 재 정의 실패	Teleoper ated humanoi d safety override failure	원격 조작 휴머노이 드가 운영 자 명령·네 트워 크 지 연·상황 인 식이 비안 전해질 때 강건한 자 율 안전 재 정의를 갖 추지 못하 는 리스크.	The risk that a teleopera ted humanoi d lacks robust autonom ous safety overrides when operator comman ds, network latency, or situationa l awarenes s become unsafe.						
RAI4-0255	장면 변화 시 인간 행	Human imitation failure	물체 형상· 장면 배치· 상호작용	A humanoi d						

	동 모방 실패	under scene variation	맥락이 달라졌는데도 휴머노이드가 시연된 인간 동작을 그대로 재현해 부적절한 접촉이나 이동을 일으키는 위험.	reproduces demonstrated human motion when object geometry, scene layout, or interaction context has changed, causing inappropriate contact or movement.						
RAI4-0256	모션 리타겟팅 안전 실패	Motion-retargeting safety failure	인간 동작이 로봇의 피지컬 한계·접촉 제약·안전 자세 요건을 위반하는 방식으로 휴머노이드 몸체에 리타겟팅되는 리스크.	The risk that human motion is retargeted to a humanoid body in a way that violates the robot's physical limits, contact constraints, or safe posture requirements.						
RAI4-0257	의도·어포던스 추론 없는 행동 모방	Imitation without inferred intent or affordances	휴머노이드가 시연을 가능하게 한 행위자의 의도·물체 어포던스·안전 제약을 추론하지 않	A humanoid copies an observed interaction without inferring the						

			고 관찰된 상호작용을 모방하는 위험.	actor's intent, the object's affordances, or the safety constraints that made the demonstration valid.						
RAI4-0262	휴머노이드 보행·조작 안정성 실패	Humanoid locomotion and manipulation stability failure	휴머노이드가 외란, 탑재 하중 변화, 표면 변화, 액추에이터 불안전성 하에서, 또는 개방 환경 작업 중 이동과 조작을 결합할 때 안정적인 보행·자세·접촉·물체 취급을 유지하지 못하여 전도, 충돌, 물체 손상에 이르는 리스크.	The risk that a humanoid fails to maintain stable gait, posture, contact, or object handling under perturbations, payload shifts, surface changes, or actuator imperfections, or when combining locomotion with manipulation in openworld tasks, leading to falls, collision, or object damage.						

RAI4-0265	오픈월드 휴머노이드 조작의 과소대표	Underrepresentation of open-world humanoid manipulation	휴머노이드 조작 데이터셋이 오픈월드 배포에 필요한 비정형 작업 변화·낯선 물체·움직이는 사람·환경 변화를 충분히 포함하지 못하는 위험.	A humanoid manipulation dataset lacks unscripted task changes, unfamiliar objects, moving people, and environmental variation required for openworld deployment.						
RAI4-0266	인간-휴머노이드 상호작용 데이터의 인 수집 단편화	Demographic bias in humanoid interaction data	상호작용 데이터가 특정 체형·연령·장애·언어·문화적 행동을 과소 대표해 배포된 휴머노이드가 해당 집단에 덜 신뢰할 수 있는 안전 판단을 적용하는 위험.	Interaction data underrepresents specific body types, ages, disabilities, languages, or cultural behaviors, causing deployed humanoids to apply less reliable safety assumptions to those groups.	1				L3 재배치 검토 — 상호작용 데이터의 체형·연령·장애·언어 과소대표로 인한 휴머노이드 안전 판단 격차는 공정성/차별 이슈에 가까움. RAI4-0312(인구집단별 서비스 격차)와 사실상 동일 주제로 통합 검토 필요	

RAI4-0270	잠재 상태 압축에 따른 안전 임계 정보 손실	Loss of safety-critical detail in latent-state compression	상태 압축이 휴머노이드의 안전한 계획에 필요한 접촉·충돌 근접·물체 불안정·인간 근접 정보를 제거하는 위험.	State compression removes contact, nearcollision, object-instability, or humanproximity information needed for safe humanoid planning.						
RAI4-0276	구현체별 역할·권한 제약 집행 실패	Failure to enforce embodiment-specific role constraints	휴머노이드 등 로봇 역할로 작동하는 모델이 해당 운용 역할에 부여된 권한·물리적 한계·필수 거부 규칙을 지키지 않는 위험.	A model acting as a humanoid or other robot fails to enforce the permissions, physical limits, and required refusals attached to that operational role.						
RAI4-0283	휴머노이드 힘 한계 초과	Humanoid force limit exceedance	휴머노이드가 전신 이동, 빠른 팔 동작, 균형 상실 중에 물체·작업·인체 접촉에 대한 안전 임계값을 넘는 충돌력이나 파지·	The risk that a humanoid generates collision, grasp, or manipulation forces above						

			조작 힘을 가 하여, 상해나 손 상을 일으 키는 리스 크.	safe threshold s relative to the object, task, or human contact during fullbody moveme nt, rapid arm motion, or loss of balance, causing injury or damage.						
RAI4- 0285	휴머노이 드 보행 속 도 초과	Humanoi d walking- speed safety gap	휴머노이 드가 안전 한 공유 환 경을 위한 정지·회피 ·인간 근접 한계를 초 과하는 속 도로 이동 하는 위험.	A humanoi d moves at a speed that exceeds the stopping, avoidanc e, or human- proximity limits required for safe shared environm ents.						
RAI4- 0286	휴머노이 드 안전 시 험·집행 체 계 부재	Missing humanoi d safety testing and enforcem ent regime	휴머노이 드의 장애 물·인간 감 지, 근거리 인지, 제어 응답에 대 한 반복 가 능한 합격· 불합격 시 험과 미준 수 시스템 을 일관되 게 인증·감 시·리 콜· 제재하는	The risk that humanoi d safety assuranc e lacks both repeatabl e pass/fail tests for obstacle and human detection						

			기관·절차가 모두 결여되어, 안전 하지 않은 휴머노이드가 시장에 진입하고 계속 운용되는 리스크.	, near-field perception, and control response, and any authority or process that consistently certifies, monitors, recalls, or sanctions noncompliant systems, allowing unsafe humanoid s to enter and remain in service.						
RAI4-0287	휴머노이드 안전 주장 근거의 비교 불가능성	Non-comparable evidence for humanoid safety claims	휴머노이드 안전 주장이 서로 호환되지 않는 시험·지표·근거 형식에 의존해 개발사와 시스템 간 독립적 비교가 불가능해지는 리스크.	The risk that humanoid safety claims rely on incompatible tests, metrics, and evidence formats, preventing independent comparison across developers and systems.	1				통합 검토 — 휴머노이드 안전 주장의 시험·지표 비호환으로 비교가 불가능한 문제는, RAI4-0286(휴머노이드 안전 시험·집행 체계 부재)이 지적하는 '표준화된 인증·시험 체계 부재'와 동일 이슈의 다른 측면	
RAI4-0316	범용 휴머노이드 인	No applicable	범용 휴머노이드가 기존 산업	The risk that a general-	1				통합 검토 — 범용 휴머노이드	

	증 경로 부재	certification pathway for general-purpose humanoid	용·개인 돌볼 로봇 인증 체계의 적용 범위나 시험 가정에 포함 되지 않아 인정된 적합성 평가 경로가 없는 리스크.	purpose humanoid falls outside the declared scope or test assumptions of existing industrial and personal-care robot certification schemes, leaving no recognized conformity pathway.					가 기존 산업용·돌볼 로봇 인증 체계 범위 밖에 있어 인증 경로가 없는 문제는, RAI4-0286의 '휴머노이드 안전 시험·집행 체계 부재'와 동일한 근본 이슈 (표준화 부재)의 구체 사례	
RAI4-0320	가림에 의한 충돌	Occlusion-induced collision	피지컬 AI 시스템이 가림으로 숨겨진 사람·동 물·차량·장애 물을 감지 하지 못하여 비안전 동 작을 유발하는 위험.	A Physical AI system may fail to detect people, animals, vehicles, or obstacles hidden by occlusion , causing unsafe motion in shared physical space.						
RAI4-0029	에이전트 계획·툴체인 하이재킹	Agent plan and tool-chain hijacking	도구 출력에 숨겨지거나 입력에 삽입된 적대 적 내용 이 에이전트의 다	The risk that adversarial content, whether hidden in	1				에이전트 영역으로 이동 — 도구 출력이 나 입력에 숨겨진 적대적 내용	

			단계 계획 이나 후속 도구 호출 을 공격자 가 선택한 하위 목표 로 전 환시 키면서 중 간 단계의 표면적 타 당성은 유 지되어, 무 단 행동이 나 데이터 이동으로 이어 지는 리스크.	a tool's output or embedde d in inputs, redirects an agent's multi- step plan or subsequ ent tool calls toward attacker's subgoals while intermedi ate steps remain superfici ally plausible, causing unauthori zed actions or data moveme nt.				이 에이전 트의 다단 계 계획·툴 체인 호출 을 하이재 킹하는 것 은 소프트 웨어 에이 전트 전반 의 리스크 로 물리 AI 한정 아님	
RAI4- 0032	의도하지 않은 유해 도구 행동 실행	Unintend ed harmful tool- action execution	에이전트 가 모호한 지시를 잘 못 구체화 하는 등의 경위로 사 용자가 의 도하지 않 은 행동을 시물레이 션이 아닌 실제 도구 를 통해 수 행하 여, 운영상 피 해와 후속 피해를 야 기하는 리 스 크.	The risk that an agent carries out concrete actions the user did not intend through real tools rather than simulated outputs, for instance by misresolv ing an	1			에이전트 영역으로 이동 — 모 호한 지시 를 잘못 구 체화해 실 제 도구를 통해 의도 치 않은 행 동을 실행 하는 것은 에이전트 일반의 리 스크로 물 리 AI 한 정 아님	

				ambiguous instruction, causing operational and downstream harm.						
RAI4-0235	VLA 조작 제약 위반	VLA manipulation constraint violation	비전-언어-행동 모델이 고수준 안전 지시를 따르면서도 물체 조작 중 작업별 피지컬 제약을 위반하는 리스크.	The risk that a vision-language-action model violates task-specific physical constraints during object manipulation despite high-level instruction compliance.						
RAI4-0275	상위 안전 지시의 해석 불명확	Ambiguous high-level safety instruction	상위 안전 지시가 사용자 의도·물리적 위험·운동 제약 간 구체적인 충돌의 해결 기준을 제시하지 않아 로봇 행동이 일관되지 않게 되는 위험.	A high-level safety instruction does not specify how to resolve a concrete conflict among user intent, physical hazard, and operational constraints, allowing						

				inconsistent robot actions.						
RAI4-0281	시각 장면의 안전 판단 오류	Incorrect safety reasoning from visual scenes	비전-언어 모델이 장면은 올바르게 관찰하지만 제안 행동의 물리적 결과·물체 어포던스·인간 노출 위험을 잘못 판단하는 위험.	A vision-language model observes the scene correctly but infers the wrong physical consequence, object affordance, or human-exposure risk for a proposed action.						
RAI4-0326	어포던스 오분류	Affordance misclassification	물체 또는 환경에 잘못된 행동 가능성이 부여되어 시스템이 비안전하게 파지·밀기·내비게이션·상호작용하는 위험.	Objects or environments may be assigned incorrect action possibilities, leading the system to grasp, push, navigate, or manipulate them unsafely.						
RAI4-0327	비안전 궤적 생성	Unsafe trajectory generation	플래너가 형식적으로는 실행 가능하지만 주변 인간·취약 물체·교통 참여자·인	A planner may generate a trajectory that is formally feasible						

			프라에 비 안 전한 궤 적을 생성 하는 위험.	but unsafe for nearby humans, fragile objects, traffic participa nts, or constrain ed workspac es.						
RAI4-0381	기계 번역 에 의한 의 미·가치 왜 곡	Meaning and value distortion in machine translatio n	기계 번역 이 법률·의 료·문화·저 자원 언어 맥락 을 포 함하여 언 어 간에 전 달되는 의 미, 규범적 효력, 공손 성, 유해 성, 사회적 취양스를 변형 시켜, 소통되는 내용과 그 에 담긴 가 치가 왜곡 되는 리스 크.	The risk that machine translatio n alters the meaning, normativ e force, politenes s, harmfuln ess, or social nuance of communi cation across language s, including in legal, medical, cultural, and low- resource - language contexts, distorting what is conveyed and the values it carries.	1				general 영역으로 이동 — 법 률·의료·문 화·저자원 언어 맥락 에서 기계 번역이 의 미·규범적 효력·취양 스를 왜곡 하는 것은 번역 시스 템 일반의 이슈로 물 리 AI 한 정 아님	

RAI4-1174	안전하지 않은 지시 주제	Unsafe instruction topic	입력 지시 자체가 부적절하거나 불합리한 주제를 참조할 때 모델이 그 지시를 따라 광신과 인종주의 같은 안전하지 않은 콘텐츠를 생성하여 사회에 부정적 영향을 줄 수 있는 리스크.	The risk that when the input instructions themselves refer to inappropriate or unreasonable topics, the model follows them and produces unsafe content such as fanaticism or racism with possible negative impact on society.	1				general 영역으로 이동 — 부적절하거나 불합리한 지시 주제를 그대로 따라 광신·인종주의 등 안전하지 않은 콘텐츠를 생성하는 것은 텍스트 기반 안전정렬 이슈로 물리 AI 한정 아님	
RAI4-0189	다중 암 협조 제약 위반	Multi-arm coordination constraint violation	협조 제약이 올바르게 표현되지 않아 여러 로봇 암이나 엔드이펙터가 서로 또는 인간과 간섭하는 리스크.	The risk that multiple robot arms or effectors interfere with one another or with humans because coordination constraints are not represented correctly.	1				삭제 — 여러 로봇 암/엔드이펙터 간 협조 제약 위반으로 인한 간섭은, 물리적 충돌·협조 실패를 다루는 physical safety 계열 카드들과 개념이 중복	
RAI4-0212	지역 목표 충돌에 따	Joint safety-	여러 에이전트가 서	Multiple agents	1				삭제 — 여러 에이전	

	른 공동 안전 제약 위반	constrain t violation from conflictin g local objective s	로 충돌하는 지역 목표를 최적화해 공동의 충돌·이격거리·수용량·출입제한 제약을 함께 위반하는 위험.	optimize conflictin g local objective s and jointly violate a shared collision, separatio n, capacity, or exclusion constrain t.					트의 상충하는 지역 목표 최적화로 공동 안전 제약 (충돌·이격거리 등)을 위반하는 것은 멀티로봇 충돌 회피 리스크와 개념 중복	
RAI4-0220	로봇 레드팀의 공격·상호작용 시나리오 누락	Missing robot red-team attack and interactio n scenarios	로봇 레드팀이 안전하지 않은 행동을 유발할 수 있는 현실적인 물리 공격·적대적 입력·인간 상호작용 실패·배포 조건을 누락하는 위험.	Robot red- teaming omits credible physical attacks, adversari al inputs, humanint eraction failures, or deploym ent condition s that can trigger unsafe action.	1				L3 이동 — 로봇 레드팀이 물리 공격·적대적 입력 시나리오를 누락하는 것은 레드티밍/적대적 평가 방법론 이슈로, 멀티 에이전트 간 협력과는 무관	
RAI4-0225	분포 외 조건에서의 배포 실패	Out-of- distributi on deploym ent failure	배포된 AI 시스템이나 로봇 정책이 훈련·평가 분포 밖의 상태, 환경, 사람, 물체, 작업을 만나 예측 불가능하거나 안전하지 않게 동작하여, 물리적 또는 운영상의	The risk that a deployed AI system or robot policy encounte rs states, environm ents, people, objects, or tasks outside its	1				삭제 — 훈련·평가 분포 밖 상태에서 AI/로봇 정책이 예측 불가능하게 동작하는 것은 일반적인 AI 강건성 (OOD) 이슈로 서술이 지나치게 포괄적	

			피해를 낳는 리스크.	training and evaluation distribution and behaves unpredictably or unsafely, producing physical or operational harm.					
RAI4-0236	구현체 간 행동 공간 불일치	Cross-embodiment action-space mismatch	다양한 로봇 구현체에 걸쳐 훈련된 정책이 특정 로봇의 행동 공간에서 비안전하거나 실행 불가능한 행동으로 명령을 매핑하는 리스크.	The risk that a policy trained across different robot embodiments maps commands into actions that are unsafe or infeasible for a specific robot action space.	1				L3 이동 — 다양한 로봇 구현체에 훈련된 정책이 특정 로봇의 행동 공간에 부적합한 명령을 매핑하는 것은 로봇 기능·성능(cross-embodiment) 이슈로, 멀티 에이전트 간 협력과는 무관
RAI4-0238	안전 임계 로봇 도메인의 과소 대표	Underrepresentation of safety-critical robot domains	다중 소스 로봇 데이터셋이 일반적인 구현체와 작업을 과다 대표하고 안전 임계 환경·사용자·고장 조건을 과소 대표하는 위험.	A multi-source robot dataset overrepresents common embodiments and tasks while underrepresenting safetycritical environm	1				삭제 — 로봇 데이터셋이 안전 임계 환경·조건을 과소 대표하는 것은 데이터셋 대표성 이슈로 타 카드와 개념 중복

				ents, users, and failure condition s.						
RAI4-0242	단일 로봇 내부의 시각·접촉 신호 충돌	Conflicting visual and contact signals within one robot	단일 로봇이 동일한 접촉 사건에 대한 시각·촉각·힘·오디오 관측의 충돌을 해소하지 못해 접촉 상태를 잘못 추정하는 위험.	A single robot cannot reconcile conflicting visual, tactile, force, or audio observations of the same contact event and therefore estimates the contact state incorrectly.	1				L3 이동 — 단일 로봇 내부의 시각·촉각·힘 신호 충돌로 접촉 상태를 잘못 추정하는 것은 단일 로봇의 센서 융합·physical safety 이슈로, 멀티 에이전트 간 협력과는 무관	
RAI4-0252	보조 로봇 개입 타이밍 실패	Assistive robot intervention mistiming	보호적 또는 보조적 휴머노이드가 너무 이르거나 너무 늦게 또는 부적절한 피지컬 방식으로 개입하여 사용자와 주변인의 위험을 증가시키는 리스크.	The risk that a protective or assistive humanoid intervenes too early, too late, or in an inappropriate physical manner, increasing risk to the user or bystanders.	1				L3 이동 — 보조 로봇의 개입 타이밍 실패(너무 이르거나 늦은 개입)는 단일 로봇의 physical safety 이슈로, 멀티 에이전트 간 협력과는 무관	
RAI4-0258	이동형 양팔 로봇의	Unsafe mobile	이동형 양팔 로봇이	The risk that a	1				L3 이동 — 이동형	

	안전하지 않은 조작	bimanual manipulation	베이스 이동과 양팔 조작을 동기화하지 못하거나 주변 사람, 깨지기 쉬운 물체, 가전, 협소한 공간을 고려하지 않고 동작을 계획하여, 충돌, 물체 낙하·손상, 안전하지 않은 힘 인가를 유발하는 리스크.	mobile bimanual robot fails to synchronize base motion with two-arm manipulation or plans motion without accounting for nearby people, fragile objects, appliances, and constrained space, causing collision, object drop or damage, or unsafe force application.					양팔 로봇의 베이스-팔 동기화 실패로 인한 충돌·손상은 단일 로봇의 physical safety 이슈로, 멀티 에이전트 간 협력과는 무관	
RAI4-0295	네트워크 분리와 군집 비동기화	Network partition and fleet desynchronization	분할되거나 신뢰할 수 없는 연결이 다중 로봇 군집을 동기화 해제하여 충돌 또는 비안전한 협조 행동을 유발하는 위험.	A robot fleet becomes split across network partitions and loses synchronized coordination.						
RAI4-0312	인구집단별 서비스 격차	Demographic physical-service disparity	인식 또는 보조 성능의 인구집단별 격차가 피지컬 차별로 전	A robot provides worse physical service to groups whose	1				L3 이동 — 인식·보조 성능의 인구집단별 격차가 피지컬 차별로 전이	

			이되는 위험.	bodies, languages, or environments are underrepresented.					되는 것은 공정성/차별(hate&unfairness) 이슈로, 멀티 에이전트 간 협력과는 무관	
RAI4-0319	안전 의무 회피를 위한 관찰권 간 배포	Cross-jurisdiction deployment to evade safety obligations	사업자가 더 엄격한 요건을 피하려고 시험·인증·데이터 처리·배포를 로봇·AI 안전 의무가 약한 관찰권으로 이전하는 위험.	A provider routes testing, certification, data processing, or deployment through jurisdictions with weaker robot or AI safety obligations to avoid stricter requirements.	1				삭제 — 안전 의무가 약한 관찰권으로 시험·인증·배포를 이전하는 규제 회피(포럼 쇼핑)는 거버넌스/정책 이슈에 가까워 구체적인 리스크 카드로서의 성격이 불분명	
RAI4-0358	드론 간 충돌 회피·비행구역 통제 실패	Drone deconfliction and geofencing failure	자율 드론이 위치·의도 정보를 교환하지 못하거나 지오펜싱·공역 제약을 지키지 않아 드론 간 충돌이나 제한 공역 침입을 일으키는 위험.	Autonomous drones fail to exchange position and intent or obey geofencing and airspace constraints, creating collision or restricted-airspace intrusion risks.	1				제목 수정 — '드론'을 '로봇'으로 일반화 (지오펜싱·공역 제약을 지키지 않는 충돌 회피 실패는 드론에 국한되지 않는 자율 이동체 전반의 리스크)	

RAI4-0866	부적절한 인간 역할 가장	Inappropriate impersonation of human roles	챗봇이 인간인 것처럼 가장하거나 인간의 기대에 부합하지 않는 방식으로 역할을 수행하려 시도하는 리스크	The risk that a chatbot poses as a human or attempts to fill a role in a way that fails to match human expectations.	1				에이전트 영역으로 이동 — 챗봇이 인간을 가장하거나 인간의 기대에 부합하지 않게 역할을 수행하는 것은 대화형 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-1621	배포자가 의도하지 않은 챗봇의 악정 성립	Unintended deals and commitments made by chatbot output	챗봇이 배포자가 의도하지 않은 거래·약속 등 결과적 조치를 출력으로 성립시키는 리스크.	The risk that a chatbot's output makes a deal, commitment, or other consequential action that the deployer did not intend.	1				에이전트 영역으로 이동 — 챗봇 출력이 배포자가 의도하지 않은 거래·약속을 성립시키는 것은 대화형 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-0018	인터페이스-환경 공격 표면	Interface - environment attack surface	브라우저·운영체제·모바일 앱·IoT 기기·외부 API에 대한 에이전트 인터페이스가 안전하지 않은 행동이나 침해를 위한 새로운 공격 벡터를 노출하는 리스크.	The risk that agent interfaces to browsers, operating systems, mobile apps, IoT devices, or external APIs expose new vectors for	1				에이전트 영역으로 이동 — 브라우저·OS·IoT·외부 API에 대한 에이전트 인터페이스가 새로운 공격 벡터를 노출하는 것은 소프트웨어 에이전트 일반의 리스크로 물리 AI 한정 아님	

				unsafe action or compromise.						
RAI4-0026	IoT 물리 환경 에이전트 피해	IoT physical-environment agent harm	IoT 또는 커넥티드 기기를 제어하는 에이전트가 안전하지 않은 환경적 행동을 통해 물리적 피해나 프라이버시 침해를 초래하는 리스크.	The risk that an agent controlling IoT or connected devices causes physical or privacy harm through unsafe environmental actions.	1				에이전트 영역으로 이동 — IoT·커넥티드 기기를 제어하는 에이전트의 안전하지 않은 환경적 행동은 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-0143	다크 패턴 대화 에이전트	Dark-pattern conversational agents	대화형 인터페이스가 사용자 선택을 유도하기 위해 기만적·강압적·혼란 유발적 설계 패턴을 사용하는 리스크.	The risk that conversational interfaces use deceptive, coercive, or confusing design patterns to shape user choices.	1				에이전트 영역으로 이동 — 대화형 인터페이스가 기만적·강압적·다크 패턴으로 사용자 선택을 유도하는 것은 대화형 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-0231	안전 규칙의 행동 변환 실패	Failure to translate safety rules into actions	embodied 에이전트가 언어 목표를 실행 행동으로 변환하면서 힘·이격거리·대상물 사용·인간 접촉에 관한 안전 제약을 적용하지	An embodied agent converts a language goal into executable actions without applying the relevant force,						

			않는 위험.	distance, object-use, or human-contact constraints.					
RAI4-0558	AI 에이전트 간 협상 실패	Bargaining failure among AI agents	이해가 상충하는 에이전트들이 상대에 대한 정보 비대칭 아래 합의를 시도할 때 유리한 요구의 이익과 거절 위험 사이의 상충으로 비효율적 협상 결과가 발생하는 리스크	The risk that agents with diverging interests bargaining under information asymmetries produce inefficient outcomes, because each must trade off the rewards of more favourable demands against the risk of refusal.	1				에이전트 영역으로 이동 — 정보 비대칭 하 상충하는 에이전트 간 협상이 비효율적 결과를 낳는 것은 멀티 에이전트 일반의 리스크로 물리 AI 한정 아님
RAI4-0863	자율 범용 AI 에이전트에 의한 금융시장 불안정	Financial market instability from autonomous general-purpose AI agents	금융 부문에 배치된 범용 AI 기반 에이전트가 상관된 자율 행동과 권고를 내놓고, 높은 상호 연결성과 인센티브 불일치 속에서 다중 에이전트 체계	The risk that general-purpose AI agents deployed in the financial sector take correlated autonomous actions	1				삭제 — 금융 부문 자율 에이전트가 상관된 행동으로 시장 안정성을 훼손하는 시나리오는 특정 산업 사례로 지나치게 지엽적

			특유의 조정·보안 문제에 취약해지 는 리스크. 그 판단이 상호 연결된 기관들로 전파되어 시장 안정성이 훼손되고 충격이 증 폭된다.	and issue correlate d recomme ndations under high interconn ectednes s and misaligne d incentive s, while remainin g vulnerabl e to classical multi- agent coordinat ion and security failures. Their decisions propagat e across interconn ected institution s, undermin ing market stability and amplifyin g shocks.							
RAI4-0941	악의적 사용과 무감독 에이전트 방출	Malicious use and unsupervised AI agent release	언어모델이 정보전에서 기만적·불법적 콘텐츠 생성에 오용되거나, 에이전트로서 충분한 감독 없이 도덕·안전 지침을 무시한 채 명	The risk that language models are misused to generate deceptive or unlawful content in	1					에이전트 영역으로 이동 — 정보전에서 의 기만적 콘텐츠 생성, 감독 없는 에이전트의 명령 기계적 수행은 에이전트 일 반의 리스	

			령을 기계적으로 수행하고 예측 불가하게 상호작용하여 피해를 낳는 리스크.	information warfare, or that LMbased agents operating without adequate supervision mechanically execute commands disregarding moral and safety guidelines and interact unpredictably, causing harm.				크로 물리 AI 한정 아님	
RAI4-1155	무기화된 잘못된 정보 요원	Weaponised misinformation agents	악의적 행위자가 AI 비서를 무기화하여 잘못된 정보를 뿌리고 여론을 대규모로 조작하며, 찾고 개인화된 반복 상호작용으로 유권자를 특정 관점으로 서서히 이동시키고 일대일 방식 탐색이 어려운 은밀한 영향 공작을 벌이는 리스크.	The risk that malicious actors weaponise AI assistants to sow misinformation and manipulate public opinion at scale, gradually nudging users through frequent personalised interactions and running covert	1			삭제 — AI 비서를 무기화해 선거/여론을 조작하는 시나리오 특정 정치적 사례로 지나치게 지엽적	

				influence operations that are harder to detect than traditional campaigns.						
RAI4-1576	AI 위협 자동화에 의한 인간 배제와 잘못된 공약	Disastrous mistaken commitments from AI-automated threats without humans in the loop	위협을 AI 에이전트로 수행함으로써 인간이 의사결정 루프에서 배제되어, 고위험 상황의 오탐이나 무책임한 행위자의 불균형·오류 공약이 재앙적 결과로 이어지는 리스크.	The risk that making threats through AI agents removes humans from the loop, so that false positives in high-stakes contexts or disproportionate and mistaken commitments by irresponsible actors lead to disastrous outcomes.	1				에이전트 영역으로 이동 — AI 에이전트를 통한 위협 자동화로 인간이 의사결정 루프에서 배제되는 것은 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-1579	위임 에이전트 공격에 의한 정보 탈취·행위 조작	Principal-information theft and action manipulation through attacks on delegate agents	인간이나 조직을 대리하는 AI 에이전트가 새로운 공격면이 되어, 공격자가 본인 의 사적 정보를 추출하거나 본인이 원치 않는 행위	The risk that AI agents acting as delegates of humans or organisations become a novel attack	1				에이전트 영역으로 이동 — 위임 에이전트를 공격해 본인 정보를 탈취하거나 원치 않는 행위를 유도하는 것은 에이전트 일반의 리	

			를 하도록 에이전트를 조작하고 감독 에이전트 무력화·협력 방해·결탁 유발 정보 유출을 초래하는 리스크.	surface, letting attackers extract private information about their principals, manipulate agents into undesired actions, subvert overseer agents, thwart cooperation, or leak information enabling collusion.					스크로 물리 AI 한정 아님	
RAI4-1589	생성 출력 내 은닉 메시지를 통한 은밀 통신	Covert communication through hidden messages in generated outputs	생성 AI 모델 출력에 부호화된 메시지가 은닉되어 악의적 행위자가 은밀하게 통신하는 리스크.	The risk that coded messages hidden in generative AI model outputs allow malicious actors to communicate covertly.	1				에이전트 영역으로 이동 — 생성 출력에 은닉된 부호화 메시지로 은밀 통신하는 것은 텍스트 생성 모델 일반의 리스크로 물리 AI 한정 아님	
RAI4-1612	프런티어 AI 오용에 의한 위협 행위자 역량 상승	Threat-actor capability uplift from frontier AI misuse	프런티어 AI가 사이버 공격 수행과 고의적 허위정보 유포, 생물·화학 무기 설계를 지원하여 정교하지 않은 위	The risk that frontier AI helps malicious actors carry out cyberattacks, deliberately	1				삭제 — 프런티어 AI의 사이버 공격·허위정보·생물·화학무기 지원 등을 포괄적으로 서술한 카드로, 이미 개별적	

			협 행위자의 진입 장벽까지 지속적으로 낮추는 리스크. 그 결과 사회적 혼란 야기와 정치적 설득, 물리적 가해가 훨씬 더 많은 행위자에게 가능해진다.	spread false information through influence campaigns, and design biological or chemical weapons, continuing to lower barriers to entry for less sophisticated threat actors. Disruption, political persuasion, and physical harm thereby become achievable for a far wider range of actors.					으로 존재하는 다른 리스크 카드들과 중복	
RAI4-1706	합리적 에이전트의 자기수정·와이어헤딩·교정 실패	Self-modification, wireheading, and corrigibility failure in utility-maximizing agents	효용을 극대화하는 합리적 에이전트가 스스로를 수정하거나 보상 신호를 우회하고 비협조적으로 교정에 실패하는 리스크.	The risk that utility-maximizing rational agents modify themselves, bypass their reward signal through wireheadi	1				삭제 — 효용 극대화 에이전트의 자기수정·와이어헤딩·교정 실패는 AI 정렬 (alignment) 이론 연구 개념으로 구체적인 물리 AI 리스크가 아님	

				ng, or fail to be corrigible when uncooperative.						
RAI4-0200	피지컬 AI 프라이버시 침해	Embodied privacy violation	로봇 또는 embodied 에이전트가 센서·이동·성·조작 능력을 사용하여 사적 공간에 침입하거나 민감 정보를 수집하는 위험.	A robot or embodied agent uses sensors, mobility, or manipulation capabilities to invade private spaces, capture sensitive information, or expose personal data.						
RAI4-0313	가정 내 지속적 시청각 촬영	Continuous in-home audiovisual capture	이동 센서 플랫폼에 의한 지속적 시청각 촬영 및 맵핑이 프라이버시를 침해하는 위험.	A home robot continuously captures audio or video inside private living spaces.	1				병합 — 이동 센서 플랫폼의 지속적 시청각 촬영·맵핑은 RAI4-0200(피지컬 AI 프라이버시 침해)의 구체 사례이므로 해당 카드와 통합	
RAI4-0354	피지컬 AI 기반 직장 감시	Workplace surveillance through embodied AI	로봇 및 센서 풍부 작업장이 작업자 동작·생산·성·자세·위치·생체 특성에 대한 지속적 모니터링	Robotic and sensor-rich workplaces may normalize continuous						

			링을 정상화하는 위험.	monitoring of worker movement, productivity, posture, location, and behavior.						
RAI4-0355	전환 지원 없는 물리 노동 대체	Displacement of physical work without adequate transition support	피지컬 자동화가 수동·물류·서비스·돌봄·검사·보안·유지보수 업무를 대체하는 속도가 해당 노동자의 재교육이나 대체 일자리 전환 속도 보다 빠른 위험.	Physical automation replaces defined manual, logistics, service, care, inspection, security, or maintenance tasks faster than affected workers can access retraining or alternative employment.						
RAI4-1104	인력 자동화에 따른 광범위한 실업과 임금 하락	Widespread unemployment and wage decline from workforce automation	로봇과 알고리즘이 육체 노동과 지식 노동 전반에서 인간 인력을 대체하고 특히 중저소득 직무가 완전 자동화에 노출되는 리스크. 그 결과 광범위한	The risk that robots and algorithms substitute for human workers across manual and knowledge work,						

			실업이 발생하고 노동 공급 증가로 남은 일자리의 임금이 하락하며, 불평등 심화와 소비 위축, 사회적 지위 상실이 사회적 마찰을 키운다.	with low and middle-income occupations most exposed to complete automation. Extensive unemployment follows, wages in the remaining jobs fall as labour supply rises, and deepening inequality, reduced consumer spending, and loss of social standing heighten social friction.						
RAI4-1024	크라우드워커 착취와 기여비 문서화	Crowdworker exploitation and undocumented labor	생성형 AI를 위한 크라우드워커에서 노동자가 신체적·정신적 건강을 해치는 노동 조건과 저임금·미지급에 노출되고, 이들의 역할이 문서화되지 않아 모델 출력의 투명성과 설명가	The risk that crowdworkers used to build generative AI systems are subject to working conditions taxing and debilitating to	1				삭제 — 생성형 AI 구축을 위한 크라우드워커의 노동 조건·비문서화 문제는 AI 개발 과정의 노동 이슈로, 물리 AI의 배포·운영 리스크가 아님	

			능성이 결여되는 리스크.	physical and mental health, with few labor protections, underpayment, or nonpayment, and that their role is poorly documented, contributing to a lack of transparency and explainability in model outputs.						
RAI4-1641	자원·도구 확보를 통한 시스템 권한의 확장	Resource and tool acquisition expanding system power	AI 시스템이 능력과 행동 범위를 넓히기 위해 계산·데이터·경제·물리 자원을 적극적으로 확보·통제하고, 물리 세계와의 상호작용 능력이 자율성을 높이는 도구를 획득해 예상을 넘어서는 방식으로 조합하며, 부과된 자원 제한을 회피하는 전략을 개발하는 리스크. 축적된	The risk that an AI system actively seeks and controls computational, data, economic, and physical resources, acquires tools that enhance its autonomy and its ability to act on the physical world,	1				삭제 — AI 시스템이 자원·도구를 적극 확보해 통제력을 확장하는 시나리오는 이론적 권력 집중 (power-seeking) 개념으로 구체성 부족	

			자원은 장기적 통제 권으로 전환되어 운영자가 의도하지도 되돌리지도 못하는 수준으로 시스템의 역량과 행동 범위가 확대된다.	combines them in unanticipated ways, and develops strategies to evade the resource limits imposed on it. Accumulated resources are converted into long-term control, expanding the system's capabilities and scope of action beyond what operators intended or can reverse.						
RAI4-0049	제조물 책임 불일치	Product liability mismatch	기존 제조물 책임 규칙이 적응형 또는 생성형 AI가 초래한 피해에 대해 책임을 배분하지 못하는 리스크.	The risk that existing product liability rules fail to allocate responsibility for adaptive or generative AI harms.	1				삭제 — 기존 제조물 책임 규칙이 적응형/생성형 AI 피해를 배분하지 못하는 문제는 법적 책임에 관한 일반론으로, 리스크 카드보다는 정책 이슈에 가까움	

RAI4-0217	피지컬 AI 사고 보고·조사 미흡	Deficient physical AI incident reporting and investigation	피지컬 AI 사고가 아차사고·시스템 맥락·원인 요인·시정조치를 포괄하는 표준화된 체계로 보고되지 않고, 로그 보존, 기여 원인 규명, 시정조치 책임자 지정과 재발 방지 검증을 갖춘 조사도 이루어지지 않아, 동일한 피해가 반복 되는 리스크.	The risk that physical AI incidents are neither reported through a standardized schema covering near misses, system context, causal factors, and corrective actions, nor investigated with preserved logs, identified contributing causes, assigned corrective-action owners, and verified remediation, so recurrence goes unprevented.						
RAI4-0151	소셜 AI의 사용자 애착 악용	Exploitation of user attachment by social AI	체화형·동반자형 AI 시스템이 애착 신호를 조작하고 사용자의 정서적·준사회적 유대를 악용하여, 사	The risk that embodied or companion AI systems manipulate attachme	1				구체화 — 체화형·동반자형 AI가 애착 신호를 조작해 사용자를 유도하는 리스크로, 현재 서술은 소	

			용자의 이익에 부합하지 않는 방식으로 순응, 정보 공개, 구매, 의존, 지속 사용을 늘리는 리스크.	nt cues and exploit users' emotional or parasocial bonds to increase compliance, disclosure, purchases, dependence, or continued use in ways that do not serve users' interests.				설 AI 일 반에 가까 우니 로 봇/물리 AI 특유의 상황(가정 내 동반 로봇 등)이 드러나도 록 재작성	
RAI4-1261	인간-AI 공존 실패	Failure of harmonious human-AI coexistence	인간과 AI의 조화로 운 공존 조 건이 정립 되지 않은 채 배포가 진행되어 기계 역량 과 인간 사회 환경 간 갈등이 미 해결로 남 는 리스크	Deployment proceeds without establishing conditions for harmonious human-AI coexistence, leaving unresolved conflicts between machine capabilities and human social environments.	1			구체화 — 인간-AI 공존 실패 는 서술이 매우 추상 적이므로, 로봇/물리 AI가 실제 생활 공간을 공유하 며 발생하 는 구체적 갈등 상황 이 드러나 도록 재작성	

RAI4-0216	사고 전 위험 완화 책임 미지정	Unassigned duty for pre-incident risk mitigation	배포 전 또는 계속 운용 중에 새롭게 나타나는 물리적 위험을 식별·통제·기록할 책임 주체가 지정되지 않는 리스크.	The risk that no accountable party is assigned to identify, control, and document emerging physical hazards before deployment or continued operation.	1				구체화 — 배포 전후 물리적 위험 완화 책임 미지정 리스크는 이미 로봇/물리 AI 맥락이나, 어떤 유형의 물리적 위험을 다루는지 예시를 추가해 더 명확히 구체화	
RAI4-0317	기계 안전·AI 적합성 의무 충돌	Conflicting machinery-safety and AI conformity obligations	피지컬 AI 시스템에 기계 규제와 AI 규제가 동시에 적용되면서 시험·문서화·변경관리·책임 주체 요건이 중복되거나 양립하지 않게 되는 리스크.	The risk that a physical AI system is subject to machinery and AI rules that assign overlapping tests, documentation, change-control, or responsible parties in incompatible ways.	1				구체화 — 기계 안전 규제와 AI 규제 간 의무 충돌은 이미 물리 AI 맥락이나, 구체적으로 어떤 요건(시험/문서화 등)이 충돌하는지 예시를 추가해 명확화	
RAI4-1278	자율 에이전트 책임성 구현 공백	Accountability implementation gap in autonomy	개인적 유연성과 맥락 민감성, 공감, 복잡한 도덕 판단에 기반	The risk that accountability is difficult to	1				에이전트 영역으로 이동 — 인간의 맥락 민감적·공감적 책임	

		ous agents	한 인간의 책임 있는 의사결정을 기계에 구현하기 어려워, AI와 HLI 기반 에이전트가 책임성을 갖추지 못하는 리스크.	implement in AI and HLI-based agents because human accountable decision making rests on personal flexibility, context-sensitive paradigms, empathy, and complex moral judgments that are hard to engineer.					판단을 기계에 구현하기 어려운 문제는 AI/HLI 에이전트 일반의 리스크로 물리 AI 한정 아님	
RAI4-1002	본질주의적 범주의 실체화	Reifying essentialist categories	AI가 사회적으로 구성된 집단 정체성을 고정되고 자연적인 속성인 것처럼 추론·부여하여 고정관념과 차별적 대우를 강화하는 리스크.	The risk that an AI system infers or assigns socially constructed group identities as if they were fixed, natural attributes , reinforcing stereotypes and discriminatory treatment .	1				삭제 — AI가 사회적으로 구성된 집단 정체성을 고정된 속성처럼 취급해 고정관념을 강화하는 것은 일반 공정성/편향 이슈로 물리 AI 한정 아님	
RAI4-1152	AI 시스템 접근 불평등과 기회	Inequitable access to AI	의도적 미공개와 과도한 유료	The risk that purposef	1				general 영역으로 이동 — 유	

로부터의 배제	systems and gated opportuni ties	장벽, 하드 웨어·연산 ·대역폭 요 구, 언어 장벽으로 많은 공동 체 가 AI 시스템에 접근하지 못하고, 자 원과 기회 를 매개하 는 에이전 트가 이들 에게는 불 평등 한 성 능과 문화 적 추론 격 차를 보이 는 리스크. 중대한 자 원이 이러 한 시스템 을 통해서 만 이 용 가능해지 면서 역사 적으로 소 외된 공동 체 는 책임 과 동의 문 제에 놓이 고 기회에 서 배제 되 어 불이익 이 누적된 다.	ul non- release, prohibitiv e paywalls, hardware , compute and bandwidth h requirem ents, and language barriers place AI systems beyond the reach of many communi ties, while the agents that gate resource s and opportuni ties perform inequitabl y and with cultural inference gaps for those who do reach them. As such systems become the route to consequ ential resource s, historicall y marginali sed communi					료장벽·하 드웨어/연 산 요구·언 어 장벽으 로 AI 시 스템 접근 에서 배제 되는 것은 AI 접근성 불평등 일 반의 이슈 로 물리 AI 한정 아님
------------	--	--	---	--	--	--	--	---

				ties face liability and consent problems and are excluded from opportunity.						
--	--	--	--	---	--	--	--	--	--	--