

Rubric

(이제부터 엑셀시트 L4-G, L4-A, L4-P에서 작업한 내용을 기준으로 작성함)

RAI Risk Taxonomy 2.0은 L0(RAI), L1(General, Agentic, and Physical), L2(System, Interaction, and Societal Impact), L3 카테고리, L4 리스크 카드로 구성이 되어 있음

전체적인 작업 순서는 L4 리스크를 수정한 후, 3개의 L1 도메인(General, Agentic, and Physical)으로 구분된 L3 카테고리에 의미적 유사도 기반으로 매핑하는 작업을 수행하는 것을 목표로 함

[작업 순서 및 원칙]

L4의 리스크 수정 작업은, 다음의 3가지 기본원칙에 따라서 L4 리스크를 수정할 것

- 첫째, instruction prompt 컬럼에 삭제를 명시적으로 표현한 L4 리스크는 삭제하고, 원본은 별도 보관할 것
- 둘째, instruction prompt 컬럼에 다중 의미가 포함된 리스크에 대해서 분리를 명시적으로 표현한 L4 리스크는 분리하고, 완결된 리스크 명칭과 한글, 영문 description으로 재정의할 것
- 셋째, instruction prompt 컬럼에 다수의 리스크들에 대해 명시적으로 통합하라고 지목한 L4 리스크를 통합하고, 완결된 리스크 명칭과 한글, 영문 description으로 정의할 것
- 단, 모든 리스크의 명칭과 정의는 학술문헌과, 정책보고서, AI 기본법, 가이드라인에 기술된 표준화된 용어를 사용하되, 한국어와 영어의 의미를 가능한 일치시킬 것. 현재, 한국어의 경우 일부는 휴먼 검수를 했고, 하지 못한 부분에서 어색한 리스크 정의서는 전체적으로 일관성과 통일감을 줄 수 있도록 수정을 할 것.
- L4리스크 명칭을 수정 또는 변경하는 과정에서 L4_Description_edited_ko, L4_Description_edited_en으로 인간이 정의한 description을 우선적으로 반영할 것

L4 리스크와 L3 카테고리와 매핑작업은 다음의 3가지 기본원칙에 따라서 수행할 것

- 첫째, L4의 instruction prompt 컬럼에 명시적으로 L1의 3개 도메인으로 이동하라는 지시를 따라서, 그 하위에 있는 가장 적합한 L3 카테고리에 매핑을 할 것
- 둘째, 모든 L3와 L4의 매핑은 EM(expectation Maximization) 알고리즘을 따를 것
- 셋째, EM 알고리즘으로 분리가 어려운 경계성 L4는 L1 아래에 Others 카테고리(G_Others, A_Others, P_Others)를 생성하여, 이곳에 분리하고, 휴먼 결정(HD)으로 표기할 것
- 기타 사항으로 L4의 Instruction prompt에서 '새로운 L3 필요' 또는 적당한 L3로 매핑 필요라고 한 것은 EM알고리즘으로 재매핑을 할것.
- 이 단계에서는 새롭게 L3를 생성하지 말것. 매핑이 불가하거나 모호한 경우는 Others로 분류할 것

ID 부여 규칙

- L0, L1, L2, L3는 리스크 명칭의 고유한 특성과 상위 계위가 드러나도록 작명할 것
- L4는 매핑과정에서 이동성과 길이를 고려하여, L3계위만 드러나도록 하고, 순번을 부여할 것
 - L4의 경우 기존 ID체계를 무시하고, 새롭게 부여할 것.
 - 단, L4에 ID가 없거나 'new'로 분류된 ID에도 새롭게 부여할 것

기타사항

- L4리스크 컬럼중에서 facet과 act-type에 대해서는 컬럼을 유지할 것. 비어 있는 부분은 빈 상태를 유지할 것.
- L4의 Instruction prompt의 지시사항과 L3 내용이 충돌하는 경우, L3 마스터 파일에 정의되어 있는 내용을 우선시 할것