

RAI Risk Taxonomy 2.0

Rebuild Technical Report

리스크 적격성 정제, EM 기반 L3 매핑 및 마스터 릴리스

기준일: 2026년 8월 26일

한국어판

Contents

1 요약	2
2 문제 진단과 재설계 원칙	2
2.1 확인된 실패	2
2.2 재설계된 순서	2
3 원천 데이터와 무결성	2
4 L4 정제와 동료 검토	3
5 L1 라우팅과 ID	3
6 EM 매핑 방법	5
7 매핑 결과	5
8 세 가지 내부 검증	7
8.1 원본 대조 및 계보 검증	7
8.2 반복 수렴 및 안정성 검증	7
8.3 한영 교차검증 및 의미 전제 검증	7
9 웹 기반 인간 검수 로그	7
10 마스터 릴리스와 동기화	7
11 한계와 후속 검토	8
12 결론	8

1 요약

본 작업은 초기 의미 유사도 파이프라인이 응급·재난 대응과 같은 적용 맥락을 폭력 리스크로 오분류한 문제를 계기로 RAI Risk Taxonomy 2.0을 원천 데이터부터 다시 구축한 결과이다. 원천 L4 892건을 동결하고, 의미적 매핑 전에 리스크 적격성 심사, 삭제, 통합, 분리, 한영 명칭·정의 재작성, 동료 검토를 수행하였다. 최종 L4는 813건이며 보존식은 $892 - 60 - 20 + 1 = 813$ 이다.

최종 카드 중 617건(75.9%)은 기존 L3에 EM으로 배정했고, 196건(24.1%)은 기존 L3 후보 사이의 경계성, 낮은 확신, 불안정성 또는 한영 불일치 때문에 도메인별 Others와 인간 결정(HD) 대기열로 분리하였다. 최종 분포는 General 623건, Agentic 78건, Physical 112건이다. 원본 L3 46행은 변경하지 않았고, 도메인별 Others 3행만 파생 구조로 추가하였다. 내부 자동 검증 39개는 모두 통과하였다.

2 문제 진단과 재설계 원칙

2.1 확인된 실패

초기 방식은 모든 입력 행을 리스크로 가정하고 곧바로 의미 공간에 투입하였다. 이 때문에 생명, 안전, 응급, CPR, 응급처치와 같은 어휘가 폭력 L3 임베딩을 끌어올려, 정상적인 응급·재난 대응 맥락이 폭력으로 배정되는 오류가 발생했다. 이는 유사도가 리스크 성립 여부를 판정할 수 없고, 가까운 어휘가 곧 올바른 위험 메커니즘을 의미하지 않음을 보여준다.

2.2 재설계된 순서

1. 원천 CSV·PDF와 L3 마스터를 SHA-256으로 동결한다.
2. AI 관여 원인, 발생 메커니즘, 부정적 결과, 영향 대상을 기준으로 리스크 적격성을 심사한다.
3. Instruction Prompt에 따른 삭제·통합·분리를 적용하고 원본 계보를 별도 보존한다.
4. 유효한 인간 수정 정의를 우선해 L4 수준의 구체적 한영 명칭과 정의를 작성한다.
5. L3 마스터와 같은 자연스러운 명사구를 명칭에 사용한다. ‘리스크’나 ‘위험’은 의미상 필요할 때만 사용한다.
6. 원문 기반 임시 EM으로 L3 작성 기준점을 산출하고, 현재 L3 명칭·정의와 의미적으로 연결되는지 심사한다.
7. 한국어와 영어 정의 각각에 AI 시스템·알고리즘·에이전트·로봇·학습 기술 또는 모델을 명시하고 L3식 위험 문장으로 통일한다.
8. 수정된 정의로 한·영 각 3개의 대표 개념을 추출하고, L3 어휘 프로파일을 보완 신호로 결합해 최종 EM을 새로 적합한다.
9. 현행 L3 어디에도 맞지 않거나 단일 L3로 표현할 수 없는 카드는 삭제 보관하고, 현행 L3 범위 안에서 후보 간 판단이 모호한 카드만 Others에 배치하여 HD 사유와 상위 2개 L3 후보를 기록한다.

3 원천 데이터와 무결성

Table 1: 도메인별 원천 및 최종 L4 수

도메인	원천	최종	순변화
General AI	591	623	+32
Agentic AI	83	78	-5
Physical AI	218	112	-106
합계	892	813	-79

Table 2: 핵심 원천 해시

자료	SHA-256
L3 마스터 CSV	b154be6ced881cc10d93779447afe3b636bcaeea6094c399fc4d49076d3812c4

자료	SHA-256
General L4 CSV	97a57589bb218a89372bf703cb569c7e5344ff09155dfb74bc624b9a0bdeeb8
Agentic L4 CSV	d790d6feda006e0026d582aa0ad0b3d1e8442257eb563583e6077039ab4623cf
Physical L4 CSV	d578772484243a6888a2e41afbefb580385debbac2ca70c29c67a1fcebdf349c

L3 원본 46행의 L1, L2, L3 한영 명칭·정의와 비교는 셀 단위로 대조하였다. 최종 계층의 추가 3행은 정식 L3가 아니라 HD 라우팅을 위한 G_Others, A_Others, P_Others이다.

4 L4 정제와 동료 검토

명시적 삭제 39건, 비리스크 적용 맥락 8건, 동료 검토 폐기 1건을 삭제 보관본으로 이동하였다. 14개 통합 그룹에서 20건을 대표 카드로 흡수했고, 다중 의미 카드 1건을 두 카드로 분리하여 순증 1건을 만들었다. 원천에서 'new'로 표시된 100건 가운데 비리스크 맥락 8건을 제거하고 92건을 재정의·재발급하였다.




Figure 1: 리스크 적격성 게이트를 포함한 L4 수량 대조

Claude 보조 검토는 713건의 한글 표기 복원, 8건의 실질적 재정의, 1건의 폐기 권고를 제시하였다. 표기 복원과 재정의는 원천 의미를 보존하는지 검토한 뒤 수용하였다. RAI4-0568은 AI 개발자의 관여와 정보주체 권리를 더 명시적으로 수정하였다. RAI4-1157은 재정의 후 사이버 공격 메커니즘이 명확해져 Physical에서 General로 이동하고 G_SYS_SECADV에 강한 작성 사전정보를 제공하였다. 모든 명칭에 '리스크'를 붙이는 규칙은 폐기했으며, 의미상 필요할 때만 피해·침해·위험 표현을 유지하였다.

이후 825개 카드를 L3 마스터의 명칭·정의와 전수 대조했다. 552건은 이미 AI 기술 주체와 위험 구조가 완결되어 유지했고, 261건은 원래 의미를 보존하면서 한·영 정의에 AI 시스템·알고리즘·에이전트·로봇·학습 기술 또는 모델을 명시하도록 보완했다. 현행 L3 중 어느 범위에도 들어가지 않거나 단일 L3로 표현할 수 없는 12건은 삭제 보관하였다. Others는 하나 이상의 현행 L3 범위에는 들어가지만 후보 간 경계가 모호한 경우에만 사용하였다.

5 L1 라우팅과 ID

Instruction Prompt가 명시한 L1 이동 103건과 별도 해결 지시 1건을 반영하였다. 동료 검토로 메커니즘이 변경된 RAI4-1157 한 건은 의미 기준으로 General에 추가 이동하였다. facet과 act-type은 L4 속성으로 유지했지만 의미 매핑 입력에서는 제외했다. 모든 L4 ID는 L3_ID + 순번 형식으로 다시 발급하였다.




Figure 2: L3 마스터 대조 후 AI 기술 정의 유지·보완 결과




Figure 3: 재구축 전후 도메인별 L4 수

6 EM 매핑 방법

BAAI/BGE-M3의 동일 로컬 스냅샷에서 한국어와 영어를 별도로 임베딩하고 CLS 벡터를 L2 정규화하였다. L4 카드 i 와 L3 후보 k 의 결합 점수는

$$s_{ik} = 0.5 \cos(\mathbf{x}_i^{ko}, \boldsymbol{\mu}_k^{ko}) + 0.5 \cos(\mathbf{x}_i^{en}, \boldsymbol{\mu}_k^{en}) \quad (1)$$

이다. E-step은 L1 내부에서 최고 점수를 선택하고, M-step은 L3 마스터 anchor 가중치 4.0와 배정 L4 평균을 결합해 중심을 갱신한다. 20260826부터 20260830까지 5개 초기값으로 반복하였다.

각 L4에서 한·영 각 3개 대표 개념을 추출하고, 46개 L3 정의에서 구성한 어휘 프로파일과 제외어를 E-step의 보완 사전정보로 사용했다. 선택된 후보의 키워드 지지도가 강하면 보수적 거절 조건을 일부 보완했지만, L3 정의 대신으로 사용하지 않았다. 민감 범주는 필수 개념어가 없는 카드의 후보에서 제외했다. 작성 힌트는 후보를 하나로 제한하지 않고 강한 사전정보로만 적용했다. 단일 현행 L3로 표현할 수 없는 복합 메커니즘이나 현행 L3와 의미적으로 양립할 수 없는 카드는 EM 입력에서 제외했다. 최고 점수 0.560 미만, 하이브리드 마진 0.012 미만, 안정성 0.80 미만, 원본 anchor 점수 0.48 미만, 낮은 마진에서의 한영 Top-1 불일치 등을 HD 신호로 사용했다.

7 매핑 결과

Table 3: 도메인별 EM 및 HD 결과

도메인	최종 L4	EM	HD/Others	HD 비율
General AI	623	462	161	25.8%
Agentic AI	78	64	14	17.9%
Physical AI	112	91	21	18.8%
합계	813	617	196	24.1%




Figure 4: 도메인별 EM 확정과 HD/Others 대기열

기준 키워드를 사용하지 않은 배정선에서는 EM 559건, HD 266건이었다. 키워드 보강과 L3 기반 정의 검토 후 EM은 617건으로 58건 늘었으며, 임금 양극화는 G_SOC_ECON, 대규모 사이버범죄 오용은 G_SYS_SECADV로 회수했다. 단, HD 196건은 매핑 실패가 아니라 경계 사례를 명시적으로 격리한 결과이며 자동 확정된 L3로 해석해서는 안 된다.

Table 4: EM 품질 진단

도메인	평균 최고점수	중앙 마진	평균 안정성	한영 Top-1 일치
General AI	0.7597	0.0309	0.9849	61.8%
Agentic AI	0.7606	0.0347	0.9872	71.8%
Physical AI	0.7316	0.0251	0.9964	64.3%




Figure 5: 도메인별 최고 유사도, 마진, 반복 안정성 분포




Figure 6: 도메인별 EM 배정 상위 L3




Figure 7: 키워드 보강 전·후 EM과 HD 건수 비교

8 세 가지 내부 검증

8.1 원본 대조 및 계보 검증

처리 전후 원천 해시, L3 46행의 셀 값, 삭제·통합·분리 보존식, 892개 원천의 crosswalk 포함 여부를 확인했다. 이는 데이터 유실, 중복, L3 번조를 검출한다.

8.2 반복 수렴 및 안정성 검증

도메인별 5개 초기화의 목적함수, 반복 수, 카드별 배정 합의율을 기록했다. 낮은 합의는 HD 신호로 처리하였다.

8.3 한영 교차검증 및 의미 전제 검증

한국어와 영어 Top-1을 별도로 기록하고, 민감 L3의 개념 전제와 원본 anchor 점수를 함께 검사했다. 정상 활동이나 적용 맥락은 EM 이전의 리스크 적격성 게이트에서 제거하였다.

자동 검증은 원천 해시, L3 불변성, 수량 보존, ID 유일성, 한영 필드, AI 기술 명시, L3식 정의문 구조, L3 범위 게이트, Others의 HD 전용성, crosswalk, 3개 대표 키워드, 상위 2개 후보, 5개 CSV 구성을 포함한 39개 항목에서 모두 PASS였다.

9 웹 기반 인간 검수 로그

모든 L4 카드는 현재 배정과 무관하게 상위 2개 비-Others L3 후보의 기본 EM 점수와 하이브리드 점수를 표시한다. 검수자가 후보를 선택하면 릴리스 해시와 검수 스냅샷을 포함한 GitHub Issue가 작성된다. 일일 자동화는 스냅샷이 일치하는 표만 유효화하고, 검수자·카드별 최신 표를 유지하며, 최소 3명의 검수자와 50% 초과 다수를 충족한 비구속적 권고안을 생성한다. 재배치는 사용자가 로그 분석과 반영을 명시적으로 지시할 때만 수행한다.

10 마스터 릴리스와 동기화

최종 정본은 L1 CSV 1개, L1/L2/L3 CSV 1개, General·Agentic·Physical L4 CSV 3개이다. 동일 CSV에서 웹 탐색용 cards.json, hierarchy.json, 공개 manifest, Validation Record, 한영 보고서와 그림을 생성하였다. 웹사이트의 행 수, 다운로드 링크, current release 포인터와 해시도 같은 릴리스에 맞췄다.

11 한계와 후속 검토

EM은 확률 혼합모형의 완전한 EM이 아니라 L3 anchor를 둔 제약 구면 hard EM이다. 점수 임계값은 내부 운영 기준이며 전문가 라벨로 외부 보정되지 않았다. Others 196건은 삭제 대상이 아니라 인간 결정 대기열이다. 향후 독립 검증은 도메인 · L3 · 점수 구간을 충화한 표본을 사용해 자동 배정의 정확도와 HD 회수율을 평가해야 한다.

12 결론

재구축은 어휘 유사도가 정상 응급 대응을 폭력으로 오인한 오류를 리스크 적격성 문제로 재정의하였다. 적격성 게이트, L3 불변성, 한영 정의 재작성, 보수적 EM과 HD 격리를 결합함으로써 813개 L4와 완전한 계보를 가진 RAI Risk Taxonomy 2.0 master를 생성하였다.