

RAI Risk Taxonomy 2.0

검수 완료 마스터 릴리스 기술보고서

Human-review recovery and independent audit release

2026년 8월 29일

요약

본 보고서는 두 단계의 작업을 기록한다. 첫째, 798개 기준선 L4 카드에 2차 휴먼 검수 지시(808행 등록부, 검토의견 251건)를 행 단위로 재적용하여 777장의 복구 릴리스를 산출했다. 둘째, 이 릴리스에 대해 독립 검수 파이프라인(AC-01 AC-08)을 적용했다. 검수는 리뷰어 에이전트 2인의 독립 전수 판정과 합의제(교집합만 적용)로 수행했으며, 하드 원칙 위반 시정, 의미 중복 흡수, 전체 L3의 MECE 큐레이션(중복·귀속력), 복합 카드 분해, 미달 L3의 문헌 근거 보강을 포함한다. 이번 단계에서도 EM 또는 Hybrid EM은 재실행하지 않았다. **최종 결과는 L4 카드 629장이며 General 487, Agentic 65, Physical 77이다. 47개 L3 전부가 3장 이상의 L4를 보유하고 Others 배정은 0건이다.**

1 복구 원칙

기준 커밋의 유효한 편집과 사용자 승인 통합은 보존했다. 2차 검수 원문의 삭제, 통합, 분리, 재배포, 정의 수정 지시만 source_row_id 계보를 통해 적용했다. L3는 신설하거나 수정하지 않았으며 SHA-256 해시를 고정했다. 휴먼검토의견 251건의 반영 충실성은 별도 검토에서 반영 246, 부분반영 3, 미반영 2로 판정되었고, 각 카드에 검토의견 원문과 반영 결과를 기재했다.

2 적용 결과

조치	검수행 수
재배정	80
정의 수정 후 유지	39
분리	19
통합	14
삭제	14

Table 1: 승인된 166건의 휴먼 검수 조치(복구 단계)




Figure 1: 도메인별 최종 L4 카드 수

3 감사 시정(AC-01 AC-08)

복구 릴리스에 대한 라인바이라인 검수와 사용자 승인에 따라 다음 시정을 적용했다. 모든 판단적 결정은 리뷰어 2인의 독립 판정 원장과 합의 목록에 기록했고, 합의(교집합) 항목만 적용했다. 2차 휴먼 검수는

시정	내용	카드 수
AC-01	자살 준비·실행 분리 복원(준비 카드 신설, 조장 카드 정의 축소)	777→778
AC-02	8개 대형 L3의 합의 중복 58장 흡수	778→720
AC-03	휴먼 검토의견 원문·반영 결과 기재, 출처 표기 정리	720
AC-04	공개 CSV에서 스코어링·키워드 컬럼 제거(전체 컬럼 원본 별도 보관)	720
AC-05	빈 L3 보충(과도한 거절 3장, 물리적 번조·파괴 3장, 전 카드 출처 링크)	720→725
AC-06	미달 L3 문헌 근거 보강 2장, 거버넌스·조작 계열 합의 16장 흡수	725→711
AC-07	전체 L3 MECE 큐레이션: 흡수 64, 귀속 이관 18, 제거 2	711→645
AC-08	합의 복합 카드 18장 분해(17장 조각 귀속 후 폐기, 위기 대응 실패 카드 신설)	645→629

Table 2: 감사 시정 요약

”부족한 성능·역량”을 다루는 신규 L3의 생성을 명시적으로 요청했다(2건의 신규 L3 요청과 17건의 이관 지시). 이 요청은 L3 마스터 불변 원칙과 충돌하여 보류되어 있었으나, 사용자 승인에 따라 AC-14에서 **성능·신뢰성 실패(Performance and Reliability Failure)** 카테고리를 신설하고 리뷰어 2인 합의로 10장을 이관했다. L3 마스터는 47개 마스터 범주와 3개 Others로 구성되며, 마스터 해시는 이에 따라 갱신되었다. 신설·수정 카드는 검증된 문헌 출처를 References로 보유한다(XSTest, OR-Bench, AgentHarm, Cao et al. CCS 2019, NIST SP 800-82r3, NIST SP 800-193, Sclar et al. ICLR 2024, Huang et al. ICLR 2024, Moore et al. FAccT 2025). 자해·자살 계열은 준비, 실행, 조장, 위기 대응 실패의 네 축으로 분리 유지된다.

4 배포 구성

최종 배포는 L1 CSV 1개, L1/L2/L3 CSV 1개, General, Agentic, Physical L4 CSV 3개로 구성한다. 공개 CSV는 계층 정의(한·영), facet, act-type, 휴먼 검토의견 원문·반영 결과, References의 28개 컬럼이며, 스코어링·키워드 컬럼을 포함한 전체 컬럼 원본은 핸드오버 패키지와 아카이브에 보관한다. 검증 폴더에는 808행 지시 등록부, 계보 간선, 삭제 기록, 통합·분해·큐레이션 로그와 감사 시정 로그(Audit_Correction_Log)를 보존한다. 카드 상세의 Mapping provenance에는 한국어 라벨과 휴먼 리뷰·반영 결과, References 링크가 표시된다.




Figure 2: 감사 시정에 따른 카드 수 변화