

RAI Risk Taxonomy 2.0

Upgrade Technical Report

L4 정제, EM 기반 L3 매핑 및 최종 릴리스 결과

기준일: 2026년 8월 26일

한국어판

Contents

1 요약	2
2 분류체계와 적용 규칙	2
3 입력 데이터와 무결성 기준선	2
4 L4 정제 결과	3
4.1 삭제, 통합, 분리	3
4.2 한영 정의와 속성정보	3
5 L1 라우팅과 L3 식별자	4
6 EM 매핑 방법	4
6.1 표현과 E-step	4
6.2 M-step과 반복	4
6.3 Others 및 HD 판정	5
7 매핑 결과	5
8 세 가지 내부 검증 방식	7
8.1 1. 원본 대조 및 수량 보존 검증	7
8.2 2. 반복 수렴 및 초기화 안정성 검증	7
8.3 3. 한영 교차검증과 경계 사례 격리	7
9 최종 릴리스 구조	7
10 한계와 후속 검증 경계	7
11 결론	7

1 요약

본 작업은 RAI Risk Taxonomy 2.0 업그레이드의 운영 파이프라인을 완료하였다. 원본 L4 892건을 수정 불가능한 기준으로 고정하고, Instruction Prompt와 확정된 원칙에 따라 삭제, 통합, 분리, 명칭 및 정의 정제, L1 라우팅을 수행하였다. 정제 결과는 834건이며 보존식은 $892 - 39 - 20 + 1 = 834$ 로 정확히 일치한다.

각 L4는 확정된 L1 내부의 기존 L3만 후보로 하는 seed-constrained spherical hard EM으로 매핑하였다. 한글과 영어 임베딩은 별도로 계산한 뒤 동일 가중으로 결합하였다. 5개 초기화의 합의로 769건을 EM 배정하고, 경계성 65건은 General 50건, Agentic 2건, Physical 13건의 Others 및 인간 결정(HD) 대기열로 분리하였다. 신규 정식 L3는 만들지 않았고, 원본 L3 46행은 해시와 셀 내용이 변경되지 않았다.

최종 기본 산출물은 5개 CSV이다. L1과 L1/L2/L3 마스터가 각각 1개이며, L4는 General, Agentic, Physical의 3개 파일로 구분하였다. 외부 독립 검증은 사용자의 별도 단계이며 본 보고서는 완료된 내부 처리와 검증 결과를 기록한다.

2 분류체계와 적용 규칙

분류체계는 L0 RAI, L1 General AI, Agentic AI, Physical AI, L2 System, Interaction, Societal Impact, L3 마스터 범주, L4 리스크 카드로 구성된다. 적용 순서는 다음과 같다.

1. 원본과 L3 마스터를 해시로 고정하고 각 L4에 불변 source_row_id를 부여한다.
2. 명시적 삭제를 격리하고, 지목된 중복 카드를 통합하며, 다중 의미 카드를 분리한다.
3. 유효한 인간 수정 description을 우선해 한영 명칭과 정의를 정합화한다.
4. Instruction Prompt의 명시적 L1 이동을 먼저 적용한다.
5. 각 L1 내부의 기존 L3만 대상으로 EM을 수행한다.
6. 낮은 마진, 낮은 안정성, 한영 신호 불일치가 결합된 경계 사례는 Others 및 HD로 이관한다.

L3 마스터와 Instruction Prompt가 충돌할 때는 L3 마스터를 우선하였다. Physical의 두 번째 빈 헤더에 있던 1건의 문구는 사용자 지시에 따라 매핑 지시로 사용하지 않았고 원본 CSV에만 남겼다. facet과 act-type은 L4 속성정보로 유지하되 EM 입력에서는 제외하였다.

3 입력 데이터와 무결성 기준선

Table 1: 입력 L4와 정제 결과

도메인	입력 L4	최종 L4	순변화
General AI	591	618	+27
Agentic AI	83	85	+2
Physical AI	218	131	-87
합계	892	834	-58

최종 도메인 수는 삭제와 통합뿐 아니라 명시적 L1 이동을 반영한 값이다. Instruction Prompt를 통해 103건이 라우팅되었고, 별도 해석한 Physical RAI4-0466 1건을 포함하면 지시 기반 라우팅은 104건이다.

Table 2: 핵심 입력 해시

자료	SHA-256
L3 마스터 CSV	b154be6ced881cc10d93779447afe3b636bcaaaa6094c399fc4d49076d3812c4
General L4 CSV	97a57589bb218a89372bf703cb569c7e5344ff09155dfb74bc624b9a0bdeebe8
Agentic L4 CSV	d790d6feda006e0026d582aa0ad0b3d1e8442257eb563583e6077039ab4623cf

자료	SHA-256
Physical L4 CSV	d578772484243a6888a2e41afbfb580385debbac2ca70c29c67a1fcebdf349c
정합화 입력 XLSX	39f36fa5ab31501a8738f59a3e71566d183d63aee4eca5eacaf188ab0931ec7a

4 L4 정제 결과

4.1 삭제, 통합, 분리

명시적 삭제 39건은 모두 Physical 원본에서 격리하였다. 14개 통합 그룹에서 피통합 카드 20건을 제거하고 대표 카드의 한영 명칭과 정의를 재작성하였다. RAI4-0793은 개인 대상 허위정보와 위험·민감 정보의 보안 위협 확산으로 분리하여 순증 1건을 만들었다.

Table 3: L4 수량 보존 결과

단계	변화	잔여 L4
원본	0	892
명시적 삭제	-39	853
통합 후 피통합 카드 제거	-20	833
복합 카드 분리	+1	834




Figure 1: L4 정제 단계별 수량 대조

삭제 원문은 Deleted_Archive.csv, 피통합 카드는 Merged_Archive.csv, 분리 계보는 Split_Lineage.csv에 보존하였다. 모든 원본 행과 최종 ID의 관계는 ID_Crosswalk.csv로 추적할 수 있다.

4.2 한영 정의와 속성정보

최종 834건의 L4 한영 명칭과 한영 정의는 모두 비어 있지 않으며 짧은 추출 잔재와 EAI 토큰은 남지 않았다. General 원본의 new ID 100건도 새 L4 ID를 부여받았다. Agentic과 Physical의 facet, act-type은 원본 값이 없으므로 빈 속성으로 보존하였다.

5 L1 라우팅과 L3 식별자

명시적 이동 지시를 적용한 뒤 General은 618건, Agentic은 85건, Physical은 131건이 되었다. Physical 원본의 범용 모델 및 소프트웨어 에이전트 리스크가 General과 Agentic으로 이동한 것이 Physical 감소의 주된 원인이다.




Figure 2: 정제 및 L1 라우팅 전후 도메인별 L4 수

L1 ID는 L1_G, L1_A, L1_P로 부여하였다. L2와 L3 ID는 상위 계위와 고유 의미를 나타내도록 구성하였다. L4 ID는 기존 ID를 사용하지 않고 L3_ID + 순번으로 재발급하였다. 예를 들어 P_SYS_CONTROL_001은 Physical, System, Unsafe Physical Control and Actuation의 첫 번째 L4를 의미한다.

Others는 정식 L3 마스터 수정이 아니라 L1 직속 HD 대기열로 표현하였다. ID는 G_Others, A_Others, P_Others이며 L2 필드는 비워 L3 마스터의 기존 L2 구조를 변경하지 않았다.

6 EM 매핑 방법

6.1 표현과 E-step

BAAI/BGE-M3의 단일 로컬 스냅샷에서 설정, 토큰라이저, pytorch_model.bin을 함께 불러오고 CLS 벡터를 L2 정규화하였다. 네트워크에서 받은 서로 다른 스냅샷의 파일은 혼합하지 않았다. L4 입력은 최종 제목과 description뿐이며 Instruction Prompt, 인간 L3 배정, facet, act-type은 임베딩에서 제외하였다.

카드 i 와 L3 k 의 결합 점수는 다음과 같다.

$$s_{ik} = \frac{1}{2} \cos(\mathbf{x}_i^{ko}, \boldsymbol{\mu}_k^{ko}) + \frac{1}{2} \cos(\mathbf{x}_i^{en}, \boldsymbol{\mu}_k^{en}). \quad (1)$$

E-step은 확정된 L1 내부에서 $z_i = \arg \max_k s_{ik}$ 를 계산한다.

6.2 M-step과 반복

M-step은 L3 마스터 임베딩을 고정 anchor로 두고 배정된 L4의 평균을 결합한다.

$$\boldsymbol{\mu}_k^{(t+1)} = \text{norm} \left(2\mathbf{a}_k + \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i \right). \quad (2)$$

빈 군집은 원래 L3 anchor로 복귀한다. 시드 20260826부터 20260830까지 5회 초기화하고 다수결 합의와 카드별 안정성을 계산하였다. 이 구현은 확률적 혼합모형의 완전한 EM이 아니라 seed-constrained spherical hard EM, 즉 앵커 제약 구면 hard EM이다.

6.3 Others 및 HD 판정

최고 결합 점수 0.30 미만, 1순위와 2순위 마진 0.005 미만, 반복 안정성 0.60 미만을 경계 신호로 사용하였다. 한영 최상위 L3가 다를 때는 평균 마진이 0.008 미만인 경우에만 HD로 전환하여 언어별 표현 차이만으로 과도하게 Others가 증가하지 않도록 하였다. L3 마스터에 요청 범주가 없는 명시적 충돌 1건도 HD에 포함하였다.

이 기준은 내부 운영용 reject rule이다. 외부 전문가 표본을 이용한 독립 임계값 보정은 본 작업 범위에 포함하지 않았다.

7 매핑 결과

Table 4: 도메인별 EM 및 HD 결과

도메인	최종 L4	EM	HD/Others	HD 비율
General AI	618	568	50	8.1%
Agentic AI	85	83	2	2.4%
Physical AI	131	118	13	9.9%
합계	834	769	65	7.8%




Figure 3: 도메인별 EM 배정과 HD/Others 대기열

Table 5: EM 품질 지표

도메인	평균 최고점수	중앙 마진	평균 안정성	한영 Top-1 일치
General AI	0.7395	0.0289	0.9686	70.7%
Agentic AI	0.7547	0.0357	0.9741	83.5%
Physical AI	0.7252	0.0247	0.9786	75.6%

5개 실행의 수렴 반복 수는 General 5회에서 7회, Agentic 2회에서 3회, Physical 4회에서 5회였다. 최종 목적함수 범위는 General 0.739425에서 0.739750, Agentic 0.754682에서 0.754912, Physical 0.725065에서 0.725349였다.




Figure 4: 도메인별 최고 유사도, 마진, 반복 안정성 분포




Figure 5: 도메인별 EM 배정 상위 L3 범주

8 세 가지 내부 검증 방식

8.1 1. 원본 대조 및 수량 보존 검증

입력 파일의 SHA-256을 처리 전후 비교하고 L3 마스터 46행을 다시 읽어 동일성을 확인하였다. 삭제, 통합, 분리의 보존식과 최종 834건을 대조하고, 원본 행마다 삭제, 피통합, 활성화, 분리 상태 중 하나 이상이 ID_Crosswalk.csv에 존재하는지 확인하였다. 이는 데이터 유실, 중복 잔존, L3 마스터 번조를 검출한다.

8.2 2. 반복 수렴 및 초기화 안정성 검증

도메인별로 5개 초기값을 사용해 EM을 반복하고 목적함수, 반복 수, 카드별 배정 일치율을 기록하였다. 평균 안정성이 세 도메인 모두 0.96을 넘고 실행별 최종 목적함수 범위가 좁다는 점을 확인하였다. 이는 특정 초기값에 의존한 불안정한 군집 배정을 검출한다.

8.3 3. 한영 교차검증과 경계 사례 격리

한국어와 영어를 별도로 임베딩하여 언어별 Top-1 L3, 결합 점수, Top-2 마진을 기록하였다. 언어별 결과가 다르면서 결합 마진이 낮은 카드와 기타 경계 신호를 Others로 보내고 HD_Reason을 부여하였다. 이는 번역 차이, 다중 의미, L3 범위 부족으로 인한 과도한 자동 확정을 줄인다.

자동 QA 10개 항목은 모두 PASS였다. 여기에는 원본 해시 불변, L3 46행 유지, L4 수량 대조, ID 유일성, 한영 필드 완전성, EM/HD 표기, Others의 HD 전용성, L3 참조 무결성, 정확히 5개 기본 CSV 존재 여부가 포함된다.

9 최종 릴리스 구조

Table 6: 최종 기본 CSV

파일	행	역할	주요 내용
L1_Master.csv	3	L1 기준	L0와 L1 ID, 한영 명칭·정의
L1_L2_L3_Master.csv	49	계층 기준	원본 L3 46행과 파생 Others 3행
L4_General.csv	618	General	L0 L4 전체 계층, 속성, EM/HD, 계보
L4_Agentic.csv	85	Agentic	L0 L4 전체 계층, 속성, EM/HD, 계보
L4_Physical.csv	131	Physical	L0 L4 전체 계층, 속성, EM/HD, 계보

각 L4 파일은 L0, L1, L2, L3, L4의 ID, 한영 리스크명, 한영 정의, Others 정보, facet, act-type, EM 점수·마진·안정성, 한영 Top-1, HD 사유, 원본 ID와 지시문, 변환 계보를 포함한다.

10 한계와 후속 검증 경계

본 결과는 주어진 L3 마스터에 대한 의미 기반 운영 매핑이다. L3 범주 자체의 이론적 완전성, 65건의 HD 최종 판정, 임계값의 전문가 보정은 외부 독립 검증 대상이다. 특히 Physical의 L3가 5개로 제한되어 있어 사회적 파급이나 공정성 성격의 일부 카드는 Others로 남을 수 있다. 이 한계를 숨기기 위해 새로운 L3를 만들지 않았으며, L3 마스터 우선 원칙을 유지하였다.

11 결론

RAI Risk Taxonomy 2.0 업그레이드의 데이터 정제, L1 라우팅, L3 EM 매핑, Others/HD 분리, 신규 ID 발급, 5개 CSV 릴리스, 감사 로그, 수치 검증, 결과 시각화가 완료되었다. 핵심 결과는 원본 892건에서 최종 834건, EM 769건, HD 65건이다. 모든 원본과 L3 마스터는 변경되지 않았고 최종 결과는 재실행 가능한 스크립트와 해시 manifest로 고정하였다.