

L4 리스크 카드 통합의 방법론과 실증 결과

Multi-Resolution Dendrogram, 생성형 명명·2 인 검수, 원천 손상 교정을 포함한 통합 기술 보고서 v2

천영삼 (Responsible AI, KT)

2026 년 8 월 6 일

Abstract

본 보고서는 RAI Risk Taxonomy 2.0 (v2.18.0-rc) 의 활성 L4 리스크 카드 1,660 장 전체를 대상으로 수행한 통합·축소 방법론과 실증 결과를 기록한다. 절차는 여섯 단계로 구성된다. (1) BGE-M3 임베딩과 agglomerative hierarchical clustering 으로 multi-resolution dendrogram 을 구축하고, (2) 절단 수준 $\tau \in [0.70, 0.94]$ 의 sweep 으로 군집 구조·품질·안정성을 정량화하며, (3) 운영 병합 수준 $\tau_{op} = 0.88$ 의 병합 그룹에 생성형 모델로 신규 카드 명칭·정의 초안을 생성하고, (4) 독립 전문 검수자 2 인 (용어·이중언어, AI 안전 도메인) 의 검수와 종합 판정을 거치며, (5) 검수가 적발한 라벨·정의 불일치를 원 소스 문헌 대조로 검증·교정하고, (6) 교정 결과를 병합 판정에 환류한다. 주요 발견은 세 가지다. 첫째, complete linkage 는 $\tau = 0.70$ 까지 percolation collapse 없이 계층을 유지하지만 single linkage 는 $\tau \leq 0.78$ 에서 붕괴한다. 둘째, τ 를 내릴수록 L3 매핑의 잡음 안정성은 유지되는 반면 (agreement ≥ 0.94) 분류학적 정당성 (auto rate $0.67 \rightarrow 0.22$) 은 단조 감소한다. 셋째, 임베딩 유사도 기반 병합 후보 11 건 중 2 건은 원천 데이터의 정의 오복사가 만든 인공적 중복이었으며, 전수 스크리닝 결과 손상은 정확히 3 쌍 6 장 (global_1726, source_mechanism_only_v2.7) 에 국한되고 원 소스 문헌에서 참 정의를 복원하였다. 최종 판정은 병합 승인 8 건, 분리 유지 2 건, 잔여 검토 1 건이다.

1 배경과 범위

선행 검토에서 Physical AI 구 182 장 집합은 이미 $\tau_{merge} = 0.94$ 에서 정제되어 임계값 조정만으로는 축소가 불가능함을 확인하였다 (최대 쌍별 유사도 0.909). 이에 전략을 수정하여 Physical AI 를 포함한 전체 활성 L4 카드 1,660 장 (General 1,221, Agentic 281, Physical 158) 을 대상으로 하되, τ 를 0.70 까지 단계적으로 내리는 접근을 채택하였다. 다만 사전 검토에서 이 접근은 파괴적 병합이 아니라 multi-resolution hierarchy 구축으로 재정의되어야 함이 밝혀졌고, 본 보고서는 그 실증 과정 전체를 기록한다. 모든 산출물은 별도 폴더 (reports/consolidation/simulation/) 에 저장되며 원본 릴리스 데이터는 읽기 전용으로만 사용한다.

2 방법론

2.1 임베딩과 dendrogram 구축

각 카드의 이중언어 텍스트 $x_i = \text{label}_i^{en} \parallel \text{label}_i^{ko} \parallel \text{def}_i^{en} \parallel \text{def}_i^{ko}$ 를 BGE-M3(ollama 구현체) 로 인코딩하여 $\mathbf{e}_i \in \mathbb{S}^{1023}$ 을 얻고, 쌍별 코사인 거리 $d_{ij} = 1 - \mathbf{e}_i \cdot \mathbf{e}_j$ 에 대해 complete, average, single linkage 의 agglomerative clustering 을 수행하였다. complete linkage 의 병합 조건은 $\min_{i,j \in C} s_{ij} \geq \tau$ 로, chaining 을 구조적으로 차단한다.

2.2 τ sweep 과 신뢰도 지표

절단 수준 τ 를 0.94 에서 0.70 까지 $\Delta\tau = 0.02$ 간격으로 내리며 네 지표를 추적하였다. auto rate(병합 그룹의 기존 L3 단일 일치율), mean margin($s_{(1)} - s_{(2)}$), perturbation agreement($\sigma = 0.01$ 가우시안 잡음 50 회 반복의 L3 매핑 일치율), silhouette coefficient 이다. 별도로 군집 구조 자체의 안정성을 Adjusted Rand Index(ARI, $\sigma \in \{0.01, 0.03, 0.05\}$, 30 회) 로 측정하였다.

2.3 신규 카드 생성과 2 인 검수

운영 병합 수준 $\tau_{op} = 0.88$ 의 다중 카드 그룹에 대해 c-TF-IDF 상위 용어와 로컬 생성형 모델 (qwen3:4b) 로 신규 카드의 한/영 명칭·정의 초안을 생성하였다. 생성형 초안은 신뢰할 수 없으므로 독립 검수자 2 인이 사후 검토한다. 검수자 A 는 용어·이중언어 편집 (오역 교정, 문체 정비) 을, 검수자 B 는 AI 안전 도메인 (구성개념 병합 타당성, L3 매핑 적정성, 원천 손상 탐지) 을 담당하며, 두 의견을 종합하여 approved 또는 defer 로 판정한다. 신규 카드의 L3 재매핑은 그룹 centroid $\bar{e}_C$ 와 기존 L3 centroid μ_k 의 최근접 배정 $\hat{k} = \arg \max_k \bar{e}_C \cdot \mu_k$ 로 수행하고, 기술보고서의 3 종 검증 (EM convergence, top-k containment, perturbation stability) 을 적용한다.

2.4 원천 손상 검증

검수자 B 가 적발한 라벨-정의 불일치 카드에 대해 (i) 활성 1,660 장 전수에서 동일 정의-상이 라벨 패턴을 스크리닝하고, (ii) 해당 카드의 참조 문헌 원문 (arXiv HTML, 정부 보고서 PDF) 을 직접 대조하여 참 정의를 복원하였다.

3 실증 결과

3.1 구조: linkage 규칙이 결과를 결정한다

Table 1: τ 절단 수준별 군집 구조 (complete vs single linkage)

τ	complete linkage			single linkage	
	군집 수	최대 군집	cross-L1	군집 수	최대 군집
0.94	1,660	1	0	1,659	2
0.88	1,649	2	1	1,635	2
0.82	1,553	3	11	1,463	8
0.76	1,254	5	62	1,000	513
0.70	873	9	114	490	1,470

single linkage 는 $\tau = 0.78$ 에서 giant component 가 전체의 5% 를 넘고 0.70 에서 89% 로 percolation collapse 를 일으킨다. complete linkage 는 0.70 에서도 최대 군집 9 장으로 안정적이며, 형성된 대주제군 (AI 과의존 9 장, loss of control 7 장, 투명성 결여 6 장 등) 은 데이터 주도 상위구조 후보로 유의미하다.




Figure 1: τ 감축 곡선 (좌) 과 최대 군집 크기 (우, log). single linkage 의 percolation collapse 가 뚜렷하다.

3.2 τ 감소에 따른 신뢰도의 이중성

perturbation agreement 는 전 구간 0.94 ~ 0.98 로 안정적이거나, auto rate 는 0.67($\tau = 0.90$) $\rightarrow$ 0.22($\tau = 0.70$) 로 단조 하락하고 cross-L1 혼입률은 0.23 까지 상승한다. 즉 기계적 매핑 안정성과 분류학적 정당성이 분




Figure 2: τ sweep 신뢰도 지표 (좌) 와 하한 진단 (우).

리되며, τ 하강의 비용은 후자에 집중된다. 군집 구조 ARI 는 $\sigma = 0.01$ 에서도 세밀 수준 ($\tau = 0.88$) 의 소그룹 이 0 수준으로 붕괴하여, 2 장 규모의 병합 그룹은 임베딩 섭동에 취약함을 보였다. 이는 임계값 단독 병합 확정을 금지하고 전문가 심의를 필수화하는 정량 근거다.

τ 하한은 세 기준의 최댓값으로 정의된다. single-linkage percolation 임계 ($\tau_c \approx 0.78$), cross-L1 혼입 10% 임계, agreement 90% 임계이다. 실증적으로 운영 병합 하한은 0.88 ~ 0.90, 표시용 계층 하한은 0.78 이며, 권장 step 은 $\Delta\tau = 0.02$ (하한 부근 0.01 세분) 이다.

3.3 신규 카드 L3 매핑의 신뢰도

$\tau_{op} = 0.88$ 의 병합 그룹 11 건에 대해 3 종 검증을 적용한 결과, EM 은 2 스텝에 수렴 ($J : 0.831 \rightarrow 0.845$), top-1/top-3 containment 100%, perturbation stability 는 $\sigma = 0.01$ 에서 96.0%, $\sigma = 0.05$ 에서 83.9% 였다 (200 회 반복). 매핑 자체는 신뢰 가능하나 margin 이 0.002 ~ 0.094 로 얇은 그룹이 있어 개별 확인이 필요하다.




Figure 3: 신규 카드 $\rightarrow$ L3 매핑의 3 종 신뢰도 검증. (1) EM convergence, (2) top-k containment 와 margin, (3) perturbation stability.

3.4 2 인 검수 결과와 원천 손상의 발견

11 건의 초안에 대한 검수 결과, 검수자 A 는 전 건에서 용어·문체 교정을 제시하였고 (“경쟁성” $\rightarrow$ “이의제기 가능성”, “전선 AI” $\rightarrow$ “프론티어 AI” 등), 검수자 B 는 4 건을 보류시켰다. 보류 사유 중 2 건 (g1462, g1458) 은 구성 카드의 라벨-정의 불일치, 1 건 (g81) 은 별개 벤치마크 구성개념 (명시적 vs 암묵적 위험 거부) 의 과병합, 1 건 (g1582) 은 메커니즘 혼합과 L3 오배정이었다. 또한 동일 L3 의 허위정보 카드 3 장 (g520, g1388, g1389) 이 실질 중복으로 판정되어 차기 umbrella 통합 대상으로 지정되었다.

3.5 원천 손상의 전수 검증과 교정

전수 스크리닝 결과 동일 정의-상이 라벨 손상은 정확히 3 쌍 6 장이며, 전부 global_1726 소스의 source_mechanism_only_v2 추출 파이프라인에서 발생하였다. 원 소스 문헌 대조 결과는 다음과 같다.

Table 2: 원천 손상 3 건의 진단과 교정

카드	손상 유형	원 소스	교정과 병합 판정 환류
RAI4-0659 (허위 정보 대량생성)	정의 오복사 (0892 의 금융 데이터 정의)	arXiv:2410.23472 GPAI 카탈로그	참 정의 복원. g1462 병합 무효. 0659 는 허위정보 umbrella 로 귀속, 0892 는 금융 카드 존치
RAI4-0863 (도덕 적 판단 영향)	정의 오복사 (0870 의 금융 GPAI 정의)	arXiv:2410.23472, §10.3	참 정의 복원. g1458 병합 무효. 0863 은 가치·상호작용 계열 L3 로 분리 재 매핑
RAI4-1427/1428 (편향 증폭/유해 응답)	단일 문장 과분할	UK Gov Future Risks of Frontier AI, Annex A §79	원 소스가 단일 서술이므로 g1582 병합 정당화 (검수자 B 의견을 소스 증거로 번복). L3 는 General 브랜치로 재매핑

이 결과는 임베딩 유사도 기반 병합 후보의 일부가 원천 데이터 품질 문제의 산물일 수 있음을 보여준다. 역으로, 병합 파이프라인이 데이터 품질 감사 도구로도 기능함을 시사한다.

3.6 최종 판정

교정 환류 후 최종 판정은 다음과 같다. 병합 승인 8 건 (g1562, g178, g957, g964, g520, g1388, g1389, g1582), 분리 유지 2 건 (g81 은 별개 평가 구성개념, g1462·g1458 은 병합 해체 후 각 카드 존치·재매핑), 잔여 검토 1 건 (g1388 의 RAI4-1201 fraud 구성개념 여부). 이번 라운드의 순 감축은 8 장이며, 허위정보 umbrella 통합 (3 4 장 추가 감축) 과 HOLD 614 장 해소가 차기 라운드로 이관된다.

4 운영 규칙 확정과 남은 결정

본 실증으로 확정하는 운영 규칙은 다음과 같다. (1) 병합은 complete linkage 만 사용한다. (2) 운영 병합 (카드 삭제) 은 $\tau \geq 0.88$ 의 동일 L3 그룹에 한하며, 임계값은 후보 발굴 수단이고 확정은 반드시 2 인 검수를 거친다. (3) $\tau \leq 0.82$ 수준은 표시·탐색용 계층으로만 사용한다. (4) 병합 확정 전 구성 카드의 원천 정합성 (라벨-정의 일치) 을 확인한다. (5) 모든 병합은 merged_into 계보와 구 ID 매핑을 포함해 날짜 명기 릴리스로만 반영한다.

남은 결정 사항은 (i) 임베딩 정보 확정 (ollama 구현체와 웹사이트 근접 네트워크 간 병합 그룹 수가 11 vs 91 로 상이), (ii) 허위정보 umbrella 카드의 설계, (iii) HOLD 해소 라운드의 심의 체계, (iv) v2.19 릴리스의 신규 카드 ID 규칙이다.

산출물 목록

reports/consolidation/simulation/ 하위. dendrogram_simulation_1660.{ipynb, html} (Task 1–10 실행 기록), embeddings_bge-m3_1660.npy, level_assignments_complete.csv, dendrogram_summary.json, merged_card_proposals_tau088.csv, draft_cards_for_review.json, reviewed_cards_final.json, merge_before_after_review (Before/Draft/Reviewed 3 단), source_corruption_{screening, corrections}.json, fig 6 중 PNG.