

L4 리스크 카드의 3단 해상도 릴리스 설계

Master / C80 / C70 세트 생성을 위한 반복 병합 절차와 임계값 선택

RAI Risk Taxonomy 2.0 — v2.19 통합 라운드 기술 보고서

2026년 8월 6일

Abstract

본 보고서는 RAI Risk Taxonomy 2.0의 L4 리스크 카드 집합을 서로 다른 세 해상도로 릴리스하기 위한 통합 절차를 기술한다. 목표는 군집 분석 뷰의 생성이 아니라, 각 해상도마다 실제 카드가 존재하고 카드 수가 감소하는 세 개의 독립 릴리스 세트(Master, C80, C70)를 만드는 것이다. 본 보고서는 (i) Master 세트를 1,652장으로 확정하고 그 실효 임계값 $\tau_{\text{eff}} = 0.945$ 를 산출하며, (ii) 통합 절차를 반복 병합 루프로 형식화하고 연결 규칙(linkage) 네 종을 실증 비교하며, (iii) $\tau \in [0.60, 0.99]$ 전 구간 스윙 결과를 보고하고, (iv) 명명가능성 검정을 병합 게이트로 도입할 것을 제안한다. 주요 실증 결과는 두 가지다. 첫째, $\tau = 0.95$ 부터 0.84까지 카드 수는 1,660에서 1,607로 3.2%만 감소하며 실질적 감축은 $\tau < 0.82$ 에서 시작한다. 둘째, 중심 연결(centroid)과 단일 연결(single)은 $\tau = 0.70$ 에서 각각 최대 군집 1,191장과 1,514장으로 붕괴하므로, 목표 해상도에서 사용 가능한 연결 규칙은 완전 연결(complete)뿐이다. 본 보고서는 설계와 실증까지만 다루며, 임베딩 재생성 이후의 실제 세트 생성은 수행하지 않았다.

1 목적과 범위

1.1 요구사항

세 개의 릴리스 세트를 만든다.

- **Master** — 현행 세트. 적용된 임계값을 기록한다.
- **C80** — $\tau = 0.80$ 수준으로 압축한 세트.
- **C70** — $\tau = 0.70$ 수준으로 압축한 세트.

핵심 요구는 세 세트가 각각 완결된 카드 집합이라는 점이다. 즉 C70은 “1,652장을 847개 군집으로 묶어 본 뷰”가 아니라, 847장의 카드가 각자 고유 ID, 명칭, 정의, 참고문헌, 부모 L3를 갖는 릴리스여야 한다. 카드 수 자체의 감축이 목적이다.

1.2 본 보고서가 다루지 않는 것

임베딩 재생성, 클러스터링 실행, 병합 카드 명명, 세트 산출물 생성은 수행하지 않았다. 본 보고서의 모든 수치는 v2.18.0-rc 기준 기존 정보 임베딩에서 산출한 것이며, 제9절에서 그 한계를 명시한다.

2 Master 세트의 확정

2.1 구성

v2.18.0-rc 릴리스는 총 1,711장(활성 1,660, 은퇴 51)으로 구성된다. 여기에 v2.19 통합 라운드의 두 가지 확정 사항을 적용하여 Master를 정의한다.

1. **승인 병합 8건**. 2인 검수 합의(two_reviewer_consensus_20260806)로 확정된 8건의 병합. 원 카드 16장을 은퇴시키고 신규 ID RAI4-1727-1734를 부여한다.

2. **라벨 교정 204장.** 도메인 용어 오역 및 기계번역 직역 170장(한글 라벨), 서술문형 라벨의 명사구 재작명 34장(한/영 라벨).

결과는 **활성 1,652장**, 은퇴 누적 67장이다. 사용 중인 L3 노드는 56개로 변동이 없다.

2.2 실효 임계값 τ_{eff}

Master에 명시적으로 적용된 임계값은 병합 판정에 사용한 운용값 $\tau_{\text{gov}} = 0.88$ 이다. 그러나 이 값은 심의 대상을 고르는 기준이었을 뿐, 세트의 실제 해상도를 규정하지 않는다. 세트의 해상도를 규정하는 값은 다음과 같이 정의한다.

$$\tau_{\text{eff}} = \max_{i \neq j} \cos(\mathbf{e}_i, \mathbf{e}_j) + \epsilon, \quad (1)$$

즉 이 값 이상에서는 어떤 두 카드도 병합되지 않는 최소 임계값이다. 실측 결과 활성 카드 쌍의 최대 코사인 유사도는 0.9437이며, 따라서 $\tau_{\text{eff}} = 0.945$ 이다.

주목할 점은 이 최댓값을 만드는 쌍이 RAI4-0659-RAI4-0892라는 사실이다. 이 쌍은 전문가 심의에서 병합 금지로 판정된 임베딩 위양성 쌍이다. 즉 임베딩 공간에서 가장 가까운 두 카드가 의미적으로는 합쳐서는 안 되는 쌍이며, 이는 임계값 단독 판정의 한계를 보여주는 직접 증거다.

유사도 분포의 상위 꼬리는 다음과 같다. $\cos \geq 0.88$ 인 쌍 12개, $\cos \geq 0.84$ 인 쌍 62개, $\cos \geq 0.80$ 인 쌍 342개다. 전체 쌍 수가 약 137만 개임을 고려하면 상위 꼬리는 매우 얇다.

3 통합 절차의 형식화

3.1 반복 병합 루프

통합은 응집형 계층 병합(agglomerative merging)으로 수행한다. 절차는 다음과 같다.

Procedure IterativeMerge($\{\mathbf{e}_i\}, \tau$)

1. 각 카드를 크기 1의 단위 $\mathcal{L}_i \leftarrow \{r_i\}$ 로 초기화한다.
2. 살아있는 모든 단위 쌍 $(\mathcal{L}_a, \mathcal{L}_b)$ 에 대해 단위 간 유사도 $\sigma(\mathcal{L}_a, \mathcal{L}_b)$ 를 계산한다.
3. σ 가 최대인 쌍을 선택한다. 그 값이 τ 미만이면 종료한다.
4. 선택된 쌍을 하나의 단위로 통합하고, 통합체를 포함하여 2단계로 돌아간다.

이 루프는 매 단계에서 가장 유사한 쌍을 통합하고 통합체를 포함해 재계산한다. 덴드로그램은 이 반복 과정 전체를 기록한 트리이며, τ 로 절단한다는 것은 유사도가 τ 아래로 떨어지는 시점에서 루프를 정지시키는 것과 동치이다.

3.2 연결 규칙 σ 의 선택

절차의 유일한 자유도는 통합체의 유사도를 어떻게 정의하는가, 즉 σ 의 선택이다. 네 가지 후보가 있다.

규칙	$\sigma(\mathcal{L}_a, \mathcal{L}_b)$	성격
Complete	$\min_{i \in \mathcal{L}_a, j \in \mathcal{L}_b} \cos(\mathbf{e}_i, \mathbf{e}_j)$	군집 내 모든 쌍이 τ 이상임을 보장
Average	$\frac{1}{ \mathcal{L}_a \mathcal{L}_b } \sum_{i,j} \cos(\mathbf{e}_i, \mathbf{e}_j)$	평균적 응집
Centroid	$\cos(\mathbf{e}_a, \mathbf{e}_b)$	통합체를 평균 벡터 한 점으로 재표현
Single	$\max_{i \in \mathcal{L}_a, j \in \mathcal{L}_b} \cos(\mathbf{e}_i, \mathbf{e}_j)$	연쇄 병합

Table 1: 연결 규칙 후보. Centroid는 “통합된 것을 포함해 전체 유사도를 재계산”이라는 직관적 서술에 가장 가깝다.

다섯 번째 대안으로 **재임베딩 방식**이 있다. 통합 단위마다 새 명칭과 정의를 실제로 작성하고 그 텍스트를 다시 임베딩하여 다음 라운드의 유사도를 계산하는 것이다. 의미론적으로는 가장 정확하지만, 매 병합 단계마다 명명이 필요하므로 수백 회 반복 시 비용이 지배적이다.

3.3 연결 규칙의 실증 비교

네 규칙을 동일 임베딩과 동일 τ 에서 실행한 결과는 표 2와 같다.

τ	규칙	카드 수	다중 군집	최대 군집	평균 군집 크기	L3 교차
0.80	complete	1,458	188	4	2.07	100
0.80	average	1,445	184	5	2.17	102
0.80	centroid	1,383	161	12	2.72	97
0.80	single	1,360	150	44	3.00	93
0.70	complete	844	510	8	2.60	341
0.70	average	702	384	21	3.49	270
0.70	centroid	354	77	1,191	17.96	49
0.70	single	128	18	1,514	86.11	13

Table 2: 연결 규칙별 실측(활성 1,660장, BGE-M3 정본 임베딩). $\tau = 0.70$ 에서 centroid와 single은 붕괴한다.

결과는 명확하다. $\tau = 0.80$ 에서는 네 규칙이 대체로 비슷한 규모를 산출하지만, $\tau = 0.70$ 에서 centroid는 최대 군집이 1,191장, single은 1,514장으로 붕괴한다. 전체 카드의 70~91%가 단 하나의 단위로 합쳐지는 것이다. 이는 평균 벡터가 병합될수록 공간의 중심으로 이동하여 남은 모든 단위와 가까워지는 중심 이동(centroid drift) 현상이다.

따라서 **목표 해상도에서 사용 가능한 연결 규칙은 complete뿐이다**. Average는 $\tau = 0.70$ 에서 최대 군집 21장으로 붕괴하지는 않으나, 21장을 포괄하는 단일 카드 명칭을 작성하는 것은 현실적으로 불가능하다.

4 τ 스윙 실측

$\tau \in [0.60, 0.99]$ 구간을 0.01 간격으로 complete linkage로 스윙한 결과를 표 3과 그림 1에 제시한다.

τ	카드 수	감축	감축률	다중 군집	단일 카드	L3 교차	L1 교차
0.945	1,660	0	0.0%	0	1,660	0	0
0.90	1,653	7	0.4%	7	1,646	3	1
0.88	1,648	12	0.7%	12	1,636	5	1
0.84	1,607	53	3.2%	53	1,554	27	2
0.82	1,545	115	6.9%	109	1,436	54	11
0.80	1,458	202	12.2%	188	1,270	100	25
0.76	1,233	427	25.7%	346	887	205	64
0.73	1,036	624	37.6%	458	578	283	95
0.70	844	816	49.2%	510	334	341	115
0.65	567	1,093	65.8%	453	114	351	134
0.60	370	1,290	77.7%	342	28	297	143

Table 3: τ 스윙 (complete linkage, 제약 없음). “L3 교차”는 구성원이 둘 이상의 L3에 걸친 군집 수, “L1 교차”는 최상위 분기에 걸친 군집 수.

곡선의 형태에서 세 가지가 관찰된다.

첫째, $\tau = 0.945$ 에서 0.84까지 구간은 **사실상 평평하다**. 감축은 53장(3.2%)에 불과하다. 이는 임베딩 공간에서 진짜 근접 쌍이 극히 희소함을 뜻하며, τ_{eff} 부근에서의 병합이 곧 “실질 중복 제거”임을 시사한다.

둘째, **실질 감축은 $\tau < 0.82$ 에서 시작한다**. 0.82에서 6.9%, 0.80에서 12.2%, 0.76에서 25.7%로 가속한다.

셋째, $\tau = 0.80$ 세트는 **Master와 88% 동일하다**. 1,458장 중 1,270장이 병합되지 않은 원 카드이며, 신규 생성되는 통합 카드는 188장뿐이다. 세 세트를 뚜렷이 구분되는 해상도로 제시하려는 목적에 비추어 보면, C80은 Master의 변형에 가깝다는 지적이 가능하다.




Figure 1: (a) τ 에 따른 카드 수 곡선과 안전 운용대. (b) 연결 규칙별 민감도. centroid는 $\tau < 0.75$ 에서 급격히 붕괴한다.

5 cannot-link 제약

5.1 문제

전문가 심의에서 병합 금지로 확정된 4쌍이 있다.

RAI4-0228-0229 RAI4-0659-0892 RAI4-0863-0870 RAI4-0682-0691

이들의 코사인 유사도는 각각 0.944, 0.905, 0.883 수준으로 임베딩 위양성이다. 제약 없이 $\tau \leq 0.88$ 로 절단하면 **4쌍 전부가 병합된다**. 즉 목표 해상도 $\tau = 0.80$ 과 0.70 에서는 전문가가 명시적으로 부정한 병합이 자동으로 발생한다.

5.2 해결

제약 클러스터링으로 강제한다. 병합 금지 쌍 (i, j) 의 거리를 $d_{ij} \leftarrow \infty$ 로 설정한 뒤 complete linkage를 수행하면, complete의 정의상 두 카드를 포함하는 어떤 두 단위도 거리 ∞ 를 가지므로 결코 병합되지 않는다. 이 성질은 complete linkage에만 성립한다.

제약 적용 시 카드 수 변화는 미미하다. $\tau = 0.80$ 에서 $1,458 \rightarrow 1,462$, $\tau = 0.70$ 에서 $844 \rightarrow 847$ 이며, 위반 건수는 모두 0이 된다. 반면 centroid와 single에 동일한 제약을 적용하면 위반이 각각 1건, 3건 잔존하는데, 평균 벡터나 최댓값 연결에서는 ∞ 거리가 전파되지 않기 때문이다. 이는 complete linkage를 선택해야 할 두 번째 독립적 근거다.

6 명명가능성 검정

6.1 동기

선행 분석에서 golden set(승인 병합 8쌍을 양성, 병합 금지 4쌍을 음성으로 사용)에 대한 τ 별 precision/recall 분석 결과, 과소병합 임계선은 $\tau > 0.84$, 과대병합 임계선은 $\tau < 0.94$ 였다. 즉 안전 운용대는 $0.84 \leq \tau < 0.94$ 이다.

목표 해상도 $\tau = 0.80$ 과 0.70 은 **이 구간 밖, 즉 과대병합 구간에 있다**. 따라서 τ 로 절단한 결과를 그대로 카드로 승격하는 것은 데이터가 지지하지 않는다.

6.2 제안

임계값 대신 인간 판정을 게이트로 사용한다. 각 통합 단위에 대해 검수자가 다음을 시도한다.

구성원 전부를 포괄하는 진짜 상위어를, 명사구로, 영문 12단어 이내로 작성할 수 있는가?

작성 가능하면 병합을 승인하고 그 명칭을 신규 카드에 부여한다. 작성이 불가능하거나 결과가 나열식이 되면(예: “프롬프트 주입 및 데이터 오염 및 모델 추출”) 병합을 기각하고 해당 단위는 분리 상태로 유지한다.

이 검정은 두 가지 기능을 한다. 첫째, 통합 카드의 명칭을 생산한다. 둘째, 명칭을 쓸 수 없다는 사실 자체가 그 군집이 의미적으로 하나가 아니라는 증거이므로 과대병합 필터로 작동한다. 명명 산출물과 병합 판정이 동일한 행위에서 나오는 것이 이 설계의 요점이다.

명명 부담은 $\tau = 0.80$ 에서 188건, $\tau = 0.70$ 에서 510건이다. 선행 라운드에서 204장 라벨 교정을 11개 배치 병렬 검수로 처리한 전례가 있으므로 절차적으로는 가능하나, C70은 규모가 2.5배이며 군집당 구성원 수도 평균 2.6장으로 늘어난다.

7 병합 카드의 속성 집계

통합 단위 $\mathcal{L}$ 로부터 신규 카드를 생성할 때의 규칙을 사전 확정한다.

속성	규칙
l4_id	신규 연번 부여(현행 최대 RAI4-1734 이후)
label_ko/en	명명가능성 검정에서 확정된 상위어
definition_ko/en	상위 개념 정의 + 구성원 사례 열거
severity_1to5	$\max_{i \in \mathcal{L}} s_i$ (보수적)
probability_0to1	$\max_{i \in \mathcal{L}} p_i$ (합집합 사건의 하한)
references	구성원 참고문헌의 합집합(중복 제거)
three_h_one_r	구성원 라벨의 합집합
primary_l3_id	동일 L3면 승계, 교차 시 심의(제9절)
merged_source_l4_ids	구성원 원 ID 전체(계보)

Table 4: 병합 카드 속성 집계 규칙.

probability에 최댓값을 쓰는 근거는 병합 카드가 구성원 사건의 합집합을 표상하므로 $P(\bigcup_i A_i) \geq \max_i P(A_i)$ 이기 때문이다. 이는 하한이며 참값은 아니다.

8 중첩 구조와 ID 매핑

세 세트를 각각 독립적으로 클러스터링하면 상호 계보가 성립하지 않는다. 대신 동일한 덴드로그램을 서로 다른 지점에서 절단한다. Complete linkage의 단조성에 의해 τ 가 낮아질수록 군집은 병합만 되고 분할되지 않으므로 다음이 성립한다.

$$\text{Master} \supseteq \text{C80} \supseteq \text{C70} \quad (2)$$

즉 모든 C70 카드는 C80 카드들의 합집합이고, 모든 C80 카드는 Master 카드들의 합집합이다. 이로써 세트 간 ID 매핑이 트리로 떨어지며, 외부 인용이 어느 해상도를 참조하든 다른 해상도로 결정론적으로 변환된다.

단, 명명가능성 검정에서 일부 병합이 기각되면 이 성질이 깨질 수 있다. C70에서 승인된 병합의 부분집합이 C80에서 기각되는 경우가 그것이다. 이를 방지하려면 검정을 C80에서 먼저 수행하고, C70은 승인된 C80 카드를 단위로 삼아 진행해야 한다. 즉 절단은 한 번에 하되 검정은 해상도 순으로 누적해야 한다.

9 한계와 미해결 쟁점

9.1 임베딩 미갱신

본 보고서의 모든 수치는 v2.18.0-rc 기준 임베딩에서 산출했다. Master 확정 과정에서 204장(12.3%)의 라벨이 교정되었고, 라벨은 임베딩 텍스트(label_en. definition_en / label_ko. definition_ko)에

포함된다. 따라서 재생성 후 군집 구성과 카드 수는 변동한다. 보고된 1,458과 844는 확정치가 아니라 규모 추정치다.

9.2 목표 해상도가 안전 운용대 밖

$\tau = 0.80$ 과 0.70 은 golden set 기반 안전 운용대 $[0.84, 0.94]$ 밖이다. 명명가능성 검정을 게이트로 도입하는 것이 본 보고서의 대응이나, 이는 통계적 보증이 아니라 절차적 보증이다.

9.3 golden set의 표본 크기

안전 운용대는 양성 8쌍, 음성 4쌍, 총 12쌍에서 추정되었다. 임계선 0.84 와 0.94 는 각각 단일 쌍(코사인 0.844 의 도구오용 쌍, 0.944 의 폭력/비폭력 범죄 쌍)에 의해 결정되므로, 표본 하나가 임계선 전체를 좌우한다. 신뢰구간을 제시할 수 없다.

9.4 L3 교차 병합

$\tau = 0.80$ 에서 100건, $\tau = 0.70$ 에서 341건의 군집이 둘 이상의 L3에 걸친다. C70의 경우 다중 군집 510개 중 341개(67%)가 교차 병합이다. 이들 카드의 부모 L3를 결정하는 것은 사실상 L3 체계 재설계에 해당하며, 본 보고서는 절차를 제시하지 않았다. L1 교차도 $\tau = 0.70$ 에서 115건 발생한다.

9.5 세 세트의 사용자 측 의미

동일 리스크가 세 세트에서 서로 다른 ID와 명칭으로 존재하게 된다. 외부 인용, 규제 매핑, 기존 논문 참조가 어느 세트를 정본으로 삼는지 명시하지 않으면 혼란이 발생한다. 릴리스 정책 차원의 결정이 필요하다.

9.6 재임베딩 방식 미검증

제3.2절의 다섯 번째 대안인 재임베딩 방식은 의미론적으로 가장 타당하나 본 보고서에서 실행하지 않았다. Complete linkage 결과와의 차이가 얼마인지 알 수 없다.

10 실행 계획

1. Master 1,652장 기준 정본 임베딩 재생성(BGE-M3, max_seq_length=256, L2 정규화).
2. cannot-link 제약을 적용한 complete linkage 덴드로그램 1회 생성.
3. $\tau = 0.80$ 절단 → C80 후보 군집 → 명명가능성 검정 → C80 확정.
4. C80 카드를 단위로 $\tau = 0.70$ 절단 → C70 후보 군집 → 검정 → C70 확정.
5. 세 세트의 cards.json, hierarchy.json, ID 매핑, manifest 생성.
6. 검증: cannot-link 위반 0건, 중첩 구조 무결성, ID 매핑 왕복 무손실, 카드 수 일치, L3 배정 근거 기록 완전성.

11 결론

Master 세트는 1,652장, $\tau_{\text{eff}} = 0.945$ 로 확정된다. C80과 C70의 생성 절차는 cannot-link 제약을 적용한 complete linkage 반복 병합과 명명가능성 검정의 결합으로 설계되었다. 연결 규칙 선택에 대해서는 실증적 결론이 명확하다—centroid와 single은 목표 해상도에서 붕괴하며, cannot-link 제약을 보존하지 못하므로 complete linkage가 유일한 선택지다. 반면 목표 해상도 자체가 통계적 안전 운용대 밖이라는 점은 해소되지 않았으며, 명명가능성 검정이라는 절차적 장치에 의존한다. 이 의존이 수용 가능한지가 본 설계의 핵심 판단 지점이다.