

RAI Risk Taxonomy

Technical Report 2.0

1,726개 글로벌 L4의 단계적 분류, 보류 정책 및 통계 검증

2026년 7월 21일

최종 정책 결과. 전체 1,726개 중 1,671개(96.8134%)를 승인 대기 상태로 50개 L3에 배치하고, 가장 불확실한 55개(3.1866%)는 분류체계 밖의 RAI-HOLD 검토 버킷으로 분리했다. 이 자동 배치는 사람 승인 정답이 아니다.

1 기술 요약

본 보고서는 Physical AI의 기존 182개 분류를 정답 잠금 집합으로 유지하면서, 글로벌 L4 1,726개를 신규 50개 L3에 연결한 단계적 절차를 기술한다. 기존 글로벌 L1-L3는 예측 특징으로 사용하지 않았고 영구 L4 ID와 교차매핑을 보존했다.

Stage 1은 엄격한 rule-semantic-anchor 합의와 두 전문 에이전트의 exact-L3 합의를 요구해 Physical 182개와 신규 제안 37개만 배치했다. Stage 2는 hierarchy-blind top-1 후보를 적극 수용해 1,553개(89.9768%)를 배치하고 173개를 보류했다. Stage 3 실험은 173개를 모두 강제 배치했으나, 정책 검토 결과 이 중 hard hold 55개를 다시 분리했다. 최종 정책 뷰는 1,671개 분류와 55개 검토 보류로 구성된다.




Figure 1: 단계별 L3 배치와 보류. 분모는 각 단계에서 동일한 1,726개다.

Stage 3의 100%는 운영상 경로 완전성을 시험한 결과이고, 최종 정책의 96.8134%는 명백한 경계 충돌을 별도 검토하도록 선택한 결과다. 두 수치를 정확도 또는 승인률로 해석해서는 안 된다.

2 범위, 데이터와 식별 원칙

분석 단위는 영구 ID RAI4-0001-RAI4-1726의 L4 카드다. Physical AI 사이트의 182개 분류는 잠금 정답이고, 동일 이름이 여러 경로에 존재할 수 있으므로 라벨을 키로 사용하지 않는다. 상위 분류체계는

L0 1개, L1 3개, L2 6개, L3 50개로 구성된다. RAI-HOLD는 운영 버킷이며 L3 노드가 아니다.

최종 정책 상태	건수	전체 비율
Physical 정답 잠금	182	10.5446%
Stage 1 전문가 합의 제안	37	2.1437%
Stage 2 알고리즘 제안	1,334	77.2885%
Stage 3 잔여 강제 후보 유지	118	6.8366%
Taxonomy Decision Hold	55	3.1866%
합계	1,726	100.0000%

Table 1: 최종 정책 뷰의 상태 구성.

3 단계별 분류 절차와 기준

3.1 Stage 1: 정확 적합성 우선

비-Physical 입력에는 계층 재진술을 제거한 L4 라벨, 직접 메커니즘 정의와 evidence title만 사용했다. 자동 후보는 단일 rule eligibility, rule/semantic/composite top-1 일치, semantic score ≥ 0.55 , composite score ≥ 0.54 , 두 margin ≥ 0.035 , anchor 2/3 이상 합의를 모두 만족해야 했다. gap sentinel과 다중 메커니즘을 배제하고 두 전문 에이전트가 동일한 exact L3를 승인한 37개만 제안했다.

3.2 Stage 2: 약 90% 커버리지

Stage 2는 보호 집합 219개를 변경하지 않고 다음 순위 점수를 사용했다.

$$S_2 = 0.55q_{sem} + 0.20q_{sm} + 0.10q_{cm} + 0.10q_{vote} + 0.05q_{rule} - p_{gap}.$$

여기서 의미 점수와 두 margin은 사전 고정 구간으로 0-1 정규화했고, anchor vote는 3으로 나눴으며, rule support는 이진값, gap penalty는 0.05다. hard hold 55개를 먼저 보존하고 S_2 하위 118개를 추가 보류해 총 173개(10.0232%)를 남겼다. 나머지 1,334개는 hierarchy-blind top-1 L3에 배치했다.

3.3 Stage 3와 최종 보류 정책

Stage 3 실험은 잔여 173개를 기존 top-1에 강제 연결해 100% 경로를 시험했다. 그러나 다음 다섯 hard-hold 사유의 55개는 자동 배치의 의미적 또는 정책적 위험이 크므로 최종 정책 뷰에서 policy_l3_id=null로 되돌리고 RAI-HOLD로 분리했다. 나머지 quota hold 118개는 강제 후보 상태와 사람 검토 의무를 유지한다.




Figure 2: Stage 2 보류 173개의 사유. 금색 55개는 최종 RAI-HOLD, 파란색 118개는 Stage 3 강제 후보 유지 대상이다.

Physical 범위 검토 23개는 Physical AI로 확정된 카드가 아니다. robot, drone, autonomous vehicle, embodied AI, cyber-physical, physical actuator 등의 표현이 탐지됐지만 잠긴 Physical 정답 182개와 동일하지 않아 경계 검토가 필요한 카드다.

4 최종 분포 통계

4.1 L1과 L2 분포

보류 55개를 제외한 1,671개 중 일반 AI는 1,140개, 에이전틱 AI는 349개, 피지컬 AI는 182개다. 분류된 카드 내 비율은 각각 68.2226%, 20.8857%, 10.8917%다. 전체 1,726개의 나머지 3.1866%는 보류다.




Figure 3: 최종 정책 뷰의 L1 분포. 분모는 L3 배치가 있는 1,671개다.

L2 ID	L2 이름	카드 수	분류 1,671개 내 비율
RAI2-G-INT	General Interaction	708	42.3698%
RAI2-G-SYS	General System	432	25.8528%
RAI2-A-SYS	Agentic System	349	20.8857%
RAI2-P-SYS	Physical System Safety	91	5.4458%
RAI2-P-INT	Physical Interaction Safety	62	3.7104%
RAI2-P-SOC	Physical Societal Safety	29	1.7355%

4.2 L3 집중도

50개 L3 모두 최소 한 카드를 포함한다. 가장 큰 L3는 Anthropomorphism 242개로 분류된 1,671개의 14.4823%다. 상위 5개는 700개(41.8911%)이며 단일 L3가 20%를 넘지 않는다. 이 집중도는 분포 진단일 뿐 의미 타당성 검증은 아니다.




Figure 4: 최종 정책 뷰의 상위 14개 L3. 정확한 조회를 위한 전체 50개 분포는 CSV 산출물에 제공한다.

5 보류 55개와 불확실성

보류 사유	건수	보류 내 비율	전체 비율
PHYSICAL_OUTSIDE_LOCK	23	41.8182%	1.3326%
FRONTIER_EXPERT_REJECTED	17	30.9091%	0.9849%
FRONTIER_EXPERT_DISAGREEMENT	7	12.7273%	0.4056%
MULTI_MECHANISM	6	10.9091%	0.3476%
LOW_ABSOLUTE_FIT	2	3.6364%	0.1159%
합계	55	100.0000%	3.1866%

보류는 승인되지 않은 51번째 L3로 취급하지 않는다. 웹 UI와 export에서는 별도 검토 큐로 표시하고, 원래 보류 사유, Stage 3 강제 후보 L3, semantic/composite 점수, anchor vote를 숨기지 않아야 한다. 전문가 거절과 불일치 24개는 L3 정의의 적합성 검토, 다중 메커니즘 6개는 primary/secondary 또는 복수 태그 구조 검토, Physical 경계 23개는 기존 182개 정답 집합과의 의미·근거 기반 비교가 필요하다.

6 검증, 제한과 강건성 점검

Physical 182개와 Stage 1 합의 37개는 후속 단계에서 변경되지 않았다. Stage 2와 Stage 3 생성기는 동일 입력에서 byte-identical placement hash를 재생성했다. Stage 2 validator는 13 PASS/0 FAIL/3

WARN, Stage 3 validator는 14 PASS/0 FAIL/4 WARN이었다. 최종 보류 정책 전용 테스트를 포함한 전체 회귀 테스트 16개가 통과했다.

주요 제한은 다음과 같다.

- Stage 2 신규 1,334개 중 1,214개는 rule eligibility 없이 의미 top-1 중심으로 배치됐다.
- Stage 2 신규 247개는 taxonomy-gap sentinel을 override했다.
- Stage 3에 남긴 118개도 calibrated probability나 사람 승인 결과가 아니다.
- Physical 경계 탐지는 제한된 키워드 sentinel이므로 오탐과 미탐 가능성이 있다.
- 50개 L3의 사용률 100%와 카드 커버리지 96.8134%는 분류체계의 충분성을 입증하지 않는다.

7 권고 검토 순서와 후속 질문

1. RAI-HOLD 55개를 전수 검토한다. Physical 경계 23개와 전문가 거절/불일치 24개를 우선한다.
2. Stage 3 quota 강제 후보 118개를 S_2 오름차순으로 검토한다.
3. taxonomy-gap override 247개와 rule-free 배치 1,214개를 L3별 층화 표본으로 검증한다.
4. 검토 결과를 근거로 L3 정의 확장, 신규 L3, 복수 태그 구조 중 필요한 변경을 승인한다.
5. 승인된 변경만 successor release와 홈페이지에 반영하고 기존 decision ID 이력을 보존한다.

추가로 결정해야 할 질문은 (1) Physical 경계 23개 중 기존 Physical L3로 편입할 카드 수, (2) 다중 메커니즘 카드에 secondary L3를 허용할지, (3) Stage 3 강제 후보 118개의 허용 가능한 사람 검토 오류율, (4) 신규 L3 제안의 최소 증거 기준이다.

재현 가능한 산출물

- data/experiments/stage2-v1/stage2_placements.json
- data/experiments/stage2-v1/stage2_hold_queue.json
- data/experiments/stage3-v1/stage3_placements.json
- data/experiments/stage3-review-hold-v1/placements.json
- data/experiments/stage3-review-hold-v1/review_hold.json
- reports/statistics/stage2_unclassified_statistics.json
- reports/statistics/stage3_statistics.json
- scripts/build_stage2_classification.py
- scripts/build_stage3_forced_matching.py
- scripts/build_stage3_review_hold.py

보고서 식별자: RAI Risk Taxonomy Technical Report 2.0

정책 데이터 뷰: stage3-review-hold-v1

작성일: 2026-07-21