

RAI Risk Taxonomy v1.0.0

1,726 개 L4 데이터 생성 및 검증

Physical AI 182 개 잠금, open-set 재분류, 전문가 합의 및 커버리지 시험

릴리스 상태	prepublication_draft; provisional=true
전체 L4	1,726 개; 영구 ID RAI4-0001-RAI4-1726
상위 구조	L0 1 개, L1 3 개, L2 6 개, L3 50 개
Physical 정답 잠금	182 개; 직접 ID 169 개 + 명시적 alias 13 개
비-Physical 결과	최종 자동 제안 37 개; 분류 체계 결정 정보류 1,507 개
50 개 L3 충분성	NOT_DEMONSTRATED
자동 검증	PASS_WITH_WARNINGS; 실패 0 건
공개 상태	로컬 생성과 검증까지 완료; GitHub push 및 사이트 공개는 수행하지 않음
작성 기준일	2026 년 7 월 21 일 (Asia/Seoul)

DATA PACKAGE READY BEFORE GITHUB PUSH

본 문서는 생성 결과를 기록한다. 비-Physical 자동 제안은 아직 사람 승인 정답이 아니다.

요약결론

최종결과

글로벌 L4 1,726 개를 신규불변 ID registry 로 생성했고, Physical AI 182 개는 기존 24 개 L3 배치를 그대로 잡았다. 나머지 1,544 개에 대해 기존 글로벌 L1-L3 를 입력특징에서 제거한 open-set 시험을 수행했다. 엄격한 알고리즘 문턱을 통과한 61 개 중 두 독립 전문가 에이전트가 동일한 제안 L3 를 모두 승인한 것은 37 개뿐이었다. 따라서 1,507 개는 `needs_taxonomy_decision` 과 `primary_l3_id=null` 로 남겼다.

이번 시험은 50 개 L3 가 1,726 개 위험 전체를 충분히 수용한다는 가설을 **입증하지 못했다**. 비-Physical 잠정 제안률은 2.4% 이고 보류율은 97.6% 이다. 이는 실패한 강제 분류가 아니라, 현 L3 정의의 경계 밖에 있는 위험을 공개적으로 보존한 결과다. 특히 거버넌스·감사·규제, 투명성·설명가능성, 정렬·통제·강건성, 의존·조작, 일반 AI 보안과 같은 반복적 공백 후보가 확인되었다. 기존 50 개 L3 의 정의 확장 또는 신규 L3 추가는 본 보고서와 보류류를 사람이 검토한 뒤 승인해야 한다.

해석제한

37 개의 상태는 `algorithm_proposed` 이며 `human_approved` 가 아니다. 두 리뷰어는 독립 전문 AI 에이전트이고, 소형 로컬 모델 2 종은 민감도 감사에만 사용되었다. 사람 골드셋 검증과 오분류 비용 기반 임계값 보정 전에는 어떤 수치도 정확도 또는 확률로 해석할 수 없다.

Contents

요약결론	1
1 범위와 준수 원칙	3
1.1 이번 작업의 경계	3
1.2 비가역 원칙의 구현	3
2 입력 동결과 출처 추적	3
2.1 동결 입력	3
2.2 Physical 182 대응	4
3 ID 및 데이터 아키텍처	4
3.1 계층 ID	4
3.2 정규화된 데이터 계약	4
4 비-Physical open-set 분류 절차	5
4.1 입력 차단과 코드북	5
4.2 BGE-M3 의미 점수와 규칙 게이트	5
4.3 독립 검토와 합의	5
4.4 모델 revision 재현성 교정	5
5 생성 결과와 50 개 L3 커버리지 시험	5
5.1 최종 상태 수량	5
5.2 보류 사유	6

5.3	반복공백후보	6
5.4	보류카드군집진단	7
6	품질검증결과	9
6.1	자동검증과 fresh smoke	9
6.2	독립아키텍처감사와보강	9
6.3	검증이보장하는것과보장하지않는것	9
7	사이트준비, 버전과재매핑	9
7.1	사이트용데이터	9
7.2	릴리스와재매핑규칙	9
8	사람승인전권고작업	10
A	50 개 L3 별현재카드분포	10
B	Physical 명시적 alias 13 개	13
C	최종자동제안 37 개	13
D	자동검증체크리스트	14
E	재현및핵심산출물	16

1 범위와준수원칙

1.1 이번작업의경계

신규독립저장소 RAI-Risk-Taxonomy 에데이터 registry, placement, crosswalk, 검증보고서, 사이트용파생본들을생성했다. 기존 AI_Topic_Space.github.io 및 Physical-AI-Risk-Taxonomy 저장소는읽기전용출처로취급했으며변경하지않았다. GitHub remote 설정, push, Pages 배포도수행하지않았다.

1.2 비가역원칙의구현

원칙	구현결과
기존글로벌계층은참고만사용	비-Physical 예측입력에서글로벌 L0-L3, source family, source ID prefix 를제외했다. 기존계층은배치후전환감사 CSV 에서만 reference_only 로보존했다.
Physical 분류는정답집합	모델호출전에 182 개를 locked_physical 로고정하고, 모든 24 개 Physical L3 의카드수와경로를원본과비교했다.
라벨은 ID 가아님	모든결합은 source namespace 와 source ID 의복합키또는승인 alias 로수행했다. 라벨 fuzzy match 는운영 crosswalk 에사용하지않았다.
신규 ID 는간결하고추적가능	상위노드는 RAI3-G-INT-06 같은경로 ID, L4 는경로와독립적인 RAI4-#### 를사용한다. 사이트카드는 ID 와위험명을함께표시할수있다.
재매핑가능성보장	L4 registry 와 release 별 placement 를분리했다. 향후경로변경은 L4 ID 를바꾸지않고 append-only migration ledger 에남긴다.
역지배치금지	정확한적합성이입증되지않은 1,507 개는 L3 가 null 인결정규로보존했다.
사람승인게이트	L3 정의확장, 신규 L3, 자동제안승인, 재매핑은현재데이터에반영하지않고다음승인단계로남겼다.

2 입력동결과출처추적

2.1 동결입력

출처	행수	SHA-256 축약	원본 commit
global_1726	1,726	57d419a1a3aac23c...	26b23e38adec
physical_182	182	116973e340f96bcf...	348d9577212d
physical_l4_references	360	79a805b0c58a1b9c...	348d9577212d
l0_l3_definition_source	50	56076ebf7dacd297...	n/a
physical_taxonomy_migrations	2	10362bd0051c6683...	348d9577212d

Physical AI Technical Report 42 쪽도분류체계해석자료로확인했다 (SHA-256 ac1c1b1ab07b...). 데이터파이프라인의직접입력은위다섯동결스냅샷이며, 각각 data/source_snapshots/v1.0.0/에복제되어 manifest 와 checksum 으로그정된다. 전체 hash 는이전계획보고서와 manifest 에서확인할수있다.

2.2 Physical 182 대응

글로벌원본과 Physical 원본간직접 ID 일치는 169 개, 명시적 alias 는 13 개다. 이 13 개는라벨유사도추론이 아니라고정태이블이며, 결과적으로 182 개모두정확히한개의신규 RAI4 ID 와기존 Physical L3 에연결된다. Physical L2 분포는 System 91, Interaction 62, Societal 29 이며원본과동일하다. 원본 Physical 근거·정당화 360 행도카드별 reference 로보존했고, 3H/Role 문자열은원문과 axis/Primary-Secondary 구조를함께저장했다.

3 ID 및데이터아키텍처

3.1 계층 ID

- L0: RAI0
- L1: RAI1-G, RAI1-A, RAI1-P
- L2 예시: RAI2-G-INT, RAI2-A-SYS, RAI2-P-SOC
- L3 예시: RAI3-G-INT-06 (Privacy), RAI3-P-INT-05 (Misinformation)
- L4: RAI4-0001-RAI4-1726; 동결글로벌 source ID 의 ASCII 사전순으로최초할당하며재사용하지않음

L4 ID 에 L3 경로를넣지않은이유는재매핑이후에도 URL, 인용, crosswalk 가유지되어야하기때문이다. 화면에서는 [RAI4-0433] Biometric privacy intrusion 처럼연구 ID 와위험명을함께출력하고, 현재상위경로는별도필드로표시한다.

3.2 정규화된데이터계약

파일	역할
taxonomy_nodes.json	L0-L3 60 개노드, parent, 순번, 정의와상태
l4_registry.json	1,726 개연구카드신원, 라벨, 정의, 메타데이터; 현재 L3 를 포함하지않음
placements.json	릴리스별 L4-L3 관계또는명시적 abstention; 한 L4 당정확히한행
source_crosswalk.json	신규 RAI4 와출처 namespace/source ID 의관계; 총 1,908 행
physical_lock.json	182 개원본 Physical 경로와신규 L3 경로의잠금증거
placement_migrations.json	공개후재매핑이벤트용 append-only ledger; 기준릴리스에서는 0 행
algorithm_config.json	모델 revision, snapshot fingerprint, codebook hash, 입력차단, threshold 와 seed 의불변설정
manifest.json	출처해시, 모델 revision, seed, 수량, 산출물 checksum, 검증상태
requirements-lock.txt, environment.json	검증실행의정확한 package, Python, OS, 로컬모델식별자
public/data/releases/v1.0.0/	홈페이지가직접읽을카드, 계층, 검색인덱스번들

모든핵심객체에는 JSON Schema 계약을두었고 canonical JSON 에서 CSV 및 public 번들을파생했다. registry 와 placement 의분리는 schema 및테스트로강제된다.

4 비-Physical open-set 분류절차

4.1 입력차단과코드북

비-Physical 1,544 개만자동분류후보가되었다. 입력은 (1) L4 라벨, (2) 기존계층을재진술하는템플릿문장을제거한직접메커니즘정의, (3) evidence title 로제한했다. 50 개 L3 중 Physical 24 개는잠금전용이므로 비-Physical 후보코드북은 General 20 개와 Agentic 6 개, 총 26 개다.

각 L3 에는사용자제공한국어정의, 충실한영문번역, 세가지의미 anchor, 양성단서, hard exclusion, 최소 eligibility 규칙을기록했다. 또한현 26 개범주가포괄하지못할가능성이큰 10 개공백 sentinel 을별도로두었다.

4.2 BGE-M3 의미점수와규칙게이트

로컬고정모델 BAAI/bge-m3 revision 5617a9f61b028005a4858fdac845db406aefb181 을로드호출에직접지정하고, 정규화 1,024 차원임베딩을사용했다. 카드 c 와 L3 l 의의미점수는세 anchor cosine 의중양값으로 계산했다.

$$s(c, l) = \text{median}_{j \in \{1,2,3\}} (\cos(e(c), e(a_{l,j})))$$

최종순위점수는 $0.75s + 0.20r + 0.05q$ 이며, 여기서 r 은규칙단서점수, q 는 eligibility 다. 의미점수 0.55, 의미 margin 0.035, composite 0.54, 세 anchor 중 top-1 표 2 개이상을요구했다. hard exclusion 과 gap sentinel 이우선하며, Agentic 은자율목표·다단계행동·도구사용같은결정적단서와보조단서를함께요구했다. 이점수는 보정된확률이다.

4.3 독립검토와합의

첫게이트를통과한엄격후보는 61 개였다. 다음두층의검토를분리했다.

1. **민감도감사:** 로컬 gemma3:4b, qwen3:4b 가더넓은 plausible pool 499 개를각각계층비공개로검토했다. 동일비보류 L3 합의는 2 개뿐이고, 상이판정은 138 개였다. 따라서이모델들을승인 authority 로쓰지않았다.
2. **독립전문에이전트검토:** 두전문 AI 에이전트가 61 개전부를서로의판정, BGE 점수, 기존글로벌계층없이검토했다. 전문가 A 는 41 개, 전문가 B 는 40 개를승인했다. 정확한동일 L3 를둘다승인한 37 개만 최종 algorithm_proposed 가되었다. 17 개양측거절과 7 개 split decision 은모두보류로되돌렸다.

이이중합의는오류를줄이기위한보수적필터이지사람골드셋검증을대신하지않는다.

4.4 모델 revision 재현성교정

독립구조감사에서첫실행이 Hugging Face refs/main 모델을사용하면서도, 기록로직은캐시디렉터리이름을사전순으로골라다른 revision 을표기한문제가발견되었다. 로드코드에 5617a9f... 를직접전달하고전체 1,544 건을다시계산했다. 그결과 algorithm_scores.json SHA-256 cdebe7fe96edb9f... 와 61 개전문가검토패킷 SHA-256 44b7071741b992a4... 가교정전과바이트단위로동일했다. 따라서기존두전문가검토는그대로유효하며, 실제사용 revision 과기록이일치하도록교정되었다. snapshot 파일목록 fingerprint 와불변 algorithm_config.json hash 도 validator 가재계산한다.

5 생성결과와 50 개 L3 커버리지시험

5.1 최종상태수량

상태	카드수	의미
locked_physical	182	기존 Physical AI 정답을 그대로 보존
algorithm_proposed	37	두 독립 전문가의 전트가 정확한 L3 를 모두 승인; 잠정 상태
human_approved	0	향후 사람 검증 릴리스에 예약
needs_taxonomy_decision	1,507	강제 배치하지 않고 L3 를 null 로 보존
합계	1,726	모든 RAI4 ID 가 정확히 한 상태를 가짐

Physical 잠금과 잠정 자동 제안을 합친 apparent placement 는 219 개 (12.6883%) 다. 그러나 source gold 로 검증된 것은 Physical 182 개 (전체의 10.5446%) 뿐이고, 비-Physical 의 잠정 제안은 37 개 (2.4%) 다. 따라서 50 개 L3 충분성 상태는 NOT_DEMONSTRATED 이다.

커버리지 판정

50 개 L3 가 “충분하다”고 결론 내릴 수 없다. 1,507 개를 최근 접범주에 억지로 넣지 않았기 때문에 현재 데이터는 정의 확장 또는 신규 L3 검토를 위한 정직한 decision queue 를 제공한다. 다음 판정은 보류 원인, gap sentinel, 군집, 대표 카드와 사람 샘플 검증을 함께 보아야 한다.

5.2 보류 사유

사유	카드수	비-Physical 비율
NO_VALID_L3	1,043	67.6%
GAP_SENTINEL	306	19.8%
RULE_SEMANTIC_DISAGREEMENT	64	4.1%
LOW_MARGIN	38	2.5%
PHYSICAL_OUTSIDE_LOCK	23	1.5%
FRONTIER_EXPERT_REJECTED	17	1.1%
FRONTIER_EXPERT_DISAGREEMENT	7	0.5%
MULTI_MECHANISM	6	0.4%
LOW_ABSOLUTE_FIT	2	0.1%
ANCHOR_VIEW_DISAGREEMENT	1	0.1%

가장 큰 원인은 정의 상 유효한 L3 를 찾지 못한 NO_VALID_L3 와, 기존 26 개 비-Physical L3 보다 명시적 공백 후보가 더 적합한 GAP_SENTINEL 이다. 전문가 거절과 split decision 도 독립된 감사 사유로 보존했다.

5.3 반복 공백 후보

공백 sentinel	카드수
GOVERNANCE_AUDIT_REGULATION	88
TRANSPARENCY_EXPLAINABILITY	48
ROBUSTNESS_ALIGNMENT_CONTROL	45
DEPENDENCY_MANIPULATION	33
GENERAL_AI_SECURITY	32

공백 sentinel	카드수
LABOR_INEQUALITY_POWER	26
ENVIRONMENT_ENERGY_RESOURCES	23
PHYSICAL_OUTSIDE_LOCK	23
PLURALISTIC_VALUE_STAKEHOLDER	21
DELIBERATE_DISINFORMATION	19

이수치는신규 L3 의자동제안이아니다. 예를들어거버넌스·감사·규제 88 개와투명성·설명가능성 48 개가 반복된다는사실은“검토우선순위”를의미할뿐, 현단계에서새노드를생성할권한은부여하지않는다.

5.4 보류카드군집진단

1,507 개보류카드의발견지원을위해 BGE-M3 정규화임베딩 KMeans 20 개군집과단어/bi-gram TF-IDF KMeans 를비교했다. seed 1726, 1727, 1728 의 BGE bootstrap ARI 는 0.603859 와 0.497390, BGE-TFIDF ARI 는 0.094404 였다. 이는군집을분류정답이아니라사람이불탐색묵음으로만사용해야함을보여준다.

군집	수	대표카드	주요공백단서
UC-18	122	Risks from delegating decision-making power to misaligned AIs; Loss of human agency and autonomy; Risks from AIs developing goals and values that are different from humans	PHYSICAL_OUTSIDE_LOCK (7), GOVERNANCE_AUDIT_REGULATION (4)
UC-16	111	Fine-tuning related (degrading safety training due to benign fine-tuning); Technical vulnerabilities (the risk of misalignment); General evaluations (AI outputs for which evaluation is too difficult for humans)	ROBUSTNESS_ALIGNMENT_CONTROL (9), TRANSPARENCY_EXPLAINABILITY (6)
UC-13	102	Alignment risks; Inherent risk; Risks from leaking or correctly inferring sensitive information	ROBUSTNESS_ALIGNMENT_CONTROL (4), GENERAL_AI_SECURITY (2)
UC-01	100	Collectively inefficient equilibria among AI agents; Heterogeneous attacks; Undesirable capabilities	ROBUSTNESS_ALIGNMENT_CONTROL (8), GOVERNANCE_AUDIT_REGULATION (4)
UC-09	91	Assistant-mediated social influence; Overreliance on AI system undermining user autonomy; Manipulation and coercion	DEPENDENCY_MANIPULATION (20), TRANSPARENCY_EXPLAINABILITY (3)
UC-07	81	Loss of right to information; Reputational damage; Loss of freedom of speech/expression	ENVIRONMENT_ENERGY_RESOURCES (7), LABOR_INEQUALITY_POWER (3)
UC-19	78	Real-world risks (risks of misuse of dual-use items and technologies); Risks from models and algorithms (risks of robustness); AI system security vulnerability	GOVERNANCE_AUDIT_REGULATION (7), ROBUSTNESS_ALIGNMENT_CONTROL (5)
UC-08	77	Tool misuse / unsafe tool invocation; Agent tool misuse; Prompt injection attack	GENERAL_AI_SECURITY (14), ROBUSTNESS_ALIGNMENT_CONTROL (7)
UC-11	73	False or misleading information; AI-generated scams; AI-enabled cyberattacks	GOVERNANCE_AUDIT_REGULATION (6), DEPENDENCY_MANIPULATION (3)
UC-14	71	Job automation instead of augmentation; Labor displacement - economic impact; Impact on labor markets (rising inequalities)	LABOR_INEQUALITY_POWER (19), ENVIRONMENT_ENERGY_RESOURCES (14)
UC-10	68	Board oversight failure; Public-sector AI governance capacity gap; Algorithmic impact assessment failure	GOVERNANCE_AUDIT_REGULATION (13), TRANSPARENCY_EXPLAINABILITY (3)
UC-20	66	Bilingual cultural alignment failure; Moral framing bias; Ethical homogenization	GOVERNANCE_AUDIT_REGULATION (21), PLURALISTIC_VALUE_STAKEHOLDER (17)

6 품질검증결과

6.1 자동검증과 fresh smoke

출처해시, 행수, ID 연속성, parent-child 무결성, crosswalk, Physical 잠금, JSON Schema, 사이트파생변들, 전문가합의조건을포함해 69 개검사가통과했고실패는 0 건이다. 경고 2 건은의도적으로남은사람골드셋 부재와명시적보류카드존재다. 최종상태는 PASS_WITH_WARNINGS 다.

별도의단위 smoke 10 개도모두통과했다. 기존 grain·ID·open-set·전문가합의검사에더해모든 source ID 의 결정적 RAI4 대응, Physical 카드별전체사슬·근거·3H 보존, 고정 algorithm configuration, 사이트의 exact canonical join 을검사했다. 데이터품질노트북은 9 개셀중코드 6 개를위에서아래로실행했으며오류 0 건, display/image output 0 건이었다.

6.2 독립아키텍처감사와보강

읽기전용독립감사는현재데이터값의불일치는발견하지않았으나, revision 기록, 카드단위변조탐지, 공개릴리스뒀어쓰기, 후속 migration, checksum 범위와환경고정을공개전보강과제로지적했다. 이에 (1) 모델 revision 직접 pin 과 byte-identical 재실행, (2) source card-alias-RAI4-L3-placement 전수검사, (3) published 디렉터리 overwrite 차단, (4) successor release 생성기와 diff-migration 양방향검사, (5) source/schema/code/report 전체 checksum, (6) package/environment lock 을구현했다. 이보강후 validator 는 69 개 PASS, 0 개 FAIL, 2 개 WARN 으로안정화되었다.

6.3 검증이보장하는것과보장하지않는것

- **보장:** 1,726 개 registry 와 placement 의완전성, 1,908 개 crosswalk, 169+13 Physical 대응, 182 개잠금, 24 개 Physical L3 수량, 60 개상위노드, public bundle 정합성.
- **보장:** 모든최종자동제안이정확히두독립전문가승인기록을갖고, 기존글로벌계층이에측특징으로쓰이지않았다는데이터계약.
- **미보장:** 37 개자동제안의사람기준정확도, 임계값 calibration, 보류군집의의미적단일성, 50 개 L3 의충분성.

7 사이트준비, 버전과재매핑

7.1 사이트용데이터

public/data/releases/v1.0.0/에는카드 1,726 개, 계층노드 60 개, 검색인덱스 1,726 개가생성되었다. 각카드에는 RAI4 ID, 위험명, 현재상태, 현재 L3 또는 null, source crosswalk 가포함된다. 이를 Physical AI 사이트와유사한구조의신규 UI 가읽을수있으나, 본작업범위에서는 UI 배포와 GitHub Pages 공개를수행하지않았다.

7.2 릴리스와재매핑규칙

1. v1.0.0 은 prepublication_draft, provisional=true 다.
2. 사람검증전에는 algorithm_proposed 를 human_approved 로승격하지않는다.
3. 승인된재매핑은 RAI4 ID 를유지한채 placement 만바꾸고, 이전 L3, 새 L3, 사유, 증거, 승인자를 migration ledger 에 append 한다.
4. L3 정의의의미확장은 minor release, 식별의미가깨지는구조변화는 major release 로관리한다.
5. 공개된 ID 는삭제·재사용하지않고필요하면 deprecated 상태로남긴다.

`create_remap_release.py` 는 기존 릴리스 디렉터리를 수정하지 않고 더 높은 semantic version 의 새 디렉터리만 생성한다. 동일 target 이 있으면 중단하고, 표준 경로에서는 Physical 잠금변경을 거부한다. dry-run smoke 에서는 1 개 예시 결정을 입력해 human-approved 1 개, 보류 1,506 개, 쓰기 0 건의 preview 를 확인했다. 실제 승인 결정은 예시 fixture 와 분리되어 있으며 아직 적용하지 않았다.

8 사람승인전권고작업

1. 37 개 전수 검토와 보류 카드 층화 표본을 사용해 사람 골드셋을 만든다.
2. 우선 공백 후보 5 개 — 거버넌스·감사·규제, 투명성·설명가능성, 정렬·통제·강건성, 의존·조작, 일반 AI 보안 — 의 대표 카드와 기존 50 개 정의 경계를 비교한다.
3. 각 공백에 대해 (a) 기존 L3 정의 확장, (b) 새 L3 생성, (c) 현재 보류 유지 중 하나를 승인한다.
4. 승인 결과를 적용하기 전에 변경 영향표와 migration preview 를 생성한다.
5. 사람 승인 및 수정 후 검증 전체를 다시 실행하고, 그때 GitHub push 와 신규 사이트 공개를 진행한다.

현재중지점

로컬 데이터 패키지는 GitHub push 직전 상태로 준비되었다. 본 보고서는 50 개 L3 정의를 임의로 확장하거나 새 L3 를 추가하지 않았으며, 보류 1,507 개를 숨기지 않았다. 다음 비가역 단계는 사람의 taxonomy decision 과 공개 승인이다.

A 50 개 L3 별 현재 카드 분포

아래 수량은 Physical 잠금 182 개와 최종 자동 제안 37 개만 포함한다. 0 은 해당 L3 가 불필요하다는 뜻이 아니라 현재 엄격 기준에서 승인 가능한 카드가 없었다는 뜻이다.

L3 ID	L2	L3 명칭	카드수	상태
RAI3-G-INT-01	Interaction	Violence	0	Provisional
RAI3-G-INT-02	Interaction	Sexual	5	Provisional
RAI3-G-INT-03	Interaction	Self-harm	1	Provisional
RAI3-G-INT-04	Interaction	Hate and Unfairness	2	Provisional
RAI3-G-INT-05	Interaction	Political Neutrality	0	Provisional
RAI3-G-INT-06	Interaction	Privacy	7	Provisional
RAI3-G-INT-07	Interaction	Illegal	0	Provisional
RAI3-G-INT-08	Interaction	Copyrights	6	Provisional
RAI3-G-INT-09	Interaction	Weaponization	8	Provisional
RAI3-G-INT-10	Interaction	Anthropomorphism	1	Provisional
RAI3-G-INT-11	Interaction	Policy Exposure	2	Provisional
RAI3-G-SYS-01	System	Over-Refusal	0	Provisional
RAI3-G-SYS-02	System	Over-Extension	0	Provisional
RAI3-G-SYS-03	System	Misinformation/Disinformation	3	Provisional
RAI3-G-SYS-04	System	Context Misalignment	0	Provisional
RAI3-G-SYS-05	System	Inconsistency	1	Provisional
RAI3-G-SYS-06	System	Overgeneralization	0	Provisional
RAI3-G-SYS-07	System	Overconfidence	0	Provisional
RAI3-G-SYS-08	System	Goal Misalignment	0	Provisional
RAI3-G-SYS-09	System	Non-Contestability	1	Provisional
RAI3-A-SYS-01	System	Excessive Authority	0	Provisional
RAI3-A-SYS-02	System	Accountability	0	Provisional
RAI3-A-SYS-03	System	Network Effects	0	Provisional
RAI3-A-SYS-04	System	Destabilising Dynamics	0	Provisional
RAI3-A-SYS-05	System	Conflict	0	Provisional
RAI3-A-SYS-06	System	Collusion	0	Provisional
RAI3-P-SYS-01	System Safety	Accidental Harm	22	Physical lock
RAI3-P-SYS-02	System Safety	Robot Control	45	Physical lock
RAI3-P-SYS-03	System Safety	Hardware & Mechanical Failures	3	Physical lock
RAI3-P-SYS-04	System Safety	Software Vulnerabilities & Design Flaws	8	Physical lock
RAI3-P-SYS-05	System Safety	Lack of Robustness in Unseen Environments	13	Physical lock
RAI3-P-INT-01	Interaction Safety	Purposeful / Malicious Harm	17	Physical lock
RAI3-P-INT-02	Interaction Safety	Physical Attacks	1	Physical lock

L3 ID	L2	L3 명칭	카드수	상태
RAI3-P-INT-03	Interaction Safety	Cybersecurity Threats	4	Physical lock
RAI3-P-INT-04	Interaction Safety	Sensor & Input Validation Failures	4	Physical lock
RAI3-P-INT-05	Interaction Safety	Misinformation	5	Physical lock
RAI3-P-INT-06	Interaction Safety	Dynamic Environmental Factors	11	Physical lock
RAI3-P-INT-07	Interaction Safety	Human Interaction & Safety Protocol Failures	13	Physical lock
RAI3-P-INT-08	Interaction Safety	Instruction Misinterpretation	1	Physical lock
RAI3-P-INT-09	Interaction Safety	Multi-Agent Collaboration	4	Physical lock
RAI3-P-INT-10	Interaction Safety	Ethical & Safety Implications of Interactive Agents	2	Physical lock
RAI3-P-SOC-01	Societal Safety	Privacy Violations	5	Physical lock
RAI3-P-SOC-02	Societal Safety	Labor Displacement	1	Physical lock
RAI3-P-SOC-03	Societal Safety	Socioeconomic Inequality	1	Physical lock
RAI3-P-SOC-04	Societal Safety	Power Concentration	1	Physical lock
RAI3-P-SOC-05	Societal Safety	Bias & Discrimination	3	Physical lock
RAI3-P-SOC-06	Societal Safety	Lack of Accountability & Liability	12	Physical lock
RAI3-P-SOC-07	Societal Safety	Lack of Transparency, Explainability & Trust	1	Physical lock
RAI3-P-SOC-08	Societal Safety	Unhealthy / Dangerous Human-EAI Relationships	4	Physical lock
RAI3-P-SOC-09	Societal Safety	Transformative Effects	1	Physical lock

B Physical 명시적 alias 13 개

글로벌 source ID	Physical source ID	신규 L4 ID
PHYSRISK-REF-0043	PHYSKR-REF-001	RAI4-0302
PHYSRISK-REF-0044	PHYSKR-REF-002	RAI4-0303
PHYSRISK-REF-0045	PHYSKR-REF-003	RAI4-0304
PHYSRISK-REF-0046	PHYSKR-REF-004	RAI4-0305
PHYSRISK-REF-0047	PHYSKR-REF-005	RAI4-0306
PHYSRISK-REF-0048	PHYSKR-REF-006	RAI4-0307
PHYSRISK-REF-0049	PHYSKR-REF-007	RAI4-0308
PHYSRISK-REF-0050	PHYSKR-REF-008	RAI4-0309
PHYSRISK-REF-0051	PHYSKR-REF-010	RAI4-0311
PHYSRISK-REF-0052	PHYSKR-REF-011	RAI4-0312
PHYSRISK-REF-0053	PHYSKR-REF-013	RAI4-0314
PHYSRISK-REF-0054	PHYSKR-REF-014	RAI4-0315
PHYSRISK-REF-0055	PHYSKR-REF-018	RAI4-0319

C 최종자동제안 37 개

다음항목은두독립전문에이전트가정확한제안 L3 를모두승인한결과다. 모두잠정상태이며사람승인전에는정답으로간주하지않는다.

L4 ID	위험명	제안 L3
RAI4-0131	Anthropomorphic overtrust	RAI3-G-INT-10
RAI4-0426	Hate speech generation	RAI3-G-INT-04
RAI4-0433	Biometric privacy intrusion	RAI3-G-INT-06
RAI4-0453	Loss of contestability	RAI3-G-SYS-09
RAI4-0496	Copyright infringement	RAI3-G-INT-08
RAI4-0559	AI-enabled CBRNE weapon development	RAI3-G-INT-09
RAI4-0617	CBRN weapon uplift	RAI3-G-INT-09
RAI4-0630	Impact on education: plagiarism	RAI3-G-INT-08
RAI4-0632	Indiscriminate weapons (CBRNE)	RAI3-G-INT-09
RAI4-0665	Child sexual abuse material (CSAM)	RAI3-G-INT-02
RAI4-0673	Child sexual exploitation	RAI3-G-INT-02
RAI4-0679	Hate-speech generation	RAI3-G-INT-04
RAI4-0684	Sex-related crimes	RAI3-G-INT-02
RAI4-0685	Sexual content	RAI3-G-INT-02
RAI4-0687	Suicide and self-harm	RAI3-G-INT-03
RAI4-0749	Personal information in data	RAI3-G-INT-06
RAI4-0759	Prompt leaking	RAI3-G-INT-11
RAI4-0777	Data privacy	RAI3-G-INT-06
RAI4-0795	Factual hallucination	RAI3-G-SYS-03
RAI4-0812	False information	RAI3-G-SYS-03

L4 ID	위험명	제안 L3
RAI4-0830	Factual hallucination	RAI3-G-SYS-03
RAI4-0915	Copyright violation	RAI3-G-INT-08
RAI4-0922	Private training data	RAI3-G-INT-06
RAI4-1114	Bioweapon-development uplift	RAI3-G-INT-09
RAI4-1139	Privacy harms	RAI3-G-INT-06
RAI4-1172	Prompt leaking	RAI3-G-INT-11
RAI4-1184	Lethal autonomous weapons systems (LAWS)	RAI3-G-INT-09
RAI4-1187	Output inconsistency	RAI3-G-SYS-05
RAI4-1194	Copyright infringement	RAI3-G-INT-08
RAI4-1357	Malicious use and abuse (sexually explicit content generation)	RAI3-G-INT-02
RAI4-1366	Copyright challenges (training models using copyrighted output)	RAI3-G-INT-08
RAI4-1367	Copyright challenges (copyright-infringing output)	RAI3-G-INT-08
RAI4-1392	Biosecurity threats	RAI3-G-INT-09
RAI4-1407	Privacy violation	RAI3-G-INT-06
RAI4-1417	AI enables development of weapons of mass destruction	RAI3-G-INT-09
RAI4-1444	Privacy loss	RAI3-G-INT-06
RAI4-1563	Misuse of AI systems to assist in the creation of weapons	RAI3-G-INT-09

D 자동검증체크리스트

검사 ID	검사내용	결과
SRC-001	Frozen source hash: global_ai_risk_l4_overlay_nodes.json	PASS
SRC-002	Frozen source hash: physical_l4_cards.json	PASS
SRC-003	Frozen source hash: physical_l4_references.json	PASS
SRC-004	Frozen source hash: physical_taxonomy_migrations.json	PASS
SRC-005	Frozen source hash: l0_l3_definition_source.txt	PASS
SRC-006	Global source row count	PASS
SRC-007	Physical source row count	PASS
SRC-008	Global source ID uniqueness	PASS
SRC-009	Physical reference row/card coverage	PASS
SRC-010	Physical source migration row count	PASS
SRC-011	Manifest enumerates and hashes every frozen source snapshot	PASS
INT-001	Checksum ledger exactly covers the project integrity scope	PASS
NODE-001	Taxonomy level counts	PASS
NODE-002	Taxonomy node ID uniqueness	PASS
NODE-003	Parent-child level integrity	PASS
NODE-004	Sibling sequence uniqueness	PASS
ID-001	L4 registry row count	PASS
ID-002	L4 ID uniqueness	PASS
ID-003	L4 ID continuous allocation	PASS
ID-004	Registry-placement separation	PASS
XW-001	Crosswalk total rows	PASS
XW-002	Global canonical rows	PASS

검사 ID	검사내용	결과
XW-003	Physical exact-ID rows	PASS
XW-004	Physical explicit aliases	PASS
XW-005	Explicit alias table exact match	PASS
XW-006	Crosswalk composite key uniqueness	PASS
XW-007	Crosswalk references valid L4 IDs	PASS
XW-008	Every global source ID maps to its deterministic RAI4 allocation	PASS
XW-009	Every Physical source ID follows the approved exact/alias chain to RAI4	PASS
PLC-001	Placement row count	PASS
PLC-002	One placement per L4	PASS
PLC-003	Needs-decision cards have null primary L3	PASS
PLC-004	Placed cards reference an active L3	PASS
PLC-005	Legacy hierarchy excluded from predictive features	PASS
PLC-006	No non-Physical algorithm proposal enters locked Physical L3	PASS
PLC-007	Taxonomy decision queue IDs are unique and populated	PASS
PHY-001	Physical locked placement count	PASS
PHY-002	Physical locked L3 equality	PASS
PHY-003	Physical L2 distribution	PASS
PHY-004	All 24 Physical L3 card counts preserved	PASS
PHY-005	Physical legacy-to-new L3 map	PASS
PHY-006	Physical migration ledger remains empty for baseline	PASS
PHY-007	Card-level Physical source→alias→RAI4→new L3→placement chain	PASS
PHY-008	Physical per-card reference counts preserved in the L4 registry	PASS
PHY-009	Physical 3H/Role tags preserve raw values and structured token counts	PASS
SCH-001	JSON Schema: taxonomy-node.schema.json	PASS
SCH-002	JSON Schema: l4-card.schema.json	PASS
SCH-003	JSON Schema: source-crosswalk.schema.json	PASS
SCH-004	JSON Schema: placement.schema.json	PASS
SCH-005	JSON Schema: migration.schema.json	PASS
SITE-001	Site card row count	PASS
SITE-002	Site card L4 uniqueness	PASS
SITE-003	Site hierarchy node count	PASS
SITE-004	Search index row count	PASS
SITE-005	Hierarchy L3 counts equal site-card placements	PASS
SITE-006	Every site card is the exact registry-plus-placement join	PASS
SITE-007	Every site hierarchy node exactly matches canonical nodes and placement counts	PASS
SITE-008	Every search-index row matches canonical card identity and placement	PASS
ALG-001	Algorithm proposals have two frontier-expert approvals	PASS
ALG-002	Confidence is not presented as calibrated	PASS
ALG-003	50-L3 sufficiency is not claimed before human validation	PASS
ALG-004	BGE-M3 revision is explicitly pinned and consistent	PASS
ALG-005	Immutable algorithm configuration hash matches run record and manifest	PASS
ALG-006	Algorithm configuration pins the active codebook hash	PASS
ALG-007	Pinned local model snapshot inventory matches the recorded fingerprint	PASS
ALG-008	Explicit-revision rerun is byte-identical to the reviewed initial run	PASS
WARN-001	Non-Physical human gold-set validation	WARN
WARN-002	Unresolved cards remain explicit	WARN
REL-001	Baseline release has no previous-release dependency	PASS
REL-002	Baseline migration ledger is empty	PASS
REL-003	Every placement carries the validated release ID	PASS

E 재현및핵심산출물

```
python3 scripts/build_release.py
python3 scripts/run_llm_review.py --model gemma3:4b
python3 scripts/run_llm_review.py --model qwen3:4b
python3 scripts/build_frontier_review_packet.py
# collect expert_a.json and expert_b.json independently
python3 scripts/apply_expert_consensus.py
python3 scripts/validate_release.py
python3 -m unittest tests/test_release.py -v
```

주요검토파일은다음과같다.

- canonical release: data/releases/v1.0.0/
- site-ready bundle: public/data/releases/v1.0.0/
- coverage: reports/validation/v1.0.0/coverage_summary.json
- expert consensus: reports/validation/v1.0.0/frontier_expert_consensus.json
- unresolved queue: reports/validation/v1.0.0/unresolved_cards.json
- validation: reports/validation/v1.0.0/validation_summary.json
- audit notebook: output/jupyter-notebook/rai_taxonomy_v1_data_quality_audit.ipynb